


Modelización y Valoración de Derivados y Carteras en
Finanzas

Métodos de estimación de parámetros y de predicción para el modelo Log-Normal

Índice

Esquema.	2
Ideas clave	3
6.1 Introducción y objetivos	3
6.2 Método de momentos estadísticos	4
6.3 Método de máxima verosimilitud.	6
6.4 Método de momentos no paramétrico	10
6.5 Validación del modelo	12
6.6 Predicción puntual y por intervalos de confianza.	13
Referencias.	18



6.1 Introducción y objetivos

Para poder describir el valor de un producto financiero en función del tiempo mediante una expresión matemática (aleatorizada o no), es necesario estimar los parámetros del modelo de manera que cuando se evalúe el mismo en unos instantes determinados el resultado se acerque a unos datos que conocemos.

La estimación de parámetros es una rama muy importante de la estadística que utiliza técnicas de investigación operativa. Existen diferentes maneras de poder estimar estos parámetros. Las técnicas de evaluación-error permiten ir comprobando cómo se parecen los resultados obtenidos a los datos reales tomando diferentes parámetros. Estas técnicas se llaman heurísticas o metaheurísticas.

También existen métodos analíticos para estimar el valor de los parámetros, que son los que estudiaremos a lo largo de este tema. Este tema está dedicado, en primer lugar, a estudiar tres métodos analíticos para estimar el valor de los parámetros: el método de los momentos, el método de máxima verosimilitud y el método no paramétrico.

A continuación, se procederá a estimar los valores de los parámetros considerando datos reales de una empresa que cotiza en el IBEX-35. Una vez se conozcan los valores de los mismos y se valide el modelo, se procederá a realizar predicciones sobre el valor del subyacente a estudiar en los próximos 5 días.

Los objetivos que trataremos de alcanzar en este tema son los siguientes:

- Descripción del método de momentos.

- Descripción del método de momentos no paramétrico.
- Descripción del método de máxima verosimilitud.
- Estimación de parámetros.
- Predicción puntual y por intervalos de confianza.

Nota: para más detalles ver por ejemplo (Casas Morente, 2021; Calatayud Gregori et al., 2019; Miñana Sellés, 2018; Gimeno Polo, 2016).

6.2 Método de momentos estadísticos

La primera técnica que vamos a describir se denomina método de los momentos estadísticos. La estimación de los parámetros se lleva a cabo imponiendo que los momentos poblacionales (del modelo teórico) coinciden con los momentos muestrales (de los datos). Esta condición se impone sobre tantos momentos como parámetros se desee estimar.

Recordemos que la solución del modelo Log-Normal viene dado por

$$S(t) = S_0 e^{(\mu - \frac{1}{2}\sigma^2)t + \sigma W(t)}, \mu \in \mathbb{R}, \sigma > 0.$$

Desde donde tenemos

$$\ln(S(t)) = \ln(S_0) + \left(\mu - \frac{\sigma^2}{2}\right)t + \sigma W(t),$$

donde $W(t) \sim N(0, t)$ y por lo tanto

$$\ln(S(t)) - \ln(S_0) = \left(\mu - \frac{\sigma^2}{2}\right)t + \sigma W(t) \sim N\left(\left(\mu - \frac{\sigma^2}{2}\right)t, \sigma^2 t\right).$$

Luego definiendo

$$S_i = S(t_i), t_i = i\Delta t, \forall i \in \{0, 1, \dots, n\},$$

evaluamos en los instantes t_i y t_{i+1} , obtenemos

$$\ln(S_{i+1}) - \ln(S_0) = \ln(S(t_{i+1})) - \ln(S_0) = \left(\mu - \frac{\sigma^2}{2}\right) t_{i+1} + \sigma W(t_{i+1}),$$

y

$$\ln(S_i) - \ln(S_0) = \ln(S(t_i)) - \ln(S_0) = \left(\mu - \frac{\sigma^2}{2}\right) t_i + \sigma W(t_i).$$

Desde donde considerando propiedades de la distribución gaussiana, se tiene

$$\begin{aligned} \ln\left(\frac{S_{i+1}}{S_i}\right) &= \ln(S_{i+1}) - \ln(S_i) \\ &= \left(\mu - \frac{\sigma^2}{2}\right) (t_{i+1} - t_i) + \sigma(W(t_{i+1}) - W(t_i)) \\ &= \left(\mu - \frac{\sigma^2}{2}\right) \Delta t + \sigma W(\Delta t) \sim N\left(\left(\mu - \frac{\sigma^2}{2}\right) \Delta t, \sigma^2 \Delta t\right), \end{aligned}$$

donde el término de la izquierda se conoce como log-retornos.

Luego, definiendo

$$U_i = \ln\left(\frac{S_i}{S_{i-1}}\right), i \in \{1, \dots, n\},$$

con media y la varianza

$$E(U_i) = \left(\mu - \frac{\sigma^2}{2}\right) \Delta t,$$

$$V(U_i) = \sigma^2 \Delta t.$$

Finalmente considerando un conjunto de datos de un parámetro financiero dados por $\{S_0, S_1, \dots, S_n\}$ y espaciado temporalmente en $t_i = i\Delta t$ con $\Delta t > 0$ e $i \in$

$\{0, 1, \dots, n\}$ aproximados por la definición 6.2, es decir, $S_i \approx S(t_i)$ ¹, calculamos la media y la varianza de nuestros datos, denotándolos mediante $\bar{U}$ y S_U^2 , respectivamente, obtenemos la siguiente aproximación

$$\left(\mu - \frac{\sigma^2}{2}\right) \Delta t \approx \bar{U} = \frac{1}{n} \sum_{i=1}^n U_i,$$

$$\sigma^2 \Delta t \approx S_U^2 = \frac{1}{n-1} \sum_{i=1}^n (U_i - \bar{U})^2.$$

Finalmente, despejando tenemos

$$\mu_{MME} = \frac{1}{\Delta t} \left(\bar{U} + \frac{S_U^2}{2} \right),$$

$$\sigma_{MME} = \frac{S_U}{\sqrt{\Delta t}},$$
(1)

con $U_i = \ln \left(\frac{S_i}{S_{i-1}} \right)$ para todo $i \in \{1, \dots, n\}$.

Observad que hemos aplicado el método de momentos para la media y la varianza porque necesitamos estimar dos parámetros.

6.3 Método de máxima verosimilitud

En esta sección nos centramos en explicar el método de máxima verosimilitud. Como su nombre bien indica consiste en maximizar una función que se denomina función de verosimilitud.

Partiendo del modelo Log-Normal se construirá una función que contenga los parámetros μ y σ que se pretenden estimar. Utilizando técnicas de optimización (analíticas

¹No confundir la muestra o conjunto de datos con la aproximación generada por el modelo Log-Normal, básicamente utilizamos la misma notación por simplificar las notaciones.

o numéricas) buscaremos el máximo de esta función.

$$p(S_0, S_1, \dots, S_n; \mu, \sigma) = p(S_0; \mu, \sigma) p(S_1|S_0; \mu, \sigma) p(S_2|S_0, S_1; \mu, \sigma) \cdots \\ \cdots p(S_n|S_0, S_1, \dots, S_{n-1}; \mu, \sigma),$$

donde $S_i = S(t_i)$ con $t_i = i\Delta t$, $\Delta t > 0$ e $i \in \{0, 1, \dots, n\}$ y $\theta = (\mu, \sigma)$ denota el vector paramétrico que debe ser estimado. En el contexto del modelo lognormal, que está formulado por una ecuación diferencial estocástica de tipo Itô, cuya solución es un proceso de Markov, se tiene

$$p(S_0, S_1, \dots, S_n; \mu, \sigma) = p(S_0) p(S_1|S_0; \mu, \sigma) p(S_2|S_1; \mu, \sigma) \cdots p(S_n|S_{n-1}; \mu, \sigma) \\ = p(S_0) \prod_{i=1}^n p(S_i|S_{i-1}; \mu, \sigma) \\ = \prod_{i=1}^n p(S_i|S_{i-1}; \mu, \sigma),$$

donde suponemos $p(S_0) = 1$ dado que S_0 es un valor determinista fijado por la condición inicial.

Se define la función de verosimilitud como

$$l(\mu, \sigma; S_0, S_1, \dots, S_n) = \prod_{i=1}^n p(S_i|S_{i-1}; \mu, \sigma).$$

Luego, por el método de máxima verosimilitud, buscaremos los valores de los parámetros μ y σ que hacen más verosímil a una muestra obtenida, maximizando $l(\mu, \sigma)$.

Desde un punto de vista numérico, es más conveniente trabajar con la siguiente función objetivo equivalente,

$$\min_{(\mu, \sigma) \in \mathbb{R}^2} L(\mu, \sigma; S_0, S_1, \dots, S_n), \quad (2)$$

donde $L(\mu, \sigma; S_0, S_1, \dots, S_n) = -\ln l(\mu, \sigma; S_0, S_1, \dots, S_n)$.

Consideramos la solución $S(t)$ del modelo Log-Normal, aplicando el esquema numé-

rico de Euler Maruyama tenemos que

$$\begin{cases} S_{i+1} = S_i + \mu S_i (t_{i+1} - t_i) + \sigma S_i (W(t_{i+1}) - W(t_i)), \\ S(t_0) = S_0, \end{cases}$$

es decir

$$\begin{cases} S_{i+1} = S_i + \mu S_i \Delta t + \sigma S_i W(\Delta t), \\ S(t_0) = S_0. \end{cases}$$

En el siguiente recurso a fondo explicamos en qué consiste el método numérico de Euler Maruyama.



Accede al vídeo: Esquema numérico de Euler Maruyama

Como

$$W(\Delta t) \sim N(0, \Delta), \forall i \in \{0, 1, \dots, n-1\},$$

tenemos que

$$S_{i+1}|S_i \sim N((1 + \mu\Delta t) S_i, \sigma^2(S_i)^2 \Delta t),$$

es decir, la función de densidad de S_{i+1} condicionada a S_i viene dada por

$$f(S_{i+1}|S_i) = \frac{1}{\sqrt{2\pi}\sigma_i} e^{-\frac{1}{2}\left(\frac{S_{i+1}-\mu_i}{\sigma_i}\right)^2},$$

donde

$$\mu_i = (1 + \mu\Delta t)S_i \text{ y } \sigma_i = \sigma S_i \sqrt{\Delta t}.$$

Sustituyendo esta expresión en (2), se tiene la siguiente representación para la función

de verosimilitud

$$\begin{aligned} L(\mu, \sigma; S_0, S_1, \dots, S_n) &= -\ln \prod_{i=0}^{n-1} f(S_{i+1}|S_i) \\ &= -\ln \prod_{i=0}^{n-1} \left(\frac{1}{\sqrt{2\pi}\sigma_i} e^{-\frac{1}{2}\left(\frac{S_{i+1}-\mu_i}{\sigma_i}\right)^2} \right) \\ &= -\sum_{i=0}^{n-1} \ln \left(\frac{1}{\sqrt{2\pi}\sigma_i} e^{-\frac{1}{2}\left(\frac{S_{i+1}-\mu_i}{\sigma_i}\right)^2} \right), \end{aligned}$$

de donde

$$\begin{aligned} L(\mu, \sigma; S_0, S_1, \dots, S_n) &= \frac{n}{2} \ln(2\pi\Delta t) + n \ln(\sigma) + \sum_{i=0}^{n-1} \ln(S_i) + \\ &+ \frac{1}{2\sigma^2} \left(\frac{1}{\Delta t} \sum_{i=0}^{n-1} \left(\frac{S_{i+1}}{S_i} - 1 - \mu\Delta t \right)^2 \right). \end{aligned}$$

Luego, derivando respecto de μ y σ e igualando a 0, es decir

$$\begin{aligned} L_\mu &= L_\mu(\mu, \sigma; S_0, S_1, \dots, S_n) = -\frac{1}{\sigma^2} \sum_{i=0}^{n-1} \left(\frac{S_{i+1}}{S_i} - 1 - \mu\Delta t \right) = 0, \\ L_\sigma &= L_\sigma(\mu, \sigma; S_0, S_1, \dots, S_n) = \frac{n}{\sigma} - \frac{1}{\sigma^3} \left(\frac{1}{\Delta t} \sum_{i=0}^{n-1} \left(\frac{S_{i+1}}{S_i} - 1 - \mu\Delta t \right)^2 \right) = 0, \end{aligned}$$

tenemos que

$$\begin{aligned} \mu_{MMV} &= \frac{1}{n\Delta t} \sum_{i=0}^{n-1} \left(\frac{S_{i+1}}{S_i} - 1 \right) = \frac{1}{n\Delta t} \sum_{i=1}^n \left(\frac{S_i}{S_{i-1}} - 1 \right), \\ \sigma_{MMV} &= \sqrt{\frac{1}{n\Delta t} \sum_{i=0}^{n-1} \left(\frac{S_{i+1}}{S_i} - 1 - \mu_{MMV}\Delta t \right)^2} = \sqrt{\frac{1}{n\Delta t} \sum_{i=1}^n \left(\frac{S_i}{S_{i-1}} - 1 - \mu_{MMV}\Delta t \right)^2}. \end{aligned}$$

Así, como

$$L_{\mu,\mu} = \frac{n\Delta t}{\sigma^2}, \quad L_{\mu,\sigma} = L_{\sigma,\mu} = -\frac{2}{\sigma} L_\mu \quad \text{y} \quad L_{\sigma,\sigma} = \frac{2n}{\sigma^2} - \frac{3}{\sigma} L_\sigma.$$

Entonces

$$H_L(\mu, \sigma) = \begin{pmatrix} \frac{n\Delta t}{\sigma^2} & -\frac{2}{\sigma}L_\mu \\ -\frac{2}{\sigma}L_\mu & \frac{2n}{\sigma^2} - \frac{3}{\sigma}L_\sigma \end{pmatrix}.$$

Por lo tanto

$$H_L(\mu_{MMV}, \sigma_{MMV}) = \frac{n}{\sigma_{MMV}^2} \begin{pmatrix} \Delta t & 0 \\ 0 & 2 \end{pmatrix},$$

es definida positiva, ya que $\lambda_1 = n\Delta t/\sigma_{MMV}^2 > 0$ y $\lambda_2 = 2n/\sigma_{MMV}^2 > 0$, por lo que podemos afirmar que $(\mu_{MMV}, \sigma_{MMV})$ es un mínimo de L para los datos de un parámetro financiero dados por $\{S_0, S_1, \dots, S_n\}$ (definidos como la sección anterior).

Finalmente por simplicidad, considerando

$$U_i = \frac{S_i}{S_{i-1}} - 1, \forall i \in \{1, \dots, n\},$$

tenemos que

$$\mu_{MMV} = \frac{\bar{U}}{\Delta t} \text{ y } \sigma_{MMV} = \sqrt{\frac{n-1}{n\Delta t}} S_U. \quad (3)$$

6.4 Método de momentos no paramétrico

El método de momentos no paramétrico destaca por su sencillez. A pesar de que las estimaciones obtenidas no son tan robustas como la de los demás métodos explicados en este tema, es muy fácil de aplicar. En caso de que se disponga de datos razonablemente frecuentes, es muy probable que los errores de aproximación sean pequeños. Además, los valores estimados por este procedimiento también pueden utilizarse como valores de partida en otros métodos computacionales para estimar los parámetros.

Para describir este método lo haremos de manera general. Consideramos un vector arbitrario $\theta \in \mathbb{R}^n$ y una ecuación diferencial estocástica descrita de manera general (de la cual el modelo lognormal es un caso particular)

$$\begin{cases} dX(t) = f(t_i, X_i, \theta)dt + g(t_i, X_i, \theta)dW(t), \\ X(0) = X_0. \end{cases} \quad (4)$$

Después se verá como aplicarlo a nuestro modelo Log-Normal.

En un primer paso, consiste en aplicar el esquema de Euler-Maruyama, al problema de valores iniciales generado por (4), es decir.

$$\begin{cases} dX(t) = f(t, X(t))dt + g(t, X(t))dW(t), \\ X(0) = X_0. \end{cases}$$

Aplicando el esquema numérico de Euler Maruyama, se tiene que

$$X_{i+1} - X_i = f(t_i, X_i, \theta)\Delta t + g(t_i, X_i, \theta)\Delta W_i, \text{ con } i \in \{0, 1, \dots, n-1\},$$

donde $\Delta W_i = W(t_{i+1}) - W(t_i) = W(\Delta t) \sim N(0, \Delta t)$.

A continuación, procedemos del mismo modo que se indica en (Allen, 2007). El método de momentos no paramétrico consiste en aplicar la siguiente propiedad.

$$\begin{aligned} E \left(\frac{X_{i+1} - X_i}{\Delta t} - f(t_i, X_i, \theta) \right) &= O(\Delta t), \\ E \left(\frac{(X_{i+1} - X_i)^2}{\Delta t} - g^2(t_i, X_i, \theta) \right) &= O(\Delta t), \end{aligned} \quad (5)$$

donde $O(\Delta t)$ indica el símbolo de Landau que se sabe que tiende a 0 para Δt pequeño.

Por tanto, de la ecuación (5) se tiene que

$$\sum_{i=0}^{n-1} f(t_i, X_i, \theta) = \frac{1}{\Delta t} \sum_{i=0}^{n-1} (X_{i+1} - X_i),$$

$$\sum_{i=0}^{n-1} g^2(t_i, X_i, \theta) = \frac{1}{\Delta t} \sum_{i=0}^{n-1} (X_{i+1} - X_i)^2.$$

Considerando que $X_i = S_i$ para todo $i \in \{0, 1, \dots, n-1\}$ (definidos como en las secciones anteriores) y adaptando las funciones f y g al modelo Log-Normal, es decir $f(t_i, S_i, \theta) = \mu S_i$ y $g(t_i, S_i, \theta) = \sigma S_i$, se tiene que

$$\sum_{i=0}^{n-1} (\mu S_i) = \frac{1}{\Delta t} \sum_{i=0}^{n-1} (S_{i+1} - S_i),$$

$$\sum_{i=0}^{n-1} (\sigma S_i)^2 = \frac{1}{\Delta t} \sum_{i=0}^{n-1} (S_{i+1} - S_i)^2.$$

Despejando los parámetros μ y σ podemos obtener una estimación de μ y σ

$$\mu_{MMNP} = \frac{1}{\Delta t} \left(\frac{\sum_{i=0}^{n-1} (S_{i+1} - S_i)}{\sum_{i=0}^{n-1} S_i} \right),$$

$$\sigma_{MMNP} = \sqrt{\frac{1}{\Delta t} \left(\frac{\sum_{i=0}^{n-1} (S_{i+1} - S_i)^2}{\sum_{i=0}^{n-1} S_i^2} \right)}.$$
(6)

6.5 Validación del modelo

Una vez conocemos cómo estimar los parámetros del modelo Log-Normal, es importante saber cómo de buenas son esas estimaciones. Para ello se compararán los datos que conocemos con los datos obtenidos mediante el modelo Log-Normal. Denotamos mediante $\{S_0, S_1, \dots, S_n\}$ los datos conocidos en los instantes de tiempo $\{t_0, t_1, \dots, t_n\}$. Los errores que vamos a considerar son los siguientes:

- **Error cuadrático medio (ECM):** El error cuadrático medio se define como la raíz cuadrada de la media de las diferencias al cuadrado entre los datos y los outputs del modelo. Matemáticamente se expresa de la siguiente manera

$$ECM = \sqrt{\frac{1}{n} \sum_{i=1}^n (S_i - S(t_i))^2}. \quad (7)$$

- **Error porcentual absoluto medio (EPAM):** El error porcentual absoluto medio se define como la media de los errores relativos entre los datos reales y los proporcionados por el modelo. Matemáticamente se expresa de la siguiente manera

$$EPAM = \frac{100}{n} \sum_{i=1}^n \left| \frac{S_i - S(t_i)}{S_i} \right|. \quad (8)$$

6.6 Predicción puntual y por intervalos de confianza

Esta sección está dedicada a aplicar los resultados de este tema a datos reales. Consideremos las cotizaciones de una compañía que cotiza en el IBEX-35 en 30 días, desde el 25 de Agosto del 2019 al 21 de septiembre del 2019. Los valores están recogidos en la Tabla 1

t	fecha	S	t	fecha	S
0	15/7/2019	24.38	14	04/08/19	25.2
1	16/7/2019	24.23	15	05/08/19	25.07
2	17/7/2019	24.26	16	06/08/19	25.33
3	20/7/2019	24.32	17	07/08/19	25.42
4	21/7/2019	24.89	18	10/08/19	25.32
5	22/7/2019	23.55	19	11/08/19	25.61
6	23/7/2019	23.79	20	12/08/19	25.48
7	24/7/2019	23.95	21	13/08/19	25.48
8	27/7/2019	23.75	22	14/08/19	25.56
9	28/7/2019	23.98	23	17/08/19	25.86
10	29/7/2019	24.59	24	18/08/19	25.91
11	30/7/2019	24.86	25	19/08/19	26.08
12	31/7/2019	24.8	26	20/08/19	25.87
13	3/8/2019	24.95	27	21/08/19	26.25

Tabla 1: Datos en 28 días hábiles.

En la Figura 1 representamos los datos mostrados en la Tabla 1




Figura 1: Datos que se van a utilizar en este estudio

A continuación calcularemos las calibraciones para cada uno de los tres métodos de estimación.

Estimación de parámetros y resultados utilizando el método de los momentos estadísticos, máxima varosimilitud y método no paramétrico

Utilizando las fórmulas dadas en (1), (3) y (6), los valores estimados para μ y para σ por método son

$$\begin{aligned}\mu_{MME} &= 0.00284 \text{ y } \sigma_{MME} = 0.01446, \\ \mu_{MMV} &= 0.00284 \text{ y } \sigma_{MMV} = 0.01400, \\ \mu_{MMNP} &= 0.00284 \text{ y } \sigma_{MMNP} = 0.01419.\end{aligned}$$

Consecuentemente, los errores ECM y EPAM respecto de la media del modelo Log-Normal (consultar el Tema 5 para obtener más detalles), es decir, considerando

$$S(t) \approx \mu_S(t) = S_0 e^{\mu t}, \quad t \geq 0,$$

y dados en las ecuaciones (7) y (8), para cada estimador son:

$$\begin{aligned}ECM_{MME} &= 0.531 \text{ y } EPAM_{MME}(\%) = 1.701, \\ ECM_{MMV} &= 0.531 \text{ y } EPAM_{MMV}(\%) = 1.700, \\ ECM_{MMNP} &= 0.518 \text{ y } EPAM_{MMNP}(\%) = 1.617.\end{aligned}$$

Donde podemos apreciar una mejor aproximación por el utilizando el método de momentos no paramétrico, ya que presente errores levemente menores.

Luego podemos calcular los intervalos de confianza al 95 % de cada método para ob-

servar con mayor detalle el ajuste de los datos, siguiendo la siguiente fórmula

$$IC = [\mu_S(t) - 1.96\sigma_S(t), \mu_S(t) + 1.96\sigma_S(t)],$$

donde

$$\sigma_S(t) = S_0 e^{\mu t} \sqrt{e^{\sigma^2 t} - 1}, t \geq 0.$$

Antes de continuar notemos que $\sigma_S(t) = \mu_S(t) \sqrt{e^{\sigma^2 t} - 1}$ y por lo tanto

$$\begin{aligned} IC &= [\mu_S(t) - 1.96\sigma_S(t), \mu_S(t) + 1.96\sigma_S(t)] \\ &= \mu_S(t) \left[1 - 1.96\sqrt{e^{\sigma^2 t} - 1}, 1 + 1.96\sqrt{e^{\sigma^2 t} - 1} \right], \end{aligned}$$

es decir, tiene mayor relevancia la estimación σ , ya que a menor valor de mejor predicción.

En la Figura 2 podemos apreciar la similitud de las estimaciones




Figura 2: Resultados obtenidos con el método de momentos estadísticos en el intervalo de confianza al 95 %.

Finalmente, una vez se ha comprobado que el modelo captura correctamente los datos, podemos predecir el futuro de la compañía en los próximos 5 días, que corresponden a la zona ubicada a la derecha de la Figura 2 delimitada por la línea vertical negra. Para ello es suficiente con evaluar el modelo, tanto la media como la varianza, en los 5 días posteriores, ilustrados en la Tabla 2.

	μ_{MME}, σ_{MME}	μ_{MMV}, σ_{MMV}	$\mu_{MMNP}, \sigma_{MMNP}$
t	$\mu_S(t), \sigma_S(t)$	$\mu_S(t), \sigma_S(t)$	$\mu_S(t), \sigma_S(t)$
27	26.40, 2.02	26.40, 1.96	26.36, 1.98
28	26.47, 2.06	26.47, 2.00	26.43, 2.02
29	26.55, 2.11	26.55, 2.04	26.51, 2.06
30	26.63, 2.15	26.62, 2.08	26.58, 2.10
31	26.70, 2.19	26.70, 2.12	26.66, 2.14
t	$IC\ 95\ \%$	$IC\ 95\ \%$	$IC\ 95\ \%$
27	[22.44,30.36]	[22.56,30.24]	[22.47,30.24]
28	[22.43,30.52]	[22.56,30.39]	[22.47,30.40]
29	[22.42,30.68]	[22.55,30.55]	[22.46,30.55]
30	[22.42,30.83]	[22.55,30.70]	[22.46,30.70]
31	[22.41,30.99]	[22.55,30.85]	[22.46,30.86]

Tabla 2: Predicción a 5 días utilizando el método de los momentos estadísticos

Referencias

- Allen, E. (2007). *Modeling with Itô stochastic differential equations*, volume 22. Springer Science & Business Media.
- Calatayud Gregori, J., Cortés López, J. C., Jornet Sanz, M., and Villanueva Micó, R. J. (2019). An introduction to random variables, random vectors and stochastic processes. *Colección Académica*.
- Casas Morente, B. (2021). El modelo estocástico log-normal con parámetros variables. aplicación a la modelización del subyacente cotizado ferrovial.
- Gimeno Polo, I. (2016). Modelización estocástica para realizar predicciones del subyacente bkia. mc (bankia) del ibex 35. realización de una página web para mostrar las predicciones diariamente.
- Miñana Sellés, G. (2018). Modelización de activos cotizados mediante modelos de difusión estocásticos de tipo itô.