



Universitat d'Alacant
Universidad de Alicante

Esta tesis doctoral contiene un índice que enlaza a cada uno de los capítulos de la misma.

Existen asimismo botones de retorno al índice al principio y final de cada uno de los capítulos.

[Ir directamente al índice](#)

Para una correcta visualización del texto es necesaria la versión de [Adobe Acrobat Reader 7.0](#) o posteriores

Aquesta tesi doctoral conté un índex que enllaça a cadascun dels capítols. Existeixen així mateix botons de retorn a l'índex al principi i final de cadascun dels capítols .

[Anar directament a l'índex](#)

Per a una correcta visualització del text és necessària la versió d' [Adobe Acrobat Reader 7.0](#) o posteriors.



Universitat d'Alacant
Universidad de Alicante

D. Enrique Sentana Iváñez, profesor e investigador del Centro de Estudios Monetarios y Financieros (CEMFI), resuelve:

Que, habiendo supervisado el trabajo de investigación por el aspirante a Doctor D. Angel M. León Valle, da su plena autorización para la presentación y lectura de la Tesis que adjunto se remite.

Que así conste donde sea necesario.

Fdo. D. Enrique Sentana Iváñez.
Director de la Tesis.




Universitat d'Alacant
Universidad de Alicante

D. Joaquín Marhuenda Fructuoso, Director del Dpto. de Economía Financiera de la Universidad de Alicante y Tutor del aspirante a Doctor D. Angel M. León Valle, da su plena autorización para la presentación y lectura de la Tesis del candidato anterior que adjunto se remite.

Que así conste donde sea necesario.

Fdo. D. Joaquín Marhuenda Fructuoso.
Tutor de la Tesis.



PROCESOS ESTOCÁSTICOS EN TIEMPO CONTINUO Y APLICACIONES A LOS ACTIVOS FINANCIEROS DERIVADOS

Àngel M. León Valle
Departamento de Economía Financiera
Universidad de Alicante

Octubre 1998





AGRADECIMIENTOS

Estoy profundamente agradecido a varias personas que me han ayudado enormemente en el transcurso de mi investigación. En primer lugar, mi supervisor Enrique Sentana quien me animó a introducirme en el tema y a quien mi tesis debe mucho gracias a sus apreciables comentarios y sugerencias a lo largo de todos los capítulos de la tesis. Le agradezco enormemente el tiempo que me ha dedicado y también por preocuparse y darme ánimos en ciertos momentos difíciles.

En segundo lugar, quisiera agradecer a Gonzalo Rubio con quien he aprendido bastante sobre la parte empírica de los modelos de valoración de opciones a lo largo de este tiempo y que manteniendo una conversación una tarde en Bilbao en 1997 tuvo origen el último capítulo de mi tesis junto con la colaboración de Gabriele Fiorentini. A estas dos personas quiero agradecer enormemente su participación en este capítulo pues sin ellos no hubiera sido posible el desarrollo de éste, además de las importantes sugerencias propuestas por Enrique Sentana.

En tercer lugar, quisiera agradecer al CEMFI por haber realizado mi último año de tesis allí y haber recibido una excelente formación en distintas áreas de la Economía durante mi curso de postgrado en el CEMFI y los correspondientes años de tesis.

Agradecimientos especiales a Juan José Dolado, quien me ha ayudado a resolver determinados problemas de convergencia de procesos estocásticos en el capítulo 1.

Agradecimientos también a personas por sus sugerencias en el capítulo 3, concretamente a Sudipto Bhattacharya, Santiago Carrillo, Gabriele Fiorentini, Lars Hansen, Albert Marcet, Rafael Repullo, Ken Singleton, Luis Veiçeira, David Webb y comentarios de seminarios en Bilbao, CEMFI y LSE.

Agradecimientos también en el capítulo 4 a Ignacio Peña, Eduardo Schwartz, Enrique Sentana y comentarios del seminario en Carlos III y el Foro de Finanzas en Segovia.

Querría expresar agradecimientos también al Departamento de Economía Financiera de la Universidad de Alicante por su continuo apoyo, especialmente a Juan Carlos Gómez y Joaquín Marhuenda.

Por último, pero no menos importante, agradecimientos a mi familia por su apoyo continuo y a mis amigos.



Universitat d'Alacant
 Universidad de Alicante

Contents

1	Introducción	6
0	<i>Capítulo 1: Del tiempo discreto al tiempo continuo y viceversa</i>	8
1	Del Tiempo Discreto al Continuo	8
1.1	El proceso browniano	8
1.1.1	Caso determinístico	8
1.1.2	Caso estocástico	9
1.2	Proceso CAR(1)	13
1.2.1	Caso determinístico	13
1.2.2	Caso estocástico	14
1.3	Proceso CAR(2)	18
1.4	Convergencia débil de un proceso ARMA(1,1)	19
1.5	Cadenas de Markov en tiempo continuo	21
1.6	Proceso de Poisson	23
1.7	Proceso de Poisson compuesto	24
1.8	Convergencia débil de procesos binomiales (trinomial) a procesos de difusión	25
1.8.1	Proceso Ornstein-Uhlenbeck	27
1.8.2	Movimiento geométrico browniano	28
1.8.3	Modelo de Heston	33
1.9	Modelos ARCH como aproximación a difusiones	35
2	Del tiempo continuo al discreto	38
2.1	Discretizaciones exactas	38
2.1.1	Movimiento browniano	38
2.1.2	Modelos CVAR	40
2.1.3	Aproximaciones en Tiempo Discreto	47
3	Referencias	51
0	<i>Capítulo 2: Las Matemáticas del Tiempo Continuo</i>	53
1	Definiciones	53

2	Algunos procesos estocásticos en tiempo continuo	53
2.1	Proceso de Poisson	53
2.2	Proceso de Poisson Compuesto	55
2.3	Movimiento browniano estándar	57
2.4	Proceso de Markov	57
3	Cálculo en media cuadrática	58
3.1	Continuidad	58
3.2	Derivabilidad	59
3.3	Integral de Riemann estocástica	61
4	Análisis del movimiento browniano estándar	62
4.1	Función de covarianza	62
4.2	Continuidad en media cuadrática	62
4.3	Derivada en media cuadrática (generalizada)	63
4.4	Ruido blanco en tiempo continuo y movimiento browniano estándar	64
4.5	Integrabilidad en media cuadrática	65
5	Convergencia de procesos en tiempo continuo	66
6	El teorema funcional central del límite	67
7	Cálculo estocástico de Ito	73
7.1	Introducción	73
7.2	Integral estocástica de Ito	74
7.3	Lema de Ito	77
7.4	Procesos de difusión con salto y lema de Ito	81
8	Modelos lineales estocásticos	83
8.1	Definiciones	83
8.2	Existencia y unicidad de una solución	84
8.3	Sistemas de EDELs en el sentido "narrow"	84
8.3.1	Caso determinístico	85
8.3.2	Caso estocástico	86
8.4	Ejemplos de EDELs	87
8.4.1	Proceso Ornstein-Uhlenbeck (OU)	87
8.4.2	Proceso OU con reversión a la media	90
8.4.3	Puente browniano	91

8.5	El sistema general de EDELs	92
8.5.1	Caso para $d=1$	92
8.5.2	Caso para d arbitrario	94
8.6	Modelos CAR	96
8.6.1	Introducción	96
8.6.2	Proceso CAR(2)	97
9	Los procesos continuos MA(q) y ARMA(k, q)	99
10	Análisis espectral para procesos en tiempo continuo	103
10.1	Definiciones	103
10.2	Filtros	104
10.3	Convergencia de espectros de procesos discretos a espectros de procesos continuos	106
11	Expansiones de Taylor estocásticas	107
11.1	Caso determinístico	107
11.2	Caso estocástico (Expansión Ito-Taylor)	108
12	Procesos de Markov y Difusión	112
12.1	Cadena de Markov y proceso de Markov	112
12.1.1	Cadena de Markov en tiempo discreto	112
12.1.2	Cadena de Markov en tiempo continuo	116
12.1.3	Proceso de Markov	117
12.2	El proceso de difusión	119
12.3	Probabilidades de transición	120
12.4	Convergencia débil de procesos de Markov a difusiones	123
13	Apéndice	126
13.1	Algunas nociones sobre análisis y topología	126
13.1.1	Espacios métricos	126
13.1.2	Integral Riemann-Stieltjes determinística	126
13.1.3	Sucesiones de funciones: Convergencia puntual y uniforme	128
13.2	Variables aleatorias	129
13.2.1	Convergencia de variables aleatorias	129
13.2.2	Relación entre $\lim E$ y EA	133
13.2.3	Acotado estocásticamente, y la notación de O_p y o_p	134



13.2.4	La función característica	135
13.2.5	Ley débil de los grandes números	136
13.3	Teorema central del límite (TCL)	137
13.4	Función delta de Dirac	138
13.5	El espacio C	139
13.6	Notación sobre la expansión Ito-Taylor	141
14	Cálculo de integrales múltiples de Ito	143
15	Referencias	146
0	<i>Capítulo 3: Valoración de opciones sobre activos con rendimientos predecibles ruido blanco</i>	147
1	Introducción	147
2	Análisis en tiempo discreto	148
2.1	Un modelo en tiempo discreto	148
2.2	Una versión discreta del modelo discreto	150
2.3	Las Consecuencias de la Agregación Temporal	153
3	Análisis en Tiempo Continuo	154
3.1	A Continuous Time Diffusion	154
3.2	Una Aproximación discreta al modelo en Tiempo Continuo . .	156
4	Conclusiones	158
5	Referencias	160
0	<i>Capítulo 4: Opciones a corto plazo con volatilidad estocástica</i>	161
1	Introducción	161
2	Datos	164
3	El Modelo de Valoración de Heston	165



4 Inferencia Indirecta	167
4.1 Metodología	167
4.2 Resultados Empíricos	170
5 Contraste Empírico	171
5.1 Período In-Sample	171
5.2 Período Out-of-Sample	173
6 Conclusiones	178
7 Referencias	180
8 Conclusiones	182

1 Introducción

El objetivo de mi investigación se basa en el análisis del tiempo continuo y su aplicación a los activos financieros derivados. Podríamos dividir el trabajo en dos partes, una primera parte (capítulos 1 y 2) donde se estudia de forma general los procesos estocásticos en tiempo continuo y una segunda parte (capítulos 3 y 4) sobre la aplicación a los derivados.

El capítulo 1 tiene como objetivo entender el paso del tiempo discreto al tiempo continuo y viceversa. Varias aplicaciones a partir de este capítulo son:

(1) Discretizaciones exactas y no exactas de procesos en tiempo continuo que definen el comportamiento de los precios de activos financieros, tipos de interés para poder estimar los parámetros por criterios de máxima verosimilitud, inferencia indirecta, etc.

(2) Árboles binomiales o trinomiales para procesos estocásticos univariantes o bivariantes para su uso en la valoración de opciones.

(3) Relación entre los modelos GARCH y los modelos de volatilidad estocástica en tiempo continuo. Mediante esta relación podemos estimar los parámetros que gobiernan la ecuación de la volatilidad en tiempo continuo mediante los parámetros de los modelos discretos de la familia GARCH.

Muchos resultados del capítulo 1 están basados en teoremas, etc. que están recogidas en el capítulo 2. Por tanto, a priori este capítulo 2 sería un apéndice del capítulo 1; sin embargo el capítulo 2 se ha convertido finalmente en unas notas sobre las matemáticas en tiempo continuo presentado con gran rigor y con ejemplos relacionados en su mayor parte con los modelos de valoración de opciones. Además, en este capítulo se puede encontrar la base para poder entender el aparato técnico que aparece en los siguientes capítulos.

El capítulo 3 constituye una generalización al trabajo de Lo y Wang (1995, Journal of Finance). Lo y Wang demuestran que la predicibilidad de los rendimientos de un activo, manifestándose en el “drift”, afecta a los precios de las opciones aunque ésta no entra en la fórmula de valoración de las opciones. Sin embargo, al trabajar con datos discretos, la predicibilidad está incorporada en los parámetros que entran en la fórmula de valoración de opciones. Para entender esto, supóngase los siguientes procesos generadores de datos para el subyacente: el proceso geométrico browniano y el proceso AR(1) en tiempo continuo (Ornstein-Uhlenbeck) con reversión a la media y tendencia siendo el parámetro de reversión γ , el cual mide el grado de

autocorrelación (predicibilidad) de los rendimientos, entonces ambos procesos conducen al mismo proceso de precios neutral al riesgo; siendo por tanto la fórmula de Black-Scholes (BS) válida para los dos procesos. Sin embargo, si estimamos el valor de σ^2 en la fórmula de BS mediante la varianza de los rendimientos compuestos continuos asumiendo que el proceso generador de datos es el proceso Ornstein-Uhlenbeck (OU) citado anteriormente entonces dicho estimador no resulta ser un estimador apropiado de σ^2 , pues σ^2 depende del parámetro γ bajo un proceso OU. Esto conduce a problemas de correcta valoración en las opciones.

En el capítulo 3, se analiza el mismo tema pero ahora los rendimientos de los activos están serialmente incorrelacionados (ruido blanco), y por tanto son impredecibles a partir de su historia pasada pero resultan ser predecibles bajo un conjunto de información mayor.

Finalmente, en el capítulo 4 se contrasta para el mercado español de opciones sobre futuros del IBEX-35 si el modelo de valoración de opciones europeas de Heston (1993) valora mejor que el modelo de Black los precios de mercado de las opciones call. El modelo de Heston a diferencia de BS permite que la volatilidad sea estocástica relajando por consiguiente el supuesto de volatilidad constante en BS obteniéndose una fórmula de valoración cerrada. A diferencia del modelo BS, que depende de un único parámetro, es decir σ^2 ; el modelo de Heston depende de los parámetros que definen la volatilidad estocástica que sigue un proceso CIR y la correlación entre volatilidad y activo subyacente.

En definitiva, el modelo de Heston resulta ser en principio bastante atractivo no sólo por ofrecer una fórmula de valoración cerrada sino además por permitir volatilidad estocástica frente a BS lo cual está de acuerdo con la evidencia empírica y también correlación entre volatilidad y subyacente mientras modelos anteriores con volatilidad estocástica no lo permiten como el modelo de Hull y White (1987) y el modelo de Stein y Stein (1991).

2 Capítulo 1: Del tiempo discreto al tiempo continuo y viceversa

1 Del Tiempo Discreto al Continuo

1.1 El proceso browniano

1.1.1 Caso determinístico

Dividamos el intervalo $[0, 1]$ en n subintervalos of longitud $h \equiv 1/n$ y definamos la siguiente ecuación determinística en diferencias de primer orden sobre el conjunto de puntos $\{0, h, 2h, \dots, 1\}$ para un valor de n fijo:

$$\Delta_h x_{n,kh} = \beta h; \quad k = 1, 2, \dots, n; \quad x_{n,0} = x_0 \quad (1)$$

donde $\Delta_h x_{n,kh}$ se define como

$$\Delta_h x_{n,kh} = x_{n,kh} - x_{n,(k-1)h}.$$

La solución de (1) es

$$x_{n,kh} = x_0 + \beta kh; \quad k = 0, 1, 2, \dots, n. \quad (2)$$

Para extender el proceso discreto al intervalo $[0, 1]$, definamos

$$x_n(t) = x_{n,[nt]h}; \quad t \in [0, 1]$$

donde $[\cdot]$ es la parte entera de su argumento. Se comprueba fácilmente la siguiente recursión

$$x_n(t) = \begin{cases} x_n(t-h) + \beta [nt]h; & t \in [h, 1] \\ x_0; & t \in [0, h). \end{cases}$$

Similarmente, podemos expresar (2) como

$$x_n(t) = x_0 + \beta [nt]h; \quad t \in [0, 1]. \quad (3)$$

$x_n(\cdot)$ representa la función $\{x_n(t); t \in [0, 1]\}$. Obsérvese que $x_n(\cdot)$ es una función real definida sobre el intervalo $[0, 1]$ con saltos en los puntos $\{h, 2h, \dots, 1\}$, por tanto $x_n(\cdot) \in D[0, 1]$ que es el espacio de funciones reales continuas en



$[0, 1]$ con discontinuidades de primera clase como máximo. Sea $\{x_n(\cdot); n \geq 1\}$ una sucesión de funciones del espacio D . La función $\{x(t); t \in [0, 1]\}$ a la que esta sucesión de funciones reales converge cuando $n \rightarrow \infty$ es

$$x(t) = x_0 + \beta t, \quad t \in [0, 1].$$

La función anterior corresponde al espacio $C[0, 1]$ que es el espacio de funciones reales continuas en $[0, 1]$ y es la solución de

$$\frac{dx(t)}{dt} = \beta; \quad t \in [0, 1], \quad x(0) = x_0 \quad (4)$$

por tanto podemos entender (4) como la ecuación diferencial límite de la ecuación en diferencias (1).

1.1.2 Caso estocástico

Definamos ahora ecuaciones estocásticas en diferencias de primer orden sobre el mismo conjunto de puntos que en el caso determinístico

$$\Delta_h X_{n,kh} = \xi_{n,kh}; \quad k = 1, 2, \dots, n \quad (5)$$

donde $\xi_{n,kh}$ es una sucesión *i.i.d.* definida como

$$\xi_{n,kh} = \begin{cases} \beta h + \sigma \sqrt{h}; & p = \frac{1}{2} \\ \beta h - \sigma \sqrt{h}; & p = \frac{1}{2}. \end{cases} \quad (6)$$

donde $0 < \sigma < \infty$. Podemos expresar (6) como

$$\xi_{n,kh} = \beta h + \sigma \sqrt{h} U_{n,kh} \quad (7)$$

donde $U_{n,kh}$ es una sucesión *i.i.d.* con media cero y varianza h definido como

$$U_{n,kh} = \begin{cases} 1; & p = \frac{1}{2} \\ -1; & 1 - p = \frac{1}{2}. \end{cases} \quad (8)$$

La esperanza y varianza para $\xi_{n,kh}$ son:

$$E(\xi_{n,kh}) = \beta h; \quad Var(\xi_{n,kh}) = \sigma^2 h.$$

Asumimos que el valor de $X_{n,0}$ es una constante y en particular $X_{n,0} = 0$ para simplificar. Estudiamos los procesos brownianos estándar, es decir $\beta = 0$ y $\sigma = 1$, y el proceso browniano con tendencia, es decir $\beta \neq 0$.

Proceso browniano estándar Para $\beta = 0$ y $\sigma = 1$, obtenemos de (5) que

$$X_{n,kh} = \sqrt{h} \sum_{j=1}^k U_{n,jh}; \quad k = 1, \dots, n. \quad (9)$$

Extendiendo el proceso discreto para todo el intervalo $[0, 1]$

$$X_n(t) = X_{n,[nt]h}; \quad t \in [0, 1].$$

Podemos expresar (9) como

$$X_n(t) = \begin{cases} \sqrt{h} \sum_{j=1}^{[nt]} U_{n,jh}; & t \in [h, 1] \\ 0; & t \in [0, h) \end{cases} \quad (10)$$

donde

$$E X_n(t) = 0, \quad Var X_n(t) = [nt]h; \quad t \in [h, 1].$$

Podemos expresar (5) sobre $[0, 1]$ mediante la siguiente recursión

$$X_n(t) = \begin{cases} X_n(t-h) + \sqrt{h}U_n(t); & t \in [h, 1] \\ 0; & t \in [0, h) \end{cases}$$

donde

$$U_n(t) = \begin{cases} U_{n,[nt]h}; & t \in [h, 1] \\ 0; & t \in [0, h) \end{cases}$$

$\{X_n(\cdot); n \geq 1\}$ representa una sucesión de funciones aleatorias de $D[0, 1]$ tal que $X_n(\cdot) \equiv \{X_n(t); t \in [0, 1]\}$ está definido en (10).

Convergencia en Distribución Puntual: Para $t \in [h, 1]$ fijo, tenemos una sucesión de variables aleatorias (va's); es decir $\{X_n(t); n \geq 1\}$. ¿Cuál es la convergencia en distribución de esta sucesión de va's? Para un valor determinado de $t \in [h, 1]$ tenemos el siguiente "double array" de va's

$$\left\{ \sqrt{h}U_{n,kh} : k = 1, 2, \dots, [nt]; \quad n \geq 1 \right\} \quad (11)$$

con va's independientes entre filas y donde es posible demostrar que

$$\lim_{n \rightarrow \infty} \frac{\sum_{k=1}^{[nt]} E |U_{n,kh}|^\nu}{\left(\sum_{k=1}^{[nt]} Var(U_{n,kh}) \right)^{\frac{\nu}{2}}} = \lim_{n \rightarrow \infty} \frac{[nt]}{[nt]^{\frac{\nu}{2}}} = 0, \quad for \nu > 2;$$

entonces podemos aplicar el teorema central del límite (TCL) para "double arrays"¹

$$\frac{X_n(t)}{\sqrt{[nt]h}} = \frac{1}{\sqrt{[nt]}} \sum_{j=1}^{[nt]} U_{n,jh} \xrightarrow{d} N(0,1)$$

significando que

$$X_n(t) \xrightarrow{d} X(t)$$

donde

$$X(t) \sim N(0,t) \quad \forall t \in (0,1].$$

Convergencia Débil: Estudiamos la convergencia débil de sucesiones de funciones aleatorias $\{X_n(\cdot); n \geq 1\}$. Aplicando el teorema funcional central del límite (TFCL) para funciones aleatorias de $D[0,1]$, es decir Teorema 29, demostramos que $X_n(\cdot) \Rightarrow X(\cdot)$ donde $X(\cdot)$ es el movimiento browniano estándar (SBM), es decir $X(\cdot) \equiv W(\cdot)$, que es una función aleatoria de $C[0,1]$. Por tanto

$$dX(t) = dW(t); \quad t \in [0,1]$$

que es el límite de la ecuación estocástica en diferencias

$$\Delta_h X_{n,kh} = \sqrt{h} U_{n,kh}; \quad k = 1, 2, \dots, n$$

con condición inicial $X_{n,0} = 0$.

Proceso browniano con tendencia Es el caso cuando $\beta \neq 0$. Ahora tenemos

$$X_n(t) = \begin{cases} \beta [nt]h + \sigma \sqrt{h} \sum_{j=1}^{[nt]} U_{n,jh}; & t \in [h, 1] \\ 0; & t \in [0, h) \end{cases}$$

donde

$$E X_n(t) = \beta [nt]h, \quad Var X_n(t) = [nt]h\sigma^2; \quad t \in [h, 1].$$

Convergencia en Distribución Puntual: Aplicando el TCL para "double arrays"

$$\frac{X_n(t) - \beta [nt]h}{\sigma \sqrt{[nt]h}} \xrightarrow{d} N(0,1);$$

¹Ver Teorema 143.



por tanto

$$X_n(t) \xrightarrow{d} X(t)$$

donde

$$X(t) \sim N(\beta t, \sigma^2 t) \quad \forall t \in (0, 1].$$

Convergencia Débil: Aplicando el Corolario 30 demostramos que $X_n(\cdot) \Rightarrow X(\cdot)$ donde

$$X(t) = \beta t + \sigma W(t).$$

A continuación presentamos otro procedimiento para obtener el proceso de Wiener con tendencia.

Procedimiento alternativo para obtener el proceso de Wiener con tendencia Sea la ecuación estocástica en diferencias de primer orden sobre el conjunto de puntos $\{0, h, 2h, \dots, 1\}$ definido como

$$\Delta_h X_{n,kh} = \eta_{n,kh}; \quad k = 1, 2, \dots, n \quad (12)$$

con condición inicial $X_{n,0} = 0$ y $\eta_{n,kh} \sim i.i.d. (\beta h; h(\sigma^2 - \beta^2 h))$ definido como

$$\eta_{n,kh} = \begin{cases} \sigma\sqrt{h}; & p_n = \frac{1}{2} \left(1 + \frac{\beta\sqrt{h}}{\sigma}\right) \\ -\sigma\sqrt{h}; & 1 - p_n \end{cases}$$

donde $\beta \in [-\sigma/\sqrt{h}; \sigma/\sqrt{h}]$. La solución de (12) sobre todos los puntos del intervalo $[0, 1]$ es

$$X_n(t) = \begin{cases} \sum_{j=1}^{[nt]} \eta_{n,jh}; & t \in [h, 1] \\ 0; & t \in [0, h) \end{cases} \quad (13)$$

donde

$$E X_n(t) = \beta [nt] h, \quad Var X_n(t) = [nt] h (\sigma^2 - \beta^2 h); \quad t \in [h, 1].$$

Analizamos en primer lugar la convergencia en distribución puntual de la sucesión de funciones aleatorias $\{X_n(\cdot) : n \geq 1\}$ donde $X_n(\cdot) \equiv \{X_n(t); t \in [0, 1]\}$ está definido en (13).

Convergencia Puntual en Distribución: Para un $t \in [h, 1]$ fijo, tenemos una sucesión de va's

$$\{\eta_{n,kh} : k = 1, \dots, [nt]; \quad n \geq 1\} \quad (14)$$

con va's independientes entre filas. Definamos la siguiente va

$$\gamma_{n,kh} = \eta_{n,kh} - \beta h = \begin{cases} \sqrt{h} (\sigma - \beta\sqrt{h}); & p_n \\ -\sqrt{h} (\sigma + \beta\sqrt{h}); & 1 - p_n. \end{cases}$$

Es posible demostrar que

$$\begin{aligned} \lim_{n \rightarrow \infty} \frac{\sum_{j=1}^{[nt]} E|\eta_{n,jh} - \beta h|^\nu}{\left(\sum_{j=1}^{[nt]} \text{Var}(\eta_{n,jh})\right)^{\frac{\nu}{2}}} &= \lim_{n \rightarrow \infty} \frac{\sum_{j=1}^{[nt]} E|\gamma_{n,jh}|^\nu}{\left(\sum_{j=1}^{[nt]} \text{Var}(\eta_{n,jh})\right)^{\frac{\nu}{2}}} \\ &= \lim_{n \rightarrow \infty} \frac{\frac{[nt]}{2} \left(1 + \frac{\beta\sqrt{h}}{\sigma}\right) (\sqrt{h}(\sigma - \beta\sqrt{h}))^\nu + \frac{[nt]}{2} \left(1 + \frac{\beta\sqrt{h}}{\sigma}\right) (\sqrt{h}(\sigma + \beta\sqrt{h}))^\nu}{([nt]h(\sigma^2 - \beta^2 h))^{\frac{\nu}{2}}} = 0 \end{aligned}$$

para $\nu > 2$. Aplicando el TCL para "double array"

$$\frac{X_n(t) - \beta [nt] h}{\sqrt{[nt] h (\sigma^2 - \beta^2 h)}} \xrightarrow{d} N(0, 1);$$

entonces

$$X_n(t) \xrightarrow{d} X(t)$$

donde

$$X(t) \sim N(\beta t, \sigma^2 t) \quad \forall t \in (0, 1].$$

Convergencia Débil: Según el Corolario 30 demostramos que $X_n(\cdot) \Rightarrow X(\cdot)$ donde

$$X(t) = \beta t + \sigma W(t).$$

1.2 Proceso CAR(1)

1.2.1 Caso determinístico

Sea la siguiente ecuación en diferencias de primer orden sobre el conjunto de puntos $\{0, h, 2h, \dots, 1\}$ para un n fijo:

$$x_{n,kh} = \alpha_h x_{n,(k-1)h} + \beta h; \quad k = 1, 2, \dots, n; \quad (15)$$



donde $\alpha_h = 1 + \alpha h$ y condición inicial $x_{n,0} = x_0$. La solución de (15) es

$$x_{n,kh} = \left(x_0 + \frac{\beta}{\alpha}\right) \alpha_h^k - \frac{\beta}{\alpha}; \quad k = 1, 2, \dots, n. \quad (16)$$

Para que (16) sea convergente, debe verificarse que $|\alpha_h| < 1$, es decir $\alpha \in (-2n, 0)$. Extendiendo el proceso discreto en todo el intervalo $[0, 1]$, podemos expresar (16) como

$$x_n(t) = \left(x_0 + \frac{\beta}{\alpha}\right) (1 + \alpha h)^{[nt]} - \frac{\beta}{\alpha}; \quad t \in [0, 1]. \quad (17)$$

Se obtiene fácilmente la siguiente recursión:

$$x_n(t) = \begin{cases} \alpha_h^{[nt] - [n(t-h)]} x_n(t-h) + \frac{\beta}{\alpha} \left(\alpha_h^{[nt] - [n(t-h)]} - 1\right); & t \in [h, 1] \\ x_0; & t \in [0, h). \end{cases}$$

De nuevo $x_n(\cdot)$ es una función real con saltos en los puntos $\{h, 2h, \dots, 1\}$, por tanto $x_n(\cdot) \in D[0, 1]$. Sea $\{x_n(\cdot); n \geq 1\}$ una sucesión de funciones en el espacio D . La función, $x(\cdot)$, a la que la sucesión de funciones reales converge cuando $n \rightarrow \infty$ es

$$x(t) = \left(x_0 + \frac{\beta}{\alpha}\right) \exp(\alpha t) - \frac{\beta}{\alpha}; \quad t \in [0, 1] \quad (18)$$

que pertenece a $C[0, 1]$ y es la solución de

$$\frac{dx(t)}{dt} = \alpha x(t) + \beta; \quad t \in [0, 1], \quad x(0) = x_0.$$

1.2.2 Caso estocástico

Sea la siguiente ecuación estocástica en diferencias de primer orden sobre el conjunto de puntos $\{0, h, 2h, \dots, 1\}$ para un n fijo definido como

$$X_{n,kh} = \alpha_h X_{n,(k-1)h} + \xi_{n,kh}; \quad X_{n,0} = 0; \quad k = 1, \dots, n \quad (19)$$

donde

$$\alpha_h = 1 + \alpha h; \quad \alpha \in (-2n, 0)$$

y $\xi_{n,kh} \sim i.i.d.$ definido en (7). A partir de (19) obtenemos iterando

$$X_{n,kh} = \beta h \sum_{j=1}^k \alpha_h^{j-1} + \sigma h^{1/2} \sum_{j=1}^k \alpha_h^{k-j} U_{n,jh}; \quad k = 1, \dots, n. \quad (20)$$

Simplificando, asumimos que $\beta = 0$ y $\sigma = 1$. Podemos expresar (20) sobre $[0, 1]$ como

$$X_n(t) = \begin{cases} h^{1/2} \sum_{k=1}^{[nt]} \alpha_h^{[nt]-k} U_{n,kh}; & t \in [h, 1] \\ 0; & t \in [0, h) \end{cases} \quad (21)$$

donde

$$E X_n(t) = 0; \quad Var X_n(t) = h \sum_{k=1}^{[nt]} \alpha_h^{2([nt]-k)}; \quad t \in [h, 1].$$

Sea $\{X_n(\cdot) : n \geq 1\}$ una sucesión de funciones aleatorias de $D[0, 1]$ donde $X_n(\cdot)$ está definido en (21).

Convergencia en Distribución Puntual: Para $t \in [h, 1]$ fijo, tenemos la siguiente sucesión de va's

$$\left\{ h^{1/2} \alpha_h^{[nt]-k} U_{n,kh} : k = 1, \dots, [nt], \quad n \geq 1 \right\} \quad (22)$$

con va's independientes entre las filas. $c_{n,kh}$ representa

$$c_{n,kh} = h^{1/2} \alpha_h^{[nt]-k} U_{n,kh}; \quad k = 1, \dots, [nt].$$

Entonces,

$$c_{n,kh} \sim i.d. \left(0, h \alpha_h^{2([nt]-k)} \right).$$

Obsérvese que $c_{n,kh}$ presenta heterocedasticidad. Es posible demostrar que

$$\lim_{n \rightarrow \infty} \frac{\sum_{k=1}^{[nt]} E |c_{n,kh}|^\nu}{\left(\sum_{k=1}^{[nt]} Var(c_{n,kh}) \right)^{\frac{\nu}{2}}} = \lim_{n \rightarrow \infty} \frac{h^{\frac{\nu}{2}} \sum_{k=1}^{[nt]} |\alpha_h^{[nt]-k}|^\nu}{h^{\frac{\nu}{2}} \alpha_h^{\nu[nt]} \left(\sum_{k=1}^{[nt]} \alpha_h^{-2k} \right)^{\frac{\nu}{2}}} = 0$$

para algún $\nu > 2$. Por ejemplo, cuando $\nu = 4$ tenemos

$$\lim_{n \rightarrow \infty} \frac{h^2 \alpha_h^{4[nt] \frac{1-\alpha_h^{-4[nt]}}{\alpha_h^4-1}}}{h^2 \alpha_h^{4[nt] \frac{1-\alpha_h^{-2[nt]}}{\alpha_h^2-1}}} = \lim_{n \rightarrow \infty} \frac{(1 + \alpha_h^{-2[nt]}) (\alpha_h^2 - 1)}{(1 - \alpha_h^{-2[nt]}) (\alpha_h^2 + 1)} = 0;$$



entonces aplicando el TCL para "double array"

$$\frac{X_n(t)}{\left(h \sum_{k=1}^{[nt]} \alpha_h^{2([nt]-k)}\right)^{\frac{1}{2}}} \xrightarrow{d} N(0, 1)$$

entonces

$$X_n(t) \xrightarrow{d} J_\alpha(t)$$

donde

$$J_\alpha(t) \sim N\left(0, \frac{e^{2\alpha t} - 1}{2\alpha}\right).$$

Convergencia Débil: Dado (20) cuando $\beta = 0$ y $\sigma = 1$,

$$\begin{aligned} X_{n,kh} &= h^{1/2} \sum_{j=1}^k \alpha_h^{k-j} U_{n,jh} \\ &= h^{1/2} \sum_{j=1}^k \left(\alpha_h^{k-j} - 1\right) U_{n,jh} + h^{1/2} \sum_{j=1}^k U_{n,jh}. \end{aligned}$$

Como

$$\frac{\alpha_h^{k-j} - 1}{\alpha_h - 1} = \sum_{i=0}^{k-j-1} \alpha_h^i,$$

entonces

$$\begin{aligned} X_{n,kh} &= h^{1/2} (\alpha_h - 1) \sum_{s=1}^{k-1} \alpha_h^{k-s-1} \sum_{j=1}^s U_{n,jh} + h^{1/2} \sum_{j=1}^k U_{n,jh} \\ &= \alpha h \sum_{s=1}^{k-1} (1 + \alpha h)^{k-s-1} \left(\sum_{j=1}^s h^{1/2} U_{n,jh} \right) + h^{1/2} \sum_{j=1}^k U_{n,jh}. \end{aligned}$$

Extendiendo el proceso de arriba sobre $[0, 1]$, entonces

$$\begin{aligned} X_n(t) &= \alpha h \sum_{s=1}^{[nt]-1} \left(1 + \frac{\alpha(t-s)}{n(t-s)}\right)^{[nt]-s-1} \left(\sum_{j=1}^s h^{1/2} U_{n,jh} \right) + h^{1/2} \sum_{j=1}^{[nt]} U_{n,jh} \\ &\Rightarrow \alpha \int_0^t e^{\alpha(t-s)} dW(s) + W(t) \equiv J_\alpha(t). \end{aligned}$$

Obsérvese que la expresión de arriba según el Teorema 40 puede escribirse como

$$J_\alpha(t) = \int_0^t e^{\alpha(t-s)} dW(s)$$

que es la solución de la ecuación diferencial estocástica

$$dJ_{\alpha}(t) = \alpha J_{\alpha}(t) dt + dW(t), \quad J_{\alpha}(0) = 0.$$

Este proceso se conoce como el proceso Ornstein-Uhlenbeck o proceso CAR(1)².

Otra forma de estudiar la convergencia débil es mediante la convergencia de funciones de densidad espectrales normalizadas de procesos discretos, representado como $f_D(\omega)$, a funciones de densidad espectrales normalizadas de procesos continuos³; representado como $f(\omega)$. Sea el proceso AR(1) definido como

$$X_{n,kh} = \alpha_h X_{n,(k-1)h} + \sigma h^{1/2} U_{n,kh}; \quad k = 1, \dots, n$$

con condición inicial

$$X_{n,0} \sim \left(0, \frac{\sigma^2 h}{1 - \alpha_h^2}\right)$$

para garantizar la estacionariedad, por tanto la función de densidad espectral normalizada correspondiente al proceso AR(1) estacionario es:

$$f_D(\omega h) = \frac{1}{2\pi} \frac{1 - \alpha_h^2}{1 - 2\alpha_h \cos \omega h + \alpha_h^2}, \quad |\omega| \leq \pi/h. \quad (23)$$

Sea $Z(t)$ la función de densidad espectral normalizada correspondiente a la serie del proceso continuo estacionario obtenido del proceso AR(1) de arriba⁴, según (158) su función de densidad espectral normalizada es

$$f_Z(\omega) = h \left[\frac{\sin(\omega h/2)}{\omega h/2} \right]^2 f_D(\omega h). \quad (24)$$

Sea $f_X(\omega)$ la función de densidad espectral normalizada del proceso en tiempo continuo obtenido a partir del límite de $f_Z(\omega)$ cuando $h \rightarrow 0$, es decir

$$f_X(\omega) = \frac{-\alpha}{\pi(\omega^2 + \alpha^2)}$$

que es la función de densidad espectral normalizada correspondiente al proceso estacionario CAR(1) definido como

$$dX(t) = \alpha X(t) + dW(t), \quad \alpha < 0.$$

²Véase Sección 8.4.1 en el Capítulo 2 para más detalles.

³Ver Sección 10 del Capítulo 2

⁴Ver Priestley (1963).



1.3 Proceso CAR(2)

Sea el siguiente proceso generador de datos

$$\begin{aligned} X_{n,kh} &= \alpha_h X_{n,(k-1)h} + \varepsilon_{n,kh}, & X_{n,0} &= 0; \\ \varepsilon_{n,kh} &= \phi_h \varepsilon_{n,(k-1)h} + h^{1/2} U_{n,kh}, & \varepsilon_{n,0} &= 0; \end{aligned} \quad (25)$$

donde $\alpha_h \equiv 1 + \alpha h$; $\phi_h \equiv 1 + \phi h$ y $U_{n,kh}$ está definido en (8). Podemos expresar (25) como el siguiente proceso AR(2):

$$X_{n,kh} = (\alpha_h + \phi_h) X_{n,(k-1)h} - \phi_h \alpha_h X_{n,(k-2)h} + h^{1/2} U_{n,kh}. \quad (26)$$

Introduciendo el operador de retardo L sobre el proceso de arriba:

$$\begin{aligned} X_{n,kh} &= (1 - \alpha_h L)^{-1} (1 - \phi_h)^{-1} h^{1/2} U_{n,kh} \\ &= \sum_{s=0}^k \alpha_h^{k-s} \sum_{j=0}^s \phi_h^{s-j} h^{1/2} U_{n,jh} \end{aligned}$$

Extendiendo el proceso AR(2) sobre $[0, 1]$ y multiplicando por h ,

$$hX_n(t) = h \sum_{s=0}^{[nt]} \alpha_h^{[nt]-s} \sum_{j=0}^s \phi_h^{s-j} h^{1/2} U_{n,jh}.$$

Siguiendo a Nabeya y Perron (1994):

$$hX_n(t) = \sum_{s=0}^{[nt]} \int_{(s-1)h}^{sh} \alpha_h^{[nt]-s} \times \left\{ \sum_{j=0}^s \int_{(j-1)h}^{jh} \phi_h^{s-j} dY_n(z) \right\} dv$$

donde

$$Y_n(t) = h^{1/2} \sum_{j=1}^{[nt]} U_{n,jh},$$

entonces

$$\begin{aligned} hX_n(t) &= \int_0^t \exp(\alpha(t-v)) \times \left\{ \int_0^v \exp(\phi(v-z)) dY_n(z) \right\} dv \\ &= \int_0^t \exp(\alpha(t-v)) \times \left\{ Y_n(v) + \phi \int_0^v \exp(\phi(v-z)) dY_n(z) \right\} dv \\ &\Rightarrow \int_0^t \exp(\alpha(t-v)) \times \left\{ W(v) + \phi \int_0^v \exp(\phi(v-z)) dW(z) \right\} dv \\ &= \int_0^t \exp(\alpha(t-v)) J_\phi(v) dv \equiv X(t). \end{aligned}$$

podemos expresar $X(t)$ como:

$$\begin{aligned} X(t) &= \int_0^t e^{\alpha(t-v)} J_\phi(v) dv = \int_0^t e^{\alpha(t-v)} \left\{ \int_0^v e^{\phi(v-z)} dW(z) \right\} dv \\ &= \int_0^t \left\{ \int_z^t e^{(\phi-\alpha)v + (\alpha t - \phi z)} dv \right\} dW(z) = \int_0^t \frac{e^{\phi(t-z)} - e^{\alpha(t-z)}}{\phi - \alpha} dW(z) \end{aligned}$$

que es la solución de la siguiente ecuación diferencial estocástica de segundo orden:

$$dX(t) = (\alpha + \phi) X(t) dt - \alpha \phi X(t) dt + dW(t).$$

Este proceso se conoce como el proceso CAR(2)⁵ cuya función de densidad espectral normalizada es

$$f_X(\omega) = \frac{-(\alpha + \phi)\alpha\phi}{\pi(\phi^2 + \omega^2)(\alpha^2 + \omega^2)} \quad (27)$$

La función de densidad espectral normalizada correspondiente a (26) cuando es estacionario, es decir con condición inicial

$$X_{n,0} \sim \left(0, \frac{h(1 + \phi_h \alpha_h)}{(1 - \phi_h \alpha_h)(1 - \alpha_h^2)(1 - \phi_h^2)} \right),$$

es

$$\begin{aligned} f_D(\omega h) &= \frac{(1 - \phi_h \alpha_h)(1 - \alpha_h^2)(1 - \phi_h^2)}{2\pi(1 + \phi_h \alpha_h)} \times \\ &\quad \frac{1}{(1 + \alpha_h^2)(1 + \phi_h^2) - 2(\alpha_h + \phi_h)(1 + \phi_h \alpha_h) \cos \omega h + 4\phi_h \alpha_h \cos^2 \omega h}. \end{aligned}$$

Si estudiamos la convergencia débil mediante la convergencia de funciones de densidad espectrales normalizadas del proceso estacionario AR(2) mediante el límite de $f_Z(\omega)$ definido en (24) para la función de arriba $f_D(\omega h)$ cuando $h \rightarrow 0$, se obtiene la función de densidad espectral normalizada en (27).

1.4 Convergencia débil de un proceso ARMA(1,1)

Dividamos el intervalo $[0, 1]$ en n subintervalos de longitud $h \equiv 1/n$ y definamos el siguiente proceso AR(1) donde los errores siguen una estructura

⁵Ver Sección 8.6.2 en el Capítulo 2.



$MA(1)$ sobre el conjunto de puntos $\{0, h, 2h, \dots, 1\}$ para n fijo:

$$X_{n,kh} = \alpha_h X_{n,(k-1)h} + \xi_{n,kh}; \quad k = 1, 2, \dots, n$$

$$\xi_{n,kh} = d_{n,kh} - \phi_h d_{n,(k-1)h};$$

$$\alpha_h = 1 + \alpha h; \quad \alpha < 0$$

$$\phi_h = 1 - \phi h^{1/2}.$$

Asumamos que $X_{n,0} = d_{n,0} = 0$ y $d_{n,kh}$ está definido como

$$d_{n,kh} = h^{1/2} U_{n,kh}$$

donde

$$U_{n,kh} = \begin{cases} 1; & p = \frac{1}{2} \\ -1; & 1 - p = \frac{1}{2}. \end{cases}$$

Sea

$$a_h = \frac{\phi_h}{\alpha_h} = \frac{1 - \phi h^{1/2}}{1 + \alpha h}$$

donde $a_h \rightarrow 1$ cuando $h \rightarrow 0$. Podemos expresar el modelo ARMA(1,1) como

$$X_{n,kh} = a_h d_{n,kh} + \frac{1 - a_h}{1 - a_h L} d_{n,kh}.$$

Por tanto,

$$\begin{aligned} X_{n,kh} &= a_h d_{n,kh} + (1 - a_h) \sum_{j=1}^k \alpha_h^{k-j} d_{n,jh} \\ &= a_h d_{n,kh} + (1 - a_h) \sum_{j=1}^k \left(\alpha_h^{k-j} - 1 \right) d_{n,jh} + (1 - a_h) \sum_{j=1}^k d_{n,jh}. \end{aligned}$$

Entonces,

$$\begin{aligned} h^{-1/2} X_{n,kh} &= a_h U_{n,kh} + h^{-1/2} (1 - a_h) \sum_{j=1}^k h^{1/2} U_{n,jh} \\ &\quad + h^{-1/2} (1 - a_h) (\alpha_h - 1) \sum_{j=1}^{k-1} \alpha_h^{k-j-1} \left(\sum_{s=1}^j h^{1/2} U_{n,sh} \right). \end{aligned}$$



Extendiendo el proceso de arriba sobre $[0,1]$

$$\begin{aligned} h^{-1/2}X_n(t) &= a_h U_n(t) + h^{-1/2}(1 - a_h) \sum_{j=1}^k h^{1/2}U_{n,jh} \\ &\quad + \alpha h^{-1/2}(1 - a_h)h \sum_{j=1}^{[nt]-1} \left(1 + \frac{\alpha(t-j)}{n(t-j)}\right)^{[nt]-j-1} \left(\sum_{s=1}^j h^{1/2}U_{n,sh}\right). \end{aligned}$$

Como $h^{-1/2}(1 - a_h) \rightarrow \phi$ cuando $h \rightarrow 0$, entonces

$$h^{-1/2}X_n(t) \Rightarrow U_\infty + \phi \left[W(t) + \alpha \int_0^t e^{\alpha(t-s)} dW(s) \right] \equiv U_\infty + \phi J_\alpha(t)$$

donde U_∞ es una va definida como

$$U_\infty = \begin{cases} 1; & p = \frac{1}{2} \\ -1; & 1 - p = \frac{1}{2}. \end{cases}$$

1.5 Cadenas de Markov en tiempo continuo

Dividamos el intervalo $[0,1]$ en n subintervalos de longitud $h \equiv 1/n$ y asumamos por simplicidad que n es un número entero⁶. Sea una cadena de Markov discreta homogénea⁷ definida en el conjunto de puntos $\{0, h, 2h, \dots, 1\}$ como:

$$\pi'_{n,kh} = \pi'_{n,(k-1)h} \mathbb{P}_h \quad \pi_{n,0} = \pi_0, \quad k = 1, \dots, n; \quad (28)$$

donde $\mathbb{P}_h$ es la matriz de transición homogénea con unidad de tiempo h . Definimos los elementos de la matriz de arriba como

$$p_{ij}^h = P(X_{n,kh} = x_j | X_{n,(k-1)h} = x_i), \quad x_i, x_j \in E$$

donde E es un espacio de estados finito de $\mathbb{R}^d$, es decir $E \equiv \{x_1, x_2, \dots, x_N\}$ y $\pi_{n,kh}$ es el vector de probabilidad $N \times 1$ correspondiente a $X_{n,kh}$, es decir

$$\pi_{n,kh} = (\pi_{n,kh}^1, \pi_{n,kh}^2, \dots, \pi_{n,kh}^N)'$$

donde

$$\pi_{n,kh}^i = P(X_{n,kh} = x_i); \quad i = 1, 2, \dots, N.$$

⁶Cuando n es un número entero, ver Geweke et al (1986).

⁷Ver Definición 166 en el Capítulo 2.



Dada la condición inicial π_0 y (28), se obtiene

$$\pi'_{n,kh} = \pi'_0 \mathbb{P}_h^k.$$

Sea $\mathbb{P}$ la matriz de transición para el intervalo $[0, 1]$, es decir

$$\mathbb{P} = \mathbb{P}_h^n.$$

Asumamos que $\mathbb{P}$ es irreducible, diagonalizable, es decir $\mathbb{P} = M\Lambda M^{-1}$ donde M es la matriz de vectores propios y $\Lambda \equiv \text{diag}(\lambda_1, \dots, \lambda_N)$ es la matriz diagonal de $\mathbb{P}$, todos los valores propios son diferentes y tomamos por conveniencia λ_1 como el valor propio tal que $|\lambda_1| \geq |\lambda_i|$ $i = 2, \dots, N$; aplicando el Teorema de Perron-Frobenius y asumiendo que $\mathbb{P}$ es una matriz primitiva, sabemos que $\lambda_1 = 1$ y $|\lambda_i| < 1$ $i = 2, \dots, N$. Dado que $\mathbb{P}_h = M\Lambda^h M^{-1}$ y (28), entonces

$$\begin{aligned} (\pi'_{n,kh} - \pi'_{n,(k-1)h})/h &= \pi'_{n,(k-1)h} (\mathbb{P}_h - I)/h \\ &= \pi'_{n,(k-1)h} M [(\Lambda^h - I)/h] M^{-1}. \end{aligned} \quad (29)$$

Extendiendo la cadena de Markov definida en (28) a todo los puntos de $[0, 1]$:

$$\pi_n(t) = \pi_{n,[nt]h}; \quad t \in [0, 1].$$

Por tanto, podemos expresar la ecuación (29) para $[0, 1]$ como

$$(\pi'_n(t) - \pi'_n(t-h))/h = \pi'_n(t-h) M [(\Lambda^h - I)/h] M^{-1}. \quad (30)$$

Asumamos que

$$\lim_{h \rightarrow 0} (\pi'_n(t) - \pi'_n(t-h))/h$$

existe, el cual denotamos por $\dot{\pi}'(t)$, entonces tomando límites en los dos lados de (30) cuando $h \rightarrow 0$ y como

$$\lim_{h \rightarrow 0} (\lambda_i^h - 1)/h = \ln(\lambda_i) = \psi_i,$$

y

$$\lim_{h \rightarrow 0} \pi_n(t) = \pi(t)$$

entonces

$$\dot{\pi}'(t) = \pi'(t) R$$



donde $R = M\Psi M^{-1}$ y $\Psi = \text{diag}(\psi_1, \dots, \psi_n)$. R se conoce como la matriz de intensidad verificándose que $\mathbb{P} = \exp(R)$. Todas las soluciones de esta ecuación matricial se llaman logaritmos (naturales) de $\mathbb{P}$, es decir $R = \ln(\mathbb{P})$. Existen dos problemas cuando vamos del tiempo discreto al tiempo continuo. Uno es que el logaritmo complejo tiene infinitas soluciones, por tanto R no es único, esto se conoce como el *problema de alisado* que aparece siempre que vamos del tiempo discreto al tiempo continuo. El segundo problema se conoce como el *problema de embedding*, es decir si existe una matriz R tal que $\mathbb{P} = \exp(R)$. Las condiciones que garantizan el "embedding" pueden verse en Singer y Spilerman (1976).

1.6 Proceso de Poisson

Particionemos el intervalo $(0, 1]$ en n subintervalos disjuntos de longitud $h \equiv 1/n$, es decir, $[(k-1)h, kh]$ $k = 1, 2, \dots, n$; donde en cada punto del conjunto $\{kh : k = 1, 2, \dots, n\}$ puede ocurrir un acontecimiento como máximo. Representemos esto mediante una va para cada punto del conjunto de arriba, es decir

$$V_{n,kh} = \begin{cases} 1, & \text{con probabilidad } \lambda h; \\ 0, & \text{con probabilidad } 1 - \lambda h. \end{cases}$$

$V_{n,h}, V_{n,2h}, \dots$ son va's *i.i.d.* La esperanza y varianza de $V_{n,kh}$ son:

$$E(V_{n,kh}) = \lambda h;$$

y

$$\text{Var}(V_{n,kh}) = \lambda h (1 - \lambda h).$$

Sea $\{N_n(t), t \in [0, 1]\}$ un proceso contador donde $N_n(t)$ es el número de acontecimientos en $(0, t]$ al particionar $[0, 1]$ en n intervalos disjuntos de longitud $h \equiv 1/n$. Entonces:

$$N_n(t) = \begin{cases} \sum_{k=1}^{[nt]} V_{n,kh}; & t \in [h, 1] \\ 0; & t \in [0, h). \end{cases}$$

Obsérvese que tenemos una función aleatoria de $D[0, 1]$ para cada n , es decir $\{N_n(t) : t \in [0, 1]\}$, representado por $N_n(\cdot)$; por tanto tenemos una



sucesión de funciones aleatorias, es decir $\{N_n(\cdot); n \geq 1\}$. Además, obsérvese que para un $t \in [h, 1]$ fijo tenemos una sucesión de va's representado por $\{N_n(t); n \geq 1\}$. Estamos interesados en la convergencia en distribución de la sucesión de va's de arriba. Sabemos que $N_n(t)$ para $t \in [h, 1]$ sigue una distribución binomial, es decir

$$N_n(t) \sim B([nt], \lambda h)$$

con función de distribución

$$P(N_n(t) = j) = \binom{[nt]}{j} (\lambda h)^j (1 - \lambda h)^{[nt]-j}; \quad j = 0, 1, \dots, [nt].$$

La esperanza y varianza de $N_n(t)$ para $t \in [h, 1]$ son:

$$E(N_n(t)) = [nt](\lambda h) \quad y \quad Var(N_n(t)) = [nt](\lambda h)(1 - \lambda h).$$

La función característica de $N_n(t)$ es

$$\begin{aligned} \phi_{N_n(t)}(s) &= E(\exp(isN_n(t))) = E\left(\exp\left(is \sum_{k=1}^{[nt]} V_{n,kh}\right)\right) = \\ &= (\phi_{V_{n,kh}}(s))^{[nt]} = (1 - (\lambda h) + e^{is}(\lambda h))^{[nt]}. \end{aligned} \quad (31)$$

La distribución asintótica de $N_n(t)$ se obtiene como el límite de (31) cuando $n \rightarrow \infty$. Por tanto

$$\lim_{n \rightarrow \infty} \phi_{N_n(t)}(s) = \lim_{n \rightarrow \infty} (1 - \lambda h + \lambda h e^{is})^{[nt]} = \exp(\lambda t(e^{is} - 1));$$

que es la distribución de Poisson con media λt . Entonces

$$N_n(t) \xrightarrow{d} N(t), \quad \text{where } N(t) \sim P(\lambda t); \quad t \in (0, 1].$$

1.7 Proceso de Poisson compuesto

Sea

$$X_n(t) = \begin{cases} \sum_{k=1}^{N_n(t)} \xi_{n,k}; & t \in [\frac{1}{n}, 1] \\ 0; & t \in [0, \frac{1}{n}); \end{cases}$$

donde $\xi_{n,1}, \xi_{n,2}, \dots \sim i.i.d. N(0, 1)$. Obsérvese que la función aleatoria $\{X_n(t) : t \in [0, 1]\}$ representada por $X_n(\cdot)$ para cada n y para un $t \in [h, 1]$ fijo, tenemos una

sucesión de va's representada por $\{X_n(t); n \geq 1\}$. Estamos interesados en la convergencia en distribución de esta sucesión. Aplicando la función característica, es decir

$$\begin{aligned}\emptyset_{X_n(t)}(s) &= E\left(\exp\left(is \sum_{k=1}^{N_n(t)} \xi_{n,k}\right)\right) = E\left\{E\left(\exp\left(is \sum_{k=1}^{N_n(t)} \xi_{n,k}\right) \mid N_n(t)\right)\right\} = \\ &= E\left\{E\left(\exp(is\xi_{n,k})\right)^{N_n(t)}\right\} = E\left(\emptyset_{\xi_{n,k}}(s)^{N_n(t)}\right) = E\left(\emptyset_{\xi_{n,k}}(s)^{V_{n,jh}}\right)^{[nt]} = \\ &= \left(1 - \lambda h + \lambda h \emptyset_{\xi_{n,k}}(s)\right)^{[nt]}.\end{aligned}$$

$X(t)$ representa la va correspondiente a la distribución asintótica de $X_n(t)$, entonces

$$\emptyset_{X(t)}(s) = \lim_{n \rightarrow \infty} \emptyset_{X_n(t)}(s) = \lim_{n \rightarrow \infty} \left(1 - \lambda h + \lambda h \emptyset_{\xi_{n,k}}(s)\right)^{[nt]} = \exp(\lambda t (\emptyset_{\xi_k}(s) - 1))$$

donde $\{\xi_k; k \geq 1\}$, verificándose que $\xi_k \sim i.i.d. N(0, 1)$; representa la sucesión $\{\xi_{n,k}; k \geq 1\}$ cuando $n \rightarrow \infty$.

1.8 Convergencia débil de procesos binomiales (trinomial) a procesos de difusión

Sea la siguiente ecuación diferencial estocástica (EDE) del proceso de dimensión uno $X(\cdot)$:

$$dX(t) = f(t, X(t)) dt + G(t, X(t)) dW(t), \quad 0 \leq t \leq T < \infty;$$

donde $W(t)$ representa un proceso de Wiener estándar de una dimensión, $f(t, X(t))$ y $G(t, X(t)) \geq 0$ son la tendencia instantánea y la desviación estándar de $X(t)$, y $X(0) = x_0$ es una constante. Estamos interesados en encontrar una sucesión de procesos binomiales que converjan débilmente a la EDE de arriba. Aplicamos el Teorema de Stroock-Varadhan⁸ para la convergencia débil. Dividamos el intervalo $[0, T]$ en n subintervalos de igual longitud, es decir $h \equiv T/n$. Consideremos para cada h la siguiente cadena de Markov unidimensional

$$\{X_{n,kh} : k = 0, 1, \dots, n\}$$

⁸Ver Teorema 91.

representado por $\{X_{n,kh}\}$, donde $X_{n,0h} = x_0, \forall h$. Representamos las probabilidades de transición correspondientes a la cadena de Markov chain para cada h y $k = 1, 2, \dots, n$ como

$$\Pi_{n,kh}(x; a) \equiv P_h(X_{n,kh} = a | X_{n,(k-1)h} = x);$$

donde $a \in \mathbb{R}$ representa un valor de la va $X_{n,kh}$ perteneciente al conjunto discreto $\Gamma_{n,kh}(x)$. Este conjunto contiene algunos valores de $X_{n,kh}$ correspondiente al período kh , que depende del valor del proceso inmediatamente antes del salto; por tanto tenemos un conjunto diferente para cada valor diferente del proceso asociado al período $(k-1)h$. El conjunto de todos los valores posibles de $X_{n,kh}$ en kh se representa como $\Gamma_{n,kh}$. Por tanto,

$$\Gamma_{n,kh} = \bigcup \Gamma_{n,kh}(x); \quad \forall x \in \Gamma_{n,(k-1)h}$$

para todo $k = 1, 2, \dots, n$. Obsérvese que el conjunto inicial es $\Gamma_{n,0h} = \{x_0\}$ para todo n , (representado como Γ_0). Se verifica que para n fijo

$$1 = l(\Gamma_0) \leq l(\Gamma_{n,h}) \leq \dots \leq l(\Gamma_{n,nh})$$

donde $l(\cdot)$ representa el número de componentes dado un conjunto discreto. Para extender el proceso discreto al intervalo $[0, T]$, se construye $\{X_{n,kh}\}$ una función constante con saltos en $h, 2h, \dots, nh$. La notación correspondiente al proceso de Markov es

$$X_n(t) = X_{n,[nt/T]h}; \quad t \in [0, T]$$

y representamos por $X_n(\cdot)$ la función aleatoria

$$\{X_n(t) : t \in [0, T]\}.$$

Para el *proceso binomial*:

$$\Gamma_{n,kh}(x) = \{x_{n,kh}^-(x), x_{n,kh}^+(x)\}; \quad x_{n,kh}^-(x) < x_{n,kh}^+(x)$$

donde $x_{n,kh}^+(x)$ es valor de salto hacia arriba del proceso en el período kh condicionado a que el valor del proceso en $(k-1)h$ es x ; mientras $x_{n,kh}^-(x)$ es el valor de salto hacia abajo. Para simplificar la notación, representaremos $\Pi_{n,kh}(x, x_{n,kh}^+(x))$ como $q_{n,kh}(x)$ y $\Pi_{n,kh}(x, x_{n,kh}^-(x))$ como $1 - q_{n,kh}(x)$. La probabilidad de un salto de subida, $q_{n,kh}(x)$, y los valores $x_{n,kh}^+(x)$ y $x_{n,kh}^-(x)$

son elegidos para garantizar la convergencia débil del proceso discreto al proceso continuo.

Mientras, para el *proceso trinomial*:

$$\Gamma_{n,kh}(x) = \{x_{n,kh}^-(x), x, x_{n,kh}^+(x)\}; \quad x_{n,kh}^-(x) < x < x_{n,kh}^+(x).$$

En este caso, representamos $\Pi_{n,kh}(x, x_{n,kh}^+(x))$ como $q_{n,kh}(x)$; $\Pi_{n,kh}(x, x_{n,kh}^-(x))$ como $p_{n,kh}(x)$ y $\Pi_{n,kh}(x, x)$ como $1 - q_{n,kh}(x) - p_{n,kh}(x)$.

1.8.1 Proceso Ornstein-Uhlenbeck

Sea el proceso O-U con reversión a la media, es decir

$$dX(t) = \beta(\alpha - X(t))dt + \sigma dW(t), \quad 0 \leq t \leq T < \infty; \quad (32)$$

donde β, α y σ son no-negativos y $X(0) = x_0$ es una constante. Siguiendo a Nelson y Ramaswamy (1990), definimos la cadena de Markov para el proceso binomial como

$$\begin{aligned} x_{n,kh}^+(x) &\equiv x + \sigma\sqrt{h}; \\ x_{n,kh}^-(x) &\equiv x - \sigma\sqrt{h}. \end{aligned} \quad (33)$$

Dado el Teorema 57,

$$\begin{aligned} E(X(kh) | X((k-1)h) = x) &= e^{-\beta h}x + \alpha(1 - e^{-\beta h}) \\ &\cong x + \beta h(\alpha - x). \end{aligned} \quad (34)$$

Representemos $X(kh)$ como $X_{n,kh}$ y k^* como $[nt/T]$, entonces el valor esperado de la función aleatoria para un t fijo es

$$\begin{aligned} E(X_n(t) | X_n(s), s \leq t) &= E(X_{n,k^*h} | X_{n,(k^*-1)h} = x) \\ &= q_{n,k^*h}(x) x_{n,k^*h}^+(x) + (1 - q_{n,k^*h}(x)) x_{n,k^*h}^-(x); \end{aligned}$$

que debe verificar la condición (34). Tenemos que

$$q_{n,k^*h}(x) = \begin{cases} \frac{1}{2} + \frac{\sqrt{h}\beta(\alpha-x)}{2\sigma}; & 0 \leq \frac{1}{2} + \frac{\sqrt{h}\beta(\alpha-x)}{2\sigma} \leq 1, \\ 0; & \frac{1}{2} + \frac{\sqrt{h}\beta(\alpha-x)}{2\sigma} < 0, \\ 1; & \frac{1}{2} + \frac{\sqrt{h}\beta(\alpha-x)}{2\sigma} \geq 1. \end{cases} \quad (35)$$



Obsérvese que la probabilidad de arriba se elige para que la media del proceso binomial converja a la media del proceso continuo, es decir expresión (34). Para garantizar que esta probabilidad pertenezca al intervalo $[0, 1]$, el valor de x debe verificar que

$$x \in \left[\alpha - \frac{\sigma}{\beta\sqrt{h}}; \alpha + \frac{\sigma}{\beta\sqrt{h}} \right].$$

En definitiva, nuestro proceso de Markov definido por las condiciones (33)⁹ y (35) converge débilmente al proceso de difusión (32) mediante el Teorema 91¹⁰.

1.8.2 Movimiento geométrico browniano

Definimos el movimiento geométrico browniano (MGB) mediante la siguiente EDE

$$dX(t) = \alpha X(t) dt + \sigma X(t) dW(t), \quad t \in [0, T]$$

verificándose que σ y la condición inicial x_0 son no negativas. Sea

$$Y(t) = \ln(X(t)),$$

entonces mediante el lema de Ito:

$$dY(t) = \beta dt + \sigma dW(t), \quad Y(0) = y_0 \quad (36)$$

donde $y_0 = \ln(x_0)$ y $\beta = \alpha - \sigma^2/2$. Por tanto, $Y(\cdot)$ es un proceso de Wiener con tendencia. Podemos desarrollar un árbol binomial simple que converja débilmente al proceso $Y(\cdot)$ y luego, transformamos los valores del proceso de arriba representado por y en valores del proceso inicial $X(\cdot)$, es decir x . Se proponen dos procesos binomiales diferentes con convergencia débil al MGB.

Proceso binomial como aproximación al MGB Definimos una cadena de Markov para el proceso binomial como

$$y_{n,kh}^+(y) \equiv y + \sigma\sqrt{h};$$

$$y_{n,kh}^-(y) \equiv y - \sigma\sqrt{h}.$$

⁹Donde k se sustituye por k^* .

¹⁰Ver Nelson y Ramaswamy (1990).



Dado el Teorema 57,

$$E(Y(kh) | Y((k-1)h) = y) = y + \beta h; \quad (37)$$

Representemos $Y(kh)$ como $Y_{n,kh}$, y k^* como $[nt/T]$, entonces el valor esperado de la función aleatoria para un t fijo es

$$\begin{aligned} E(Y_n(t) | Y_n(s), s \leq t) &= E(Y_{n,k^*h} | Y_{n,(k^*-1)h} = y) \\ &= q_{n,k^*h}(y) y_{n,k^*h}^+(y) \\ &\quad + (1 - q_{n,k^*h}(y)) y_{n,k^*h}^-(y); \end{aligned}$$

que debe verificar la condición (37). Entonces, tenemos

$$q_{n,k^*h}(y) = \begin{cases} \frac{1}{2} \left(1 + \frac{\beta\sqrt{h}}{\sigma}\right); & 0 \leq \frac{1}{2} \left(1 + \frac{\beta\sqrt{h}}{\sigma}\right) \leq 1, \\ 0; & \frac{1}{2} \left(1 + \frac{\beta\sqrt{h}}{\sigma}\right) < 0, \\ 1; & \frac{1}{2} \left(1 + \frac{\beta\sqrt{h}}{\sigma}\right) \geq 1. \end{cases}$$

Para garantizar que esta probabilidad pertenezca al intervalo $[0, 1]$, el valor β debe verificar que

$$\beta \in \left[-\sigma/\sqrt{h}; \sigma/\sqrt{h}\right].$$

Aplicando el Teorema 91, el proceso de Markov $\{Y_n(\cdot) : n \geq 1\}$ converge débilmente al proceso $Y(\cdot)$. Volviendo al proceso inicial, es decir $X(\cdot)$, sabemos que

$$X(t) = e^{Y(t)},$$

entonces

$$\begin{aligned} x_{n,kh}^+(x) &\equiv e^{\sigma\sqrt{h}}x; \\ x_{n,kh}^-(x) &\equiv e^{-\sigma\sqrt{h}}x. \end{aligned} \quad (38)$$

Se verifica que

$$X(kh) | X((k-1)h) = x \sim \log normal;$$



con media

$$E(X(kh) | X((k-1)h) = x) = e^{\alpha h} x.$$

La probabilidad $q_{n,kh}(x)$ es

$$q_{n,kh}(x) = \frac{e^{\alpha h} - e^{-\sigma\sqrt{h}}}{e^{\sigma\sqrt{h}} - e^{-\sigma\sqrt{h}}} \cong \frac{1}{2} + \frac{\alpha\sqrt{h}}{2\sigma}.$$

Para garantizar que $q_{n,kh}(x)$ pertenezca al intervalo $[0, 1]$, debe verificarse que

$$\alpha \in \left[-\sigma/\sqrt{h}; \sigma/\sqrt{h} \right].$$

Se demuestra que el proceso de Markov correspondiente a esta cadena de Markov converge débilmente al MGB aplicando el Teorema de Stroock-Varadhan.

Otro proceso binomial como aproximación al MGB Presentamos otro proceso de Markov que converge débilmente a la ecuación (36). Sea la ecuación de primer orden estocástica

$$Y_{n,kh} = \beta h + Y_{n,(k-1)h} + \sigma d_{n,kh}, \quad Y_{n,0} = y_0; \quad (39)$$

donde

$$d_{n,kh} = \begin{cases} \sqrt{h}; & p = 1/2 \\ -\sqrt{h}; & p = 1/2. \end{cases}$$

A partir de (39), se obtiene

$$Y_{n,kh} = y_0 + \beta kh + \sigma \sum_{j=1}^k d_{n,jh}; \quad k = 1, 2, \dots, n. \quad (40)$$

Representemos la realización de la y va $Y_{n,(k-1)h}$ como y , entonces tenemos una cadena de Markov definida como

$$y_{n,kh}^+(y) \equiv y + \beta h + \sigma\sqrt{h};$$

$$y_{n,kh}^-(y) \equiv y + \beta h - \sigma\sqrt{h};$$

$$q_{n,kh}(y) \equiv 1/2.$$

Extendiendo el proceso discreto (40) al intervalo $[0, T]$, tenemos que

$$Y_n(t) = \begin{cases} y_0 + [nt/T]\beta + \sigma \sum_{j=1}^{[nt/T]} d_{n,jh}; & t \in [h, T] \\ 0; & t \in [0, h). \end{cases}$$

Aplicando el Corolario 30¹¹ demostramos que $Y_n(\cdot) \Rightarrow Y(\cdot)$ donde $Y(t) = \beta t + \sigma W(t)$. Volviendo al proceso inicial, es decir $X(\cdot)$, sabemos que

$$X(t) = e^{Y(t)},$$

entonces

$$x_{n,kh}^+(x) \equiv e^{\beta h} e^{\sigma \sqrt{h}} x;$$

$$x_{n,kh}^-(x) \equiv e^{\beta h} e^{-\sigma \sqrt{h}} x.$$

Como

$$E(X(kh) | X((k-1)h) = x) = e^{\alpha h},$$

entonces la probabilidad $q_{n,kh}(x)$ es

$$q_{n,kh}(x) = \frac{e^{\alpha h} e^{-\beta h} - e^{-\sigma \sqrt{h}}}{e^{\sigma \sqrt{h}} - e^{-\sigma \sqrt{h}}} \cong \frac{1}{2} + \frac{(\alpha - \beta) \sqrt{h}}{2\sigma}.$$

Para garantizar que $q_{n,kh}(x)$ pertenece al intervalo $[0, 1]$, debe verificarse que

$$\alpha \in \left[\beta - \sigma/\sqrt{h}; \beta + \sigma/\sqrt{h} \right].$$

Proceso trinomial como aproximación al MGB Definamos un proceso con tres saltos como

$$x_{n,kh}(x) \equiv \begin{cases} u(h)x, & \text{con prob. } q_{n,kh}; \\ x, & \text{con prob. } 1 - q_{n,kh} - p_{n,kh}; \\ d(h)x, & \text{con prob. } p_{n,kh}. \end{cases}$$

donde $u(h)x$ es el valor del salto hacia arriba y $d(h)x$ es el valor del salto hacia abajo en el período kh . Los términos $u(h)$ y $d(h)$, para abreviar u

¹¹El resultado de este Corolario puede extenderse también al espacio $D[0, T]$.



y d respectivamente, no están especificados aún pero imponemos la condición que $ud = 1$. Nuestro objetivo es encontrar valores adecuados para las probabilidades de arriba y el parámetro u . Dos condiciones se imponen:

(1) La media de la distribución discreta:

$$uxq_{n,kh} + \frac{x}{u} p_{n,kh} + x(1 - q_{n,kh} - p_{n,kh}) \equiv M_{n,kh}x;$$

es igual a la media de la distribución continua lognormal, es decir

$$e^{\alpha h}x = M_{n,kh}x.$$

(2) La varianza de la distribución discreta:

$$u^2x^2q_{n,kh} + \frac{x^2}{u^2} p_{n,kh} + x^2(1 - q_{n,kh} - p_{n,kh}) - M_{n,kh}^2x^2 \equiv V_{n,kh}x^2;$$

es igual a la varianza de la distribución continua, es decir

$$e^{2\alpha h} (e^{\sigma^2 h} - 1) x^2 = V_{n,kh}x^2.$$

Para abreviar, escribimos $M_{n,kh}$ y $V_{n,kh}$ como M y V respectivamente. Expresiones explícitas¹² para $q_{n,kh}$ y $p_{n,kh}$ se obtienen de las ecuaciones anteriores:

$$q_{n,kh} = \frac{(V+M^2-M)u - (M-1)}{(u-1)(u^2-1)},$$

$$p_{n,kh} = \frac{u^2(V+M^2-M) - u^3(M-1)}{(u-1)(u^2-1)}.$$

Usamos la siguiente notación para las probabilidades de arriba:

$$q_{n,kh} = q(u, M, V),$$

$$p_{n,kh} = p(u, M, V).$$

Dado (38), el valor de u puede ser

$$u = e^{\sigma\sqrt{h}}.$$

¹²La notación y expresiones explícitas de las probabilidades pueden verse en Boyle (1988).



Si usamos este valor de u , podemos encontrar muchos valores de $1 - q_{n,kh} - p_{n,kh}$ que pueden ser negativos, ver Boyle¹³ (1988). Para evitar esto, Boyle define u como

$$u = e^{\lambda \sigma \sqrt{h}},$$

donde $\lambda > 1$.

1.8.3 Modelo de Heston

Sea el modelo de Heston (1993) bajo la medida neutral al riesgo como función de dos procesos de Wiener independientes, es decir

$$dS(t) = rS(t)dt + \sqrt{V(t)}S(t) \left[\sqrt{1 - \rho^2}dZ_s(t) + \rho dZ_v(t) \right]$$

$$dV(t) = k^*(\theta^* - V(t))dt + \sigma\sqrt{V(t)}dZ_v(t)$$

$$dZ_s(t)dZ_v(t) = 0.$$

Podemos expresar las difusiones de arriba en forma matricial como

$$dX(t) = f(t)dt + G(t)dZ(t) \quad (41)$$

donde

$$\begin{aligned} X(t) &= (S(t), V(t))' \\ f(t) &= (rS(t), k^*(\theta^* - V(t)))' \\ G(t) &= \begin{pmatrix} \sqrt{V(t)}S(t)\sqrt{1-\rho^2} & \sqrt{V(t)}S(t)\rho \\ 0 & \sigma\sqrt{V(t)} \end{pmatrix} \\ Z(t) &= (Z_s(t), Z_v(t))'. \end{aligned}$$

Los procesos S y V deben ser transformados para tener varianza constante con el fin de obtener una red (lattice) computacionalmente simple para valorar opciones con volatilidad estocástica. El vector de transformación, es decir $Y = (Y_1, Y_2)'$, se obtiene aplicando el lema de Ito¹⁴ sobre (41) :

$$dY = \left[Y_x f + \frac{1}{2} \text{tr}(GG'Y_{xx}) \right] dt + Y_x G dZ$$

¹³Para $\sigma = 0.2$, $\alpha = 0.1$, $T = 1$ y $n = 20$; se obtienen los siguientes valores: $u = 1.045736$, $q_{n,kh} = 0.553859$, $p_{n,kh} = 0.464581$ y $1 - q_{n,kh} - p_{n,kh} = -0.018440$.

¹⁴ Y es independientemente del tiempo, es decir; $Y_t = 0$.

donde Y_x y Y_{xx} representan la matriz de primera y segunda derivadas respectivamente sobre Y y $Y_x G$ verificándose la restricción que $Y_x G = I$. Por tanto

$$\begin{pmatrix} Y_{1s} & Y_{1v} \\ Y_{2s} & Y_{2v} \end{pmatrix} \begin{pmatrix} V^{1/2} S (1 - \rho^2)^{1/2} & V^{1/2} S \rho \\ 0 & \sigma V^{1/2} \end{pmatrix} = \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix}.$$

Resolviendo el sistema de arriba,

$$\begin{pmatrix} Y_{1s} & Y_{1v} \\ Y_{2s} & Y_{2v} \end{pmatrix} = \frac{1}{\sigma V S (1 - \rho^2)^{1/2}} \begin{pmatrix} \sigma V^{1/2} & -V^{1/2} S \rho \\ 0 & V^{1/2} S (1 - \rho^2)^{1/2} \end{pmatrix}.$$

Entonces, se verifica que

$$Y_2 = \frac{2}{\sigma} \sqrt{V}$$

y

$$\sigma Y_{1v} + \rho S Y_{1s} = 0.$$

Resolviendo la ecuación anterior en derivadas parciales, se obtiene:

$$Y_1 = S \exp \left(-\frac{\rho}{\sigma} V \right).$$

Finalmente,

$$\begin{aligned} dY_1 &= m_1 dt + dZ_s \\ dY_2 &= m_2 dt + dZ_v \end{aligned} \tag{42}$$

donde

$$m_1 = S \exp \left(-\frac{\rho}{\sigma} V \right) \left[r - \frac{\rho}{\sigma} k^* (\theta^* - V) - \frac{\rho^2}{2} V \right]$$

$$m_2 = \left[\frac{k^* (\theta^* - V)}{\sigma} - \frac{\sigma}{4} \right] V^{-1/2}.$$

Como en el modelo estándar univariante con volatilidad unitaria, los saltos del binomial para los procesos transformados Y_1 y Y_2 se definen como:

$$y_{1n,kh}(y_1) \equiv \begin{cases} y_1 + \sqrt{h}, & \text{con prob. } p_{n,kh} = \frac{1}{2} (1 + m_1 \sqrt{h}) \\ y_1 - \sqrt{h}, & \text{con prob. } 1 - p_{n,kh} \end{cases}$$



donde $y_{1n,(k-1)h} = y_1$ y

$$y_{2n,kh}(y_2) \equiv \begin{cases} y_2 + \sqrt{h}, & \text{con prob. } q_{n,kh} = \frac{1}{2} (1 + m_2 \sqrt{h}) \\ y_2 - \sqrt{h}, & \text{con prob. } 1 - q_{n,kh} \end{cases}$$

donde $y_{2n,(k-1)h} = y_2$. Esta red para variables transformadas puede aproximarse al tiempo continuo, es decir (42), de dos formas diferentes: usando las probabilidades de una distribución conjunta bivalente según la metodología de Hilliard y Schwartz (1996) o la aproximación trinomial del proceso bivalente con iguales estados probables, ver He (1990).

1.9 Modelos ARCH como aproximación a difusiones

Sea el siguiente proceso bivalente¹⁵:

$$dS(t)/S(t) = \mu dt + \sqrt{V(t)} dW_1(t) \quad (43)$$

$$dV(t) = \phi(\theta - V(t))dt + \xi V(t) dW_2(t) \quad (44)$$

$$dW_1(t) dW_2(t) = \rho dt \quad (45)$$

donde (43) representa el comportamiento del rendimiento instantáneo del stock que sigue un proceso browniano aritmético, mientras (44) representa el comportamiento de la volatilidad que sigue un proceso geométrico browniano con reversión a la media donde $\phi, \theta, \xi > 0$. Hay conexiones entre los modelos de la clase ARCH y el proceso de difusión (44). Nelson (1990) demuestra que una difusión de la forma de (44) resulta ser el límite de algunos modelos de la familia GARCH (1, 1) cuando el intervalo de tiempo se hace arbitrariamente pequeño, pues los primeros y segundos momentos del modelo de volatilidad de arriba convergen a los momentos teóricos de la difusión (44). Las discretizaciones de Euler correspondientes a las ecuaciones (43) y (44) con un intervalo muestral τ son:

$$r_t = \mu\tau + (V_t\tau)^{1/2} \varepsilon_{1t}, \quad (46)$$

$$V_t = \phi\theta\tau + (1 - \phi\tau) V_{t-\tau} + \sigma V_{t-\tau} \tau^{1/2} \varepsilon_{2t}, \quad (47)$$

¹⁵ Este proceso es modelo de Hull and White (1987) para valorar opciones.

donde $r_t \equiv (S(t) - S(t - \tau)) / S(t - \tau)$, $V_t \equiv V(t)$ y $\varepsilon_{1t}, \varepsilon_{2t}$ va's normales estandarizadas con coeficiente de correlación ρ .

Definamos h_t como la varianza condicional de r_t , es decir $h_t \equiv Var_{t-1}(r_t)$. Debido a la correlación entre rendimiento y volatilidad, varios modelos asimétricos de la familia GARCH(1,1); concretamente el modelo GJR(1,1)¹⁶ y el modelo no lineal asimétrico GARCH(1,1)¹⁷, NAGARCH(1,1), convergen a la difusión (44). Sea el siguiente proceso generador de datos en tiempo discreto:

$$r_t = \bar{r} + \eta_t = \bar{r} + h_t^{1/2} \zeta_t, \quad \zeta_t \sim iid N(0, 1). \quad (48)$$

Igualando los momentos condicionales de r_t en las ecuaciones (46) y (48) entonces $\bar{r} = \mu\tau$ y $h_t = V_t\tau$. La media y varianza condicional de la ecuación (47) son:

$$\begin{aligned} E_t(V_{t+\tau}) &= \phi\theta\tau + (1 - \phi\tau) V_t, \\ Var_t(V_{t+\tau}^2) &= \sigma^2\tau V_t^2. \end{aligned} \quad (49)$$

Mientras, la media, varianza y correlación condicionales de

(i) NAGARCH(1, 1) :

La varianza condicional h_t se define como

$$h_t = \omega + \beta h_{t-1} + \alpha \left(\eta_{t-1} + \gamma \sqrt{h_{t-1}} \right)^2$$

donde $\omega, \beta, \alpha > 0$. Obsérvese que el GARCH(1,1) está anidado en este modelo cuando $\gamma = 0$. Se verifica que

$$\begin{aligned} E_{t-1}(h_{t+1}) &= \omega + [\alpha(1 + \gamma^2) + \beta] h_t, \\ Var_{t-1}(h_{t+1}) &= 2\alpha^2(1 + 2\gamma^2) h_t^2, \\ Corr_{t-1}(r_t, h_{t+1}) &= \frac{\sqrt{2}\gamma}{\sqrt{1+2\gamma^2}}. \end{aligned} \quad (50)$$

(ii) GJR(1, 1) :

La varianza condicional h_t se define como

$$h_t = \omega + \beta h_{t-1} + (\alpha + \gamma D_{t-1}) \eta_{t-1}^2$$

¹⁶Ver Glosten et al (1993).

¹⁷Ver Engle y Ng (1993).



donde $\omega, \beta, \alpha > 0$ y D_t es una variable dummy definida como

$$D_t \equiv \begin{cases} 1; & \eta_t < 0 \\ 0; & \eta_t > 0. \end{cases}$$

Obsérvese que el GARCH(1,1) está también anidado en este modelo cuando $\gamma = 0$. Se verifica que¹⁸

$$\begin{aligned} E_{t-1}(h_{t+1}) &= \omega + (\alpha + \gamma/2 + \beta) h_t, \\ Var_{t-1}(h_{t+1}) &= (2\alpha^2 + 2\alpha\gamma + \frac{5}{4}\gamma^2) h_t^2, \\ Corr_{t-1}(r_t, h_{t+1}) &= -\gamma / \sqrt{(2\alpha^2 + 2\alpha\gamma + \frac{5}{4}\gamma^2) \frac{\pi}{2}}. \end{aligned} \quad (51)$$

Dado que $h_t = V_t \tau$, se igualan los momentos de la difusión, o sea (49), con (50) y (51). La relación entre los parámetros del continuo y el discreto son:

(i) NAGARCH(1,1) :

$$\phi = [1 - \alpha(1 + \gamma^2) - \beta] / \tau$$

$$\theta = \sigma^2 / \tau$$

$$\xi = \alpha \sqrt{2(1 + 2\gamma^2)} / \tau$$

$$\rho = \frac{\sqrt{2}\gamma}{\sqrt{1+2\gamma^2}}$$

donde σ^2 es la varianza incondicional de (48) cuando h_t es un proceso NAGARCH(1,1), es decir

$$\sigma^2 = \frac{\omega}{1 - \alpha(1 + \gamma^2) - \beta}.$$

¹⁸Ver Engle y Lee (p. 346-348) en Rossi (1996).



(ii) $GJR(1,1)$:

$$\phi = [1 - (\alpha + \beta + \gamma/2)]/\tau$$

$$\theta = \sigma^2/\tau$$

$$\xi = \sqrt{(2\alpha^2 + 2\alpha\gamma + \frac{5}{4}\gamma^2)}/\tau$$

$$\rho = -\gamma/\sqrt{(2\alpha^2 + 2\alpha\gamma + \frac{5}{4}\gamma^2)} \frac{\pi}{2}$$

donde σ^2 es la varianza incondicional de (48) cuando h_t es un proceso $GJR(1,1)$, es decir

$$\sigma^2 = \frac{\omega}{1 - (\beta + \alpha + \gamma/2)}.$$

Supongamos ahora que el proceso de volatilidad en lugar de ser la ecuación (44) es la difusión¹⁹

$$d \ln V(t) = -\beta (\ln V(t) - \omega) dt + \lambda dW_v(t) \quad (52)$$

que es un proceso OU con reversión a la media para $V(t)$. Se demuestra que el modelo EGARCH(1,1) de Nelson (1991), es decir

$$\ln h_t = \omega + \beta \ln h_{t-1} + \theta \zeta_{t-1} + \gamma (|\zeta_{t-1}| - \sqrt{2/\pi}),$$

converge débilmente a la ecuación (52). Se verifica que²⁰

$$\xi = (1 - 2/\pi) \gamma^2 + \theta^2.$$

2 Del tiempo continuo al discreto

2.1 Discretizaciones exactas

2.1.1 Movimiento browniano

Caso determinístico Sea la siguiente ecuación diferencial determinística de primer orden:

$$\frac{dx(t)}{dt} = \beta; \quad t \in [0, 1] \quad (53)$$

¹⁹Este proceso de volatilidad puede verse en Melino y Turnbull (1990) para valoración de opciones.

²⁰See Nelson (1990).



con condición inicial $x(0) = x_0$. Entonces, la solución de (53) es:

$$x(t) = x_0 + \beta t; \quad t \in [0, 1]. \quad (54)$$

Estamos interesados en extraer aquellos valores de la función (54) para el conjunto de datos

$$\{kh : k = 0, 1, \dots, n\}$$

donde $n = \left\lceil \frac{1}{h} \right\rceil$, i.e.

$$\{x(0), x(h), x(2h), \dots, x(nh)\}$$

Podemos definir una ecuación en diferencias determinística sobre el conjunto de puntos anteriores del siguiente modo:

$$x(t) = x(t-h) + \beta h; \quad t \in [h, 1].$$

Sea $x_{n,kh} \equiv x(kh)$ donde $k = 0, 1, \dots, n$. Podemos reescribir la ecuación anterior como

$$\Delta x_{n,kh} = \beta h; \quad k = 0, 1, \dots, n; \quad x_{n,0} = x_0. \quad (55)$$

Obsérvese que para $h = 1/n$ tenemos la ecuación (1).

Caso estocástico Sea la ecuación diferencial estocástica de primer orden

$$dX(t) = \beta dt + \sigma dW(t); \quad t \in [0, 1]$$

donde $W(\cdot)$ es el proceso de Wiener estándar y $\sigma > 0$. Entonces, la solución es

$$X(t) = \beta t + \sigma W(t); \quad t \in [0, 1]$$

con condición inicial $W(0) = 0$. La ecuación estocástica en diferencias de primer orden sobre el conjunto de puntos

$$\{X(0), X(h), X(2h), \dots, X(nh)\}$$

es

$$X(t) = \beta h + X(t-h) + \sigma \Delta_h W(t); \quad t \in [h, 1] \quad (56)$$

donde $\Delta_h W(t)$ se define como

$$\Delta_h W(t) \equiv W(t) - W(t-h).$$



Sea $X_{n,kh} \equiv X(kh)$ y $\xi_{n,kh} \equiv \Delta_h W(t)$, por tanto $\xi_{n,kh} \sim i.i.d. N(0, h)$; podemos reescribir la ecuación (56) como

$$\Delta X_{n,kh} = \beta h + \sigma \xi_{n,kh}; \quad k = 1, \dots, n; \quad X_{n,0} = 0.$$

A partir del proceso anterior, se obtiene

$$X_{n,kh} = \beta kh + \sigma \sum_{j=1}^k \xi_{n,jh}; \quad k = 1, \dots, n$$

entonces

$$X_{n,kh} \sim N(\beta kh; \sigma^2 kh).$$

2.1.2 Modelos CVAR

CAR(1)

Caso determinístico Sea la siguiente ecuación de primer orden diferencial determinística:

$$\frac{dx(t)}{dt} = \alpha x(t) + \beta; \quad x(0) = x_0; \quad t \in [0, 1]. \quad (57)$$

Mediante el Teorema 52, la solución de (57) es

$$x(t) = \left(x_0 + \frac{\beta}{\alpha}\right) \exp(\alpha t) - \frac{\beta}{\alpha}; \quad t \in [0, 1]. \quad (58)$$

Definiendo una ecuación determinística de primer orden en diferencias sobre el conjunto de puntos

$$\{x(0), x(h), x(2h), \dots, x(nh)\}$$

se obtiene

$$x(t) = e^{\alpha h} x(t-h) + (e^{\alpha h} - 1) \frac{\beta}{\alpha}; \quad t \in [h, 1].$$

Sea $x_{n,kh} \equiv x(kh)$ donde $k = 0, 1, \dots, n$. Podemos reescribir la ecuación de arriba como

$$x_{n,kh} = a_h x_{n,(k-1)h} + b_{n,kh}; \quad x_{n,0} = x_0; \quad 1 \leq k \leq n \quad (59)$$



donde

$$a_h \equiv e^{\alpha h};$$

$$b_{n,kh} \equiv (e^{\alpha h} - 1) \frac{\beta}{\alpha}.$$

La solución de (59) es:

$$x_{n,kh} = \left(x_0 + \frac{\beta}{\alpha} \right) \exp(\alpha kh) - \frac{\beta}{\alpha}; \quad k = 0, 1, 2, \dots, n. \quad (60)$$

Caso estocástico Sea la ecuación diferencial estocástica

$$dX(t) = \alpha X(t) dt + \sigma dW(t); \quad X(0) = x_0; \quad \alpha < 0; \quad t \in [0, 1] \quad (61)$$

donde x_0 es una constante. Según el Corolario (55), la solución de (61) es

$$X(t) = e^{\alpha t} x_0 + \sigma \int_0^t e^{\alpha(t-u)} dW(u). \quad (62)$$

Definiendo una ecuación diferencial estocástica de primer orden sobre

$$\{X(0), X(h), X(2h), \dots, X(nh)\}$$

obtenemos

$$X(t) = e^{\alpha h} X(t-h) + \sigma \int_{t-h}^t e^{\alpha(t-u)} dW(u); \quad t \in [h, 1].$$

Sea

$$X_{n,kh} \equiv X(kh); \quad k = 0, 1, \dots, n$$

$$a_h \equiv e^{\alpha h};$$

$$\gamma_{n,kh} \equiv \int_{(k-1)h}^{kh} e^{\alpha(kh-u)} dW(u).$$

Reescribiendo la ecuación de arriba como

$$X_{n,kh} = a_h X_{n,(k-1)h} + \sigma \gamma_{n,kh}; \quad X_{n,0} = x_0; \quad k = 0, 1, \dots, n \quad (63)$$

donde $\gamma_{n,kh} \sim i.i.d. N(0, (e^{2\alpha h} - 1)/2\alpha)$. Otra forma de escribir (63) es

$$X_{n,kh} = a_h X_{n,(k-1)h} + \sigma \sqrt{\frac{e^{2\alpha h} - 1}{2\alpha}} \xi_{n,kh}; \quad \xi_{n,kh} \sim i.i.d. N(0, 1).$$

A partir de (63) se obtiene

$$X_{n,kh} = a_h^k x_0 + \sigma \sum_{j=1}^k a_h^{k-j} \gamma_{n,jh}$$

entonces

$$X_{n,kh} \sim N\left(a_h^{\alpha h k} x_0; \sigma^2 \frac{e^{2\alpha h k} - 1}{2\alpha}\right).$$

CVAR(1) Sea el siguiente sistema de EDEs para el proceso $X(t)$ de dimensión d sobre el intervalo $[0, 1]$ definido como

$$dX(t) = (AX(t) + a)dt + b dW(t), \quad X(0) = x_0 \quad (64)$$

donde $W(t) = (W_1(t), \dots, W_m(t))'$ es un proceso de Wiener de dimensión m , A es una matriz de valores reales $(d \times d)$, a es un vector del espacio $\mathbb{R}^d$ y b es una matriz de valores reales $(d \times m)$ y $x_0 \in \mathbb{R}^d$. El proceso de arriba es un proceso multivariante Ornstein-Uhlenbeck o un proceso VAR(1), es decir CVAR(1). La solución de (64) es según el Corolario 55,

$$X(t) = e^{At} x_0 + \int_0^t e^{A(t-u)} a du + \int_0^t e^{A(t-u)} b dW(u), \quad t \in [0, 1]. \quad (65)$$

Sea el conjunto de puntos de la ecuación anterior

$$\{X(0), X(h), X(2h), \dots, X(nh)\},$$

podemos definir un sistema lineal de primer orden de ecuaciones diferenciales estocásticas:

$$X(t) = e^{Ah} X(t-h) + \int_{t-h}^t e^{A(t-u)} a du + \int_{t-h}^t e^{A(t-u)} b dW(u); \quad t \in [h, 1]. \quad (66)$$



Sea

$$X_{n,kh} \equiv X(kh); \quad k = 0, 1, \dots, n$$

$$F_h \equiv e^{Ah};$$

$$g_h \equiv \int_{(k-1)h}^{kh} e^{A(kh-u)} a du = (e^{Ah} - I) A^{-1} a;$$

$$\gamma_{n,kh} \equiv \int_{(k-1)h}^{kh} e^{A(kh-u)} b dW(u); \quad k = 1, 2, \dots, n;$$

donde

$$E(\gamma_{n,kh}) = 0;$$

$$\begin{aligned} E(\gamma_{n,kh} \gamma'_{n,kh}) &= \int_{(k-1)h}^{kh} e^{A(kh-u)} b b' e^{-A'(kh-u)} du \\ &= \int_0^h e^{uA} b b' e^{uA'} du \equiv \Omega_{0,h}; \end{aligned}$$

$$E(\gamma_{n,ih} \gamma'_{n,jh}) = 0; \quad \forall i \neq j, \quad i, j = 1, 2, \dots, n;$$

donde $E[dW(t) dW(t)'] = Idt$. Podemos expresar (66) como

$$X_{n,kh} = g_h + F_h X_{n,(k-1)h} + \gamma_{n,kh}; \quad X_{n,0} = x_0; \quad k = 0, 1, \dots, n.$$

Por tanto, tenemos un proceso VAR(1) discreto.

CAR(2) Sea la siguiente EDE:

$$\ddot{X}(t) = \alpha_1 \dot{X}(t) + \alpha_2 X(t) + \sigma \xi(t); \quad t \in [0, T].$$

Puede expresarse como

$$d[DX(t)] = \int_0^t [\alpha_1 DX(s) + \alpha_2 X(s)] ds + \sigma W(t).$$

Podemos expresar también el CAR(2), según (135), del siguiente modo:

$$\begin{bmatrix} \dot{X}(t) \\ X(t) \end{bmatrix} - \begin{bmatrix} \dot{X}(0) \\ X(0) \end{bmatrix} = \int_0^t \begin{bmatrix} \alpha_1 & \alpha_2 \\ 1 & 0 \end{bmatrix} \begin{bmatrix} \dot{X}(s) \\ X(s) \end{bmatrix} ds + \begin{bmatrix} \sigma & 0 \\ 0 & 0 \end{bmatrix} \begin{bmatrix} W(t) \\ 0 \end{bmatrix}, \quad (67)$$

podemos escribir (67) como

$$\dot{Y}(t) = a + AY(t) + bW(t) \quad (68)$$

donde

$$Y(t) = \int_0^t \begin{bmatrix} \dot{X}(s) \\ X(s) \end{bmatrix} ds; \quad a = \begin{bmatrix} \dot{X}(0) \\ X(0) \end{bmatrix};$$

$$A = \begin{bmatrix} \alpha_1 & \alpha_2 \\ 1 & 0 \end{bmatrix}; \quad W(t) = \begin{bmatrix} W(t) \\ 0 \end{bmatrix};$$

$$b = \begin{bmatrix} \sigma & 0 \\ 0 & 0 \end{bmatrix}.$$

La solución de (68) es

$$Y(t) = \int_0^t e^{A(t-s)} a ds + \int_0^t e^{A(t-s)} b dW(s).$$

Podemos escribir un sistema de primer orden en diferencias estocástico sobre el conjunto de puntos

$$\{Y(0), Y(h), Y(2h), \dots, Y(nh)\}$$

como

$$\begin{bmatrix} X(t) - X(0) \\ \int_0^t X(s) ds \end{bmatrix} = \begin{bmatrix} e^{\alpha_1 h} & e^{\alpha_2 h} \\ e^h & 1 \end{bmatrix} \begin{bmatrix} X(t-h) - X(0) \\ \int_0^{t-h} X(s) ds \end{bmatrix} + \begin{bmatrix} g_{1h} \\ g_{2h} \end{bmatrix}$$

$$+ \int_{t-h}^t \begin{bmatrix} e^{\alpha_1(t-u)} & e^{\alpha_2(t-u)} \\ e^{h(t-u)} & 1 \end{bmatrix} \begin{bmatrix} \sigma dW(u) \\ 0 \end{bmatrix}, \quad (69)$$

donde

$$\begin{bmatrix} g_{1h} \\ g_{2h} \end{bmatrix} = \begin{bmatrix} e^{\alpha_1 h} - 1 & e^{\alpha_2 h} \\ e^h & 0 \end{bmatrix} \begin{bmatrix} \alpha_1 & \alpha_2 \\ 1 & 0 \end{bmatrix}^{-1} \begin{bmatrix} \dot{X}(0) \\ X(0) \end{bmatrix}.$$



$\int_0^t X(s) ds$ se representa como $Z(t)$. Se obtienen las siguientes ecuaciones de (69) :

$$\Delta X(t) = e^{\alpha_1 h} \Delta X(t-h) + e^{\alpha_2 h} Z(t-h) + g_{1h} + \sigma \int_{t-h}^t e^{\alpha_1(t-u)} dW(u); \quad (70)$$

y

$$Z(t) = e^h \Delta X(t-h) + Z(t-h) + g_{2h} + \sigma \int_{t-h}^t e^{h(t-u)} dW(u). \quad (71)$$

A partir de la ecuación (71) se obtiene

$$Z(t-h) = e^h \Delta X(t-2h) + Z(t-2h) + g_{2h} + \sigma \int_{t-2h}^{t-h} e^{h(t-h-u)} dW(u); \quad (72)$$

y de la ecuación (70)

$$\begin{aligned} Z(t-h) &= e^{-\alpha_2 h} \Delta X(t) - e^{(\alpha_1 - \alpha_2)h} \Delta X(t-h) \\ &\quad - g_{1h} e^{-\alpha_2 h} - \sigma e^{-\alpha_2 h} \int_{t-h}^t e^{\alpha_1(t-u)} dW(u); \end{aligned} \quad (73)$$

y de la ecuación (73)

$$\begin{aligned} Z(t-2h) &= e^{-\alpha_2 h} \Delta X(t-h) - e^{(\alpha_1 - \alpha_2)h} \Delta X(t-2h) \\ &\quad - g_{1h} e^{-\alpha_2 h} - \sigma e^{-\alpha_2 h} \int_{t-2h}^{t-h} e^{\alpha_1(t-h-u)} dW(u). \end{aligned} \quad (74)$$

Sustituyendo de (73) y (74), para $Z(t-h)$, $Z(t-2h)$, respectivamente, en (72) y premultiplicando por $e^{\alpha_2 h}$ ambos lados

$$\begin{aligned} \Delta X(t) &= (1 + e^{\alpha_1 h}) \Delta X(t-h) + (e^{(\alpha_2 + 1)h} - e^{\alpha_1 h}) \Delta X(t-2h) \\ &\quad + \sigma \int_{t-h}^t e^{\alpha_1(t-u)} dW(u) + \sigma e^{\alpha_2 h} \int_{t-2h}^{t-h} e^{h(t-h-u)} dW(u) \\ &\quad - \sigma \int_{t-2h}^{t-h} e^{\alpha_1(t-h-u)} dW(u) + e^{\alpha_2 h} g_{2h}. \end{aligned}$$



Por simplicidad, asumamos que $X(0) = \dot{X}(0) = 0$; por tanto $g_h = 0$ y $\Delta X(t) = X(t)$. Entonces, podemos escribir la ecuación anterior como

$$X(t) = (1 + e^{\alpha_1 h}) X(t-h) + (e^{(\alpha_2+1)h} - e^{\alpha_1 h}) X(t-2h) + U_h(t)$$

donde

$$U_h(t) = \sigma \int_{t-h}^t e^{\alpha_1(t-u)} dW(u) + \sigma \int_{t-2h}^{t-h} (e^{h(t-h-u+\alpha_2)} - e^{\alpha_1(t-h-u)}) dW(u);$$

verificando que

$$E U_h(t) = 0;$$

$$Var U_h(t) = \sigma^2 \int_0^h e^{2\alpha_1(t-u)} du$$

$$+ \sigma^2 \int_0^h (e^{h(h-u+\alpha_2)} - e^{\alpha_1(h-u)})^2 du;$$

$$Cov(U_h(t) U_h(t-h)) = \sigma^2 \int_0^h (e^{h(t-h-u+\alpha_2)} - e^{\alpha_1(t-h-u)}) e^{\alpha_1(t-u)} du;$$

$$Cov(U_h(t) U_h(t-kh)) = 0; \quad k \neq 0, 1.$$

Sea

$$X_{n,kh} \equiv X(kh); \quad k = 0, 1, \dots, n$$

$$F_{1h} \equiv (1 + e^{\alpha_1 h});$$

$$F_{2h} \equiv (e^{(\alpha_2+1)h} - e^{\alpha_1 h})$$

$$\gamma_{n,kh} \equiv U_h(kh); \quad k = 1, 2, \dots, n;$$

entonces

$$X_{n,kh} = F_{1h} X_{n,(k-1)h} + F_{2h} X_{n,(k-2)h} + \gamma_{n,kh}; \quad X_{n,0} = 0; \quad k = 2, 3, \dots, n.$$

Por tanto, tenemos un proceso discreto $ARMA(2, 1)$. Siguiendo la misma metodología, la discretización exacta correspondiente a un proceso continuo $VAR(2)$, es decir $CVAR(2)$; es proceso $VARMA(2, 1)$ discreto²¹.

²¹Ver Bergstrom (1984), concretamente Teorema 9.



2.1.3 Aproximaciones en Tiempo Discreto

Sea la siguiente EDE²²

$$dX(t) = [a_1 + a_2 X(t)] dt + \sigma X(t)^\gamma dW(t), \quad t \in [0, T]. \quad (75)$$

Proponemos diferentes aproximaciones en tiempo discreto para la EDE anterior mediante la expansión de Ito-Taylor truncada (165) donde

$$u(t, x) = u(x) \equiv x;$$

$$f(t, x) = f(x) \equiv a_1 + a_2 x;$$

$$G(t, x) = G(x) \equiv \sigma x^\gamma.$$

Discretización de Euler La discretización de Euler se obtiene cuando el conjunto "hierarchical" es:

$$\mathcal{A}_1 = \{v, (0), (1)\}.$$

Aplicando la ecuación (165) a (75) obtenemos

$$\begin{aligned} X(t) &= X(\tau) + [a_1 + a_2 X(\tau)] I_{(0)} + \sigma X(\tau)^\gamma I_{(1)} \\ &= X(\tau) + [a_1 + a_2 X(\tau)] \int_{\tau}^t ds + \sigma X(\tau)^\gamma \int_{\tau}^t dW(s). \end{aligned}$$

Sea $\tau = t - h$, entonces

$$\begin{aligned} X(t) &= X(t-h) + [a_1 + a_2 X(t-h)] \int_{t-h}^t ds + \sigma X(t-h)^\gamma \int_{t-h}^t dW(s) \\ &= X(t-h) + [a_1 + a_2 X(t-h)] h + \sigma X(t-h)^\gamma \Delta_h W(t) \end{aligned} \quad (76)$$

²²Este proceso en tiempo continuo se utiliza para modelizar el comportamiento del tipo de interés a corto plazo. Imponiendo restricciones sobre los parámetros se obtiene los diferentes modelos de un factor que aparecen en la literatura, ver Tabla I de la pág. 1697 en Nowman (1997).

donde²³

$$\Delta_h W(t) \equiv \int_{t-h}^t dW(s) = W(t) - W(t-h).$$

Estamos interesados en los valores correspondientes al conjunto de datos

$$\{kh : k = 0, 1, \dots, n\}$$

donde $n = \left\lceil \frac{T}{h} \right\rceil$, o sea

$$\{X(0), X(h), X(2h), \dots, X(nh)\}.$$

Sea $X_{n,kh} \equiv X(kh)$ donde $k = 0, 1, \dots, n$. Podemos reescribir (76) como

$$X_{n,kh} = X_{n,(k-1)h} + h[a_1 + a_2 X_{n,(k-1)h}] + h^{1/2} \sigma X_{n,(k-1)h}^\gamma \xi_{n,kh}; \quad k = 1, 2, \dots, n$$

donde

$$\Delta_h W(kh) \equiv h^{1/2} \xi_{n,kh} \stackrel{i.i.d}{\sim} N(0, h); \quad k = 1, 2, \dots, n$$

por tanto,

$$\xi_{n,kh} \stackrel{i.i.d}{\sim} N(0, 1).$$

La aproximación de Milstein La aproximación de Milstein tiene como conjunto "hierarchical":

$$\mathcal{A}_2 = \mathcal{A}_1 \cup \{(1, 1)\},$$

entonces tenemos

$$\begin{aligned} X(t) &= X(\tau) + [a_1 + a_2 X(\tau)] I_{(0)} + \sigma X(\tau)^\gamma I_{(1)} + \sigma^2 \gamma X(\tau)^{2\gamma-1} I_{(1,1)} \\ &= X(\tau) + [a_1 + a_2 X(\tau)] \int_{\tau}^t ds + \sigma X(\tau)^{1/2} \int_{\tau}^t dW(s) \\ &\quad + \sigma^2 \gamma X(\tau)^{2\gamma-1} \int_{\tau}^t \int_{\tau}^s dW(z) dW(s). \end{aligned}$$

Sea $\tau = t - h$, entonces

$$\begin{aligned} X(t) &= X(t-h) + h \left[a_1 - \frac{\sigma^2}{2} \gamma X(t-h)^{2\gamma-1} + a_2 X(t-h) \right] \\ &\quad + \sigma X(t-h)^\gamma \Delta_h W(t) + \frac{\sigma^2}{2} \gamma X(t-h)^{2\gamma-1} \Delta_h W(t)^2. \end{aligned} \tag{77}$$

²³Sea $Y(t)$ un vector aleatorio, entonces $\Delta_h Y(t) = Y(t) - Y(t-h)$.



Para el mismo conjunto de datos y notación que en la aproximación anterior de Euler, tenemos

$$\begin{aligned} X_{n,kh} &= X_{n,(k-1)h} + h \left[a_1 - \frac{\sigma^2}{2} \gamma X_{n,(k-1)h}^{2\gamma-1} + a_2 X_{n,(k-1)h} \right] \\ &\quad + h^{1/2} \sigma X_{n,(k-1)h}^{1/2} \xi_{n,kh} + h \frac{\sigma^2}{2} \gamma X_{n,(k-1)h}^{2\gamma-1} \xi_{n,kh}^2; \end{aligned}$$

para $k = 1, 2, \dots, n$.

Aproximación de orden 1.5 strong Taylor Sea el conjunto "hierarchical" siguiente:

$$\mathcal{A}_3 = \mathcal{A}_2 \cup \{(0, 0), (1, 0), (0, 1), (1, 1, 1)\}$$

entonces podemos obtener la expansión truncada de Ito-Taylor²⁴ correspondiente al ejemplo (68) para $\tau = t - h$, es decir

$$\begin{aligned} X(t) &= X(t-h) + [a_1 + a_2 X(t-h)] I_{(0)} + \sigma X(t-h)^\gamma I_{(1)} \\ &\quad + \sigma^2 \gamma X(t-h)^{2\gamma-1} I_{(1,1)} + a_2 \sigma X(t-h)^\gamma I_{(1,0)} + a_2 (a_1 + a_2 X(t-h)) I_{(0,0)} \\ &\quad + \sigma \gamma X(t-h)^{\gamma-1} \left[a_1 + a_2 X(t-h) + \frac{\sigma^2}{2} (\gamma-1) X(t-h)^{2\gamma-1} \right] I_{(0,1)} \\ &\quad + \sigma^3 \gamma (2\gamma-1) X(t-h)^{3\gamma-2} I_{(1,1,1)}. \end{aligned}$$

Discretización de Nowman²⁵ Asumamos que la volatilidad de la ecuación (75) cambia al principio del período de unidad de observación y luego permanece constante. Por tanto, existe un cambio de la volatilidad en los puntos

$$\{kh : k = 0, 1, \dots, n\}$$

donde $n = \lceil \frac{T}{h} \rceil$ y permanece constante entre ellos. Entonces,

$$dX(t) = [a_1 + a_2 X(s)] ds + \sigma X((k-1)h)^\gamma dW(s) \quad (78)$$

donde $t \in [(k-1)h, kh]$. Obsérvese que esta ecuación tiene una volatilidad constante para un intervalo de tiempo dado y obsérvese que (78) es el

²⁴Ver Apéndice F para la obtención de las integrales de Ito múltiples.

²⁵Ver Nowman (1997).



proceso OU con reversión a la media²⁶. Por tanto, podemos obtener una discretización exacta²⁷ de (78) :

$$X(t) = e^{a_2(t-(k-1)h)} X((k-1)h) - \frac{a_1}{a_2} (1 - e^{a_2(t-(k-1)h)}) \\ + \sigma X((k-1)h)^\gamma \int_{(k-1)h}^t e^{a_2(t-s)} dW(s).$$

Cuando $t = kh$, obtenemos

$$X(kh) = e^{a_2h} X((k-1)h) - \frac{a_1}{a_2} (1 - e^{a_2h}) \\ + \sigma X((k-1)h)^\gamma \int_{(k-1)h}^{kh} e^{a_2(kh-s)} dW(s).$$

Podemos expresar la ecuación anterior como

$$X(kh) = e^{a_2h} X((k-1)h) + a(h) + \eta(kh); \quad k = 1, 2, \dots, n$$

tal que

$$a(h) = -\frac{a_1}{a_2} (1 - e^{a_2h});$$

$$\eta(kh) = \sigma X((k-1)h)^\gamma \int_{(k-1)h}^{kh} e^{a_2(kh-s)} dW(s);$$

donde

$$E[\eta(kh)\eta(sh)] = 0, \quad k \neq s$$

y

$$E[\eta^2(kh)] = \sigma^2 X((k-1)h)^{2\gamma} \frac{e^{2a_2h} - 1}{2a_2}.$$

²⁶Ver ecuación (128).

²⁷Ver ecuación (129), donde $\alpha = a_2$ y $\theta = -a_1/a_2$.

3 Referencias

Bergstrom, A.R. (1984): "Continuous time stochastic models and issues of aggregation over time", en *Handbook of Econometrics* vol.2, ed. by Z. Griliches y M.D. Intriligator, North Holland, Amsterdam.

Boyle, P.P. (1988): "A lattice framework for option pricing with two state variables", *Journal of Financial and Quantitative Analysis* 1, p. 1-12.

Engle, R. F. y V.K. Ng (1993): "Measuring and testing the impact of news on volatility", *Journal of Finance* 48, p. 1749-1778.

Geweke, J., Marshall, R.C. y G.A. Zarkin (1986): "Exact inference for continuous time markov chain models", *Review of Economic Studies* 53, p. 653-659.

Glosten, L.R., Jaganathan, R. y D.E. Runkle (1993): "On the relation between the expected value and the volatility of the nominal excess return on stocks", *Journal of Finance* 48, p. 1779-1801.

He, H. (1990): "Convergence from discrete to continuous-time contingent claim prices", *Review of Financial Studies* 4, p. 523-546.

Heston, S.L. (1993): "A closed-form solution for options with stochastic volatility, with applications to bond and currency options", *Review of Financial Studies* 6, p. 327-343.

Hilliard, J.E. y A. Schwartz (1996): "Binomial option pricing under stochastic volatility and correlated state variables", *Journal of Derivatives* (Fall), p. 23-39.

Hull, J. y A. White (1987): "The pricing of options on assets with stochastic volatilities", *Journal of Finance* 42, p. 281-300.

Melino, A. y S. Turnbull (1990): "Pricing foreign currency options with stochastic volatility", *Journal of Econometrics* 45, p.239-266.

Nabeya

Nelson, D.B. (1990): "ARCH models as diffusion approximations", *Journal of Econometrics* 45, p. 7-38.

Nelson, D.B. y K. Ramaswamy (1990): "Simple binomial processes as diffusion approximations in financial models", *Review of Financial Studies* 3, p. 393-430.

Nelson, D.B. (1991): "Conditional heteroskedasticity in asset returns: A new approach", *Econometrica* 59, p. 347-370.

Nowman, K.B. (1997): "Gaussian estimation of single factor continuous time models of the term structure of interest rates", *Journal of Finance* 4, p. 1695-1706.

Priestley, M.B. (1963): "The spectrum of a continuous process derived from a discrete process", *Biometrika*, 51, p. 517-520.

Priestley, M.B. (1981): *Spectral Analysis and Time Series Analysis*, Academic Press.

Rossi, P.E. (1996): *Modelling stock market volatility. Bridging the gap to continuous time*, Academic Press.

Singer, B. y S. Spilerman (1976): "The representation of social processes by Markov models", *American Journal of Sociology* 82, p. 1-54.

4 Capítulo 2: Las Matemáticas del Tiempo Continuo

1 Definiciones

Definition 1 Sea T un conjunto arbitrario no vacío de índices y (Ω, F, P) el espacio de probabilidad. Una familia $\{X(t); t \in T\}$ de variables aleatorias del espacio $\mathbb{R}^d$ definido sobre el mismo espacio de probabilidad se denomina proceso estocástico (función aleatoria) con el conjunto de parámetros (conjunto de índices) T y espacio de estados $\mathbb{R}^d$. Si T es contable, o sea $T = \{1, 2, \dots\}$ o $T = \{\dots, -1, 0, 1, \dots\}$, tenemos un proceso de parámetro discreto o un proceso en tiempo discreto. Si T es no contable, es decir un intervalo $[a, b]$, donde $a < b$, del eje real $\mathbb{R}$; entonces tenemos un proceso de parámetro continuo o proceso en tiempo continuo. Se admiten los casos donde $a = -\infty$ y $b = \infty$, entonces $[a, b]$ puede ser también $(-\infty, b]$, $[a, \infty)$, o $(-\infty, \infty)$.

Aunque el conjunto de índices T puede ser arbitrario, en esta sección y en las siguientes lo definimos como el tiempo. En definitiva, un proceso estocástico $X(\cdot) \equiv \{X(t); t \in T\}$ es una función de dos argumentos:

$$\{X(t, \omega); t \in T, \omega \in \Omega\}.$$

Para $t \in T$ fijo, $X(t, \cdot)$ es por tanto una variable aleatoria y para ω fijo, $X(\cdot, \omega)$ es una función del tiempo que se denomina función muestral (realización, trayectoria, senda) de el proceso estocástico.

Para $T = [0, 1]$, trabajamos con funciones muestrales definidas sobre los siguientes espacios de funciones reales:

- (i) $C = C[0, 1]$, es el espacio de funciones reales continuas sobre $[0, 1]$;
- (ii) $D = D[0, 1]$, es el espacio de funciones reales sobre $[0, 1]$ con discontinuidades como máximo de primera clase.

2 Algunos procesos estocásticos en tiempo continuo

2.1 Proceso de Poisson

Definition 2 Un proceso estocástico $\{N(t), t \in [0, 1]\}$ es un proceso con-



tador si $N(t)$ representa el número de acontecimientos ocurridos desde el período 0 hasta el período t . Un proceso contador verifica:

- (i) $N(t) \geq 0$;
- (ii) $N(t) \in \mathbb{Z}^+$, donde $\mathbb{Z}^+ = \{0, 1, 2, \dots\}$;
- (iii) If $s < t$, $N(t) - N(s)$ es el número de acontecimientos ocurridos en el intervalo de tiempo $[s, t]$.

Obsérvese que cualquier realización del proceso estocástico $\{N(t), t \in [0, 1]\}$ pertenece al espacio de funciones $D[0, 1]$. Un proceso contador tiene *incrementos independientes* si el número de acontecimientos que ocurren en intervalos de tiempo disjuntos son independientes. Por ejemplo, el número de acontecimientos ocurridos hasta el período t , $N(t)$, debe ser independiente respecto al número de acontecimientos ocurridos entre t y $t + h$, es decir $N(t + h) - N(t)$ donde $h > 0$.

Un proceso contador tiene *incrementos estacionarios independientes* si al trabajar con intrvalos de la forma $(t, t + h]$ donde $t \in [0, 1]$ y $h > 0$ entonces $E\{N(t + h) - N(t)\}$ y $Var\{N(t + h) - N(t)\}$ son constantes para un h dado. Se verifica también (por el supuesto de independencia) que $\forall t_1 \neq t_2$ tal que $t_1, t_2 \in [0, 1]$ y $(t_1, t_1 + h] \cap (t_2, t_2 + h] = \emptyset$ entonces la covarianza correspondiente a los dos intervalos de tiempo es cero, o sea

$$Cov\{N(t_1 + h) - N(t_1), N(t_2 + h) - N(t_2)\} = 0.$$

Definition 3 Un proceso contador $\{N(t), t \in [0, 1]\}$ es un proceso Poisson de parámetro λ , $\lambda > 0$, si:

- (i) $N(0) = 0$;
- (ii) El proceso tiene incrementos independientes;
- (iii) El número de acontecimientos en un intervalo de amplitud h sigue una distribución de Poisson con media λh , o sea; $\forall t, h$ donde $h > 0$

$$P\{N(t + h) - N(t) = k\} = \frac{(\lambda h)^k}{k!} e^{-\lambda h}, \quad k = 0, 1, 2, \dots$$

De la condición (iii), un proceso de Poisson tiene incrementos estacionarios independientes si tomamos intervalos de amplitud h , o sea $(t, t + h]$, donde $t \in [0, 1]$

$$E\{N(t + h) - N(t)\} = \lambda h; \quad Var\{N(t + h) - N(t)\} = \lambda h.$$

Otra definición del proceso de Poisson es la siguiente:

Definition 4 Un proceso contador $\{N(t), t \in [0, 1]\}$ es un proceso Poisson de parámetro λ , $\lambda > 0$, y $(t, t+h]$ un intervalo de amplitud h , $h > 0$, si:

(i) $N(0) = 0$;

(ii) El proceso tiene incrementos independientes estacionarios;

(iii) $P\{0 \text{ acontec. en } (t, t+h]\} = 1 - \lambda h + o(h)^{28}$;

(iv) $P\{1 \text{ acontec. en } (t, t+h]\} = \lambda h + o(h)$;

(v) $P\{2 \text{ o más acontec. en } (t, t+h]\} = o(h)$.

Theorem 5 Las Definiciones 3 y 4 son equivalentes.

2.2 Proceso de Poisson Compuesto

Definition 6 Un proceso estocástico $\{X(t), t \in [0, 1]\}$ es un proceso de Poisson compuesto si puede representarse para $t \in [0, 1]$ mediante:

$$X(t) = \begin{cases} \sum_{k=1}^{N(t)} \xi_k; & t \in (0, 1] \\ 0; & t = 0. \end{cases}$$

donde $\{N(t), t \in [0, 1]\}$ es un proceso de Poisson, $N(t)$ es el número de acontecimientos en $(0, t]$. $\{\xi_k, k \geq 1\}$ es una sucesión de variables aleatorias i.i.d. tal que $E(\xi_k^2) < \infty$. Se verifica que $\{N(t), t \in [0, 1]\}$ y $\{\xi_k, k \geq 1\}$ son independientes.

Theorem 7 Un proceso de Poisson compuesto $\{X(t), t \in [0, 1]\}$ tiene incrementos estacionarios independientes y la siguiente función característica:

$$\emptyset_{X(t)}(s) = \exp(\lambda t (\emptyset_{\xi_k}(s) - 1)), \quad \forall t \in (0, 1]. \quad (79)$$

²⁸i.e. $\frac{o(h)}{h} \rightarrow 0$ as $h \rightarrow 0$.

Proof. (i) $\{X(t), t \in [0, 1]\}$ tiene (79) como función característica.

$$\begin{aligned}
 \phi_{X(t)}(s) &= E(\exp(isX(t))) = E\left(\exp\left(is \sum_{k=1}^{N(t)} \xi_k\right)\right) \\
 &= E\left(E\left(\exp\left(is \sum_{k=1}^{N(t)} \xi_k\right) \mid N(t)\right)\right) = E\left(E(\exp(is\xi_k))^{N(t)}\right) \\
 &= E\left(\phi_{\xi_k}(s)^{N(t)}\right) = \sum_{j=0}^{\infty} \phi_{\xi_k}(s)^j P(N(t) = j) \\
 &= \sum_{j=0}^{\infty} \phi_{\xi_k}(s)^j \frac{(\lambda t)^j e^{-\lambda t}}{j!} = e^{-\lambda t} \sum_{j=0}^{\infty} \frac{(\lambda t \phi_{\xi_k}(s))^j}{j!} \\
 &= \exp(-\lambda t) \exp(\lambda t \phi_{\xi_k}(s)) = \exp(\lambda t (\phi_{\xi_k}(s) - 1)).
 \end{aligned}$$

(ii) $\{\xi_k, k \geq 1\}$ tiene incrementos estacionarios independientes.

Como $\{N(t), t \in [0, 1]\}$ tiene incrementos independientes y $\{\xi_k, k \geq 1\}$ son independientes, intuitivamente es evidente que $\{X(t), t \in [0, 1]\}$ tiene incrementos independientes (no damos una demostración formal). Para demostrar que el proceso tiene incrementos estacionarios, en primer lugar obtenemos los momentos de primer y segundo orden de $X(t)$ usando la función característica; es decir

$$\phi_{X(t)}^{(1)}(0) = i\lambda t E(\xi_k) = iE(X(t));$$

$$\phi_{X(t)}^{(2)}(0) = i^2 \lambda t (E(\xi_k^2) + \lambda t E(\xi_k)^2) = i^2 E(X^2(t)).$$

Entonces,

$$E(X(t)) = \lambda t E(\xi_k);$$

$$\text{Var}(X(t)) = \lambda t E(\xi_k^2).$$

Supongamos que $s < t$, entonces

$$\begin{aligned}
 \text{Cov}(X(s), X(t)) &= \text{Cov}\{X(s), (X(t) - X(s)) + X(s)\} \\
 &= \text{Var}(X(s)) = \lambda s E(\xi_k^2) = \lambda \min(s, t) E(\xi_k^2).
 \end{aligned}$$

Finalmente, demostramos que $X(t)$ tiene incrementos estacionarios. Sea

$$\Delta_h X(t) = X(t+h) - X(t),$$



entonces para un valor dado de h ($h > 0$) :

$$E(\Delta_h X(t)) = \lambda h E(\xi_k);$$

$$Var(\Delta_h X(t)) = \lambda h E(\xi_k^2).$$

Se observa que la esperanza y varianza son constantes para un valor dado de h .

■

2.3 Movimiento browniano estándar

Definition 8 Sea (Ω, F, P) un espacio de probabilidad y $T = [0, 1]$ el conjunto índice. Un proceso estocástico $\{W(t); t \in [0, 1]\}$ es un movimiento browniano estándar (o un proceso de Wiener estándar) sobre (Ω, F, P) si verifica las siguientes condiciones:

- (i) $W(t) \sim N(0, t)$, donde $t \in (0, 1]$;
- (ii) Para cualquier $0 \leq t_0 \leq t_1 \leq \dots \leq t_k \leq 1$, las variables aleatorias $W(t_0)$ y $W(t_i) - W(t_{i-1})$, $1 \leq i \leq k$ son independientes;
- (iii) $P(W(0) = 0) = 1$.

2.4 Proceso de Markov

Definition 9 Sea t_i y t los elementos del conjunto índice T tal que $t_1 < t_2 < \dots < t_k < t$. Un proceso estocástico $\{X(t), t \in T\}$ se define como proceso de Markov si

$$P\{X(t) \leq x \mid X(t_1), X(t_2), \dots, X(t_k)\} = P\{X(t) \leq x \mid X(t_k)\}. \quad (80)$$

Si un proceso estocástico verifica la propiedad de Markov property, o sea la condición (80), entonces la distribución de probabilidad para todos los valores futuros del proceso depende sólo de su valor actual, por tanto no está afectado por los valores pasados del proceso. Nótese que los procesos de Poisson y Wiener verifican la propiedad de Markov.



3 Cálculo en media cuadrática

3.1 Continuidad

El concepto de continuidad en el caso de funciones ordinarias es:

Definition 10 Sea f una función de valores reales, entonces f es continua en el punto $t_0 \in \mathbb{R}$ si:

$$\forall \varepsilon > 0 \quad \exists \delta_\varepsilon > 0 / |t - t_0| < \delta_\varepsilon \quad |f(t) - f(t_0)| < \varepsilon.$$

Se representa como

$$\lim_{t \rightarrow t_0} f(t) = f(t_0).$$

En el caso de procesos en tiempo continuo existen cuatro conceptos de límite, implicando que existen cuatro clases de continuidad estocástica. La continuidad más fuerte correspondería a la convergencia segura de las funciones muestrales:

Definition 11 Un proceso en tiempo continuo es continuo en funciones muestrales en $t_0 \in T$ si

$$\lim_{t \rightarrow t_0} X(t, \omega) = X(t_0, \omega) \quad \forall \omega \in \Omega,$$

o sea

$$\forall \omega \in \Omega \quad \forall \varepsilon > 0 \quad \exists \delta_\varepsilon > 0 / |t - t_0| < \delta_\varepsilon \quad |X(t, \omega) - X(t_0, \omega)| < \varepsilon.$$

Definition 12 Un proceso en tiempo continuo es continuo casi seguro en $t_0 \in T$ si

$$P\left(\lim_{t \rightarrow t_0} X(t) = X(t_0)\right) = 1$$

o sea

$$P(\omega \in \Omega : \forall \varepsilon > 0 \quad \exists \delta_\varepsilon > 0 / |t - t_0| < \delta_\varepsilon \quad |X(t, \omega) - X(t_0, \omega)| < \varepsilon) = 1.$$

Asociado al concepto de límite en probabilidad, podemos estudiar el concepto de límite en probabilidad.

Un proceso en tiempo continuo es continuo en probabilidad en $t_0 \in T$ si

$$\lim_{t \rightarrow t_0} P(|X(t) - X(t_0)| < \varepsilon) = 1$$



Universitat d'Alacant
Universidad de Alicante

o sea

$$\lim_{t \rightarrow t_0} P(\omega \in \Omega : X(t, \omega) \in]X(t_0, \omega) - \varepsilon, X(t_0, \omega) + \varepsilon[) = 1.$$

El concepto más útil y tratable de continuidad resulta ser la definición basada en la media cuadrática. Este es el concepto que utilizaremos casi de forma exclusiva. Para las siguientes definiciones, trabajaremos con procesos estocásticos de segundo orden, es decir

Definition 13 *Un proceso estocástico $\{X(t); t \in T\}$ se dice que es de segundo orden si $EX^2(t) < \infty \quad \forall t \in T$.*

Para estos procesos la función media

$$m_X(t) = EX(t)$$

y la función de covarianza

$$K_X(s, t) = E\{(X(s) - m_X(s))(X(t) - m_X(t))'\}$$

existen.

Definition 14 *Un proceso en tiempo continuo de segundo orden $\{X(t); t \in T\}$ se dice que es continuo en media cuadrática en $t_0 \in T$ si*

$$\lim_{t \rightarrow t_0} E|X(t) - X(t_0)|^2 = 0.$$

Theorem 15 *Un proceso en tiempo continuo de segundo orden $\{X(t); t \in T\}$ se dice que es continuo en media cuadrática en $t_0 \in T$ si y solo si la función media $m_X(t)$ es continua en $t = t_0$ y la función covarianza $K_X(s, t)$ es continua en $(s, t) = (t_0, t_0)$ donde $s, t \in T$.*

3.2 Derivabilidad

Definition 16 *Un proceso en tiempo continuo de segundo orden $\{X(t); t \in T\}$ tiene una derivada en media cuadrática en $t_0 \in T$ si existe una variable aleatoria $X'(t_0)$ con $E(X'(t_0))^2 < \infty$ tal que el límite*

$$\lim_{h \rightarrow 0} \frac{X(t_0 + h) - X(t_0)}{h} = X'(t_0)$$



existe en el sentido de convergencia en media cuadrática, o sea

$$\lim_{h \rightarrow 0} E \left| \frac{X(t_0 + h) - X(t_0)}{h} \right|^2$$

existe.

Supongamos un proceso en tiempo continuo de segundo orden que es estacionario en media y covarianza, donde asumimos que $m_X(t) = 0$ y $K_X(t, t) = \sigma_X^2$; entonces

$$E \left[\frac{X(t_0 + h) - X(t_0)}{h} \right]^2 = \frac{2\sigma_X^2}{h^2} (1 - \rho(h))$$

donde $\rho(h)$ es la función de autocorrelación, o sea

$$\rho(h) = E[X(t)X(t+h)]/\sigma_X^2. \quad (81)$$

Por tanto, para que $X(t)$ sea diferenciable estocásticamente en t_0 debe verificarse que

$$\lim_{h \rightarrow 0} \frac{2\sigma_X^2}{h^2} (1 - \rho(h))$$

exista, esto requiere como mínimo que $\rho'(0)$ exista y sea cero. Si $X'(t)$ existe, diferenciando la ecuación (81) respecto a h , obtenemos

$$\sigma_X^2 \rho'(h) = E[X(t)X'(t+h)]. \quad (82)$$

Debido a la estacionariedad, podemos reemplazar t por $(t-h)$, obteniendo

$$\sigma_X^2 \rho'(h) = E[X(t-h)X'(t)].$$

Diferenciando nuevamente respecto a h ,

$$\sigma_X^2 \rho''(h) = -E[X'(t-h)X'(t)].$$

Por tanto, $\{-\sigma_X^2 \rho''(h)\}$ es la función de autocovarianza de $X'(t)$ y como

$$\text{Var} X'(t) = -\sigma_X^2 \rho''(0),$$

entonces la función de autocorrelación de $X'(t)$ es $\rho''(h)/\rho''(0)$. Para $h = 0$ en (82),

$$E[X(t)X'(t)] = \sigma_X^2 \rho'(0) = 0.$$

Theorem 17 *Un proceso en tiempo continuo de segundo orden $\{X(t); t \in T\}$ tiene una derivada en media cuadrática en $t_0 \in T$ si y solo si $\frac{\partial m_X(t)}{\partial t}$ existe en $t = t_0$ y $\frac{\partial^2 K_X(s,t)}{\partial s \partial t}$ existe en $(s,t) = (t_0, t_0)$.*

Theorem 18 *Si un proceso en tiempo continuo de segundo orden $\{X(t); t \in T\}$ con $m_X(t)$ y $K_X(s,t)$ tiene una derivada en media cuadrática $X'(t)$, entonces las funciones de media y covarianza de $X'(t)$ están expresadas por*

$$m_{X'}(t) = \frac{dm_X(t)}{dt}$$

y

$$K_{X'}(s,t) = \frac{\partial^2 K_X(s,t)}{\partial s \partial t}.$$

3.3 Integral de Riemann estocástica

Definimos la integral del proceso en tiempo continuo de segundo orden teniendo en cuenta la suma S_n para funciones ordinarias procedentes de la expresión (184), donde $\alpha(t) = t \quad \forall t \in [a, b]$.

Definition 19 *Sea $\{X(t); t \in T\}$ un proceso en tiempo continuo de segundo orden. Sea P una partición de $[a, b] \subset T$. Consideremos la suma*

$$S_n = \sum_{i=1}^n X(\tau_{i,n})(t_{i,n} - t_{i-1,n});$$

donde para cada $n \in \mathbb{N}$ tenemos una partición diferente de $[a, b]$, o sea $t_{0,n} = a < t_{1,n} < t_{2,n} < \dots < t_{n,n} = b$ son los elementos correspondientes de la partición $P_n \in [a, b]$; mientras $\tau_{i,n} \in [t_{i-1,n}, t_{i,n}] \quad i = 1, 2, \dots, n$. Decimos que la integral estocástica de Riemann de $\{X(t); t \in T\}$ sobre $[a, b]$ existe en media cuadrática y con valor I_R si

$$\lim_{n \rightarrow \infty} E |S_n - I_R|^2 = 0;$$

tal que

$$\max_{1 \leq i \leq n} |t_{i-1,n} - t_{i,n}| \rightarrow 0 \quad \text{as } n \rightarrow \infty \quad \text{and} \quad \forall \tau_{i,n} \quad i = 1, 2, \dots, n.$$

Se representa como

$$I_R = \int_a^b X(t) dt.$$

Theorem 20 Sea $\{X(t); t \in T\}$ un proceso en tiempo continuo de segundo orden con $m_X(t)$ y $K_X(s, t)$. El proceso integrable de Riemann estocástico sii las integrales

$$\int_a^b m_X(t) dt$$

y

$$\int_a^b \int_a^b K_X(s, t) ds dt$$

existen.

4 Análisis del movimiento browniano estándar

En esta sección estudiamos la función de covarianza, continuidad en media cuadrática, derivada en media (cuadrática) e integrabilidad en media cuadrática para el movimiento browniano estándar (MBS), o sea $W(\cdot) \equiv \{W(t); t \in [0, 1]\}$.

4.1 Función de covarianza

Sea $0 < s \leq t \leq 1$, entonces

$$\begin{aligned} K_W(s, t) &= \text{Cov}(W(s), W(t)) = \text{Cov}(W(s), W(s) + W(t) - W(s)) = \\ &= \text{Cov}(W(s), W(s)) + \text{Cov}(W(s), W(t) - W(s)) = s = \min(s, t). \end{aligned}$$

4.2 Continuidad en media cuadrática

Proposition 21 El MBS es continuo en media cuadrática $\forall t_0 \in [0, 1]$.

Proof. Aplicando la definición 10 tenemos:

$$E(W(t) - W(t_0))^2 = t + t_0 - 2 \min(t, t_0)$$

entonces

$$\lim_{t \rightarrow t_0} E(W(t) - W(t_0))^2 = \lim_{t \rightarrow t_0} \{t + t_0 - 2 \min(t, t_0)\} = 0.$$

Obsérvese que la función de covarianza del MBS es $K_W(s, t) = \min(s, t)$. Como esta función es continua en (t_0, t_0) , entonces aplicando el Teorema 15 se obtiene la continuidad en media cuadrática del MBS $\forall t_0 \in [0, 1]$.

■

4.3 Derivada en media cuadrática (generalizada)

Proposition 22 *El MBS no tiene derivada en media cuadrática $\forall t_0 \in [0, 1]$.*

Proof. *Aplicando el Teorema 17,*

$$\begin{aligned} \frac{\partial K_W(s, t)}{\partial t} &= \frac{\partial}{\partial t} \begin{cases} s, & s < t \\ t, & s > t \end{cases} \\ &= \begin{cases} 0, & s < t \\ 1, & s > t \end{cases} \end{aligned}$$

que implica que la segunda derivada mixta no existe. Por tanto, MBS no es derivable.

■

Sin embargo, MBS tiene una derivada en media cuadrática generalizada²⁹ $\forall t_0 \in [0, 1]$.

$$\begin{aligned} \frac{\partial^2 K_W(s, t)}{\partial s \partial t} &= \frac{\partial}{\partial s} \begin{cases} 0, & s < t \\ 1, & s > t, \end{cases} \\ &= \frac{\partial}{\partial s} u(s - t) \\ &= \delta(s - t). \end{aligned} \tag{83}$$

donde $u(s - t)$ es la función unitaria step y $\delta(s - t)$ es la función δ -Dirac.

²⁹Para la comprensión de la derivada en media cuadrática generalizada, ver la función delta (δ) de Dirac en la Sección del Apéndice 13.4.



4.4 Ruido blanco en tiempo continuo y movimiento browniano estándar

Sea $\xi(\cdot) \equiv \{\xi(t); t \in [0, 1]\}$ un *proceso ruido blanco en tiempo continuo*. Asumiendo (igual que en el caso discreto) que

$$E\xi(t) = 0; \quad \text{Var}\xi(t) = \sigma_\xi^2 \quad \forall t.$$

La función de covarianza tiene la forma

$$K_\xi(s, t) = \begin{cases} \sigma_\xi^2; & s = t \\ 0; & s \neq t. \end{cases}$$

Sea un proceso en tiempo continuo $X(\cdot)$ definido como

$$X(t) = \int_0^t \xi(s) ds; \quad t \in [0, 1].$$

Entonces

$$EX(t) = 0, \quad \forall t$$

$$\begin{aligned} \text{Var}X(t) &= \int_0^t \int_0^t \text{Cov}(\xi(u), \xi(v)) dudv = \\ &= \int_0^t \int_0^t I(u - v) dudv \end{aligned}$$

donde

$$I(u - v) = \begin{cases} \sigma_\xi^2; & u = v \\ 0; & u \neq v. \end{cases}$$

Si σ_ξ^2 es finito entonces $\text{Var}X(t) = 0$, por tanto no tenemos un proceso en tiempo continuo. La única forma de obtener un proceso en tiempo continuo es permitir que σ_ξ^2 sea infinito. Entonces $I(u - v)$ es la función delta de Dirac, por tanto $\text{Var}X(t) = t$. En definitiva, la función de covarianza del proceso de ruido blanco en tiempo continuo es

$$K_\xi(s, t) = \delta(s - t). \quad (84)$$

Obsérvese que por el Teorema 18, (83), (84) la derivada en media cuadrática generalizada del proceso *MBS* es el ruido blanco en tiempo continuo. Por tanto,



Universitat d'Alacant
Universidad de Alicante

$$\dot{W}(t) = \xi(t)$$

entonces

$$W(t) = \int_0^t \xi(s) ds,$$

esta expresión se conoce también como un proceso $MA(t)$ de parámetro continuo³⁰.

4.5 Integrabilidad en media cuadrática

Proposition 23 *El MBS es integrable de Riemann estocástico $\forall [0, t] \subset [0, 1]$.*

Proof. $Z(\cdot)$ representa el proceso estocástico $\{Z(t); t \in [0, 1]\}$ donde $Z(t)$ se define como

$$Z(t) = \int_0^t W(s) ds.$$

Aplicando el Teorema 20, tenemos que demostrar que

$$E(Z(t)) \quad \text{and} \quad \text{Cov}(Z(s), Z(t)) \quad s, t \in [0, 1]$$

existe. Entonces

$$E(Z(t)) = \int_0^t E(W(s)) ds = 0.$$

Supongamos que $s \leq t$, entonces

$$\begin{aligned} \text{Cov}(Z(s), Z(t)) &= E(Z(s)Z(t)) = E\left\{\left(\int_0^s W(u) du\right) \times \left(\int_0^t W(y) dy\right)\right\} = \\ &= \int_0^s \int_0^t \text{Cov}(W(u), W(y)) dy du = \int_0^s \left[\int_0^t \min(u, y) dy\right] du = \\ &= \int_0^s \left[\int_0^u y dy + \int_u^t u dy\right] du = \int_0^s \left(\frac{u^2}{2} + ut - u^2\right) du = \\ &= \int_0^s \left(ut - \frac{u^2}{2}\right) du = \left[\frac{u^2 t}{2} - \frac{u^3}{6}\right]_0^s = s^2 \left(\frac{t}{2} - \frac{s}{6}\right). \end{aligned}$$

³⁰Ver Capítulo 3 en Priestley (1984).

En definitiva, como $E(Z(t))$ y $Cov(Z(s), Z(t))$ existen entonces $W(\cdot)$ es integrable de Riemann estocástico.

■

5 Convergencia de procesos en tiempo continuo

Trabajaremos con funciones aleatorias cuyas funciones muestrales pertenezcan a la clase de funciones $C[0, 1]$ con métrica la norma del "supremo"³¹.

Theorem 24 Sean $\{X_n(\cdot); n \geq 1\}$ y $X(\cdot)$ funciones aleatorias de C . Entonces $X_n(\cdot)$ converge débilmente a $X(\cdot)$, representado por $X_n(\cdot) \Rightarrow X(\cdot)$, si y solo si

(i) Para cualquier colección finita de k puntos,

$$0 \leq t_1 < t_2 < \dots < t_k \leq 1,$$

la sucesión de vectores aleatorios de dimensión k $\{Y_n; n \geq 1\}$ converge en distribución al vector aleatorio Y , o sea $Y_n \xrightarrow{d} Y$; donde

$$Y_n \equiv (X_n(t_1), X_n(t_2), \dots, X_n(t_k))'; \quad Y \equiv (X(t_1), X(t_2), \dots, X(t_k))';$$

(ii) $X_n(\cdot)$ es "tight"³².

La convergencia en distribución de variables aleatorias es invariante bajo transformaciones continuas. Podemos extender esta propiedad a la convergencia débil de funciones aleatorias:

Theorem 25 (teorema del mapping continuo) Sea $\{X_n(\cdot); n \geq 1\}$ y $X(\cdot)$ funciones aleatorias de C tal que $X_n(\cdot) \Rightarrow X(\cdot)$ y $g(\cdot)$ es un funcional continuo³³, entonces

$$g(X_n(\cdot)) \Rightarrow g(X(\cdot)).$$

Será útil extender la definición de convergencia en probabilidad de sucesiones de variables aleatorias al caso de sucesiones de funciones aleatorias.

³¹Ver Definición 183 en la Sección 13.1.1 del Apéndice.

³²Tightness se refiere a la idea de acotado estocásticamente en variables aleatorias pero en funciones aleatorias de C .

³³Un funcional va de una función de $C[0, 1]$ a otra función de $C[0, 1]$ o un escalar.

Definition 26 Sean $\{X_n(\cdot); n \geq 1\}$ y $\{Y_n(\cdot); n \geq 1\}$ sucesiones de funciones aleatorias de C . Sea Z_n una variable aleatoria donde

$$Z_n = \sup_{0 \leq t \leq 1} |X_n(t) - Y_n(t)|;$$

por tanto, $\{Z_n; n \geq 1\}$ es una sucesión de variables aleatorias. Si se verifica que $\text{plim } Z_n = 0$, entonces decimos que $\{X_n(\cdot); n \geq 1\}$ converge en probabilidad a $\{Y_n(\cdot); n \geq 1\}$, o sea $\text{plim } X_n(\cdot) = Y_n(\cdot)$.

Theorem 27 Sean $\{X_n(\cdot); n \geq 1\}$ y $\{Y_n(\cdot); n \geq 1\}$ sucesiones de funciones aleatorias en C tal que $\text{plim } X_n(\cdot) = Y_n(\cdot)$ y $Y_n(\cdot) \Rightarrow Y(\cdot)$ entonces $X_n(\cdot) \Rightarrow Y(\cdot)$.

6 El teorema funcional central del límite

El TCL se ocupa de la convergencia en distribución de sumas normalizadas de variables aleatorias. Esta sección tiene como objetivo formular un TCL para procesos estocásticos. Trabajamos con el conjunto índice $T = [0, 1]$ y nuestro TCL construido con funciones aleatorias normalizadas de $C[0, 1]$.

Theorem 28 Sea $\{X_n(\cdot); n \geq 1\}$ una sucesión de funciones aleatorias del espacio $C[0, 1]$, donde cualquier realización de $X_n(\cdot)$ se define con la expresión (188); entonces $X_n(\cdot)$ converge débilmente al proceso MBS, es decir $X_n(\cdot) \Rightarrow W(\cdot)$.

Proof. Usamos el Teorema 24 para la demostración. Probamos únicamente la sección (i)³⁴ de este teorema, es decir

Para cualquier colección finita de k puntos,

$$0 \leq t_1 < t_2 < \dots < t_k \leq 1,$$

la sucesión de vectores aleatorios de dimensión k $\{\mathbf{Y}_n; n \geq 1\}$ converge en distribución al vector aleatorio $\mathbf{Y}$, o sea $\mathbf{Y}_n \xrightarrow{d} \mathbf{Y}$; donde

$$\mathbf{Y}_n \equiv (X_n(t_1), X_n(t_2), \dots, X_n(t_k))'; \quad \mathbf{Y} \equiv (X(t_1), X(t_2), \dots, X(t_k))'.$$

(i.1) Empecemos con un vector aleatorio de dimensión $k = 1$. Por tanto, tenemos que demostrar que $\mathbf{X}_n(t) \sim W(t)$ cuando $t \in (0, 1]$. Usamos el

³⁴Con respecto a la demostración de la sección (ii), o sea, tightness de $X(\cdot)$, ver Billingsley (1968).



Teorema 121. Teniendo en cuenta (189), entonces para un valor dado de $t \in [0, 1]$ tenemos que demostrar en primer lugar que³⁵

$$\lim_{n \rightarrow \infty} P(|X_n(t) - Y_n(t)| < \varepsilon) = 1 \quad \forall \varepsilon > 0.$$

Como $V_n(t) = X_n(t) - Y_n(t)$, aplicando la desigualdad de Chebyshev:

$$P(|V_n(t)| < \varepsilon) \geq 1 - \frac{\text{Var}(V_n(t))}{\varepsilon^2} \quad \forall \varepsilon > 0; \quad (85)$$

donde

$$\text{Var}(V_n(t)) = \frac{(nt - [nt])^2}{n}.$$

Tomando límites sobre (85) cuando $n \rightarrow \infty$

$$\lim_{n \rightarrow \infty} P(|V_n(t)| < \varepsilon) \geq 1 - \lim_{n \rightarrow \infty} \frac{(nt - [nt])^2}{n\varepsilon^2} = 1,$$

entonces

$$|X_n(t) - Y_n(t)| \xrightarrow{p} 0.$$

En segundo lugar, tenemos que obtener la distribución límite de $Y_n(t)$:

$$\emptyset_{Y_n(t)}(s) = E\left(\exp\left(\frac{is}{\sqrt{n}} \sum_{k=1}^{[nt]} U_{n,kh}\right)\right) = \left(\emptyset_{U_{n,kh}}\left(\frac{s}{\sqrt{n}}\right)\right)^{[nt]};$$

como

$$\emptyset_{U_{n,kh}}\left(\frac{s}{\sqrt{n}}\right) = 1 - \frac{s^2}{2n} + o\left(\frac{s^2}{n}\right);$$

entonces

$$\lim_{n \rightarrow \infty} \emptyset_{Y_n(t)}(s) = \lim_{n \rightarrow \infty} \left(1 - \frac{s^2}{2n} + o\left(\frac{s^2}{n}\right)\right)^{[nt]} = \exp\left(-\frac{s^2 t}{2}\right);$$

por el Corolario 133

$$Y_n(t) \xrightarrow{d} N(0, 1) \quad t \in (0, 1].$$

³⁵ Todos los teoremas usados en las secciones (i.1) y (i.2) de esta prueba están en la Sección de variables aleatorias del Apéndice.



Entonces, por el Teorema 121

$$X_n(t) \xrightarrow{d} N(0, 1) \quad t \in (0, 1].$$

(i.2) Sea la función aleatoria $\mathbf{Y}_n$ de dimensión $k = 2$. Tenemos que demostrar que

$$(X_n(t_1), X_n(t_2))' \xrightarrow{d} (W(t_1), W(t_2))' \quad 0 < t_1 < t_2 \leq 1. \quad (86)$$

Aplicamos el Teorema 121 para vectores aleatorios para demostrar (86). En primer lugar, mediante el Teorema 108 demostramos que

$$(X_n(t_1), X_n(t_2))' \xrightarrow{p} (Y_n(t_1), Y_n(t_2))' \quad 0 < t_1 < t_2 \leq 1.$$

En segundo lugar, tenemos que demostrar ahora que

$$(Y_n(t_1), Y_n(t_2))' \xrightarrow{d} (W(t_1), W(t_2))' \quad 0 < t_1 < t_2 \leq 1. \quad (87)$$

Mediante el Teorema 123 – (iii), si

$$(Y_n(t_1), Y_n(t_2) - Y_n(t_1))' \xrightarrow{d} (W(t_1), W(t_2) - W(t_1))' \quad 0 < t_1 < t_2 \leq 1; \quad (88)$$

entonces demostramos (87).

Representemos (88) como

$$\tilde{\mathbf{Y}}_n \equiv (Y_n(t_1), Y_n(t_2) - Y_n(t_1))' \quad \text{and} \quad \tilde{\mathbf{W}} \equiv (W(t_1), W(t_2) - W(t_1))'.$$

Se demuestra (88) usando el Teorema 136.

Sea

$$Y_n(t_1) = \frac{1}{\sqrt{n}} \sum_{k=1}^{[nt_1]} U_{n,kh},$$

$$\Delta Y_n(t_2) = \frac{1}{\sqrt{n}} \sum_{k=[nt_1]+1}^{[nt_2]} U_{n,kh};$$

donde $\Delta Y_n(t_2) = Y_n(t_2) - Y_n(t_1)$ y

$$\lambda = (\lambda_1, \lambda_2)';$$

entonces

$$\lambda' \tilde{\mathbf{Y}}_n = \lambda_1 Y_n(t_1) + \lambda_2 \Delta Y_n(t_2).$$



Como $Y_n(t_1)$ y $\Delta Y_n(t_2)$ son independientes, la función característica de $\lambda' \tilde{Y}_n$ es:

$$\emptyset_{\lambda' \tilde{Y}_n}(s) = \emptyset_{Y_n(t_1)}(s\lambda_1) \emptyset_{\Delta Y_n(t_2)}(s\lambda_2);$$

entonces

$$\emptyset_{\lambda' \tilde{Y}}(s) = \lim_{n \rightarrow \infty} \emptyset_{\lambda' \tilde{Y}_n}(s) = \lim_{n \rightarrow \infty} \emptyset_{Y_n(t_1)}(s\lambda_1) \emptyset_{\Delta Y_n(t_2)}(s\lambda_2);$$

por tanto

$$\begin{aligned} \emptyset_{\lambda' \tilde{Y}}(s) &= \exp\left(-\frac{s^2 \lambda_1^2 t_1}{2}\right) \exp\left(-\frac{s^2 \lambda_2^2 (t_2 - t_1)}{2}\right) = \\ &= \exp\left(-\frac{1}{2} \left((s\lambda_1)^2 t_1 + (s\lambda_2)^2 (t_2 - t_1) \right)\right) = \\ &= \exp\left(-\frac{1}{2} s^2 (\lambda_1, \lambda_2) \begin{pmatrix} t_1 & 0 \\ 0 & t_2 - t_1 \end{pmatrix} \begin{pmatrix} \lambda_1 \\ \lambda_2 \end{pmatrix}\right); \end{aligned}$$

mediante el Teorema 132 :

$$\lambda' \tilde{Y} \sim N\left(0, \left((\lambda_1, \lambda_2) \begin{pmatrix} t_1 & 0 \\ 0 & t_2 - t_1 \end{pmatrix} \begin{pmatrix} \lambda_1 \\ \lambda_2 \end{pmatrix} \right)\right).$$

Aplicando el Teorema 134

$$\tilde{Y} \sim N\left(0, \begin{pmatrix} t_1 & 0 \\ 0 & t_2 - t_1 \end{pmatrix}\right);$$

por tanto se demuestra (87).

Finalmente, aplicando el Teorema 121 para vectores aleatorios demostramos (86).

(i.3) Aplicando lo mismo que (i.2) demostramos

$$(X_n(t_1), X_n(t_2), \dots, X_n(t_k))' \xrightarrow{d} (W(t_1), W(t_2), \dots, W(t_k))'.$$

■

Introducimos ahora la siguiente versión del Teorema 28 para funciones aleatorias de D :

Theorem 29 Sea $\{Y_n(\cdot); n \geq 1\}$ una sucesión de funciones aleatorias del espacio $D[0, 1]$, donde $Y_n(\cdot)$ se define mediante la expresión (187); entonces $Y_n(\cdot)$ converge débilmente a MBS, es decir $Y_n(\cdot) \Rightarrow W(\cdot)$.



Corollary 30 Sea

$$Y_n(t, \omega) = \frac{1}{\sqrt{n}} \sum_{k=1}^{[nt]} \xi_{n,kh}(\omega)$$

donde $\xi_{n,kh} \sim i.i.d. (\beta\sqrt{h}, \sigma^2)$, entonces $Y_n(\cdot) \Rightarrow \beta t + \sigma W(\cdot)$, que es un proceso de Wiener con tendencia.

Se introduce ahora un proceso en tiempo continuo en $[0, 1]$ que va más lejos del proceso *MBS*. Permite que la varianza de los términos $\xi_{n,kh}$ varíe con el tiempo.

Definition 31 Sea (Ω, F, P) un espacio de probabilidad y $T = [0, 1]$ el conjunto índice. Un proceso estocástico $\{W_\eta(t); t \in [0, 1]\}$ es un proceso browniano transformado (*MBT*) sobre (Ω, F, P) si

$$W_\eta(t) = W(\eta(t)); \quad t \in [0, 1]$$

donde $W(\cdot)$ es un *MBS* y η es un homeomorfismo creciente³⁶ sobre $[0, 1]$ con $\eta(0) = 0$ y $\eta(1) = 1$, verificándose:

- (i) $W_\eta(t) \sim N(0, \eta(t))$, donde $t \in (0, 1]$;
- (ii) Para cualquier $0 \leq t_0 \leq t_1 \leq \dots \leq t_k \leq 1$, las variables aleatorias $W_\eta(t_0)$ y $W_\eta(t_i) - W_\eta(t_{i-1})$, $1 \leq i \leq k$ son independientes;
- (iii) $P(W_\eta(0) = 0) = 1$.

Dividamos el intervalo $[0, 1]$ en n subintervalos de longitud $h \equiv 1/n$. Sea $\{kh : k = 1, 2, \dots, n\}$ el conjunto de puntos donde existe una variable aleatoria en cada punto; entonces tenemos una sucesión de variables aleatorias independientes $\{\xi_{n,kh} : k = 1, 2, \dots, n\}$ definido sobre el mismo espacio de probabilidad (Ω, F, P) donde $E(\xi_{n,kh}) = 0$ y $E(\xi_{n,kh}^2) = \sigma_{n,k}^2$, $0 < \sigma_{n,k}^2 < \infty$. Tenemos un "double array" representado como $\{\xi_{n,kh} : 1 \leq k \leq n; n \geq 1\}$. Sea

$$b_n^2 = E\left(\sum_{k=1}^n \xi_{n,kh}\right)^2 = \sum_{k=1}^n \sigma_{n,k}^2.$$

y

$$b_{[nt]}^2 = \begin{cases} \sum_{k=1}^{[nt]} \sigma_{n,kh}^2; & t \in [h, 1] \\ 0; & t \in [0, h]. \end{cases}$$

³⁶Una función continua 1-1 con función inversa continua.

Definamos la siguiente función aleatoria $\{Y_n(t, \omega) : \omega \in \Omega, t \in [0, 1]\}$ en $D[0, 1]$ como

$$Y_n(t, \omega) = \begin{cases} \frac{1}{b_n} \sum_{k=1}^{[nt]} \xi_{n,kh}(\omega); & \omega \in \Omega, t \in [h, 1] \\ 0; & \omega \in \Omega, t \in [0, h]. \end{cases} \quad (89)$$

Theorem 32 Sea $\{Y_n(\cdot); n \geq 1\}$ un espacio de funciones aleatorias del espacio $D[0, 1]$, donde $Y_n(\cdot)$ se define mediante la expresión (89); entonces si $\forall t \in [0, 1]$

$$\frac{b_{[nt]}^2}{b_n^2} \rightarrow \eta(t) \quad \text{as } n \rightarrow \infty$$

donde la función límite $\eta : [0, 1] \mapsto [0, 1]$ es continua y estrictamente creciente en todo el intervalo, entonces

$$Y_n(\cdot) \Rightarrow W_\eta(\cdot).$$

El siguiente teorema es un resultado de Herrndorf (1984), permite que las innovaciones, es decir $\xi_{n,kh}$, tenga distribución con dependencia débil y heterogénea. Asumamos que la sucesión de innovaciones $\{\xi_{n,kh}\}_{k=1}^n$ verifique la siguientes condiciones generales:

- (i) $E(\xi_{n,kh}) = 0 \quad \forall k$;
- (ii) $\sup_k \left(E |\xi_{n,kh}|^{\beta+\varepsilon} \right) < \infty$ para algún $\beta > 2$ y $\varepsilon > 0$;
- (iii) $\sigma^2 = \lim_{n \rightarrow \infty} E \left[n^{-1} \left(\sum_{k=1}^n \xi_{n,kh} \right)^2 \right]$ existe y $\sigma^2 > 0$;
- (iv) $\{\xi_{n,kh}\}_{k=1}^n$ es "strong mixing" con coeficientes "mixing" α_m verificando:

$$\sum_{m=1}^{\infty} \alpha_m^{1-2/\beta} < \infty.$$

Las Condiciones (i) – (iv) son bastante débiles, pues permiten dependencia temporal y heterocedasticidad en la sucesión $\{\xi_{n,kh}\}_{k=1}^n$.

Sea la función aleatoria $\{Y_n(t, \omega) : \omega \in \Omega, t \in [0, 1]\}$ en $D[0, 1]$ definida como

$$Y_n(t, \omega) = \begin{cases} n^{-1/2} \sigma^{-1} \sum_{k=1}^{[nt]} \xi_{n,kh}(\omega); & \omega \in \Omega, t \in [h, 1] \\ 0; & \omega \in \Omega, t \in [0, h]. \end{cases} \quad (90)$$

Theorem 33 Sea $\{Y_n(\cdot); n \geq 1\}$ una sucesión de funciones aleatorias del espacio $D[0, 1]$, donde $Y_n(\cdot)$ está definida por la expresión (90), si $\{\xi_{n,kh}\}_{k=1}^n$ verifica las condiciones (i) – (iv); entonces $Y_n(\cdot)$ converge débilmente al MBS, es decir $Y_n(\cdot) \Rightarrow W(\cdot)$.

7 Cálculo estocástico de Ito

7.1 Introducción

Sea el siguiente proceso estocástico definido como

$$X(t) = \int_{t_0}^t W(u) dW(u); \quad t \in [t_0, T]. \quad (91)$$

Aplicando las reglas de integración por partes

$$\int_{t_0}^t W(u) dW(u) = \frac{1}{2} (W(t)^2 - W(t_0)^2). \quad (92)$$

Este cálculo asume la existencia de la integral de Riemann-Stieltjes, o sea;

$$S_n = \sum_{i=1}^n W(\tau_{i,n}) (W(t_{i,n}) - W(t_{i-1,n}));$$

donde $\tau_{i,n} \in [t_{i-1,n}; t_{i,n}]$. Entonces

$$\lim_{n \rightarrow \infty} E \left| S_n - \frac{1}{2} (W(t)^2 - W(t_0)^2) \right|^2 = 0; \quad (93)$$

tal que

$$|t_{i-1,n} - t_{i,n}| \rightarrow 0 \text{ as } n \rightarrow \infty \text{ and } \forall \tau_{i,n} \quad i = 1, 2, \dots, n.$$

Sin embargo (93) no se verifica, el límite de $\{S_n\}$ depende de la elección de los puntos $\tau_{i,n}$. Definamos $\tau_{i,n}$ como

$$\tau_{i,n} = (1-a)t_{i-1,n} + at_{i,n}; \quad a \in [0, 1]; \quad i = 1, 2, \dots, n.$$

Se demuestra³⁷ que

$$\lim_{n \rightarrow \infty} E \left| S_n - \frac{1}{2} (W(t)^2 - W(t_0)^2) \right|^2 = (a - 1/2) (t - t_0);$$

³⁷Ver Arnold (1974).



Si elegimos $a = 0$, o sea, $\tau_{i,n} = t_{i-1,n}$; obtenemos la *integral estocástica de Ito*. En definitiva,

$$\int_{t_0}^t W(u) dW(u) = \frac{1}{2} (W(t)^2 - W(t_0)^2) - \frac{1}{2} (t - t_0). \quad (94)$$

Obsérvese que la ecuación de arriba no coincide con la regla de integración por partes, es decir; ecuación (92). Si elegimos el valor $a = 1/2$, entonces obtenemos (92). Esta integral estocástica se conoce como la *integral de Stratonovich*. La desventaja de esta integral es que no es una martingala mientras la integral de Ito se caracteriza por ser una martingala. Podemos extender (94) al caso del proceso MBT³⁸, es decir

$$\int_{t_0}^t W_\eta(u) dW_\eta(u) = \frac{1}{2} (W_\eta(t)^2 - W_\eta(t_0)^2) - \frac{1}{2} (\eta(t) - \eta(t_0)).$$

7.2 Integral estocástica de Ito

Definition 34 Sea $W(\cdot) \equiv \{W(t) : t \geq 0\}$ un proceso de Wiener definido sobre el espaciode probabilidad $(\Omega, \mathcal{F}, P)$. Una familia de " σ -fields" $\mathcal{F}_t$ en $\mathcal{F}$ definido para $t \geq 0$ se dice que es *nonanticipating* con respecto a $W(\cdot)$ si verifica:

- (i) $\mathcal{F}_{t_1} \subset \mathcal{F}_{t_2}$ para $t_1 \leq t_2$;
- (ii) $\mathcal{F}_t$ contiene el " σ -field" generado por $W(s)$, o sea

$$\sigma(W(s), 0 \leq s \leq t) \subseteq \mathcal{F}_t;$$

- (iii) $\mathcal{F}_t$ is independiente del " σ -field" generado por $W(u) - W(t)$, $t \leq u < \infty$, o sea

$$\sigma(W(u) - W(t), t \leq u < \infty).$$

La condición (iii) significa que $\mathcal{F}_0$ puede contener sólo acontecimientos independientes del proceso entero de Wiener, o sea $W(\cdot)$.

Definition 35 Sea $G(t, \omega) : [t_0, T] \times \Omega \rightarrow \mathbb{R}^{d \times m}$, donde $t_0 \geq 0$, que se asume ser medible en (s, ω) . Se dice que es *nonanticipating* respecto a la familia of " σ -fields" $\mathcal{F}_t$ si verifica las dos siguientes condiciones:

- (i) $G(t, \cdot)$ es $\mathcal{F}_t$ -medible $\forall t \in [t_0, T]$;

³⁸Ver p.508 en Davidson (1995).



Universitat d'Alacant
Universidad de Alicante

(ii) La integral

$$\int_{t_0}^t |G(t, \omega)|^2 dt < \infty$$

con probabilidad uno

Sea $\mathcal{M}[t_0, T]$ el conjunto de funciones verificando las dos condiciones de arriba. La última integral se interpreta como la integral de Lebesgue, que coincide con la integral de Riemann en el caso de funciones continuas. Sea $|G|$ la norma vectorial (matricial), es decir

$$|G| = \begin{cases} (G'G)^{1/2} & \text{si } G \text{ es un vector columna;} \\ [\text{tr}(G'G)]^{1/2} & \text{si } G \text{ es una matriz.} \end{cases}$$

Definition 36 Una función $G \in \mathcal{M}[t_0, T]$ es una función "step" si existe una descomposición $t_0 < t_1 < \dots < t_n = t$ tal que $G(s, \omega) = G(t_{i-1}, \omega)$ para todo $s \in [t_{i-1}, t_i)$, donde $i = 1, \dots, n$.

A continuación trabajaremos con la siguiente integral estocástica de Ito

$$\int_{t_0}^t G dW = \int_{t_0}^t G(s, \omega) dW(s, \omega). \quad (95)$$

Theorem 37 Para cada función $G \in \mathcal{M}[t_0, T]$ tal que

$$\int_{t_0}^t E |G(s, \omega)|^2 ds < \infty,$$

existe una sucesión $\{G_n\}$ de funciones step en $\mathcal{M}[t_0, T]$ teniendo la misma propiedad, tal que

$$\lim_{n \rightarrow \infty} \int_{t_0}^t E |G_n(s, \omega) - G(s, \omega)|^2 ds = 0$$

y

$$\lim_{n \rightarrow \infty} E \left| \int_{t_0}^t G_n(s, \omega) dW(s, \omega) - \int_{t_0}^t G(s, \omega) dW(s, \omega) \right|^2 = 0.$$

Theorem 38 Sean G, G_1, G_2 y G_n representando funciones de valores matriciales $d \times m$ en $\mathcal{M}[t_0, T]$ y sea $W(\cdot)$ un proceso de Wiener de dimensión m . Entonces, la integral estocástica definida por (95) tiene las siguientes propiedades:

$$(i) \quad \int_{t_0}^t (aG_1 + bG_2) dW = a \int_{t_0}^t G_1 dW + b \int_{t_0}^t G_2 dW; \quad a, b \in \mathbb{R}.$$

$$(ii) \quad \int_{t_0}^t G dW = \sum_{i=1}^m \begin{pmatrix} \int_{t_0}^t G_{1i} dW_i \\ \vdots \\ \int_{t_0}^t G_{di} dW_i \end{pmatrix}, \quad W(t) = \begin{pmatrix} W_1(t) \\ \vdots \\ W_m(t) \end{pmatrix}.$$

$$(iii) \quad \text{Si } \int_{t_0}^t E |G|^2 ds < \infty, \text{ entonces}$$

$$E \left(\int_{t_0}^t G dW \right) = 0; \quad E \left\{ \left(\int_{t_0}^t G dW \right) \left(\int_{t_0}^t G dW \right)' \right\} = \int_{t_0}^t E (GG') ds.$$

$$(iv) \quad \text{Si } \int_{t_0}^t E |G|^2 ds < \infty, \text{ entonces } E \left| \int_{t_0}^t G dW \right|^2 = \int_{t_0}^t E |G|^2 ds.$$

Corollary 39 Si G es independiente de ω y pertenece a $\mathcal{L}[t_0, t]$ ³⁹, entonces la integral estocástica (95) es un vector aleatorio $d \times 1$ con distribución

$$N \left(0, \int_{t_0}^t G(s) G(s)' ds \right).$$

Theorem 40 Si $G \in \mathcal{M}[t_0, t]$ y $G(\cdot, \omega)$ es absolutamente continuo sobre $[t_0, t]$ con derivada $\dot{G}$, entonces

$$\int_{t_0}^t G(s) dW = G(t) W(t) - G(t_0) W(t_0) - \int_{t_0}^t \dot{G}(s) W(s) ds.$$

³⁹Todas las funciones medibles tal que $\int_{t_0}^t |f(s)|^2 ds < \infty$.

7.3 Lema de Ito

Lemma 41 (Ito). Sea $u(t, x) : [t_0, T] \times \mathbb{R} \rightarrow \mathbb{R}$ una función continua determinística continua con derivadas parciales continuas u_t, u_x y u_{xx} . Sea $X(t) = X(t, \omega)$, $f(t) = f(t, \omega)$, $G(t) = G(t, \omega) : [t_0, T] \times \Omega \rightarrow \mathbb{R}$ y sea la siguiente ecuación diferencial estocástica:

$$dX(t) = f(t) dt + G(t) dW(t). \quad (96)$$

Sea $Y(t) = u(t, X(t))$. Entonces el proceso $Y(t)$ tiene también un diferencial en $[t_0, T]$ dado por

$$\begin{aligned} dY(t) = & \left[u_t(t, X(t)) + u_x(t, X(t)) f(t) + \frac{1}{2} u_{xx}(t, X(t)) G^2(t) \right] dt \\ & + u_x(t, X(t)) G(t) dW(t). \end{aligned} \quad (97)$$

Example 42 (Melino & Turnbull, 1990). Sea la siguiente EDE para la varianza instantánea

$$d \ln V(t) = (\alpha + \delta \ln V(t)) dt + \gamma dW(t).$$

Sea $X(t) \equiv \ln V(t)$, estamos interesados en el proceso $V(t)$, por tanto $Y(t) = e^{X(t)}$. Entonces,

$$dV(t) = (\alpha + \delta \ln V(t) + \gamma^2/2) V(t) dt + \gamma V(t) dW(t).$$

Lemma 43 (Ito Generalizado). Sea $u(t, x) : [t_0, T] \times \mathbb{R}^d \rightarrow \mathbb{R}^k$ una función continua determinística tal que sus derivadas parciales $u_t, u_{x_i}, u_{x_i x_j}$ son continuas, donde

$$u_t = \frac{\partial}{\partial t} u(t, x);$$

$$u_{x_i} = \frac{\partial}{\partial x_i} u(t, x), \quad i = 1, 2, \dots, d;$$

$$u_{x_i x_j} = \frac{\partial^2}{\partial x_i \partial x_j} u(t, x), \quad i, j \leq d.$$

Sea

$$X(t) = X(t, \omega) : [t_0, T] \times \Omega \rightarrow \mathbb{R}^d;$$

$$f(t) = f(t, \omega) : [t_0, T] \times \Omega \rightarrow \mathbb{R}^d;$$

$$G(t) = G(t, \omega) : [t_0, T] \times \Omega \rightarrow \mathbb{R}^{d \times m};$$

$$W(t) = W(t, \omega) : [t_0, T] \times \Omega \rightarrow \mathbb{R}^m;$$

entonces tenemos la siguiente ecuación diferencial estocástica:

$$dX(t) = f(t) dt + G(t) dW(t). \quad (98)$$

Sea $Y(t) = u(t, X(t))$. Entonces, el proceso $Y(t)$ tiene también una diferencial sobre $[t_0, T]$ dado por

$$\begin{aligned} dY(t) = & [u_t(t, X(t)) + u_x(t, X(t)) f(t) \\ & + \frac{1}{2} \sum_{i=1}^d \sum_{j=1}^d u_{x_i x_j}(t, X(t)) (G(t) G(t)')_{ij}] dt \\ & + u_x(t, X(t)) G(t) dW(t) \end{aligned}$$

donde $u_x = (u_{x_1}, \dots, u_{x_d})$ es una matriz $k \times d$ y $u_{x_i x_j}$ es un vector columna de dimensión k .

Obsérvese que la doble suma puede escribirse también como

$$\sum_{i=1}^d \sum_{j=1}^d u_{x_i x_j} (GG')_{ij} = \text{tr}(u_{xx} GG') = \text{tr}(GG' u_{xx})$$

donde $u_{xx} = (u_{x_i x_j})$ es una matriz $d \times d$ cuyos elementos son vectores de orden k . Una expresión alternativa para $dY(t)$ es

$$dY(t) = u_t dt + u_x dX(t) + \frac{1}{2} \text{tr}(GG' u_{xx}) dt. \quad (99)$$

Definimos los operadores de difusión para la ecuación diferencial estocástica (98) como:

$$\begin{aligned} L^0 &= \frac{\partial}{\partial t} + \sum_{i=1}^d f_i \frac{\partial}{\partial x_i} + \frac{1}{2} \sum_{i=1}^d \sum_{j=1}^m G_{ij}^2 \frac{\partial^2}{\partial x_i^2}; \\ L^j &= \sum_{i=1}^d G_{ij} \frac{\partial}{\partial x_i}, \quad j = 1, \dots, m. \end{aligned} \quad (100)$$

Expresando $Y(t)$ como una función de los operadores de anteriores se obtiene:

$$Y(t) = Y(t_0) + \int_{t_0}^t L^0 Y(s) ds + \sum_{j=1}^m \int_{t_0}^t L^j Y(s) dW_j(s).$$

Example 44 (Heston, 1993). Introducimos aquí opciones call europeas call sobre un activo con volatilidad estocástica. El proceso generador de datos (PGD) bajo la medida neutral al riesgo es:

$$dS(t) = rS(t)dt + \sqrt{V(t)}S(t)dW_s(t) \quad (101)$$

$$dV(t) = k^*(\theta^* - V(t))dt + \sigma\sqrt{V(t)}dW_v(t) \quad (102)$$

$$dW_s(t)dW_v(t) = \rho dt$$

donde $S(t)$ es el precio del activo subyacente, $V(t)$ es la varianza instantánea y r es el tipo de interés. Podemos expresar los procesos de Wiener anteriores como función de procesos de Wiener independientes, es decir

$$dW_s(t) = dZ_s(t); \quad (103)$$

$$dW_v(t) = \rho dZ_s(t) + \sqrt{1 - \rho^2}dZ_v(t);$$

verificando que $dZ_s(t)dZ_v(t) = 0$. Por tanto, dados (198) a (103) :

$$dS(t) = rS(t)dt + \sqrt{V(t)}S(t)dZ_s(t); \quad (104)$$

$$dV(t) = k^*(\theta^* - V(t))dt + \sigma\sqrt{V(t)}\left[\rho dZ_s(t) + \sqrt{1 - \rho^2}dZ_v(t)\right]. \quad (105)$$

Sea $Y(S(t), V(t), t)$ el valor del derivado sobre $S(t)$. Para abreviar denotemos como Y . Sea el siguiente sistema de EDEs:

$$dX(t) = f(t)dt + G(t)dZ(t)$$

donde

$$X(t) = (S(t), V(t))'; \quad Z(t) = (Z_s(t), Z_v(t))';$$

$$f(t) = (rS(t), k^*(\theta^* - V(t)))';$$

y

$$G(t) = \begin{pmatrix} \sqrt{V(t)}S(t) & 0 \\ \rho\sigma\sqrt{V(t)} & \sqrt{1 - \rho^2}\sigma\sqrt{V(t)} \end{pmatrix}.$$

Para abreviar denotemos como v y S a $V(t)$ y $S(t)$ respectivamente, entonces

$$\text{tr}(GG'Y_{xx}) = vS^2Y_{ss} + 2\rho\sigma vSY_{sv} + v\sigma^2Y_{vv}.$$



Aplicando el lema de Ito generalizado sobre $Y(t)$, concretamente la ecuación (99), se obtiene

$$\begin{aligned} dY &= Y_t dt + Y_s dS + Y_v dv \\ &+ \frac{1}{2} (v S^2 Y_{ss} + 2\rho\sigma v S Y_{sv} + v\sigma^2 Y_{vv}) dt. \end{aligned} \quad (106)$$

Dados (104) y (105), y (106), calculamos $E(dY)$:

$$\begin{aligned} E(dY) &= [Y_t dt + rSY_s + k^*(\theta^* - v)Y_v \\ &+ \frac{1}{2}vS^2Y_{ss} + \rho\sigma vSY_{sv} + \frac{1}{2}v\sigma^2Y_{vv}]dt. \end{aligned}$$

Debe verificarse que

$$E(dY) = rYdt$$

entonces se obtiene la siguiente ecuación diferencial en derivadas parciales (EDP)

$$\begin{aligned} Y_t dt + rSY_s + k^*(\theta^* - v)Y_v + \frac{1}{2}vS^2Y_{ss} \\ + \rho\sigma vSY_{sv} + \frac{1}{2}v\sigma^2Y_{vv} - rY = 0; \end{aligned} \quad (107)$$

que es la ecuación (6) en Heston (1993). Dado (199) sujeto a la siguiente condición terminal

$$Y(S(T), V(T), T) = \max(S(T) - K, 0),$$

entonces $Y(t)$ es el valor de la opción call europea con precio de ejercicio K y con vencimiento en T . La fórmula de $Y(t)$ tiene la misma forma que la fórmula de Black-Scholes, es decir

$$Y(t) = S(t)P_1 - Ke^{-r(T-t)}P_2$$

pero ahora P_1 y P_2 no son las probabilidades de una distribución normal estandarizada, ver ecuación (18) en Heston. Finalmente, eliminando el término $-rY$ en (199) y cambiando la condición terminal anterior por

$$Y(S(T), V(T), T) = S(T),$$

entonces $Y(t)$ es el precio del futuro con vencimiento en T cuya fórmula es

$$Y(t) = S(t)e^{r(T-t)}.$$

7.4 Procesos de difusión con salto y lema de Ito

Podemos extender el lema de Ito al caso cuando la EDE es un proceso de difusión con salto, es decir

$$dX(t) = f(t)dt + G(t)dW(t) + X(t)dq(t), \quad t \in [0, T] \quad (108)$$

donde $dq(t)$ representa los posibles saltos porcentuales en un instante mediante un proceso de Poisson, es decir

$$dq(t) \equiv \begin{cases} S - 1, & \text{if } dN(t) = 1; \\ 0, & \text{if } dN(t) = 0; \end{cases}$$

donde $dN(t) \sim P(\lambda dt)$ es un proceso de Poisson⁴⁰ que representa el número de saltos en un instante dt con intensidad λ . En definitiva, $dq(t)$ es un proceso de Poisson compuesto⁴¹. Según el Teorema 7,

$$E[dq(t)] = k\lambda dt$$

donde $k \equiv E(S - 1)$. Por tanto $(S - 1)$ es la variable aleatoria porcentual tal que cuando un acontecimiento de Poisson ocurre se produce un salto finito de $X(t)$ a $SX(t)$. Se asume que $dq(t)$ y $dW(t)$ son independientes. Podemos reescribir (108) en términos de saltos no anticipados, un proceso de Poisson compuesto sin tendencia, es decir

$$dX(t) = a(t)dt + G(t)dW(t) + X(t)dJ(t), \quad t \in [0, T]$$

donde $a(t) \equiv f(t) + k\lambda$ y

$$dJ(t) = dq(t) - k\lambda dt$$

por tanto

$$E[dJ(t)] = 0.$$

En definitiva,

$$dX(t) = \begin{cases} f(t)dt + G(t)dW(t), & \text{si un acontec. Poisson no ocurre;} \\ f(t)dt + G(t)dW(t) + (S - 1)X(t), & \text{si un acontec. Poisson ocurre;} \end{cases}$$

⁴⁰Ver Definición 3.

⁴¹Ver Definición 6.

verificándose con probabilidad uno que no más de un acontecimiento de Poisson ocurre en un instante, y si el acontecimiento ocurre; se produce un salto finito de $X(t)$ a $SX(t)$. La senda muestral resultante será prácticamente continua con algunos saltos finitos en puntos discretos del tiempo.

Una extensión del lema de Ito a la ecuación de difusión con salto (108) donde $Y(t) = u(t, X(t))$ es

$$dY(t) = f_y(t) dt + G_y(t) dW(t) + dq_y(t), \quad t \in [0, T] \quad (109)$$

tal que

$$f_y(t) \equiv u_t(t, X(t)) + u_x(t, X(t)) f(t) + \frac{1}{2} u_{xx}(t, X(t)) G^2(t);$$

$$G_y(t) \equiv u_x(t, X(t)) G(t);$$

y $dq_y(t)$ es un proceso de Poisson compuesto independiente definido como

$$dq_y(t) \equiv \begin{cases} Y(SX(t)) - Y(X(t)), & \text{if } dN(t) = 1; \\ 0, & \text{if } dN(t) = 0; \end{cases}$$

verificándose que

$$E[dq_y(t)] = k_y \lambda dt$$

donde

$$k_y \equiv E_t[Y(SX(t)) - Y(X(t))].$$

Otra forma de escribir la ecuación (109) es

$$dY(t) = a_y(t) dt + G_y(t) dW(t) + dJ_y(t), \quad t \in [0, T]$$

donde

$$a_y(t) \equiv f_y(t) + k_y \lambda,$$

$$dJ_y(t) \equiv dq_y(t) - k_y \lambda dt;$$

entonces

$$dY(t) = \begin{cases} f_y(t) dt + G_y(t) dW(t), & \text{no jump;} \\ f_y(t) dt + G_y(t) dW(t) + [Y(SX(t)) - Y(X(t))], & \text{jump.} \end{cases}$$

8 Modelos lineales estocásticos

8.1 Definiciones

Definition 45 *Un sistema de ecuaciones diferenciales estocásticas (EDE)*

$$dX(t) = f(t, X(t)) dt + G(t, X(t)) dW(t) \quad (110)$$

para el proceso $X(t)$ de dimensión d sobre el intervalo $[t_0, T]$ se dice que es lineal si

$$f(t, x) = A(t)x + a(t),$$

donde $A(t)$ es una matriz de valores reales $d \times d$, $a(t)$ pertenece a $\mathbb{R}^d$, y

$$G(t, x) = (B_1(t)x + b_1(t), \dots, B_m(t)x + b_m(t)),$$

donde $B_i(t)$ es una matriz $d \times d$ y $b_i(t)$ pertenece a $\mathbb{R}^d$ para $i = 1, \dots, m$. Por tanto, un sistema de ecuaciones diferenciales estocásticas lineales (EDEL) tiene la forma

$$dX(t) = (A(t)X(t) + a(t)) dt + \sum_{i=1}^m (B_i(t)X(t) + b_i(t)) dW_i(t), \quad (111)$$

donde $W(t)$ es proceso de Wiener de dimensión m con componentes $W_1(t), \dots, W_m(t)$ que son procesos de Wiener escalares independientes.

Definition 46 *La EDEL (111) se dice que es homogénea si*

$$a(t) = b_1(t) = \dots = b_m(t) \equiv 0.$$

Definition 47 *La EDEL (111) dicese que es lineal en el sentido "narrow" si*

$$B_1(t) = \dots = B_m(t) \equiv 0,$$

es decir

$$dX(t) = (A(t)X(t) + a(t)) dt + b(t) dW(t), \quad (112)$$

donde $b(t) = (b_1(t), \dots, b_m(t))$ es una matriz $d \times m$.



8.2 Existencia y unicidad de una solución

Theorem 48 Sea el sistema de EDEs

$$dX(t) = f(t, X(t))dt + G(t, X(t))dW(t), \quad X(t_0) = X_0, \quad t_0 \leq t \leq T < \infty, \quad (113)$$

donde $W(t)$ es un proceso estándar de Wiener del espacio $\mathbb{R}^m$ y X_0 es un vector aleatorio independiente de $W(t) - W(t_0)$ para $t \geq t_0$. Supongamos que $f(t, x)$ es un vector $\mathbb{R}^d$ de funciones reales and $G(t, x)$ que es una matriz $d \times m$ de funciones reales están definidas y son medibles en $[t_0, T] \times \mathbb{R}^d$ verificándose las siguientes propiedades: Existe una constante $K > 0$ tal que

(i) (condición de Lipschitz) $\forall t \in [t_0, T], x \in \mathbb{R}^d, y \in \mathbb{R}^d,$

$$|f(t, x) - f(t, y)| + |G(t, x) - G(t, y)| \leq K|x - y|.$$

(ii) (Restricción de crecimiento) $\forall t \in [t_0, T], x \in \mathbb{R}^d,$

$$|f(t, x)|^2 + |G(t, x)|^2 \leq K(1 + |x|^2).$$

Entonces (113) tiene sobre $[t_0, T]$ una única solución $X(t) \in \mathbb{R}^d$ continua con probabilidad 1, que verifica la condición inicial $X(t_0) = X_0$; es decir, si $X(t)$ y $Y(t)$ son soluciones continuas de (113) con el mismo valor inicial X_0 , entonces

$$P \left[\sup_{t_0 \leq t \leq T} |X(t) - Y(t)| > 0 \right] = 0.$$

Cuando $W(t)$ del lado derecho de (113) está dado exógenamente y entonces $X(t)$ está determinado, obtenemos la *solución fuerte* de la EDE. Esto es similar a las soluciones de las ecuaciones diferenciales ordinarias. Otro tipo de solución específica a EDEs es la *solución débil*. En la solución débil se encuentra el par $(\tilde{X}(t), \tilde{W}(t))$ tal que (113) se verifica.

8.3 Sistemas de EDELs en el sentido "narrow"

En esta sección, investigaremos aquellas ecuaciones de la forma (112). Pero en primer lugar, revisemos los sistemas lineales determinísticos ($b_i(t) = 0, \forall i$).



8.3.1 Caso determinístico

Sea el sistema lineal determinístico

$$\dot{X}(t) = A(t)X(t) + a(t) \quad (114)$$

Definition 49 La matriz $\Phi(t) = \Phi(t, t_0)$ de soluciones del sistema homogéneo

$$\dot{X}(t) = A(t)X(t) \quad (115)$$

se denomina la matriz fundamental y verifica

$$(i) \quad \frac{d}{dt}\Phi(t) = A(t)\Phi(t);$$

$$(ii) \quad \Phi(t_0) = I.$$

Theorem 50 Sea $X(t)$ la solución de (114) sobre $[t_0, T]$ y $\Phi(t)$ la matriz fundamental de (115), entonces

$$X(t) = \Phi(t) \left(x_0 + \int_{t_0}^t \Phi(s)^{-1} a(s) ds \right),$$

donde $X(t_0) = x_0$ es la condición inicial.

Theorem 51 Sea

$$\dot{X}(t) = AX(t), \quad (116)$$

entonces la matriz $\Phi(t) = e^{A(t-t_0)}$ es la matriz fundamental de (116).

Corollary 52 La solución de

$$\dot{X}(t) = AX(t) + a(t)$$

sobre $[t_0, T]$ es

$$X(t) = e^{A(t-t_0)}x_0 + \int_{t_0}^t e^{A(t-s)}a(s) ds.$$

Example 53 Sea el siguiente sistema

$$\begin{pmatrix} \dot{X}_1(t) \\ \dot{X}_2(t) \end{pmatrix} = \begin{pmatrix} 0 & 2 \\ -1 & -3 \end{pmatrix} \begin{pmatrix} X_1(t) \\ X_2(t) \end{pmatrix} + \begin{pmatrix} 0 \\ 1 \end{pmatrix}, \quad t \geq 0$$



con condición inicial

$$\begin{pmatrix} X_1(0) \\ X_2(0) \end{pmatrix} = \begin{pmatrix} 2 \\ 1 \end{pmatrix}.$$

La matriz fundamental, según el Teorema 51, es

$$\Phi(t) = \begin{pmatrix} 2e^{-t} - e^{-2t} & 2e^{-t} - 2e^{-2t} \\ -e^{-t} + e^{-2t} & -e^{-t} + 2e^{-2t} \end{pmatrix}$$

y la solución del sistema, según el Teorema 52, es

$$\begin{pmatrix} X_1(t) \\ X_2(t) \end{pmatrix} = \begin{pmatrix} 4e^{-t} - 3e^{-2t} + 1 \\ -2e^{-t} + 3e^{-2t} \end{pmatrix}.$$

8.3.2 Caso estocástico

Theorem 54 El sistema (112) tiene sobre $[t_0, T]$ la solución

$$X(t) = \Phi(t) \left(X_0 + \int_{t_0}^t \Phi(s)^{-1} a(s) ds + \int_{t_0}^t \Phi(s)^{-1} b(s) dW(s) \right),$$

donde $X(t_0) = X_0$.

Consideremos dos casos particulares:

Corollary 55 Si $A(t) \equiv A$ en la ecuación (112), es decir es independiente de t ; entonces

$$X(t) = e^{A(t-t_0)} X_0 + \int_{t_0}^t e^{A(t-s)} a(s) ds + \int_{t_0}^t e^{A(t-s)} b(s) dW(s).$$

Corollary 56 Para $d = 1$ y m arbitrario,

$$\Phi(t) = \exp \left(\int_{t_0}^t A(s) ds \right),$$

y por tanto

$$X(t) = \exp \left(\int_{t_0}^t A(s) ds \right) \times \\ \left(X_0 + \int_{t_0}^t \exp \left(- \int_{t_0}^s A(u) du \right) (a(s) ds + b(s) dW(s)) \right).$$

Theorem 57 Para la solución $X(t)$ del sistema (112), bajo el supuesto que $E|X_0|^2 < \infty$, se obtiene

$$(i) \quad m(t) = EX(t) = \Phi(t) \left(EX_0 + \int_{t_0}^t \Phi(s)^{-1} a(s) ds \right),$$

$$(ii) \quad K(s, t) = \text{Var}(X(s), X(t)) = \Phi(s) \times$$

$$\left(\text{Var}(X_0) + \int_{t_0}^{\min(s, t)} \Phi(u)^{-1} b(u) b(u)' (\Phi(u)^{-1})' du \right) \Phi(t)'$$

Theorem 58 La solución de (112) es un proceso estocástico gaussiano sii X_0 se distribuye normal o es constante. El valor medio $m(t)$ y la matriz de covarianzas $K(s, t)$ vienen dados en el Teorema 57.

Theorem 59 La solución de (112) es un proceso estacionario gaussiano si $A(t) \equiv A$, $a(t) \equiv 0$, $b(t) \equiv b$, los valores propios de A tienen partes reales negativas, y X_0 es $N(0, \Omega)$, donde Ω es

$$\Omega = \int_0^\infty e^{At} b b' e^{A't} dt.$$

Entonces,

$$m(t) = 0, \quad \forall t$$

y

$$K(s, t) = \begin{cases} e^{A(s-t)} \Omega, & s \geq t \geq t_0; \\ \Omega e^{A'(s-t)}, & t \geq s \geq t_0. \end{cases}$$

8.4 Ejemplos de EDEs

8.4.1 Proceso Ornstein-Uhlenbeck (OU)

Sea la siguiente EDE con $d = 1$, $m = 1$ y $t \in [0, T]$

$$dX(t) = \alpha X(t) dt + \sigma dW(t), \quad X(0) = X_0; \quad \alpha < 0. \quad (117)$$

Este proceso es el modelo AR(1) en tiempo continuo, o sea; CAR(1). Según el Corolario 55, la solución de (117) es

$$X(t) = e^{\alpha t} X_0 + \sigma \int_0^t e^{\alpha(t-s)} dW(s). \quad (118)$$



Dado el Teorema 57, $X(t)$ tiene valor medio

$$m(t) = EX(t) = e^{\alpha t} EX_0 = e^{\alpha t} m(0).$$

y covarianza

$$\begin{aligned} K(s, t) &= E(X(s) - m(s))(X(t) - m(t)) \\ &= e^{\alpha(t+s)} \left[\text{Var } X_0 + \frac{\sigma^2}{2\alpha} (1 - e^{-2\alpha \min(t,s)}) \right]. \end{aligned}$$

En particular,

$$K(t, t) = \text{Var } X(t) = e^{2\alpha t} \text{Var}(X_0) + \frac{\sigma^2}{2\alpha} (e^{2\alpha t} - 1).$$

Si asumimos que

$$X_0 \sim N\left(0, \frac{-\sigma^2}{2\alpha}\right), \quad (119)$$

por el Teorema 59, $X(t)$ es un proceso estacionario gaussiano verificando

$$m(t) = 0;$$

$$K(s, t) = \frac{-\sigma^2}{2\alpha} \exp(\alpha |t - s|). \quad (120)$$

Podemos expresar el proceso estacionario CAR(1), es decir ecuaciones (117) y (119), como una función del MBT⁴²:

$$X(t) = \sqrt{\frac{-\sigma^2}{2\alpha}} e^{\alpha t} W(e^{-2\alpha t}). \quad (121)$$

Obsérvese que los incrementos de este proceso, son gaussianos pero no son independientes. Para comprobar esto, reescribamos (121) por simplicidad como

$$X(t) = g(t) W(\eta(t))$$

donde $g(t) = \sqrt{\frac{-\sigma^2}{2\alpha}} e^{\alpha t}$ y $\eta(t) = e^{-2\alpha t}$.

⁴²Ver Definición 31 y p. 445 de Davidson (1995) para el caso de varianza unitaria, es decir $\sigma = \sqrt{-2\alpha}$.



Proposition 60 *Los incrementos del proceso CAR(1) no son independientes.*

Proof. Definamos $\Delta f(t)$ como

$$\Delta f(t) \equiv f(t) - f(s),$$

podemos reescribir $\Delta X(t)$ como

$$\Delta X(t) = g(t)(W(\eta(t)) - W(\eta(s))) + \Delta g(t)W(\eta(s)).$$

Sea $t \geq s \geq t' \geq s'$, entonces

$$E(\Delta X(t) \Delta X(t')) = \Delta g(t) \Delta(g(t') \eta(t')) \neq 0.$$

■

Obsérvese que podemos expresar la ecuación (117) del siguiente modo⁴³

$$\dot{X}(t) = \alpha X(t) + \sigma \xi(t) \quad (122)$$

donde $\xi(t)$ es el ruido blanco en tiempo continuo. Usando el operador D , o sea

$$D \equiv \frac{d}{dt};$$

podemos escribir la ecuación (122) como

$$(D - \alpha)X(t) = \sigma \xi(t).$$

La solución general es

$$X(t) = f(t) + \frac{1}{D - \alpha} \sigma \xi(t) \quad (123)$$

donde

$$f(t) = x_0 e^{\alpha t}, \quad x_0 \in \mathbb{R}$$

es la solución homogénea de

$$(D - \alpha)X(t) = 0.$$

⁴³No es necesario que X_0 verifique la condición de estacionariedad dada por (119).



Siguiendo exactamente el mismo argumento que el modelo AR(1) discreto, $f(t)$ debe decaer a 0 como $t \rightarrow \infty$. La condición para estacionariedad en el CAR(1) es

$$\alpha < 0. \quad (124)$$

Podemos expresar la solución particular de (123) como⁴⁴

$$\frac{\sigma}{D - \alpha} \xi(t) = \sigma \int_{-\infty}^t e^{\alpha(t-u)} \xi(u) du. \quad (125)$$

Dado la condición (124), podemos ignorar para un t grande la solución homogénea $f(t)$ de (123) y dado (125); tenemos

$$X(t) = \sigma \int_{-\infty}^t e^{\alpha(t-u)} \xi(u) du. \quad (126)$$

que es la solución estacionaria de (123). Podemos calcular la función de covarianza de (126), por tanto tenemos

$$\begin{aligned} K(t, t + \tau) &= \sigma^2 \int_{-\infty}^t \int_{-\infty}^{t+\tau} e^{\alpha(t-u)} e^{\alpha((t+\tau)-v)} \text{cov}(\xi(u), \xi(v)) dv du \\ &= \sigma^2 e^{\alpha(2t+\tau)} \int_{-\infty}^t \int_{-\infty}^{t+\tau} e^{-\alpha(u+v)} \delta(u-v) dv du \\ &= \frac{-\sigma^2}{2\alpha} e^{\alpha(2t+\tau)} \int_{-\infty}^t e^{-2\alpha u} du = \frac{-\sigma^2}{2\alpha} e^{\alpha\tau}. \end{aligned} \quad (127)$$

Obsérvese que en (120) cuando $s = t + \tau$, obtenemos (127). En definitiva, podemos expresar un proceso estacionario CAR(1) como una de las siguientes ecuaciones: (118) y (119) o (121) o (126).

8.4.2 Proceso OU con reversión a la media

Sea la siguiente EDE con $d = 1$, $m = 1$ y $t \in [0, T]$

$$dX(t) = -\alpha(\theta - X(t))dt + \sigma dW(t), \quad X(0) = X_0; \quad \alpha < 0. \quad (128)$$

Obsérvese que este proceso es una extensión del proceso OU, es decir ecuación (117); la magnitud de la velocidad de ajuste $-\alpha > 0$ mide el grado de

⁴⁴Ver Priestley (1981), concretamente p. 163-4. Obsérvese que este procedimiento se aplica al proceso AR(1) (ver también p. 123).



reversión a la media a largo plazo del proceso, representado por θ . Según el Corolario 55, la solución de (128) es

$$X(t) = e^{\alpha t} X_0 + (1 - e^{\alpha t}) \theta + \sigma \int_0^t e^{\alpha(t-s)} dW(s). \quad (129)$$

Según el Teorema 57,

$$m(t) = e^{\alpha t} m(0) + (1 - e^{\alpha t}) \theta;$$

$$K(s, t) = e^{\alpha(t+s)} \left[\text{Var } X_0 + \frac{\sigma^2}{2\alpha} (1 - e^{-2\alpha \min(t,s)}) \right].$$

Por tanto, existe un cambio en la media del proceso respecto al proceso OU

8.4.3 Puente browniano

Sea la siguiente EDE

$$dX(t) = \frac{-1}{1-t} X(t) dt + \sigma dW(t), \quad t \in [0, 1] \quad (130)$$

verificando la condición

$$X(0) = X(1) = 0.$$

Según el Corolario 56,

$$\Phi(t) = 1 - t$$

y la solución de (130) es

$$X(t) = \sigma (1-t) \int_0^t \frac{1}{1-s} dW(s); \quad t \in (0, 1).$$

Aplicando el Teorema 40, podemos escribir la solución como

$$X(t) = \sigma W(t) + \sigma (1-t) \int_0^t (1-s)^{-2} W(s) ds; \quad t \in (0, 1).$$

Dado el Teorema 57, $X(t)$ tiene valor medio

$$m(t) = 0, \quad \forall t$$

y covarianza

$$K(s, t) = \sigma^2 (1-s)(1-t) \left[\frac{1}{1 - \min(s, t)} - 1 \right],$$



entonces

$$K(s, t) = \begin{cases} s(1-t)\sigma^2, & s < t \\ t(1-s)\sigma^2, & s > t. \end{cases}$$

En particular,

$$K(t, t) = t(1-t)\sigma^2.$$

Finalmente, el puente browniano puede identificarse como una transformación del MBS condicionado a $X(1) = 0$, es decir

$$X(t) = \sigma(1-t)W\left(\frac{t}{1-t}\right), \quad t \in (0, 1).$$

Las funciones de media y covarianza son

$$EX(t) = \sigma(1-t)EW\left(\frac{t}{1-t}\right) = 0;$$

y

$$\begin{aligned} E(X(t)X(s)) &= \sigma(1-s)(1-t)E\left(W\left(\frac{t}{1-t}\right)W\left(\frac{s}{1-s}\right)\right) \\ &= \sigma(1-s)(1-t)\min\left(\frac{t}{1-t}, \frac{s}{1-s}\right) \\ &= \begin{cases} s(1-t)\sigma^2; & s < t \\ t(1-s)\sigma^2; & s > t. \end{cases} \end{aligned}$$

Otra versión del puente browniano es

$$X(t) = \sigma(W(t) - tW(1)); \quad t \in [0, 1].$$

8.5 El sistema general de EDELs

Consideremos en primer lugar cuando $d = 1$ y m arbitrario de la ecuación (111) con condición inicial $X(t_0) = X_0$.

8.5.1 Caso para $d=1$

Theorem 61 *El sistema (111) para el caso $d = 1$ tiene la solución*

$$\begin{aligned} X(t) &= \Phi(t) \left(X_0 + \int_{t_0}^t \Phi(s)^{-1} (a(s) - \sum_{i=1}^m B_i(s) b_i(s)) ds \right) \\ &\quad + \Phi(t) \left(\sum_{i=1}^m \int_{t_0}^t \Phi(s)^{-1} b_i(s) dW_i(s) \right); \end{aligned}$$

donde

$$\Phi(t) = \exp \left(\int_{t_0}^t \left(A(s) - \frac{1}{2} \sum_{i=1}^m B_i(s)^2 \right) ds + \sum_{i=1}^m \int_{t_0}^t B_i(s) dW_i(s) \right).$$

Dos casos especiales se muestran en el siguiente Corolario:

Corollary 62 *Supongamos que $d = 1$. Entonces, la solución de (i) ecuación (111) cuando $a(t) = b(t) = 0$, es decir*

$$dX(t) = A(t) X(t) dt + \sum_{i=1}^m B_i(t) X(t) dW_i(t), \quad X(t_0) = X_0;$$

es

$$X(t) = X_0 \exp \left(\int_{t_0}^t \left(A(s) - \frac{1}{2} \sum_{i=1}^m B_i(s)^2 \right) ds \right) \times \exp \left(\sum_{i=1}^m \int_{t_0}^t B_i(s) dW_i(s) \right);$$

(ii) ecuación (111) cuando $a(t) = b(t) = 0$ y $A(t) \equiv A$, $B_i(t) \equiv B_i$, es decir

$$dX(t) = AX(t) dt + \sum_{i=1}^m B_i X(t) dW_i(t), \quad X(t_0) = X_0;$$

es

$$X(t) = X_0 \exp \left(\left(A - \frac{1}{2} \sum_{i=1}^m B_i^2 \right) (t - t_0) \right) \times \exp \left(\sum_{i=1}^m B_i (W_i(t) - W_i(t_0)) \right).$$

Theorem 63 *La solución $X(t)$ de (111) para $d = 1$ tiene, para todo $t \in [t_0, T]$, un momento de orden p si $E |X_0|^p < \infty$. En particular,*

$$(a) \quad m(t) = EX(t) = \varphi(t) \left(EX_0 + \int_{t_0}^t \varphi(s)^{-1} a(s) ds \right)$$

donde

$$\varphi(t) = \exp \left(\int_{t_0}^t A(s) ds \right).$$

(b) $P(t) = EX^2(t)$ es la solución única de la ecuación diferencial ordinaria

$$\begin{aligned} \dot{P}(t) &= (2A(t) + \sum_{i=1}^m B_i(t)^2) P(t) \\ &\quad + 2m(t) (a(t) + \sum_{i=1}^m B_i(t) b_i(t)) + \sum_{i=1}^m b_i(t)^2. \end{aligned}$$

con condición inicial

$$P(t_0) = EX_0^2.$$

Example 64 Sea la siguiente EDE escalar

$$dX(t) = -\frac{1}{2}X(t)dt + X(t)dW_1(t) + X(t)dW_2(t), \quad t \in [0, T]$$

donde $W_1(t)$ y $W_2(t)$ son procesos de Wiener independientes. Entonces, la solución según el Corolario 62

$$X(t) = X_0 \exp\left(-\frac{3}{2}t + W_1(t) + W_2(t)\right).$$

Según el Teorema 63, los valores de $m(t)$ y $P(t)$ para el proceso de arriba son:

$$m(t) = e^{-t/2}m(0);$$

$$P(t) = P(0)e^t;$$

por tanto la varianza es

$$\text{Var} X(t) = P^2(0)e^{2t} - m^2(0)e^{-t}.$$

8.5.2 Caso para d arbitrario

Theorem 65 El sistema (111) con condición inicial $X(t_0) = X_0$ tiene sobre $[t_0, T]$ la solución

$$X(t) = \Phi(t) \left(X_0 + \int_{t_0}^t \Phi(s)^{-1} dY(s) \right) \quad (131)$$

donde

$$dY(t) = \left(a(t) - \sum_{i=1}^m B_i(t) b_i(t) \right) dt + \sum_{i=1}^m b_i(t) dW_i(t)$$

y la matriz $\Phi(t)$ de orden $d \times d$ es la solución de la EDE

$$d\Phi(t) = A(t)\Phi(t)dt + \sum_{i=1}^m B_i(t)\Phi(t)dW_i(t)$$

con valor inicial

$$\Phi(t_0) = I.$$

Theorem 66 Para la solución (194) del sistema (111), bajo el supuesto $E |X_0|^2 < \infty$, $m(t) = E X(t)$ es la solución única de la ecuación

$$\dot{m}(t) = A(t) m(t) + a(t), \quad m(t_0) = E X_0$$

y $E X(t) X(t)' = P(t)$ es la única solución simétrica definida no negativa del sistema

$$\begin{aligned} \dot{P}(t) &= A(t) P(t) + P(t) A(t)' + a(t) m(t)' + m(t) a(t)' \\ &+ \sum_{i=1}^m (B_i(t) P(t) B_i(t)' + B_i(t) m(t) b_i(t)') \\ &+ \sum_{i=1}^m (b_i(t) m(t)' B_i(t)' + b_i(t) b_i(t)'). \end{aligned}$$

con valor inicial

$$P(t_0) = E X_0 X_0'.$$

Example 67 Sea la EDEL de dimensión dos

$$dX(t) = \begin{pmatrix} 0 & -1 \\ 1 & 0 \end{pmatrix} X(t) dt + \begin{pmatrix} 0 \\ \sigma \end{pmatrix} dW(t), \quad t \in [0, T]$$

donde $X(t) = (X_1(t), X_2(t))'$ y $W(t)$ es un proceso de Wiener escalar. Según el Teorema 65, la matriz fundamental de este proceso verifica que

$$d\Phi(t) = A(t) \Phi(t) dt,$$

$$\Phi(0) = I,$$

entonces

$$\Phi(t) = e^{At} = \begin{pmatrix} \cos(t) & -\sin(t) \\ \sin(t) & \cos(t) \end{pmatrix}.$$

La solución es

$$\begin{pmatrix} X_1(t) \\ X_2(t) \end{pmatrix} = \begin{pmatrix} \cos(t) & -\sin(t) \\ \sin(t) & \cos(t) \end{pmatrix} \left[\begin{pmatrix} X_1(0) \\ X_2(0) \end{pmatrix} + \sigma \int_0^t \begin{pmatrix} \sin(u) \\ \cos(u) \end{pmatrix} dW(u) \right].$$

Según el Teorema 66, $m(t)$ es

$$m(t) = \Phi(t) X_0$$

y $P(t)$ es la solución de

$$\dot{P}(t) = AP(t) + P(t) A' + bb'$$

donde $b = (0, \sigma)'$.



Universitat d'Alacant
Universidad de Alicante

8.6 Modelos CAR

8.6.1 Introducción

Sea la siguiente EDE:

$$X^{(k)}(t) = \alpha_1 X^{(k-1)}(t) + \dots + \alpha_k X(t) + \xi(t) \quad (132)$$

donde

$$X^{(k)}(t) \equiv \left(\frac{d}{dt}\right)^k X(t) \equiv D^k X(t);$$

y $\alpha_1, \dots, \alpha_k$ son constantes. Definimos la ecuación (132) como un proceso CAR(k). (132) puede escribirse como

$$d[D^{k-1}X(t)] = \alpha_1 D^{k-1}X(t)dt + \dots + \alpha_{k-1}DX(t)dt + \alpha_k X(t)dt + dW(t). \quad (133)$$

A partir de (133) obtenemos

$$D^{k-1}X(t) - D^{k-1}X(0) = \int_{-\infty}^t [\alpha_1 D^{k-1}X(s) + \dots + \alpha_{k-1}DX(s) + \alpha_k X(s)] ds + W(t). \quad (134)$$

Podemos expresar (134) como un proceso VAR(1) continuo, es decir, como el sistema (112) :

$$\begin{aligned} & \begin{bmatrix} D^{k-1}X(t) \\ D^{k-2}X(t) \\ \vdots \\ X(t) \end{bmatrix} - \begin{bmatrix} D^{k-1}X(0) \\ D^{k-2}X(0) \\ \vdots \\ X(0) \end{bmatrix} = \\ & \int_{-\infty}^t \left\{ \begin{bmatrix} \alpha_1 & \alpha_2 & \alpha_3 & \dots & \alpha_{k-1} & \alpha_k \\ 0 & 0 & 1 & \dots & 0 & 0 \\ \cdot & \cdot & \cdot & & \cdot & \cdot \\ \cdot & \cdot & \cdot & & \cdot & \cdot \\ \cdot & \cdot & \cdot & & \cdot & \cdot \\ 0 & 0 & 0 & \dots & 1 & 0 \end{bmatrix} \begin{bmatrix} D^{k-1}X(s) \\ D^{k-2}X(s) \\ \cdot \\ \cdot \\ \cdot \\ X(s) \end{bmatrix} \right\} ds + \begin{bmatrix} W(t) \\ 0 \\ \cdot \\ \cdot \\ \cdot \\ 0 \end{bmatrix}. \quad (135) \end{aligned}$$



Usando el operador diferencial, D , podemos escribir (132) como

$$\alpha_k(D) X(t) = \xi(t)$$

donde

$$\alpha_k(z) = z^k - \alpha_1 z^{k-1} - \dots - \alpha_k.$$

La condición de estacionariedad es que todas las raíces de $\alpha(z)$ tengan partes reales negativas. La función de autocorrelación, $\rho(\tau)$, verifica la ecuación diferencial

$$\alpha_k(D) \rho(\tau) = 0, \quad \tau \geq 0 \quad (136)$$

y la solución es de la forma,

$$\rho(\tau) = \sum_{i=1}^k \gamma_i \exp(c_i | \tau |), \quad (137)$$

donde $\gamma_1, \dots, \gamma_k$ son constantes, y $c_1, \dots, c_k$ son las raíces (se asumen distintas).

8.6.2 Proceso CAR(2)

Sea la EDE con $d = 1$, $m = 1$:

$$\ddot{X}(t) = \alpha_1 \dot{X}(t) + \alpha_2 X(t) + \xi(t); \quad t \in [0, T]. \quad (138)$$

La solución completa de (138) es

$$X(t) = f(t) + (D^2 - \alpha_1 D - \alpha_2)^{-1} \xi(t),$$

donde $f(t)$ es la solución de la ecuación homogénea

$$(D^2 - \alpha_1 D - \alpha_2) X(t) = 0$$

y es diferente dependiendo de las raíces c_1, c_2 de

$$\alpha_2(z) = z^2 - \alpha_1 z - \alpha_2.$$

Por tanto,

$$f(t) = \begin{cases} a_1 e^{c_1 t} + a_2 e^{c_2 t}, & c_1, c_2 \in \mathbb{R} \text{ and } c_1 \neq c_2; \\ a_1 e^{c_1 t} + a_2 t e^{c_1 t}, & c_1, c_2 \in \mathbb{R} \text{ and } c_1 = c_2; \\ A_1 e^{c_1 t} + A_2 t e^{c_2 t}, & c_1, c_2 \in \mathbb{C}; \end{cases}$$



donde $a_1, a_2 \in \mathbb{R}$ y A_1, A_2 son números complejos conjugados definidos como $a+bi$ y $a-bi$ respectivamente, tal que $a, b \in \mathbb{R}$. Para garantizar la estacionariedad, $f(t)$ debe decaer a 0 como $t \rightarrow \infty$, que implica que las raíces tengan partes reales negativas. Comentamos ahora el caso de raíces complejas. Las raíces complejas son:

$$c_1 = \lambda + \theta i; \quad c_2 = \lambda - \theta i$$

donde

$$\lambda = \alpha_1/2; \quad \theta = \frac{1}{2}\sqrt{-(\alpha_1^2 + 4\alpha_2)} = \sqrt{-(\alpha_2 + \alpha_1^2/4)}.$$

Entonces⁴⁵

$$\begin{aligned} f(t) &= A_1 e^{c_1 t} + A_2 t e^{c_2 t} = e^{\lambda t} (A_1 e^{i\theta t} + A_2 e^{-i\theta t}) \\ &= e^{\lambda t} [(A_1 + A_2) \cos(\theta t) + i(A_1 - A_2) \sin(\theta t)] \\ &= e^{\lambda t} (B_1 \cos(\theta t) + B_2 \sin(\theta t)) = B e^{\lambda t} \cos(\theta t - \vartheta); \end{aligned}$$

donde $B_1 \equiv A_1 + A_2 = 2a$; $B_2 \equiv i(A_1 - A_2) = -2b$ y las nuevas constantes B y ϑ se obtienen a partir de

$$\cos(\vartheta) = B_1/B, \quad \sin(\vartheta) = B_2/B.$$

La solución estacionaria de (138) puede escribirse del siguiente modo:

$$\begin{aligned} X(t) &= ((D - c_1)(D - c_2))^{-1} \xi(t) \\ &= \frac{1}{c_1 - c_2} \left(\frac{1}{D - c_1} - \frac{1}{D - c_2} \right) \xi(t), \end{aligned}$$

entonces dado (125), la expresión anterior puede escribirse como

$$\begin{aligned} X(t) &= \int_{-\infty}^t \left(\frac{\exp(c_1(t-u)) - \exp(c_2(t-u))}{c_1 - c_2} \right) \xi(u) du \\ &= \int_{-\infty}^t \left(\frac{\exp(c_1(t-u)) - \exp(c_2(t-u))}{c_1 - c_2} \right) dW(u). \end{aligned}$$

⁴⁵Para la siguiente expresión de $f(t)$ téngase en cuenta el resultado: $e^{\pm i\theta t} = \cos(\theta t) \pm i \sin(\theta t)$.

La función de autocorrelación verifica, según (136), la siguiente ecuación diferencial

$$\ddot{\rho}(\tau) - \alpha_1 \dot{\rho}(\tau) - \alpha_2 \rho(\tau) = 0, \quad \tau \geq 0$$

cuya solución (137) es

$$\rho(\tau) = \gamma_1 \exp(c_1 \tau) + \gamma_2 \exp(c_2 \tau), \quad \tau \geq 0.$$

Como $\rho(0) = 1$, $\dot{\rho}(0) = 0$; obtenemos los valores de γ_1 y γ_2 , entonces

$$\rho(\tau) = \frac{c_2 \exp(c_1 \tau) - c_1 \exp(c_2 \tau)}{c_2 - c_1}.$$

Dependiendo de si las raíces c_1, c_2 , son reales o complejas. Tenemos los siguientes casos:

- (a) *Raíces reales:* $\rho(\tau)$ decae a cero en una forma exponencial suave.
- (b) *Raíces complejas:* $\rho(\tau)$ puede escribirse como

$$\rho(\tau) = \exp\left(\frac{\alpha_1 \tau}{2}\right) \left[\frac{\cos(\theta \tau + \phi)}{\cos(\phi)} \right],$$

donde

$$\phi = \arctan\left(\frac{\alpha_1}{2\theta}\right).$$

9 Los procesos continuos MA(q) y ARMA(k, q)

Definamos el *modelo continuo* MA(q), es decir CMA(q), por

$$X(t) = \int_0^q b(u) \xi(t-u) du \quad (139)$$

donde $b(u)$ es alguna función dada y $\xi(\cdot)$ es la derivada del proceso de Wiener. Podemos expresar (139) en términos del operador diferencial D , del mismo modo que en el proceso CAR(k); pero se introduce de un modo diferente. Haciendo una expansión de Taylor⁴⁶ sobre $\xi(t-u)$,

$$\xi(t-u) = \left(1 - \frac{uD}{1!} + \frac{u^2 D^2}{2!} - \dots\right) \xi(t) = \exp(-uD) \xi(t); \quad (140)$$

⁴⁶Ver Priestley (1984), p. 175 del capítulo 3.



por tanto el operador es $\exp(-uD)$. Dado (139) y (140), obtenemos

$$X(t) = \left\{ \int_0^q b(u) \exp(-uD) du \right\} \xi(t) \equiv B(D) \xi(t). \quad (141)$$

Obsérvese que $B(D)$ no es una función racional, por tanto reemplazamos la función $B(z)$ por el polinomio de orden finito, $\theta_q(z)$, donde

$$\theta_q(z) \equiv \theta_0 z^q + \theta_1 z^{q-1} + \dots + \theta_q;$$

entonces expresamos (141) como

$$X(t) = \theta_q(D) \xi(t) = \theta_0 \xi^{(q)}(t) + \theta_1 \xi^{(q-1)}(t) + \dots + \theta_q \xi(t) \quad (142)$$

donde $\xi^{(i)}(t)$ es la derivada i -ésima del proceso de ruido blanco en tiempo continuo.

Definimos el *modelo ARMA(k, q) continuo*, o sea *CARMA(k, q)*, como

$$X^{(k)}(t) - \alpha_1 X^{(k-1)}(t) - \dots - \alpha_k X(t) = \theta_0 \xi^{(q)}(t) + \theta_1 \xi^{(q-1)}(t) + \dots + \theta_q \xi(t); \quad (143)$$

entonces usando el operador diferencial obtenemos

$$\alpha_k(D) X(t) = \theta_q(D) \xi(t),$$

donde

$$X(t) = \frac{\theta_q(D)}{\alpha_k(D)} \xi(t) \equiv H(D) \xi(t). \quad (144)$$

Como $\xi(t)$ y sus derivadas, o sea $\xi^{(i)}(t)$, no existen en el sentido usual; el proceso *CARMA(k, q)* (con $0 \leq q < k$) definido en (143) puede interpretarse como equivalente a las ecuaciones de *observación y estado*⁴⁷:

$$X(t) = \theta' Y(t) \quad (145)$$

donde

$$\theta = (\theta_0, \theta_1, \dots, \theta_{k-1})'_{k \times 1}; \quad \theta_j = 0 \quad \forall j > q$$

y

$$dY(t) = AY(t) dt + b dW(t) \quad (146a)$$

⁴⁷ Ver el filtro de Kalman aplicado al proceso discreto (k,q) en Hamilton (1994).



donde

$$\mathbf{Y}(t) = (Y(t), Y^{(1)}(t), \dots, Y^{(k-1)}(t))'_{k \times 1};$$

$$A = \begin{pmatrix} 0 & 1 & 0 & \cdots & 0 \\ 0 & 0 & 1 & \cdots & 0 \\ \cdot & \cdot & \cdot & \cdot & \cdot \\ \cdot & \cdot & \cdot & \cdot & \cdot \\ \cdot & \cdot & \cdot & \cdot & \cdot \\ 0 & 0 & 0 & \cdots & 1 \\ \alpha_k & \alpha_{k-1} & \alpha_{k-2} & \cdots & \alpha_1 \end{pmatrix}_{k \times k};$$

$$b = (0, 0, \dots, 1)'_{k \times 1}$$

y $W(\cdot)$ es un proceso de Wiener unidimensional. Obsérvese que la última ecuación de (146a) es

$$dY^{(k)}(t) = \alpha_1 Y^{(k-1)}(t) dt + \dots + \alpha_k Y(t) dt + dW(t)$$

que puede expresarse también como

$$Y(t) = (D^k - \alpha_1 D^{k-1} - \dots - \alpha_k)^{-1} \xi(t). \quad (147)$$

Podemos expresar (145) como

$$X(t) = (\theta_0 + \theta_1 D + \dots + \theta_{k-1} D^{k-1}) Y(t)$$

entonces

$$X(t) = \frac{(\theta_0 + \theta_1 D + \dots + \theta_{k-1} D^{k-1})}{(D^k - \alpha_1 D^{k-1} - \dots - \alpha_k)} \xi(t); \quad \theta_j = 0 \quad \forall j > q$$

que es la ecuación (144).

La solución de (146a) puede escribirse según el Corolario 55 como

$$\mathbf{Y}(t) = e^{At} \mathbf{Y}(0) + \int_0^t e^{A(t-s)} b dW(s) \quad (148)$$

que es estrictamente estacionario sii

$$\mathbf{Y}(0) \sim N(0, \Omega)$$



donde

$$\Omega = \int_0^\infty e^{At} b b' e^{A't} dt.$$

Dado el Teorema 59, la matriz de covarianza de (148) es

$$K_Y(s, t) = \begin{cases} e^{A(s-t)} \Omega, & s \geq t; \\ \Omega e^{A'(t-s)}, & s \leq t. \end{cases}$$

Por tanto, la función de covarianza para el proceso $X(\cdot)$ es

$$K_X(s, t) = \begin{cases} \theta' e^{A(s-t)} \Omega \theta, & s \geq t; \\ \theta' \Omega e^{A'(t-s)} \theta, & s \leq t. \end{cases}$$

Para terminar esta sección, podemos reopresentar un proceso CARMA(k, q) con $q < k$ como la primera componente de un CAR(1)⁴⁸ de orden k . Sea $X(t)$ la primera componente de $\mathbf{X}(t)$, o sea

$$X(t) = (1, 0, \dots, 0) \mathbf{X}(t); \quad t \geq 0$$

y $\mathbf{X}(t)$ verifica la ecuación de estado

$$d\mathbf{X}(t) = B A B^{-1} \mathbf{X}(t) dt + B b dW(t)$$

donde

$$B = \begin{pmatrix} \theta_0 & \theta_1 & \theta_2 & \cdots & \theta_{k-1} \\ 0 & 1 & 0 & \cdots & 0 \\ 0 & 0 & 1 & \cdots & 0 \\ \cdot & \cdot & \cdot & \cdot & \cdot \\ \cdot & \cdot & \cdot & \cdot & \cdot \\ \cdot & \cdot & \cdot & \cdot & \cdot \\ 0 & 0 & 0 & \cdots & 1 \end{pmatrix}_{k \times k}.$$

⁴⁸Ver Brockwell (1995).

10 Análisis espectral para procesos en tiempo continuo

10.1 Definiciones

La *función de densidad espectral normalizada* (f_{den}) para un proceso en tiempo continuo $X(\cdot)$ se define como

$$\begin{aligned} f(\omega) &= \frac{1}{2\pi} \int_{-\infty}^{+\infty} e^{-i\omega\tau} \rho(\tau) d\tau \\ &= \frac{1}{2\pi} \int_{-\infty}^{+\infty} \cos(\omega\tau) \rho(\tau) d\tau. \end{aligned} \quad (149)$$

donde $\rho(\tau)$ es la función de autocorrelación de $X(\cdot)$, es decir $\rho(\tau) \equiv K(\tau)/\sigma_X^2$; donde $K(\tau) \equiv K(s, t)$ tal que $\tau = s - t$ y $\sigma_X^2 \equiv K(0)$. Definimos la *función de densidad espectral no-normalizada* como (f_{den}) $h(\omega)$ como

$$h(\omega) = \sigma_X^2 f(\omega). \quad (150)$$

Se verifica que $\rho(\tau)$ es la transformación de Fourier de $f(\omega)$ ⁴⁹, o sea

$$\rho(\tau) = \int_{-\infty}^{+\infty} e^{i\omega\tau} f(\omega) d\omega.$$

Definimos el *espectro integrado normalizado*, $F(\omega)$, por

$$F(\omega) = \int_{-\infty}^{\omega} f(\theta) d\theta,$$

por tanto

$$f(\omega) = dF(\omega)/d\omega.$$

Las propiedades de $f(\omega)$ son las siguientes:

- (1) $\int_{-\infty}^{+\infty} f(\omega) d\omega = 1$;
- (2) $f(\omega) \geq 0, \quad \forall \omega$;
- (3) $f(-\omega) = f(\omega), \quad \forall \omega$.

⁴⁹ $K(\tau)$ es la transformación de Fourier de $h(\omega)$.



Y las propiedades de $F(\omega)$ son:

$$\begin{aligned} (1') \quad & 0 \leq F(\omega) \leq 1, \quad \forall \omega; \\ (2') \quad & F(-\infty) = 0, \quad F(+\infty) = 1; \\ (3') \quad & \omega_1 > \omega_2 \Rightarrow F(\omega_1) \geq F(\omega_2). \end{aligned}$$

Según las propiedades anteriores, $f(\omega)$ y $F(\omega)$ tienen todas las propiedades de las funciones de densidad y distribución respectivamente.

10.2 Filtros

Supongamos que los procesos en tiempo continuo $X(\cdot)$ y $Y(\cdot)$ están relacionados por una ecuación de la forma

$$X(t) = \theta(D)Y(t) \quad (151)$$

donde $\theta(D)$ se conoce como la *función de transferencia* y $X(t)$ es una "versión filtrada" de $Y(t)$, entonces

$$\sigma_X^2 f_X(\omega) = \sigma_Y^2 |\theta(i\omega)|^2 f_Y(\omega) \quad (152)$$

donde

$$|\theta(i\omega)|^2 = \theta(i\omega)\theta(-i\omega).$$

En los siguientes ejemplos sea $Y(\cdot) \equiv \xi(\cdot)$, es decir el ruido blanco en tiempo continuo. Para este proceso estocástico en tiempo continuo, se verifica que la función de correlación es:

$$\rho_\xi(\tau) = \begin{cases} 1, & \tau = 0; \\ 0, & \tau \neq 0. \end{cases}$$

Entonces, dado (149) obtenemos

$$f_\xi(\omega) = 0, \quad \forall \omega;$$

y dado (150) y (84)

$$h_\xi(\omega) = \frac{1}{2\pi}, \quad \forall \omega. \quad (153)$$



Una función de transferencia definida como (151) es el proceso CMA(q), o sea (142)

$$X(t) = (\theta_0 D^q + \theta_1 D^{q-1} + \dots + \theta_q) \xi(t) \equiv \theta(D) \xi(t),$$

entonces, según (152)

$$\sigma_X^2 f_X(\omega) = \frac{1}{2\pi} |\theta_0 (i\omega)^q + \theta_1 (i\omega)^{q-1} + \dots + \theta_q|^2.$$

Si tenemos la siguiente relación,

$$\alpha(D) X(t) = Y(t) \quad (154)$$

entonces

$$\sigma_X^2 f_X(\omega) = \sigma_Y^2 \frac{1}{|\alpha(i\omega)|^2} f_Y(\omega). \quad (155)$$

Una función de transferencia definida como (154) donde $Y(\cdot) \equiv \xi(\cdot)$ es el proceso CAR(k), o sea (132)

$$(D^k - \alpha_1 D^{k-1} - \dots - \alpha_k) X(t) = \xi(t)$$

donde

$$\alpha(D) = D^k - \alpha_1 D^{k-1} - \dots - \alpha_k,$$

entonces según (155)

$$\sigma_X^2 f_X(\omega) = \frac{1}{2\pi} \frac{1}{|(i\omega)^k - \alpha_1 (i\omega)^{k-1} - \dots - \alpha_k|^2}.$$

Finalmente, si tenemos

$$\alpha(D) X(t) = \theta(D) \xi(t) \quad (156)$$

entonces

$$\sigma_X^2 f_X(\omega) = \sigma_Y^2 \frac{|\theta(i\omega)|^2}{|\alpha(i\omega)|^2} f_Y(\omega). \quad (157)$$

Una función de transferencia se define como (156) donde $Y(\cdot) \equiv \xi(\cdot)$ es el proceso CARMA(k, q), es decir (143)

$$(D^k - \alpha_1 D^{k-1} - \dots - \alpha_k) X(t) = (\theta_0 D^q + \theta_1 D^{q-1} + \dots + \theta_q) \xi(t)$$

entonces según (157)

$$\sigma_X^2 f_X(\omega) = \frac{1}{2\pi} \frac{|\theta_0 (i\omega)^q + \theta_1 (i\omega)^{q-1} + \dots + \theta_q|^2}{|(i\omega)^k - \alpha_1 (i\omega)^{k-1} - \dots - \alpha_k|^2}.$$

10.3 Convergencia de espectros de procesos discretos a espectros de procesos continuos

En esta sección estamos interesados en la forma de generar un procesos continuos a partir de procesos dado la relación entre los espectros de los dos procesos. Sea $Y(t)$ un proceso continuo estacionario con fden

$$f_Y(\omega) = \frac{1}{2\pi} \int_{-\infty}^{+\infty} \rho_Y(\tau) \cos(\omega\tau) d\tau, \quad -\infty < \omega < \infty$$

donde $\rho_Y(\tau)$ es la función de autocorrelación de $Y(t)$. Sea $\{X_t\}$ un proceso en tiempo discreto estacionario que se obtiene muestreando $Y(t)$ en intervalos de longitud h , o sea

$$X_t \equiv Y(th), \quad t = 0, \pm 1, \pm 2, \dots$$

Su fden es

$$f_X(\omega) = \frac{1}{2\pi} \sum_{r=-\infty}^{+\infty} \rho_r \cos(\omega r), \quad |\omega| \leq \pi$$

donde $\{\rho_r; r = 0, \pm h, \pm 2h, \dots\}$ es la función de autocorrelación de X_t . Sea $Z(t)$ un proceso estacionario en tiempo continuo del proceso discreto anterior⁵⁰. Su fden es

$$f_Z(\omega) = \frac{1}{2\pi} \int_{-\infty}^{+\infty} \rho_Z(\tau) \cos(\omega\tau) d\tau, \quad -\infty < \omega < \infty$$

donde $\rho_Z(\tau)$ es la función de autocorrelación de $Z(t)$ definida como

$$\rho_Z(\tau) = \frac{h+r-\tau}{h} \rho_r + \frac{\tau-r}{h} \rho_{r+h}, \quad \tau \in [r, r+h)$$

y

$$\rho_Z(\tau) = \rho_Z(-\tau), \quad \forall \tau.$$

Expresando $f_Z(\omega)$ en términos de $f_X(\omega)$, obtenemos⁵¹

$$f_Z(\omega) = h \left[\frac{\sin(\omega h/2)}{\omega h/2} \right]^2 f_X(\omega h), \quad (158)$$

⁵⁰Ver Priestley (1963).

⁵¹Ver Priestley (1963).



entonces

$$\lim_{h \rightarrow 0} f_Z(\omega) = f_Y(\omega).$$

Finalmente, obsérvese que si estamos interesados en ir del tiempo continuo al tiempo discreto, podemos encontrar muchos procesos continuos que generan el mismo proceso en tiempo discreto, esto se conoce como el "efecto alisado".

11 Expansiones de Taylor estocásticas

11.1 Caso determinístico

Sea la siguiente ecuación diferencial de primer orden determinística

$$\frac{d}{dt} X(t) = f(X(t)), \quad t \in [t_0, T].$$

Podemos escribir en la forma de la ecuación de la integral equivalente, es decir

$$X(t) = X(t_0) + \int_{t_0}^t f(X(s)) ds. \quad (159)$$

Sea f suficientemente suave y cota de crecimiento lineal, y $u : \mathbb{R} \rightarrow \mathbb{R}$ una función continuamente diferenciable. Aplicando la regla de la cadena tenemos

$$\frac{d}{dt} u(X(t)) = f(X(t)) \frac{\partial}{\partial x} u(X(t)). \quad (160)$$

Usando el operador

$$L = f \frac{\partial}{\partial x},$$

podemos expresar (160) como

$$u(X(t)) = u(X(t_0)) + \int_{t_0}^t Lu(X(s)) ds. \quad (161)$$

Cuando $u(x) = x$, tenemos $Lu = f$, $L^2u = Lf$, ... y (161) se reduce a la ecuación (159). Aplicando (161) a la función $u = f$ en la ecuación (159), obtenemos

$$\begin{aligned} X(t) &= X(t_0) + \int_{t_0}^t \left[f(X(t_0)) + \int_{t_0}^s Lf(X(z)) dz \right] ds \\ &= X(t_0) + f(X(t_0))(t - t_0) + \int_{t_0}^t \int_{t_0}^s Lf(X(z)) dz ds. \end{aligned}$$

Aplicando (161) a la función $g = Lf$ en la última ecuación, obtenemos

$$\begin{aligned} X(t) &= X(t_0) + f(X(t_0))(t - t_0) + \int_{t_0}^t \int_{t_0}^s Lf(X(t_0)) dz ds \\ &\quad + \int_{t_0}^t \int_{t_0}^s \int_{t_0}^z L^2 f(X(u)) du dz ds. \end{aligned}$$

Sea

$$R_3 = \int_{t_0}^t \int_{t_0}^s \int_{t_0}^z L^2 f(X(u)) du dz ds,$$

entonces podemos escribir la última ecuación como

$$X(t) = X(t_0) + (t - t_0) f(X(t_0)) + \frac{1}{2} (t - t_0)^2 Lf(X(t_0)) + R_3.$$

Para una función general u continuamente diferenciable $r + 1$ veces, obtenemos la *fórmula de Taylor en forma integral*

$$\begin{aligned} u(X(t)) &= u(X(t_0)) + \sum_{j=1}^r \frac{(t-t_0)^j}{j!} L^j u(X(t_0)) \\ &\quad + \int_{t_0}^t \cdots \int_{t_0}^{s_2} L^{r+1} u(X(s_1)) ds_1 \dots ds_{r+1} \end{aligned}$$

para $t \in [t_0, T]$ y $r = 1, 2, 3, \dots$

11.2 Caso estocástico (Expansión Ito-Taylor)

Consideremos la solución $X(t)$ de la siguiente EDE unidimensional

$$X(t) = X(t_0) + \int_{t_0}^t f(X(s)) ds + \int_{t_0}^t G(X(s)) dW(s) \quad (162)$$

para $t \in [t_0, T]$, donde f y G verifican una cota de crecimiento lineal. Entonces, para cualquier función $u : R \rightarrow R$ continua y diferenciable dos veces, aplicando el lema de Ito

$$u(X(t)) = u(X(t_0)) + \int_{t_0}^t L^0 u(X(s)) ds + \int_{t_0}^t L^1 u(X(s)) dW(s),$$



donde

$$L^0 = f \frac{\partial}{\partial x} + \frac{1}{2} G^2 \frac{\partial^2}{\partial x^2};$$

$$L^1 = G \frac{\partial}{\partial x}.$$

Aplicando el lema de Ito a las funciones $u = f$ y $u = G$ en (162) :

$$X(t) = X(t_0) + f(X(t_0)) \int_{t_0}^t ds + G(X(t_0)) \int_{t_0}^t dW(s) + R, \quad (163)$$

donde el conjunto "remainder" R es

$$\begin{aligned} R = & \int_{t_0}^t \int_{t_0}^s L^0 f(X(z)) dz ds + \int_{t_0}^t \int_{t_0}^s L^1 f(X(z)) dW(z) ds \\ & + \int_{t_0}^t \int_{t_0}^s L^0 G(X(z)) dz dW(s) + \int_{t_0}^t \int_{t_0}^s L^1 G(X(z)) dW(z) dW(s). \end{aligned}$$

Aplicando el lema de Ito a $u = L^1 G$ en (163) :

$$\begin{aligned} X(t) = & X(t_0) + f(X(t_0)) \int_{t_0}^t ds + G(X(t_0)) \int_{t_0}^t dW(s) \\ & + L^1 G(X(t_0)) \int_{t_0}^t \int_{t_0}^s dW(z) dW(s) + \bar{R} \end{aligned}$$

con "remainder"

$$\begin{aligned} \bar{R} = & \int_{t_0}^t \int_{t_0}^s L^0 f(X(z)) dz ds + \int_{t_0}^t \int_{t_0}^s L^1 f(X(z)) dW(z) ds \\ & + \int_{t_0}^t \int_{t_0}^s L^0 G(X(z)) dz dW(s) + \int_{t_0}^t \int_{t_0}^s \int_{t_0}^z L^0 L^1 G(X(u)) du dW(u) dW(s) \\ & + \int_{t_0}^t \int_{t_0}^s \int_{t_0}^z L^1 L^1 G(X(u)) dW(u) dW(z) dW(s). \end{aligned}$$

Obsérvese que tenemos una expansión con varias integrales de Ito múltiples, en concreto

$$\int_{t_0}^t ds, \quad \int_{t_0}^t dW(s), \quad \int_{t_0}^t \int_{t_0}^s dW(z) dW(s).$$

Ahora formulamos la expansión de the Ito-Taylor para una función general $u(t, X(t))$ donde $X(t)$ es una EDE de dimensión d no-autónoma⁵², o sea

$$dX(t) = f(t, X(t)) dt + G(t, X(t)) dW(t)$$

donde f y G son matrices respectivamente de órdenes $d \times 1$ y $d \times m$ y $W(\cdot)$ es un proceso de Wiener de dimensión m . La expansión Ito-Taylor⁵³ es

$$u(t, X(t)) = \sum_{\lambda \in \mathcal{A}} I_{\lambda} [u_{\lambda}(\tau, X(\tau))]_{\tau, t} + \sum_{\lambda \in \mathcal{B}(\mathcal{A})} I_{\lambda} [u_{\lambda}(\cdot, X(\cdot))]_{\tau, t} \quad (164)$$

donde $t_0 \leq \tau \leq t \leq T$. Definimos la expansión de Ito-Taylor truncada como

$$u(t, X(t)) = \sum_{\lambda \in \mathcal{A}} I_{\lambda} [u_{\lambda}(\tau, X(\tau))]_{\tau, t}. \quad (165)$$

Example 68 Apliquemos la expansión de Ito-Taylor truncada en el caso $d = m = 1$ para $u(t, x) = x$ y el conjunto "hierarchical"

$$\mathcal{A} = \{v, (0), (1), (0, 0), (0, 1), (1, 0), (1, 1), (1, 1, 1)\}$$

a la EDE (162).

1. En primer lugar, calculemos las funciones coeficientes de Ito de u . Tenemos:

$$\begin{aligned} u_v &= u, & u_{(0)} &= L^0 u = f, \\ u_{(1)} &= L^1 u = G, & u_{(0,1)} &= L^0 G = fG' + \frac{1}{2}G^2G'', \\ u_{(1,0)} &= L^1 f = Gf', & u_{(0,0)} &= L^0 f = ff' + \frac{1}{2}G^2f'', \\ u_{(1,1)} &= L^1 G = GG', & u_{(1,1,1)} &= L^1 GG' = G(G'^2 + GG''). \end{aligned}$$

2. La expansión de Ito-Taylor truncada es:

$$\begin{aligned} X(t) &= X(\tau) + f(X(\tau)) I_{(0)} + G(X(\tau)) I_{(1)} + [fG' + \frac{1}{2}G^2G''] (X(\tau)) I_{(0,1)} \\ &+ [Gf'] (X(\tau)) I_{(1,0)} + [ff' + \frac{1}{2}G^2f''] (X(\tau)) I_{(0,0)} + [GG'] (X(\tau)) I_{(1,1)} \\ &+ \left[G(G'^2 + GG'') \right] (X(\tau)) I_{(1,1,1)}. \end{aligned}$$

⁵²Cuando f y G de (162) dependen explícitamente de t , o sea $f = f(t, x)$ y $G = G(t, x)$.

⁵³Ver Sección Apéndice 13.6 para entender la expansión generalizada de la fórmula de Ito-Taylor, o sea la ecuación (164), y los ejemplos de la ecuación (165).

Example 69 Sea el conjunto "hierarchical" $\mathcal{A} = \{v\}$ que tiene como resto el conjunto

$$\mathcal{B}(\{v\}) = \{(0), (1), \dots, (m)\}$$

entonces (164) se reduce a la familia de Ito, o sea

$$\begin{aligned} u(t, X(t)) &= u(\tau, X(\tau)) + \int_{\tau}^t L^0 u(s, X(s)) ds \\ &\quad + \sum_{j=1}^m \int_{\tau}^t L^j u(s, X(s)) dW_j(s) \end{aligned}$$

donde L^0 y L^j están definidos en (100).

Example 70 Sea $d = 1$, $u(t, x) = u(x)$, $f = 1$, $G = 0$, $t_0 = \tau$ y $X(t_0) = t_0$ entonces obtenemos de (162)

$$X(t) = t, \quad t \in [t_0, T].$$

Tomando como conjunto "hierarchical"

$$\Gamma_k = \{\lambda \in \mathcal{M} : l(\lambda) \leq k\}, \quad k = 1, 2, \dots$$

entonces

$$\mathcal{B}(\Gamma_k) = \{\lambda \in \mathcal{M} : l(\lambda) = k + 1\}$$

y la ecuación (164) es la expansión determinística de Taylor. Vamos a mostrar esto, obsérvese que:

(i) Como $m = 0$ entonces $\lambda = (j_1, \dots, j_k) = (0, \dots, 0) \in R^k$ y asumiendo que $u \in C^\infty$ entonces

$$u_\lambda = \begin{cases} u; & \lambda = v \\ u^{(k)}; & k \geq 1 \end{cases}$$

(ii) Como se verifica que

$$I_\lambda [u(X(\cdot))]_{t_0, t} = \begin{cases} \int_{t_0}^t \cdots \int_{t_0}^{s_2} u(t_0) ds_1 \dots ds_k; & l = 0 \\ \int_{t_0}^t \cdots \int_{t_0}^{s_2} u^{(k)}(t_0) ds_1 \dots ds_k; & l \neq 0. \end{cases}$$



Entonces, la expansión de Ito-Taylor es:

$$\begin{aligned}
 u(t) &= u(t_0) + \sum_{\lambda \in \Gamma_k \setminus \{v\}} I_\lambda [u_\lambda(t_0)]_{t_0, t} + \sum_{\lambda \in B(\Gamma_k)} I_\lambda [u_\lambda(\cdot)]_{t_0, t} \\
 &= u(t_0) + \sum_{i=1}^k \int_{t_0}^t \cdots \int_{t_0}^{s_2} u^{(i)}(t_0) ds_1 \dots ds_i + R \\
 &= u(t_0) + \sum_{i=1}^k \frac{1}{i!} u^{(i)}(t_0) (t - t_0)^i + R,
 \end{aligned}$$

donde R es

$$R = \int_{t_0}^t \cdots \int_{t_0}^{s_2} u^{(k+1)}(s_1) ds_1 \dots ds_{k+1}.$$

12 Procesos de Markov y Difusión

12.1 Cadena de Markov y proceso de Markov

12.1.1 Cadena de Markov en tiempo discreto

Definition 71 Una cadena de Markov en tiempo discreto es un proceso estocástico $\{X_t : t = 0, 1, 2, \dots\}$ con un conjunto contable de espacio de estados $E \equiv \{x_1, x_2, x_3, \dots\}$ de $\mathbb{R}^d$ sobre un espacio de probabilidad (Ω, F, P) verificando: $\forall x_j, a_0, a_1, \dots, a_t \in E$ y $\forall t \in T$, donde $T \equiv \{0, 1, 2, 3, \dots\}$

$$\begin{aligned}
 P(X_{t+n} = x_j | X_0 = a_0, X_1 = a_1, \dots, X_t = a_t) \\
 = P(X_{t+n} = x_j | X_t = a_t)
 \end{aligned} \tag{166}$$

La ecuación (166) se denomina la propiedad de Markov. La propiedad de Markov dice que el pasado y futuro son estadísticamente independientes dado el presente conocido. Todo lo que importa en determinar el próximo valor de X_{t+1} es el valor actual de X_t . Nos centraremos en las cadenas de Markov chains con un número finito de estados, es decir $E \equiv \{x_1, x_2, \dots, x_N\}$.

Definition 72 Definimos una matriz de transición $N \times N$ de período n $\mathbb{P}_{n,t} = [p_{ij}^{t,t+n}]$ con componentes

$$p_{ij}^{t,t+n} = P(X_{t+n} = x_j | X_t = x_i), \quad i, j = 1, \dots, N$$



donde obviamente,

$$\begin{aligned} (i) \quad & 0 \leq p_{ij}^{t,t+n} \leq 1; \\ (ii) \quad & \sum_{j=1}^N p_{ij}^{t,t+n} = 1, \quad \forall i \text{ y } \forall t. \end{aligned} \quad (167)$$

Definimos (167) como la matriz de transición de n períodos de la cadena de Markov y sus componentes las probabilidades de transición de n períodos en el tiempo t .

Definition 73 Una cadena de Markov es homogénea si las probabilidades de transición de n períodos son independientes del tiempo, es decir; $\mathbb{P}_{n,t} = \mathbb{P}_n$, $\forall t \in T$. Representamos las probabilidades de transición como

$$p_{ij}^n = P(X_{t+n} = x_j | X_t = x_i).$$

La matriz $\mathbb{P}_n$ se denomina matriz de transición homogénea de la cadena de Markov homogénea. Por simplicidad, $p_{ij}^1 = p_{ij}$ y $\mathbb{P}_1 = \mathbb{P} = [p_{ij}]$.

Obsérvese que la ecuación (ii) de la Definición 72 requiere que cada fila de $\mathbb{P}$ sume la unidad, o $\mathbb{P}\mathbf{1} = \mathbf{1}$ donde $\mathbf{1}$ representa un vector $N \times 1$ de unos. Por tanto, $\mathbf{1}$ es un vector propio derecho de la matriz $\mathbb{P}$ y 1 es el valor propio asociado. Como $\mathbb{P} \geq 0$, o sea $p_{ij} \geq 0$, $\mathbb{P} \neq 0$; y asumiendo que es irreducible⁵⁴ entonces se verifica por el Teorema de Perron-Frobenious⁵⁵ que existe un único valor propio positivo de $\mathbb{P}$, λ^* , tal que $\lambda^* \geq |\lambda_i|$ donde λ_i son los valores propios de $\mathbb{P}$ verificándose que $\lambda^* = 1$.

Sea una cadena de Markov homogénea de dos estados, la matriz de transición es

$$\mathbb{P} = \begin{bmatrix} p_{11} & 1 - p_{11} \\ 1 - p_{22} & p_{22} \end{bmatrix}.$$

Supongamos que $p_{11} = 1$, entonces $\mathbb{P}$ es triangular inferior. Una vez que el proceso entra en el estado 1, no existe posibilidad de volver al estado 2. Por tanto el estado 1 se define como *estado absorbente* y la cadena de Markov es *reducible*. Una cadena de Markov que no es reducible se define *irreducible*. Una cadena de Markov de dos estados es irreducible si $p_{11} < 1$ y $p_{22} < 1$.

⁵⁴Ver Definición 74.

⁵⁵Ver capítulo 15 en Lancaster (1985).



Definition 74 Una cadena de Markov homogénea de N estados se dice que es reducible si la matriz de transición puede escribirse de la siguiente forma

$$\mathbb{P} = \begin{bmatrix} B & 0 \\ C & D \end{bmatrix}$$

donde B representa una matriz $K \times K$ donde $1 \leq K < N$.

Si $\mathbb{P}$ es triangular inferior, entonces $\mathbb{P}^m$ es también para cualquier entero m . Una vez que un proceso entra en un estado j tal que $j \leq K$, no hay posibilidad de volver a los estados $K + 1, K + 2, \dots, N$.

Definition 75 Sea γ el número de valores propios de $\mathbb{P}$ whose moduli are equal to 1.

Definition 76 Una matriz irreducible $\mathbb{P}$ es primitiva si $\gamma = 1$, en caso contrario $\mathbb{P}$ es imprimitiva, es decir $\gamma > 1$.

Definition 77 Consideremos una cadena de Markov irreducible de N estados con matriz de transición $\mathbb{P}$ verificando que $\mathbb{P}$ es primitiva y diagonalizable en tonces la cadena de Markov se dice que es ergódica. Sea ϑ un vector propio de $\mathbb{P}$ asociado al valor propio unidad tal que $\mathbf{1}'\vartheta = 1$ entonces ϑ es el vector $N \times 1$ de probabilidades ergódicas y se verifica⁵⁶ que

$$\lim_{m \rightarrow \infty} \mathbb{P}^m = \lim_{m \rightarrow \infty} M \Lambda^m M^{-1} = \mathbf{1}\vartheta'; \quad (168)$$

donde M es la matriz de vectores propios de $\mathbb{P}$, donde la primera columna de M es el vector de unos y $\Lambda \equiv \text{diag}(1, \lambda_2, \dots, \lambda_N)$.

Obsérvese que ϑ es la primera fila de M^{-1} . Obsérvese que si $\mathbb{P}$ es irreducible y primitiva, entonces existe un único valor propio igual a la unidad. Sin embargo, si $\mathbb{P}$ es imprimitiva pueden haber más de un valor propio en el círculo unidad, por tanto no todas las cadenas de Markov irreducibles son ergódicas. Sea el siguiente ejemplo

$$\mathbb{P} = \begin{bmatrix} 0 & 1 \\ 1 & 0 \end{bmatrix}.$$

⁵⁶Ver Hamilton (1994, p. 681-2).

Los valores propios de la matriz de transición son 1 y -1. Por tanto, la matriz $\mathbb{P}^m$ no converge. Si el proceso está en el estado 1 en la fecha t entonces estará de nuevo en las fechas $t + 2, t + 4, \dots$. Diremos que tal cadena de Markov es *periódica* con periodo 2. Podemos generalizar este resultado en el siguiente Teorema:

Theorem 78 *Sea una cadena de Markov irreducible de N estados con matriz de transición $\mathbb{P}$ con $\gamma > 1$ valores propios estrictamente en el círculo unidad, entonces la cadena es periódica de periodo γ .*

Definition 79 *Las ecuaciones Chapman-Kolmogorov para calcular las probabilidades de transición de n períodos para cadenas de Markov homogéneas son*

$$p_{ij}^{n+m} = \sum_{k=1}^N p_{ik}^n p_{kj}^m \quad \forall n, m \geq 0, \quad \forall i, j.$$

En notación matricial, la ecuación anterior puede escribirse como

$$\mathbb{P}_{n+m} = \mathbb{P}_n \mathbb{P}_m. \quad (169)$$

Si calculamos $\mathbb{P}_n$, entonces aplicando (169) conseguimos

$$\mathbb{P}_n = \mathbb{P} \mathbb{P}_{n-1} = \mathbb{P} \mathbb{P} \mathbb{P}_{n-2} = \dots = \mathbb{P}^n;$$

donde $\mathbb{P}$ es la matriz de transición de un período homogénea. Sea π_t el vector de probabilidad $N \times 1$ correspondiente a la distribución de la t -ésima X_t , es decir

$$\pi_t = (\pi_{1,t}, \dots, \pi_{N,t})'$$

donde

$$\pi_{i,t} = P(X_t = x_i).$$

El vector de probabilidad π_{t+1} correspondiente a X_{t+1} se obtiene como⁵⁷

$$\pi'_{t+1} = \pi'_t \mathbb{P}. \quad (170)$$

Dado la condición inicial π_0 y la condición (170), tenemos

$$\pi'_t = \pi'_0 \mathbb{P}^t. \quad (171)$$

⁵⁷A partir de ahora, vamos a trabajar con cadenas de Markov homogéneas.



Podemos expresar la condición (170) como

$$\pi'_{t+k-1} = \pi'_k \mathbb{P}^{t-1}$$

para $k = 0, 1, 2, 3, \dots$ and $t = 1, 2, 3, \dots$

Finalmente, dado (168) y tomando límites en la ecuación (171) cuando $t \rightarrow \infty$; obtenemos

$$\lim_{t \rightarrow \infty} \pi'_t = \lim_{t \rightarrow \infty} \pi'_0 \mathbb{P}^t = \pi'_0 \mathbf{1} \vartheta' = \vartheta'.$$

En definitiva, la cadena converge a una distribución única *estacionaria* (o *invariante*) que no depende de la distribución inicial π_0 y t .

12.1.2 Cadena de Markov en tiempo continuo

Definition 80 Una cadena de Markov en tiempo continuo es un proceso estocástico $\{X(t) : t \in [0, T]\}$ sobre un espacio de estados contable $E \equiv \{x_1, x_2, \dots, x_N\}$ en un espacio de probabilidad (Ω, F, P) verificando:

$$\begin{aligned} P(X(t_1) = x_j | X(s_1) = a_1, X(s_2) = a_2, \dots, X(s_n) = a_n) \\ = P(X(t_1) = x_j | X(s_n) = a_n); \end{aligned}$$

$$\forall 0 \leq s_1 \leq s_2 \leq \dots \leq s_n \leq t_1 \leq T \text{ and } \forall x_j, a_1, a_2, \dots, a_n \in E.$$

Definimos la probabilidad de transición del proceso anterior como

$$p_{ij}(t) = P(X(t+s) = x_j | X(t) = x_i).$$

Ahora, obtendremos dos conjuntos de ecuaciones diferenciales estocásticas para $p_{ij}(t)$, que pueden a veces resolverse explícitamente. Sin embargo, previamente necesitamos los siguientes lemas.

Lemma 81

$$(i) \quad \lim_{t \rightarrow 0} \frac{1 - p_{ii}(t)}{t} = v_i.$$

$$(ii) \quad \lim_{t \rightarrow 0} \frac{p_{ij}(t)}{t} = q_{ij}, \quad i \neq j.$$



Lemma 82 Para todo s, t ,

$$p_{ij}(s+t) = \sum_{k=1}^N p_{ik}(t) p_{kj}(s).$$

El Lema 81 significa que la probabilidad de dos o más transiciones en el período t es $o(t)$. Mientras el Lema 82 es la versión en tiempo continuo de las ecuaciones Chapman-Kolmogorov de las cadenas de Markov en tiempo discreto. Los lemas anteriores se usan para los siguientes dos teoremas⁵⁸.

Theorem 83 (Ecuaciones Backward de Kolmogorov) $\forall i, j$, y $t \geq t_0$,

$$\dot{p}_{ij}(t) = \sum_{k \neq i} q_{ik} p_{kj}(t) - v_i p_{ij}(t).$$

Theorem 84 (Ecuaciones Forward de Kolmogorov) Bajo ciertas condiciones,

$$\dot{p}_{ij}(t) = \sum_{k \neq j} q_{kj} p_{ik}(t) - v_j p_{ij}(t).$$

Si definimos $q_{ii} \equiv -v_i$, entonces las ecuaciones backward pueden escribirse como

$$\dot{\mathbb{P}}(t) = Q\mathbb{P}(t) \quad (172)$$

y las ecuaciones forward como

$$\dot{\mathbb{P}}(t) = \mathbb{P}(t) Q \quad (173)$$

con las mismas condiciones iniciales, $\mathbb{P}(0) = I$; donde $\mathbb{P}(t)$, Q y $\dot{\mathbb{P}}(t)$ son las matrices cuyos elementos son $p_{ij}(t)$, q_{ij} y $\dot{p}_{ij}(t)$ respectivamente. Las soluciones de (172) y (173) son iguales, es decir

$$\mathbb{P}(t) = e^{Qt}.$$

12.1.3 Proceso de Markov

Definition 85 Un proceso estocástico $\{X(t) : t \in [0, T]\}$ definido sobre un espacio de probabilidad (Ω, F, P) y con un espacio de estados $\mathbb{R}^d$ se denomina un proceso de Markov si se verifica la siguiente propiedad de Markov: $\forall 0 \leq s \leq t \leq T$ y $\forall \Gamma \in \mathcal{B}^d$ (conjuntos σ -álgebra de Borel en $\mathbb{R}^d$), la ecuación

$$P(X(t) \in \Gamma | \sigma(X(u), 0 \leq u \leq s)) = P(X(t) \in \Gamma | X(s))$$

se verifica con probabilidad 1, donde $\sigma(\cdot)$ es el σ -field generado por todas las variables aleatorias $X(u)$ para $u \in [0, s]$.

⁵⁸Ver Ross (1983) para la prueba de los dos teoremas.

Igual que en el tiempo discreto, lo que importa en un proceso de Markov en determinar su comportamiento futuro no es su pasado sino su posición actual. Escribimos las probabilidades de transición como

$$P(s, x; t, \Gamma) = P(X(t) \in \Gamma | X(s) = x).$$

Sea $P(s, x; t, \cdot)$ una función de probabilidad (medida) sobre $\mathcal{B}^d$ y $p(s, x; t, \cdot)$ la densidad de transición, entonces

$$P(s, x; t, \Gamma) = \int_{\Gamma} p(s, x; t, y) dy \quad \forall \Gamma \in \mathcal{B}^d.$$

Definition 86 *Un proceso de Markov es homogéneo (con respecto al tiempo) si su probabilidad de transición $P(s, x; t, \Gamma)$ es independiente del tiempo o estacionaria, es decir*

$$P(s + u, x; t + u, \Gamma) = P(s, x; t, \Gamma)$$

se verifica para $0 \leq s \leq t \leq T$ y $0 \leq s + u \leq t + u \leq T$.

Esto significa que la probabilidad de transición depende sólo de tres argumentos; $x, t - s$ y Γ . Como

$$P(s, x; t, \Gamma) = P(0, x; t - s, \Gamma),$$

se omite normalmente la primera variable y escribimos simplemente $P(x; t - s, \Gamma)$ y

$$p(s, x; t, y) = p(0, x; t - s, y)$$

para las densidades de transición y también escribimos $p(x; t - s, y)$.

La ecuación de Chapman-Kolmogorov para un proceso de Markov es:

$$p(s, x; t, y) = \int_{\mathbb{R}^d} p(s, x; \tau, z) p(\tau, z; t, y) dz, \quad \forall s \leq \tau \leq t; \quad x, y \in \mathbb{R}^d.$$

Para probabilidades de transición:

$$P(s, x; t, \Gamma) = \int_{\mathbb{R}^d} P(\tau, z; t, \Gamma) P(s, x; \tau, dz) \quad \forall x \in \mathbb{R}^d.$$



12.2 El proceso de difusión

Definition 87 *Un proceso de Markov $\{X(t); t \in [0, T]\}$ con valores en $\mathbb{R}$ es un proceso de difusión si su densidad de transición $p(s, x; t, y)$ verifica las siguientes tres condiciones para todo $s \in [0, T)$, $x \in \mathbb{R}$ y $\varepsilon > 0$:*

$$\begin{aligned} \lim_{t \rightarrow s} \frac{1}{t-s} \int_{|y-x| > \varepsilon} p(s, x; t, y) dy &= 0; \\ \lim_{t \rightarrow s} \frac{1}{t-s} \int_{|y-x| \leq \varepsilon} (y-x) p(s, x; t, y) dy &= f(s, x); \\ \lim_{t \rightarrow s} \frac{1}{t-s} \int_{|y-x| \leq \varepsilon} (y-x)^2 p(s, x; t, y) dy &= b^2(s, x); \end{aligned} \quad (174)$$

donde $f(\cdot)$ y $b(\cdot)$ son funciones continuas de valores reales en $[t_0, T) \times \mathbb{R}$.

Podemos expresar las condiciones de arriba como:

$$\lim_{t \rightarrow s} \frac{1}{t-s} P\{|X(t) - X(s)| > \varepsilon | X(s) = x\} = 0; \quad (175)$$

$$\lim_{t \rightarrow s} \frac{1}{t-s} E\{|X(t) - X(s)| \leq \varepsilon | X(s) = x\} = f(s, x); \quad (176)$$

$$\lim_{t \rightarrow s} \frac{1}{t-s} E\{(X(t) - X(s))^2 \leq \varepsilon | X(s) = x\} = b^2(s, x). \quad (177)$$

La condición (175) dice que grandes desplazamientos, de orden excediendo un ε fijo, son muy poco probables en intervalos de tiempo cortos. Esto significa que las sendas muestrales del proceso son continuas. Las condiciones (176) y (177) son momentos truncados donde $f(s, x)$ y $b^2(s, x)$ son los parámetros infinitesimales del proceso. En particular, $f(s, x)$ se denomina el *parámetro de tendencia* y $b^2(s, x)$ el *parámetro de difusión*.

Para un proesode difusión con dimensión d , en lugar de las condiciones (174), tenemos:

$$\begin{aligned} \lim_{t \rightarrow s} \frac{1}{t-s} \int_{|y-x| > \varepsilon} p(s, x; t, y) dy &= 0; \\ \lim_{t \rightarrow s} \frac{1}{t-s} \int_{|y-x| \leq \varepsilon} (y-x) p(s, x; t, y) dy &= f(s, x); \\ \lim_{t \rightarrow s} \frac{1}{t-s} \int_{|y-x| \leq \varepsilon} (y-x)(y-x)' p(s, x; t, y) dy &= B(s, x); \end{aligned} \quad (178)$$

donde f es el *vector de tendencia* y B es la *matriz de difusión*. $B(s, x)$ es simétrica y definida no negativa.

Finalmente, las soluciones de EDEs y procesos de difusión representan la misma clase de procesos a pesar de tener definiciones completamente diferentes⁵⁹.

12.3 Probabilidades de transición

Sea el siguiente proceso de difusión

$$dX(t) = f(t, X(t)) dt + G(t, X(t)) dW(t), \quad 0 \leq t \leq T$$

donde $f \in \mathbb{R}^d$, G es una matriz de valores reales $d \times m$ y W es un proceso de Wiener de dimensión m . A cada proceso de difusión se le asigna un operador diferencial de segundo orden definido como

$$\mathcal{D} \equiv \sum_{i=1}^d f_i(s, x) \frac{\partial}{\partial x_i} + \frac{1}{2} \sum_{i=1}^d \sum_{j=1}^d b_{ij}(s, x) \frac{\partial^2}{\partial x_i \partial x_j},$$

$$B(s, x) = [b_{ij}(s, x)] = G(s, x) G(s, x)', \quad f = (f_1, \dots, f_d)'$$

Sea $P(s, x; t, \Gamma)$ la probabilidad de transición de $X(t)$ y definamos $u(s, x)$ como

$$u(s, x) = E_{s,x} g(t, X(t)) = \int_{\mathbb{R}^d} g(t, y) P(s, x; t, dy).$$

Definamos la *ecuación backward* como

$$\frac{\partial u(s, x)}{\partial s} + \mathcal{D}u(s, x) = 0,$$

⁵⁹Ver capítulo 9 en Arnold (1974).



con la condición final

$$\lim_{s \rightarrow t} u(s, x) = g(x).$$

Cuando

$$g(x) = \exp(i\lambda'x), \quad \lambda \in \mathbb{R}^d;$$

entonces obtenemos la función característica de $X(t) | X(s) = x$ para $s < t$, que determina únicamente la distribución de la probabilidad de transición, es decir $P(s, x; t, \cdot)$.

Example 88 (Heston, 1993). Sea el siguiente PGD:

$$dY(t) = \alpha dt + \sqrt{V(t)} dW_s(t)$$

$$dV(t) = k(\theta - V(t)) dt + \sigma \sqrt{V(t)} dW_v(t)$$

$$dW_s(t) dW_v(t) = \rho dt$$

donde $Y(t) = \ln(S(t))$ es la transformación de Ito sobre

$$dS(t) = \mu S(t) dt + \sqrt{V(t)} S(t) dW_s(t)$$

y $\alpha = \mu - V(t)/2$. Estamos interesados en obtener la función característica de $Y(t) | Y(s) = y, V(s) = v$ para $s < t$, entonces la ecuación backward correspondiente al modelo de Heston es

$$\alpha u_y + k(\theta - V) u_v + \frac{1}{2} V u_{yy} + \sigma V \rho u_{yv} + \frac{1}{2} \sigma^2 V u_{vv} - u_h = 0$$

s.a. la condición terminal⁶⁰

$$g(y, v) = \exp(i\lambda y), \quad \forall y, v, \lambda$$

donde $h = t - s$. Según Das y Sundaram (1997), la función característica⁶¹ tiene la forma de

$$u(y, v, h; \lambda) = C(h) \exp[i\lambda y + A(h) + vB(h)]$$

⁶⁰Cuando $h \rightarrow 0$.

⁶¹Rescribimos $u(y, v, h; \lambda)$ en lugar de $u(y, v)$.

donde $A(h) = i\alpha\lambda h$, y

$$B(h) = \frac{-\lambda^2[e^{\phi h}-1]}{(\phi+\gamma)[e^{\phi h}-1]+2\phi} \quad C(h) = \left[\frac{2\phi\left(e^{(\phi+\gamma)\frac{h}{2}}\right)}{(\phi+\gamma)[e^{\phi h}-1]+2\phi} \right]^{2k\theta/\sigma^2}$$

donde $\gamma = k - \rho\sigma i\lambda$ y $\phi = \sqrt{\gamma^2 + \sigma^2\lambda^2}$. Invirtiendo la función característica, se obtiene la distribución de probabilidad de transición⁶². La función característica para rendimientos de activo condicional, es decir $Y_h^*(t) = \Delta_h Y(t) | Y(t) = y, V(t) = v$, es

$$\begin{aligned} u^*(v, h; \lambda) &= u(y, v, h; \lambda) \exp(-i\lambda y) \\ &= C(h) \exp[A(h) + vB(h)] \end{aligned}$$

Los momentos condicionales de $Y_h^*(t)$ pueden obtenerse mediante

$$E_t[(Y_h^*(t))^m] = \frac{1}{i^m} \frac{\partial^m u^*}{\partial \lambda^m} \Big|_{\lambda=0}.$$

$\bar{u}(h, \lambda)$ representa la función característica incondicional de los rendimientos y $g(v)$ la densidad estacionaria correspondiente al proceso de volatilidad estocástica definido por un modelo CIR en Heston que es una distribución gamma, es decir

$$g(v) = \frac{1}{\Gamma(\beta)} \omega^\beta v^{\beta-1} e^{-\omega v}$$

donde $\omega = 2k/\sigma^2$ y $\beta = \omega\theta$. Entonces,

$$\begin{aligned} \bar{u}(h, \lambda) &= \int u^*(v, h; \lambda) g(v) dv \\ &= \left(\frac{\omega}{\omega - B(h)} \right)^\beta C(h) \exp(A(h)). \end{aligned}$$

Theorem 89 Sea $\{X(t); t \in [0, T]\}$ un proceso de difusión de dimensión d con coeficientes continuos $f(s, x)$ y $B(s, x)$. Las relaciones límite (178) se sostienen uniformemente en $s \in [0, T]$. Si la densidad de transición $p(s, x; t, y)$ es continua respecto a s y si las derivadas $\partial p/\partial x_i$ y $\partial^2 p/\partial x_i x_j$

⁶²Ver ecuación (18) en Heston (1993).



existen y son continuas con respecto a s , entonces p verifica la siguiente ecuación diferencial parcial

$$\frac{\partial p}{\partial s} + \mathcal{D}p = 0; \quad (179)$$

con la condición final

$$\lim_{t \rightarrow s} p(s, x; t, y) = \delta(x - y),$$

donde δ es la función delta de Dirac. La ecuación (179) se conoce como la ecuación backward de Kolmogorov.

Theorem 90 Sea $\{X(t); t \in [0, T]\}$ un proceso de difusión con dimensión d para el que las relaciones límite (178) se sostienen uniformemente en $s \in [0, T]$ y x con una densidad de transición $p(s, x; t, y)$. Si las derivadas $\partial p / \partial t$, $\partial(f_i(t, y)p) / \partial y_i$ y $\partial^2(b_{ij}(t, y)p) / \partial y_i \partial y_j$ existen y son funciones continuas, entonces para s y x fijos tal que $s \leq t$, la función de densidad de transición verifica

$$\frac{\partial p}{\partial t} + \sum_{i=1}^d \frac{\partial}{\partial y_i} (f_i(t, y)p) - \frac{1}{2} \sum_{i=1}^d \sum_{j=1}^d \frac{\partial^2}{\partial y_i \partial y_j} (b_{ij}(t, y)p) = 0, \quad (180)$$

verificando que

$$\lim_{t \rightarrow s} p(s, x; t, y) = \delta(y - x).$$

La ecuación (180) con la condición terminal se conoce ecuación de Kolmogorov o ecuación Fokker-Planck.

12.4 Convergencia débil de procesos de Markov a difusiones

Sea el intervalo $[0, T]$ y dividamos en n partes iguales de longitud $h \equiv T/n$. Ahora, consideremos para cada h la cadena de Markov de dimensión d

$$\{X_{n,kh} : k = 0, 1, \dots, n\} \quad (181)$$

representado por $\{X_{n,kh}\}$ donde $X_{n,0h} = X_0 \forall h$. Denotemos las probabilidades de transición correspondientes a la cadena de Markov para cada h como

$$\Pi_{n,kh}(x, \Gamma) \equiv P_h(X_{n,kh} \in \Gamma | X_{n,(k-1)h} = x) \quad \Gamma \in \mathcal{B}^d$$



para todo $k = 1, 2, \dots, n$ y el correspondiente a X_0 como

$$\Pi_0(\Gamma) \equiv P_h(X_{n,0h} \in \Gamma) = P(X_0 \in \Gamma).$$

Formamos el proceso en tiempo continuo, o sea el proceso de Markov, a partir del proceso en tiempo discreto (181). Convertimos $\{X_{n,kh}\}$ en una función "step" con saltos en los períodos $h, 2h, \dots, nh$. La notación correspondiente al proceso de Markov es

$$X_n(t) = X_{n,[nt/T]h}; \quad t \in [0, T]$$

y representamos $X_n(\cdot)$ la función aleatoria

$$\{X_n(t) : t \in [0, T]\}.$$

$X_n(\cdot)$ pertenece a $D([0, T], R^d)$ que es un espacio de "mappings" desde $[0, T]$ a R^d que son continuas por la derecha con límites finitos por la izquierda donde D es la métrica de Skorohod⁶³. En definitiva, tenemos una sucesión de funciones aleatorias, o sea

$$\{X_n(\cdot) : n \geq 1\}. \quad (182)$$

Ahora, para cada $h > 0$ y cada $\varepsilon > 0$ definimos

$$f_h(t, x) \equiv h^{-1} \int_{R^d} (y - x) \Pi_{n,[nt/T]h}(x, dy);$$

$$B_h(t, x) \equiv h^{-1} \int_{R^d} (y - x)(y - x)' \Pi_{n,[nt/T]h}(x, dy);$$

$$\Delta_{h,\varepsilon}(t, x) \equiv h^{-1} \int_{|y-x| \geq \varepsilon} \Pi_{n,[nt/T]h}(x, dy);$$

donde las dos primeras integrales están bien-definidas y son finitas bajo ciertas condiciones⁶⁴. La interpretación de estas tres ecuaciones son las mismas que las correspondientes a (178).

Estamos interesados en la convergencia débil de sucesiones de funciones aleatorias (182) a un cierto proceso de difusión $X(\cdot)$. El resultado de convergencia de esta sección requerirá los siguientes supuestos:

⁶³Ver Billingsley (1968).

⁶⁴Ver Nelson (1990), concretamente Supuesto 5.

Supuesto 1. Existe un "mapping" continuo y medible $B(t, x)$ desde $[0, T] \times R^d$ al espacio $d \times d$ de matrices definidas no negativas simétricas; y un "mapping" continuo y medible $f(t, x)$ desde $[0, T] \times R^d$ en R^d tal que $\forall \delta > 0$ y $\varepsilon > 0$

$$\lim_{h \rightarrow 0} \sup_{|x| \leq \delta, 0 \leq t \leq T} |B_h(t, x) - B(t, x)| = 0;$$

$$\lim_{h \rightarrow 0} \sup_{|x| \leq \delta, 0 \leq t \leq T} |f_h(t, x) - f(t, x)| = 0;$$

$$\lim_{h \rightarrow 0} \sup_{|x| \leq \delta, 0 \leq t \leq T} \Delta_{h, \varepsilon}(t, x) = 0.$$

Las dos primeras ecuaciones requieren que el segundo momento y la tendencia por unidad de tiempo converjan uniformemente en conjuntos compactos a funciones de tiempo y variables estado x de buen comportamiento. La última ecuación garantiza que las sendas muestrales del proceso límite son continuas con probabilidad uno.

Supuesto 2. Existe un "mapping" continuo y medible $G(t, x)$ desde $[0, T] \times R^d$ a R^d en el espacio de matrices de orden $d \times d$, tal que $\forall x \in R^d$ y $\forall t \in [0, T]$,

$$B(t, x) = G(t, x) G(t, x)'$$

Supuesto 3. Cuando $n \rightarrow \infty$, $X_n(0)$ converge en distribución a un vector aleatorio X_0 con medida de probabilidad Π_0 .

Supuesto 4. Π_0 , $B(t, x)$, y $f(t, x)$ únicamente⁶⁵ especifica la distribución del proceso límite $X(\cdot)$, con distribución inicial Π_0 , matriz de difusión $B(t, x)$ y vector de tendencia $f(t, x)$.

Theorem 91 (Stroock-Varadhan, 1979). *Bajo las condiciones 1 a 4, la sucesión de funciones aleatorias (182) converge débilmente cuando $n \rightarrow \infty$ al proceso límite $X(\cdot)$ de orden $d \times 1$ definido como*

$$X(t) = X_0 + \int_0^t f(u, X(u)) du + \int_0^t G(u, X(u)) dW(u), \quad 0 \leq t \leq T < \infty;$$

donde $X(0) = X_0$, con distribución Π_0 . $W(t)$ es un proceso de Wiener estándar de dimensión R^d independiente de X_0 . Lo representamos como $X_n(\cdot) \Rightarrow X(\cdot)$.

⁶⁵En el Apéndice A de Nelson (1990), se encuentran condiciones bajo las que Π_0 , $B(t, x)$ y $f(t, x)$ especifican únicamente el proceso de difusión $X(\cdot)$ en conjuntos compactos y también, condiciones que aseguren que $X(\cdot)$ no va a infinito en tiempo finito.



13 Apéndice

13.1 Algunas nociones sobre análisis y topología

13.1.1 Espacios métricos

Definition 92 Sea S un conjunto no vacío. Una métrica sobre S es un mapping $\rho : S \times S \mapsto \mathbb{R}$ con las siguientes propiedades: $\forall x, y, z \in S$,

- (i) $\rho(x, y) \geq 0$ y $\rho(x, y) = 0 \Leftrightarrow x = y$;
- (ii) $\rho(x, y) = \rho(y, x)$ (simetría);
- (iii) $\rho(x, y) \leq \rho(x, z) + \rho(z, y)$ (desigualdad triangular).

Definition 93 (S, ρ) se llama espacio métrico.

En nuestro caso S es una clase de funciones reales sobre $[0, 1]$. Para $S = C$, se utiliza la métrica de la norma "supremo":

$$\forall f, g \in C[0, 1] \quad \rho(f, g) = \sup_{0 \leq t \leq 1} |f(t) - g(t)| \quad (183)$$

es decir

$$\forall \omega_0, \omega_1 \in \Omega \quad \text{s.t. } \omega_0 \neq \omega_1, \text{ then } f = X(\cdot, \omega_0) \quad \text{and} \quad g = X(\cdot, \omega_1).$$

La métrica definida en D es la topología de korohod (ver Billingsley (1968)).

13.1.2 Integral Riemann-Stieltjes determinística

Sea $f : \mathbb{R} \rightarrow \mathbb{R}$ tal que f está acotada en $[a, b] \subset \mathbb{R}$ y se desea encontrar la integral de f sobre el $[a, b]$. A este efecto, particionemos el intervalo

$$a = t_0 < t_1 < t_2 < \dots < t_n = b,$$

sea

$$M_i = \sup_{t_{i-1} \leq t \leq t_i} f(t); \quad i = 1, 2, \dots, n.$$

$$m_i = \inf_{t_{i-1} \leq t \leq t_i} f(t); \quad i = 1, 2, \dots, n.$$



Definamos las sumas

$$S(P, f) = \sum_{i=1}^n M_i(t_i - t_{i-1});$$

$$s(P, f) = \sum_{i=1}^n m_i(t_i - t_{i-1});$$

donde P es una partición dada de $[a, b]$. Se verifica que $S(P, f) \geq s(P, f)$. Sea P y Q dos particiones de $[a, b]$, decimos que P es *más fina* que Q si todos los elementos de Q están contenidos en P . Si P es más fina que Q entonces $s(P, f) \geq s(Q, f)$ y $S(P, f) \leq S(Q, f)$. Para cualquier par de particiones P, Q de $[a, b]$, se verifica que $s(P, f) \leq S(Q, f)$. Sea Ψ el conjunto de todas las posibles particiones correspondientes al intervalo $[a, b]$, entonces

$$\bar{s}(f) = \sup_{P \in \Psi} s(P, f); \quad \underline{S}(f) = \inf_{P \in \Psi} S(P, f).$$

$\bar{s}(f)$, $\underline{S}(f)$ siempre existen y, evidentemente, $\bar{s}(f) \leq \underline{S}(f)$.

Definition 94 Sea $f : \mathbb{R} \rightarrow \mathbb{R}$ acotada en $[a, b] \subset \mathbb{R}$. Decimos que la integral de Riemann existe sii $\bar{s}(f) = \underline{S}(f)$ y representemos la integral de Riemann por

$$I_R = \int_a^b f(t) dt.$$

Proposition 95 f es integrable Riemann en $[a, b]$ sii

$$\forall \varepsilon > 0 \quad \exists P \in \Psi \quad \text{tal que } |S(P, f) - s(P, f)| < \varepsilon.$$

La integral Riemann-Stieltjes (RS) se define similarmente, excepto que f está ponderada por otra función, es decir α , sobre el intervalo $[a, b]$. Estamos interesados en obtener la integral de f con respecto a α sobre el intervalo $[a, b]$. Supongamos que f está acotada. Sea (P, Γ) donde P es una partición de $[a, b]$ y $\Gamma = \{\tau_1, \tau_2, \dots, \tau_n\} \subset [a, b]$ tal que $\tau_i \in [t_{i-1}, t_i]$ $i = 1, 2, \dots, n$.

Definamos la suma asociada a P, Γ, f y α como:

$$S(P, \Gamma, f, \alpha) = \sum_{i=1}^n f(\tau_i)(\alpha(t_i) - \alpha(t_{i-1})).$$



Definition 96 Decimos que la integral de Riemann Stieltjes de f con respecto a α sobre $[a, b]$ existe y con valor I_{RS} si

$$\forall \varepsilon > 0 \quad \exists P_\varepsilon \in \Psi \quad \text{s.t.} \quad |S(P, \Gamma_P, f, \alpha) - I_{RS}| < \varepsilon \quad \forall P \text{ finer than } P_\varepsilon \text{ and } \forall \Gamma_P,$$

donde Γ_P es el conjunto de puntos representado por $\{\tau_1^P, \tau_2^P, \dots, \tau_n^P\}$; tal que $\tau_i^P \in [t_{i-1}^P, t_i^P]$ $i = 1, 2, \dots, n$; donde la partición P es $a = t_0^P < t_1^P < t_2^P < \dots < t_n^P = b$. Representamos I_{RS} como

$$I_{RS} = \int_a^b f(t) d\alpha(t).$$

Podemos expresar la integral RS como:

Para cada $n \in \mathbb{N}$ tenemos una partición deferente de $[a, b]$, es decir

$$t_{0,n} = a < t_{1,n} < t_{2,n} < \dots < t_{n,n} = b$$

son los elementos correspondientes a la partición $P_n \in [a, b]$. Consideremos la suma

$$S_n = \sum_{i=1}^n f(\tau_{i,n}) (\alpha(t_{i,n}) - \alpha(t_{i-1,n})); \quad (184)$$

donde $\tau_{i,n} \in [t_{i-1,n}, t_{i,n}]$. Decimos que la integral RS de f con respecto a α sobre $[a, b]$ existe y de valor I_{RS} si

$$\lim_{n \rightarrow \infty} S_n = I_{RS},$$

tal que

$$\max_{1 \leq i \leq n} |t_{i-1,n} - t_{i,n}| \rightarrow 0 \quad \text{as } n \rightarrow \infty \quad \text{and} \quad \forall \tau_{i,n} \quad i = 1, 2, \dots, n.$$

13.1.3 Sucesiones de funciones: Convergencia puntual y uniforme

Definition 97 La sucesión de funciones reales $\{f_n(\cdot) : n \geq 1\}$ donde $f_n(\cdot) : [0, 1] \subset \mathbb{R} \mapsto \mathbb{R}$ converge puntualmente a la función $f(\cdot)$ si para cada $t \in [0, 1]$ la sucesión de números reales $\{f_n(t) : n \geq 1\}$ converge a $f(t)$, es decir

$$\forall t \in [0, 1], \quad \forall \varepsilon > 0, \quad \exists N_{\varepsilon, t_0} \in \mathbb{N} / |f_n(t) - f(t)| < \varepsilon \quad \forall n \geq N_{\varepsilon, t_0};$$

se representa como $f_n(\cdot) \rightarrow f(\cdot)$.



Supongamos que cada función de la sucesión $\{f_n\}$ es continua en t_0 , ¿se garantiza esta propiedad para la función límite f ? En general no se verifica. La convergencia puntual no es lo suficientemente fuerte como para transferir las propiedades correspondientes a las funciones f_n a la función límite f . La *convergencia uniforme* intenta preservar estas propiedades a la función límite. La convergencia uniforme verifica que:

$$\lim_{t \rightarrow t_0} \lim_{n \rightarrow \infty} f_n(t) = \lim_{n \rightarrow \infty} \lim_{t \rightarrow t_0} f_n(t).$$

Definition 98 La sucesión de funciones reales $\{f_n(\cdot) : n \geq 1\}$ donde $f_n(\cdot) : [0, 1] \subset \mathbb{R} \mapsto \mathbb{R}$ converge uniformemente a la función $f(\cdot)$ si para cada $t \in [0, 1]$ la sucesión de números reales $\{f_n(t) : n \geq 1\}$ converge a $f(t)$, es decir

$$\forall t \in [0, 1], \quad \forall \varepsilon > 0, \quad \exists N_\varepsilon \in \mathbb{N} / |f_n(t) - f(t)| < \varepsilon \quad \forall n \geq N_\varepsilon;$$

se representa como $f_n(\cdot) \xrightarrow{u} f(\cdot)$.

La diferencia entre las dos definiciones es que N es para la convergencia puntual donde la función depende sólo de ε y t_0 , es decir N_{ε, t_0} ; mientras para la convergencia uniforme N depende sólo de ε , es decir N_ε .

Theorem 99 Supongamos que $f_n(\cdot) \xrightarrow{u} f(\cdot)$ en S . Si para toda función f_n es continua en $t_0 \in S$, entonces f es también continua en t_0 .

13.2 Variables aleatorias

Sea (Ω, F, P) un espacio de probabilidad, donde Ω es el conjunto de puntos, F es un σ -álgebra de subconjuntos de Ω y P es una medida de probabilidad sobre los elementos de F .

Una *variable aleatoria* $X(\omega)$ es una transformación de Ω en $\mathbb{R}$ tal que las imágenes de $X^{-1}(B)$ de conjuntos de Borel B son elementos de F .

13.2.1 Convergencia de variables aleatorias

Definition 100 Sea $\{c_n, n \geq 1\}$ una sucesión de números reales. La sucesión $\{c_n, n \geq 1\}$ converge al número real c si :

$$\forall \varepsilon > 0, \quad \exists N_\varepsilon \in \mathbb{N} / |c_n - c| < \varepsilon \quad \forall n \geq N_\varepsilon,$$

se representa como $c_n \rightarrow c$.



Theorem 101 (*criterio de Cauchy*) Una sucesión de números reales $\{c_n, n \geq 1\}$ converge al límite c si

$$|x_n - x_m| \rightarrow 0 \quad \text{cuando } n \text{ y } m \rightarrow \infty.$$

Sea $\{X_n, n \geq 1\}$ una sucesión de variables aleatorias (va's) definido sobre el mismo espacio de probabilidad, es decir (Ω, F, P) , entonces:

Definition 102 $\{X_n, n \geq 1\}$ converge con probabilidad 1 (o fuertemente, casi segura) al número real c si:

$$P\left(\lim_{n \rightarrow \infty} X_n = c\right) = 1;$$

es decir

$$P\{\omega : \forall \varepsilon > 0, \exists N_\varepsilon \in \mathbb{N} \text{ } / \text{ } |X_n(\omega) - c| < \varepsilon \quad \forall n \geq N_\varepsilon\} = 1,$$

se representa como $X_n \xrightarrow{p1} c$.

Definition 103 $\{X_n, n \geq 1\}$ converge con probabilidad 1 (o fuertemente, casi segura) a la va X , donde X pertenece al espacio de probabilidad (Ω, F, P) si:

$$P\left(\lim_{n \rightarrow \infty} X_n = X\right) = 1;$$

es decir

$$P\{\omega : \forall \varepsilon > 0, \exists N_\varepsilon \in \mathbb{N} \text{ } / \text{ } |X_n(\omega) - X(\omega)| < \varepsilon \quad \forall n \geq N_\varepsilon\} = 1,$$

se representa como $X_n \xrightarrow{p1} X$.

Definition 104 $\{X_n, n \geq 1\}$ converge en probabilidad a la constante c si:

$$\lim_{n \rightarrow \infty} P(|X_n - c| < \varepsilon) = 1 \quad \forall \varepsilon > 0;$$

es decir

$$\lim_{n \rightarrow \infty} P\{\omega : X_n(\omega) \in (c - \varepsilon, c + \varepsilon) \quad \forall \varepsilon > 0\} = 1,$$

se representa como $X_n \xrightarrow{p} c$ o $p\lim X_n = c$.



Theorem 105 Sea $\{X_n, n \geq 1\}$ una sucesión de va's y c una constante. Entonces

$$X_n \xrightarrow{p1} c \Rightarrow X_n \xrightarrow{p} c.$$

Definition 106 $\{X_n, n \geq 1\}$ converge en probabilidad a la va X , donde X pertenece al espacio de probabilidad (Ω, F, P) si:

$$\lim_{n \rightarrow \infty} P(|X_n - X| < \varepsilon) = 1 \quad \forall \varepsilon > 0;$$

es decir

$$\lim_{n \rightarrow \infty} P\{\omega : X_n(\omega) \in (X(\omega) - \varepsilon, X(\omega) + \varepsilon)\} = 1 \quad \forall \varepsilon > 0,$$

se representa como $X_n \xrightarrow{p} X$ o $p\lim X_n = X$.

Theorem 107 Sea $\{X_n, n \geq 1\}$ una sucesión de va's y X una va. Entonces

$$X_n \xrightarrow{p1} X \Rightarrow X_n \xrightarrow{p} X.$$

Theorem 108 Sean $\mathbf{X}_n \equiv (X_{1n}, X_{2n}, \dots, X_{kn})'$ y $\mathbf{X} \equiv (X_1, X_2, \dots, X_k)'$ vectores aleatorios. Entonces $\mathbf{X}_n$ converge con probabilidad 1 (en probabilidad) a $\mathbf{X}$ si

$$X_{jn} \xrightarrow{p1} X_j \quad \left(X_{jn} \xrightarrow{p} X_j \right) \quad j = 1, 2, \dots, k.$$

Definition 109 Sea $\{X_n, n \geq 1\}$ una sucesión de va's tal que $E|X_n|^2 < \infty$, decimos que $\{X_n, n \geq 1\}$ converge en media cuadrática al número real c si:

$$\lim_{n \rightarrow \infty} E|X_n - c|^2 = 0;$$

se representa como $X_n \xrightarrow{2} c$.

Theorem 110 Sea $\{X_n, n \geq 1\}$ una sucesión de va's y c una constante. Entonces

$$X_n \xrightarrow{2} c \Rightarrow X_n \xrightarrow{p} c.$$

Definition 111 Sea $\{X_n, n \geq 1\}$ una sucesión de va's tal que $E|X_n|^2 < \infty$. Una sucesión $\{X_n, n \geq 1\}$ se dice que converge en media cuadrática a la va X , s.a. $E|X|^2 < \infty$ y X pertenece al espacio de probabilidad (Ω, F, P) , si:

$$\lim_{n \rightarrow \infty} E|X_n - X|^2 = 0,$$

se representa como $X_n \xrightarrow{2} X$.



Theorem 112 Sea $\{X_n, n \geq 1\}$ una sucesión de va's y X otra va. Entonces

$$X_n \xrightarrow{2} X \Rightarrow X_n \xrightarrow{p} X.$$

Theorem 113 Sea $\{X_n, n \geq 1\}$ una sucesión de va's y X una va tal que

$$X_n \xrightarrow{2} X$$

entonces

$$\lim_{n \rightarrow \infty} E(X_n) = E(X) \quad y \quad \lim_{n \rightarrow \infty} E(X_n^2) = E(X^2).$$

Theorem 114 Sea $\{X_n, n \geq 1\}$ y $\{Y_n, n \geq 1\}$ dos pares de sucesiones va's tal que $X_n \xrightarrow{2} X$ y $Y_n \xrightarrow{2} Y$, verificando que $E|X|^2 < \infty$, $E|Y|^2 < \infty$ y X, Y pertenecientes al mismo espacio de probabilidad (Ω, F, P) ; entonces

$$\lim_{n \rightarrow \infty} E(X_n Y_n) = E(XY).$$

Definition 115 Sea $\{X_n, n \geq 1\}$ una sucesión de va's tal que $E|X_n|^r < \infty$, para algún $r > 0$. Una sucesión $\{X_n, n \geq 1\}$ se dice que converge en media r -ésima a X , tal que $E|X|^r < \infty$ y X pertenece al espacio de probabilidad (Ω, F, P) , si:

$$\lim_{n \rightarrow \infty} E|X_n - X|^r = 0,$$

se representa como $X_n \xrightarrow{r} X$.

Theorem 116 Si $r > s$, entonces

$$X_n \xrightarrow{r} X \Rightarrow X_n \xrightarrow{s} X.$$

Theorem 117 Supongamos que $X_n \xrightarrow{r} X$ y $E|X|^r < \infty$. Entonces

$$\lim_{n \rightarrow \infty} E(X_n^r) = E(X^r) \quad y \quad \lim_{n \rightarrow \infty} E|X_n^r| = E|X^r|.$$

Definition 118 Sea $\{F_n(\cdot), n \geq 1\}$ una sucesión de funciones de distribución correspondientes a la sucesión de va's $\{X_n, n \geq 1\}$ y $F(\cdot)$ la función de distribución correspondiente a la va X , X_n converge en distribución a X (o F_n converge débilmente a F) if:

$$\lim_{n \rightarrow \infty} F_n(t) = F(t), \text{ en cada punto } t \text{ donde } F \text{ es continua;}$$

se representa como $X_n \xrightarrow{d} X$.

Remark 1 Cuando decimos que una sucesión de va's $\{X_n, n \geq 1\}$ converge en distribución a X , significa que la sucesión converge a un miembro de la clase de va's que tiene la distribución $F(\cdot)$; siendo X un representante de esa clase.

Theorem 119 Sea $\{X_n, n \geq 1\}$ una sucesión de va's y X una va. Entonces

$$X_n \xrightarrow{p} X \Rightarrow X_n \xrightarrow{d} X.$$

Theorem 120 Sea c una constante. Entonces $X_n \xrightarrow{p} c \Leftrightarrow X_n \xrightarrow{d} c$.

Theorem 121 Sea $\{X_n, Y_n; n \geq 1\}$ una sucesión de pares de va's y X, Y dos va's definidos sobre el mismo espacio de probabilidad (Ω, F, P) . Entonces

$$|X_n - Y_n| \xrightarrow{p} 0 \text{ y } Y_n \xrightarrow{d} Y \Rightarrow X_n \xrightarrow{d} Y.$$

Theorem 122 (Slutsky) Sea $\{X_n, Y_n; n \geq 1\}$ una sucesión de pares de va's, y sea c una constante. Entonces

$$\begin{aligned} (a) \quad & X_n \xrightarrow{d} X, \quad Y_n \xrightarrow{p} c \Rightarrow X_n \pm Y_n \xrightarrow{d} X \pm c; \\ (b) \quad & X_n \xrightarrow{d} X, \quad Y_n \xrightarrow{p} c \Rightarrow \begin{cases} X_n Y_n \xrightarrow{d} cX & \text{if } c \neq 0, \\ X_n Y_n \xrightarrow{p} 0 & \text{if } c = 0; \end{cases} \\ (c) \quad & X_n \xrightarrow{d} X, \quad Y_n \xrightarrow{p} c \Rightarrow \frac{X_n}{Y_n} \xrightarrow{d} \frac{X}{c} \quad \text{if } c \neq 0. \end{aligned}$$

Theorem 123 (Mann-Wald) Sea $\{X_n, n \geq 1\}$ una sucesión de va's y X una va. Sea $g(\cdot)$ una función continua de valores reales. Entonces

$$\begin{aligned} (a) \quad & X_n \xrightarrow{p1} X \Rightarrow g(X_n) \xrightarrow{p1} g(X); \\ (b) \quad & X_n \xrightarrow{p} X \Rightarrow g(X_n) \xrightarrow{p} g(X); \\ (c) \quad & X_n \xrightarrow{d} X \Rightarrow g(X_n) \xrightarrow{d} g(X). \end{aligned}$$

13.2.2 Relación entre $\lim E$ y EA

Sea F_n la función de distribución de X_n y $F_n \rightarrow F$ en los puntos de continuidad de F . Definimos $\lim E$ y AE como:



Universitat d'Alacant
Universidad de Alicante

$$\lim_{n \rightarrow \infty} EX_n = \lim_{n \rightarrow \infty} \int_{-\infty}^{\infty} x dF_n(x)$$

y

$$EA X_n = \int_{-\infty}^{\infty} x dF(x)$$

AE, *esperanza asintótica*, es la media de la distribución límite.

Theorem 124 Si $E |X_n|^r < M$ para todo n , entonces $\lim EX_n^s = EA X_n^s$ para cualquier $s < r$. En particular, si $EX_n^2 < M$, entonces $\lim EX_n = EA X_n$.

13.2.3 Acotado estocásticamente, y la notación de O_p y o_p

Definition 125 Una sucesión de va's $\{X_n, n \geq 1\}$, con respecto a las funciones de distribución $\{F_n(\cdot), n \geq 1\}$, se dice que está acotado estocásticamente (o acotado en probabilidad) si

$$\forall \varepsilon > 0 \quad \exists M_\varepsilon, N_\varepsilon \quad \text{tal que} \quad F_n(M_\varepsilon) - F_n(-M_\varepsilon) > 1 - \varepsilon \quad \forall n > N_\varepsilon.$$

La notación $X_n = O_p(1)$ será usada.

Theorem 126 Si $X_n \xrightarrow{d} X \Rightarrow X_n = O_p(1)$.

Para dos sucesiones de va's $\{U_n, n \geq 1\}$ y $\{V_n, n \geq 1\}$, la notación $U_n = O_p(V_n)$ representa que la sucesión $\left\{\frac{U_n}{V_n}, n \geq 1\right\}$ es $O_p(1)$. Además, la notación $U_n = o_p(V_n)$ representa que $\frac{U_n}{V_n} \xrightarrow{p} 0$.

Theorem 127 Sea $\{Y_n, n \geq 1\}$ acotado en probabilidad, si $X_n \xrightarrow{p} 0$ entonces

$$X_n Y_n \xrightarrow{p} 0.$$



13.2.4 La función característica

Definition 128 Sea X una va, la función $\emptyset(s) = E(e^{iXs})$, donde $i = \sqrt{-1}$, se denomina la función característica (FC) de X .

La expansión en serie de potencia de e^{iXs} es

$$e^{iXs} = \sum_{r=0}^{\infty} \frac{(iXs)^r}{r!}$$

Además, la función característica puede escribirse también como

$$\emptyset(s) = \sum_{r=0}^{\infty} \frac{E[(iXs)^r]}{r!} = \sum_{r=0}^{\infty} \frac{i^r s^r}{r!} \mu_r \quad (185)$$

donde $\mu_r = E(X^r)$ es el momento r-ésimo de X .

Theorem 129 Una función característica es uniformemente continua en la línea real.

Theorem 130 Si $E|X|^r < \infty$, entonces

$$\emptyset^{(r)}(0) = \left(\frac{d^r \emptyset(s)}{ds^r} \right)_{s=0} = i^r \mu_r.$$

Theorem 131 Dos funciones de distribución son idénticas sii sus funciones características son también idénticas.

Theorem 132 Sea $\mathbf{X}$ un vector aleatorio en $\mathbb{R}^k$ con una distribución normal multivariante con media μ y matriz de covarianzas $\Sigma > 0$ ⁶⁶. La función característica asociada es

$$\emptyset(s) = E(e^{is'\mathbf{X}}) = \exp\left(is'\mu - \frac{1}{2}s'\Sigma s\right).$$

Corollary 133 La función característica de una distribución normal con media μ y varianza σ^2 es

$$\emptyset(s) = \exp\left(is'\mu - \frac{1}{2}s^2\sigma^2\right).$$

⁶⁶ Σ es una matriz definida positiva (bajo supuesto), la notación es $\Sigma > 0$.



Theorem 134 Sea $\mathbf{X}$ un vector aleatorio en $\mathbb{R}^k$ con media μ y matriz de covarianzas Σ . Si $\forall \lambda \in \mathbb{R}^k$

$$\lambda' \mathbf{X} \sim N(\lambda' \mu, \lambda' \Sigma \lambda),$$

entonces

$$\mathbf{X} \sim N(\mu, \Sigma).$$

Theorem 135 Sean $\{F_n(\cdot), F(\cdot); n \geq 1\}$, $\{\emptyset_n, \emptyset; n \geq 1\}$ respectivamente sucesiones de funciones de distribución y sus funciones características asociadas. Entonces,

$$F_n \text{ converge débilmente a } F \quad \text{sii} \quad \lim_{n \rightarrow \infty} \emptyset_n(s) = \emptyset(s).$$

El siguiente resultado, debido a Cramér y Wold, permite que la convergencia de funciones de distribución multivariantes se reduzca a la convergencia de funciones de distribución univariantes.

Theorem 136 En $\mathbb{R}^k$, los vectores aleatorios $\mathbf{X}_n$ convergen en distribución al vector aleatorio $\mathbf{X}$ sii para cada vector $\lambda \in \mathbb{R}^k$,

$$\lambda' \mathbf{X}_n \xrightarrow{d} \lambda' \mathbf{X}.$$

13.2.5 Ley débil de los grandes números

Sea $\{X_n, n \geq 1\}$ una sucesión de va's y $S_n = \sum_{k=1}^n X_k$, $n = 1, 2, \dots$. Estamos interesados en la siguiente cuestión: ¿Existe una sucesión de constantes a_n y $b_n > 0$, que verifican que $b_n \rightarrow \infty$ cuando $n \rightarrow \infty$, tal que la sucesión de va's $b_n^{-1}(S_n - a_n) \xrightarrow{p} 0$?

Definition 137 Sea $\{X_n, n \geq 1\}$ una sucesión de va's y $S_n = \sum_{k=1}^n X_k$, $n = 1, 2, \dots$. Decimos que $\{X_n, n \geq 1\}$ verifica la ley débil de los grandes números (LDGN) con respecto a la sucesión de constantes $\{b_n, n \geq 1\}$, $b_n > 0$, $b_n \rightarrow \infty$ cuando $n \rightarrow \infty$, si existe una sucesión de constantes reales $\{a_n, n \geq 1\}$ tal que $b_n^{-1}(S_n - a_n) \xrightarrow{p} 0$.

Theorem 138 Sea $\{X_n, n \geq 1\}$ una sucesión va's incorrelacionadas con $EX_k = \mu_k$ y $Var X_k = \sigma_k^2$, $k = 1, 2, \dots$. Si $\sum_{k=1}^n \sigma_k^2 \rightarrow \infty$ cuando $n \rightarrow \infty$, podemos elegir $a_n = \sum_{k=1}^n \mu_k$ y $b_n = \sum_{k=1}^n \sigma_k^2$, o sea, $b_n^{-1}(S_n - a_n) \xrightarrow{p} 0$.

Corollary 139 En el Teorema 138 podemos elegir $b_n = n$, probándose que $\sum_{k=1}^n \frac{\sigma_k^2}{n^2} \rightarrow 0$ cuando $n \rightarrow \infty$.

Definition 140 Sea $\{X_n, n \geq 1\}$ una sucesión de va's, y sea $S_n = \sum_{k=1}^n X_k$, $n = 1, 2, \dots$. Decimos que $\{X_n, n \geq 1\}$ verifica la ley débil de los grandes números (LDGN) con respecto a sucesión de constantes $\{b_n, n \geq 1\}$, $b_n > 0$, $b_n \rightarrow \infty$ cuando $n \rightarrow \infty$, si existe una sucesión de constantes reales $\{a_n, n \geq 1\}$ tal que $b_n^{-1} (S_n - a_n) \xrightarrow{p} 0$.

13.3 Teorema central del límite (TCL)

Sea $X_1, X_2, X_3, \dots$ una sucesión de va's, S_n se define como $\sum_{k=1}^n X_k$, y $\bar{X}_n = \frac{S_n}{n}$. Definamos la media estandarizada

$$Z_n = \frac{\bar{X}_n - E\bar{X}_n}{\sqrt{\text{Var}\bar{X}_n}} = \frac{S_n - ES_n}{\sqrt{\text{Var}S_n}}.$$

Entonces bajo una variedad de supuestos alternativos (ver los siguientes teoremas), $Z_n \xrightarrow{d} Z$, donde $Z \sim N(0, 1)$. Se representa como $Z_n \xrightarrow{d} N(0, 1)$.

Theorem 141 (TCL de Lindeberg-Lévy). Sea $X_1, X_2, X_3, \dots$ una sucesión de va's i.i.d. con $EX_k = \mu < \infty$ y $\text{Var}X_k = \sigma^2 < \infty$. Entonces $Z_n \xrightarrow{d} N(0, 1)$.

Theorem 142 (TCL de Liapounov). Sea $X_1, X_2, X_3, \dots$ una sucesión de va's independientes con $EX_k = \mu_k < \infty$, $\text{Var}X_k = \sigma_k^2 < \infty$, $E|X_k - \mu_k|^\nu < \infty$ ($\nu > 2$), y

$$\lim_{n \rightarrow \infty} \frac{\sum_{k=1}^n E|X_k - \mu_k|^\nu}{\left(\sum_{k=1}^n \sigma_k^2\right)^{\frac{\nu}{2}}} = 0,$$

entonces $Z_n \xrightarrow{d} N(0, 1)$.

Consideremos ahora va's "double array";

$$\begin{array}{cccc} X_{11}, & X_{12}, & \dots, & X_{1k_1}; \\ X_{21}, & X_{22}, & \dots, & X_{2k_2}; \\ \dots & & & \\ X_{n1}, & X_{n2}, & \dots, & X_{nk_n}; \\ \dots & & & \end{array}$$



Para cada $n \geq 1$, hay k_n va's $\{X_{nj}, 1 \leq j \leq k_n\}$. Se asume que $k_n \rightarrow \infty$.
El caso cuando $k_n = n$ se denomina "triangular" array.

Sea

$$\begin{aligned}\mu_{nj} &= EX_{nj}, \\ a_n &= E\left(\sum_{j=1}^{k_n} X_{nj}\right) = \sum_{j=1}^{k_n} \mu_{nj}; \\ b_n^2 &= \text{Var}\left(\sum_{j=1}^{k_n} X_{nj}\right).\end{aligned}$$

Theorem 143 Sea $\{X_{nj} : 1 \leq j \leq k_n; n = 1, 2, \dots\}$ un "double array" con va's independientes entre filas. Supongamos que, para algún $\nu > 2$,

$$\lim_{n \rightarrow \infty} \frac{\sum_{j=1}^{k_n} E |X_{nj} - \mu_{nj}|^\nu}{b_n^\nu} = 0.$$

Entonces

$$\frac{\sum_{j=1}^{k_n} X_{nj} - a_n}{b_n} \xrightarrow{d} N(0, 1).$$

13.4 Función delta de Dirac

Definition 144 La función delta de Diracfunction, $\delta(x)$, es una función que es cero siempre excepto en $x = 0$ que es infinito verificando

$$\int_{-\infty}^{+\infty} \delta(x) dx = 1.$$

Otra definición de $\delta(x)$ es

$$\delta(x) = \lim_{a \rightarrow \infty} a \text{ rect}(ax)$$

donde

$$\text{rect}(x/b) = \begin{cases} 1; & |x| < b/2 \\ 0; & \text{otro caso.} \end{cases}$$

Esta función se llama *función rectangular*. Obsérvese que la función $a \text{ rect}(ax)$ tiene un área unitaria decreciendo rápidamente a cero cuando $x \neq 0$. Consideremos ahora la *función unitaria step* $u(x - c)$ definida como

$$u(x - c) = \begin{cases} 1; & x \geq c \\ 0; & x < c. \end{cases}$$



Esta función es discontinua en $x = c$ con $u(0) = 1$ y puede verse como el límite de la siguiente función:

$$f(x) = \begin{cases} 0; & x < c - h \\ \frac{h-c}{2h} + \frac{1}{2h}x; & c - h \leq x \leq c + h \\ 1; & x > c + h. \end{cases}$$

La derivada de la función $f(x)$ es

$$\dot{f}(x) = \frac{1}{h} \text{rect}\left(\frac{x-c}{h}\right).$$

Entonces, la derivada de $u(x-c)$ puede interpretarse como

$$\dot{u}(x-c) = \lim_{h \rightarrow 0} \frac{1}{h} \text{rect}\left(\frac{x-c}{h}\right) = \delta(x-c)$$

donde

$$\delta(x-c) = \begin{cases} \infty; & x = c \\ 0; & x \neq c. \end{cases}$$

13.5 El espacio C

Dividamos $[0, 1]$ en n subintervalos de longitud $h \equiv 1/n$. Sea $\{kh : k = 1, 2, \dots, n\}$ el conjunto de puntos donde existe una va en cada punto; entonces tenemos una sucesión de va's $\{U_{n,kh} : k = 1, 2, \dots, n\}$ que son *i.i.d.* definidas sobre el mismo espacio de probabilidad (Ω, F, P) con media 0 y varianza unitaria. Construyamos el siguiente double array $\{S_{nr} : 1 \leq r \leq n, n \geq 1\}$ de va's donde S_{nr} se define como:

$$S_{nr} = \frac{1}{\sqrt{n}} \sum_{k=1}^r U_{n,kh}.$$

Para cada $\omega_0 \in \Omega$, tenemos una realización de la sucesión $\{S_{nr}\}_{r=1}^n$; es decir

$$\{S_{nr}(\omega_0) : r = 1, 2, \dots, n\}.$$

Si dibujamos el siguiente conjunto de puntos:

$$\left\{ \left(\frac{r}{n}, S_{nr}(\omega_0) \right) : r = 1, 2, \dots, n \right\} \cup \{(0, 0)\}^{67}; \quad (186)$$

podemos ver $n + 1$ puntos. Podemos extender esta realización sobre $[0, 1]$. Sea $\{Y_n(\cdot); n \geq 1\}$ una sucesión de funciones aleatorias donde $Y_n(\cdot)$ se define como:

$$Y_n(t, \omega) = \begin{cases} \frac{1}{\sqrt{n}} \sum_{k=1}^{[nt]} U_{n, kh}(\omega); & \omega \in \Omega, t \in [h, 1] \\ 0; & \omega \in \Omega, t \in [0, h). \end{cases} \quad (187)$$

Para un valor dado de $\omega_0 \in \Omega$, tenemos una realización de $Y_n(t, \omega)$, es decir $Y_n(t, \omega_0)$. Al dibujarlo, obtenemos una función real con saltos en kh , $k = 1, 2, 3, \dots, n$. Por tanto, $Y_n(t, \omega_0)$ pertenece a $D[0, 1]$. ¿Cómo podemos suavizar los saltos en $Y_n(t, \omega_0)$? Obteniendo una realización de $C[0, 1]$. Interpolamos los datos mediante splines. Una función spline está formada por varios polinomios, cada una se define sobre un subintervalo, unidos mediante condiciones de continuidad. Supongamos que se especifican $n + 1$ puntos, $t_0 < t_1 < \dots < t_n$. Estos puntos se denominan *nudos*⁶⁸. Sea $k \geq 0$ un valor entero fijado, entonces

Definition 145 Una función spline de orden k con nudos $t_0, t_1, \dots, t_n$ es una función g verificando la siguientes condiciones:

(i) En cada intervalo $[t_r, t_{r+1}]$ $r = 0, 1, \dots, n - 1$, g es un polinomio de orden $\leq k$

$$g(t) = \begin{cases} g_0(t); & t \in [t_0, t_1] \\ g_1(t); & t \in [t_1, t_2] \\ \dots & \dots \\ g_{n-1}(t); & t \in [t_{n-1}, t_n]. \end{cases}$$

(ii) g tiene derivadas continuas hasta el orden $(k - 1)$ en $[t_0, t_n]$.

Example 146 Para un valor dado $\omega_0 \in \Omega$ podemos construir un spline de primer orden para interpolar los puntos dados en (186). Tenemos un

⁶⁷ $(0, 0)$ es el punto inicial, es decir para $t = 0$ y $\forall \omega \in \Omega$ tomamos el valor de 0; mientras tomamos una $U_{n, kh}$ para cada kh , $k = 1, 2, \dots, n$.

⁶⁸ En nuestro caso, $t_r = rh$ donde $r = 0, 1, \dots, n$.

polinomio diferente de primer orden en cada intervalo $[rh, (r+1)h]$, $r = 0, 1, \dots, n-1$. El polinomio de primer orden en cada intervalo es

$$X_n(t, \omega_0) = \begin{cases} \frac{1}{\sqrt{n}} \sum_{k=1}^r U_{n,kh}(\omega_0) + \frac{nt-r}{\sqrt{n}} U_{n,(r+1)h}(\omega_0); & rh \leq t \leq (r+1)h, \\ & r = 1, \dots, n-1. \\ \frac{nt}{\sqrt{n}} U_{n,h}(\omega_0); & 0 \leq t \leq h. \end{cases}$$

La realización anterior sobre $[0, 1]$ se expresa del siguiente modo:

$$X_n(t, \omega_0) = \begin{cases} \frac{nt}{\sqrt{n}} U_{n,h}(\omega_0); & t \in [0, h); \\ \frac{1}{\sqrt{n}} \sum_{k=1}^{[nt]} U_{n,kh}(\omega_0) + \frac{nt-[nt]}{\sqrt{n}} U_{n,([nt]+1)h}(\omega_0); & t \in [h, 1); \\ \sum_{k=1}^n U_{n,kh}(\omega_0); & t = 1. \end{cases} \quad (188)$$

Entonces, tenemos la siguiente función aleatoria:

$$X_n(\cdot) = \{Y_n(t, \omega) + V_n(t, \omega) : \omega \in \Omega, t \in [0, 1]\} \quad (189)$$

donde

$$V_n(t, \omega) = \frac{nt - [nt]}{\sqrt{n}} U_{n,([nt]+1)h}(\omega).$$

13.6 Notación sobre la expansión Ito-Taylor

Introduciremos alguna notación para entender la expansión de Ito-Taylor⁶⁹. Sea el vector fila

$$\lambda = (j_1, j_2, \dots, j_l); \quad j_i \in \{0, 1, \dots, m\}$$

para $i \in \{0, 1, \dots, l\}$ y $m = 1, 2, 3, \dots$; donde l representa la longitud de λ , o sea el número de componentes del vector. Entonces

$$l = l(\lambda) \in \{1, 2, \dots\}$$

y m representa el número de componentes del proceso de. Representamos por v el vector de longitud cero, o sea $l(v) = 0$, y $\mathcal{M}$ el conjunto de todos los vectores λ y v . Representamos $-\lambda$ y $\lambda-$ los vectores obtenidos eliminando el primer y último componente respectivamente.

⁶⁹Ver ecuación (164).

Definition 147 Un subconjunto $\mathcal{A} \subset \mathcal{M}$ es un conjunto hierarchial si verifica las siguientes condiciones:

- (i) $\mathcal{A} \neq \emptyset$;
- (ii) $\sup_{\lambda \in \mathcal{A}} l(\lambda) < \infty$;
- (iii) $-\lambda \in \mathcal{A}$ para cada $\lambda \in \mathcal{A} \setminus \{v\}$.

Par cualquier conjunto $\mathcal{A}$ definimos el conjunto "remainder" $\mathcal{B}(\mathcal{A})$ por

$$\mathcal{B}(\mathcal{A}) = \{\lambda \in \mathcal{M} \setminus \mathcal{A} : -\lambda \in \mathcal{A}\}.$$

Sea $\lambda = (j_1, j_2, \dots, j_l) \in \mathcal{M}$ y u un proceso estocástico en tiempo continuo, definimos la integral de Ito múltiple $I_\lambda[u(\cdot)]_{\tau, t}$ recursivamente mediante

$$I_\lambda[u(\cdot)]_{\tau, t} = \begin{cases} u(\tau); & l = 0 \\ \int_{\tau}^t I_{\lambda-}[u(\cdot)]_{\tau, s} ds; & l \geq 1 \text{ and } j_l = 0 \\ \int_{\tau}^t I_{\lambda-}[u(\cdot)]_{\tau, s} dW_{j_l}(s); & l \geq 1 \text{ and } j_l \geq 1. \end{cases}$$

Si $u(\cdot) = 1$, abreviaremos $I_\lambda[1]_{\tau, t}$ a $I_{\lambda, t}$ o I_λ .

Example 148 Sean varias integrales de Ito múltiples cuando $u(\cdot) = 1$ y $d = m = 1$:

$$I_{(0)} = \int_{\tau}^t ds;$$

$$I_{(1)} = \int_{\tau}^t dW(s);$$

$$I_{(0,1)} = \int_{\tau}^t \int_{\tau}^s dz dW(s);$$

$$I_{(1,0)} = \int_{\tau}^t \int_{\tau}^s dW(z) ds;$$

$$I_{(0,0)} = \int_{\tau}^t \int_{\tau}^s dz ds;$$

$$I_{(1,1)} = \int_{\tau}^t \int_{\tau}^s dW(z) dW(s);$$

$$I_{(1,1,1)} = \int_{\tau}^t \int_{\tau}^s \int_{\tau}^z dW(u) dW(z) dW(s);$$



para el valor de estas integrales múltiples véase la siguiente sección del Apéndice.

Para cada $\lambda = (j_1, j_2, \dots, j_l)$ y $u \in \mathcal{C}^h(R^+ \times R^d, R)$ ⁷⁰ with $h = l(\lambda) + n(\lambda)$ ⁷¹ definimos la función de coeficientes de Ito como

$$u_\lambda = \begin{cases} u; & l = 0 \\ L^{j_1} u_{-\lambda}; & l \geq 1. \end{cases}$$

14 Cálculo de integrales múltiples de Ito

Aquí calculamos las integrales múltiples de Ito que aparecen en la sección anterior del Apéndice, que son necesarias para las diferentes aproximaciones en tiempo discreto de las EDEs.

(i) $I_{(1,0)}$

$$I_{(1,0)} = \int_{\tau}^t \int_{\tau}^s dW(z) ds = (Z(t) - Z(\tau)) - W(\tau)(t - \tau)$$

donde

$$Z(t) = \int_0^t W(s) ds.$$

Sea $\tau = t - h$, entonces

$$I_{(1,0)} = \Delta_h Z(t) - hW(t - h),$$

(ii) $I_{(0,1)}$

$$I_{(0,1)} = \int_{\tau}^t \int_{\tau}^s dz dW(s) = \int_{\tau}^t s dW(s) - \tau(W(t) - W(\tau));$$

aplicando el Teorema 40, tenemos

$$\int_{\tau}^t s dW(s) = tW(t) - \tau W(\tau) - \int_{\tau}^t W(s) ds;$$

⁷⁰El espacio de h veces continuo diferenciable $u : R^+ \times R^d \rightarrow R$.

⁷¹ $n(\lambda)$ es el número de componentes de λ que son iguales a cero.



entonces

$$I_{(0,1)} = (tW(t) - \tau W(\tau)) - (Z(t) - Z(\tau)).$$

Sea $\tau = t - h$, entonces

$$I_{(0,1)} = hW(t) - \Delta_h Z(t).$$

(iii) $I_{(1,1)}$

$$I_{(1,1)} = \int_{\tau}^t \int_{\tau}^s dW(z) dW(s) = \int_{\tau}^t W(s) dW(s);$$

aplicando (94)

$$I_{(1,1)} = \int_{\tau}^t W(s) dW(s) = \frac{1}{2} (W(t) - W(\tau))^2 - \frac{1}{2} (t - \tau).$$

Para $\tau = t - h$, podemos escribir la expresión de arriba como

$$I_{(1,1)} = \frac{1}{2} [\Delta_h W(t)^2 - h].$$

(iv) $I_{(1,1,1)}$

$$\begin{aligned} I_{(1,1,1)} &= \int_{\tau}^t \int_{\tau}^s \int_{\tau}^z dW(u) dW(z) dW(s) \\ &= \int_{\tau}^t \left[\int_{\tau}^s W(z) dW(z) - W(\tau) \int_{\tau}^s dW(z) \right] dW(s) \\ &= \int_{\tau}^t \frac{1}{2} [W(s)^2 - W(\tau)^2 - (s - \tau)] dW(s) \\ &\quad - \int_{\tau}^t W(\tau) [W(s) - W(\tau)] dW(s). \end{aligned}$$

Operando y aplicando el Teorema 40 y (94) a $I_{(1,1,1)}$, obtenemos

$$\begin{aligned} I_{(1,1,1)} &= \frac{1}{2} \int_{\tau}^t W(s)^2 dW(s) + \frac{1}{2} [W(\tau)^2 W(t) - W(\tau) W(t)^2] \\ &\quad - \frac{1}{2} (t - \tau) [W(t) - W(\tau)] + \frac{1}{2} (Z(t) - Z(\tau)). \end{aligned} \tag{190}$$



Sea

$$X(t) = W(t);$$

$$Y(t) = u(t, X(t)) \equiv X(t)^3;$$

entonces aplicando el lema de Ito (97) :

$$\int_{\tau}^t W(s)^2 dW(s) = \frac{1}{3} (W(t)^3 - W(\tau)^3) - (Z(t) - Z(\tau)).$$

Aplicando este resultado a (190) :

$$\begin{aligned} I_{(1,1,1)} &= \frac{1}{6} (W(t)^3 - W(\tau)^3) + \frac{1}{2} [W(\tau)^2 W(t) - W(\tau) W(t)^2] \\ &\quad - \frac{1}{2} (t - \tau) [W(t) - W(\tau)]. \end{aligned}$$

Para $\tau = t - h$, podemos escribir la expresión anterior como

$$I_{(1,1,1)} = \frac{1}{6} \Delta_h W(t)^3 - \frac{1}{2} [h + W(t) W(t-h)] \Delta_h W(t).$$

15 Referencias

- Arnold, L. (1974): *Stochastic differential equations: Theory and applications*, Wiley, New York.
- Billingsley (1968): *Convergence of probability measures*, Wiley, New York
- Brockwell (1995)
- Davidson
- Hamilton, J.D. (1994): *Time Series Analysis*, Princeton.
- Herrndorf (1984)
- Heston, S.L. (1993): "A closed-form solution for options with stochastic volatility, with applications to bond and currency options", *Review of Financial Studies* 6, p. 327-343.
- Hull, J. y A. White (1987): "The pricing of options on assets with stochastic volatilities", *Journal of Finance* 42, p. 281-300.
- Lancaster (1985)
- Melino, A. y S. Turnbull (1990): "Pricing foreign currency options with stochastic volatility", *Journal of Econometrics* 45, p.239-266.
- Nelson, D.B. (1990): "ARCH models as diffusion approximations", *Journal of Econometrics* 45, p. 7-38.
- Priestley, M.B. (1963): "The spectrum of a continuous process derived from a discrete process", *Biometrika*, 51, p. 517-520.
- Priestley, M.B. (1981): *Spectral Analysis and Time Series Analysis*, Academic Press.
- Ross (1983)
- Stroock, D.W., y S.R.S., Varadhan (1979): *Multidimensional Diffusion Processes*, Springer-Verlag, Berlin.

16 *Capítulo 3: Valoración de opciones sobre activos con rendimientos predecibles ruido blanco*

1 Introducción

En un artículo reciente, Lo y Wang (1995) demuestran que la predicibilidad de los rendimientos de un activo pueden afectar a los precios de las opciones sobre un activo, aunque la predicibilidad esté presente en la tendencia y no entre en la fórmula de valoración de opciones. Dado el proceso geométrico browniano con tendencia constante subyacente en la fórmula de Black-Scholes (BS), la varianza muestral a partir de los rendimientos discretos obtenidos a una frecuencia determinada no es un estimador apropiado de la varianza instantánea si los rendimientos son predecibles. Lo y Wang (1995) demuestran que este es el caso para procesos AR(1) en tiempo continuo en los casos univariantes y multivariantes con rendimientos correlacionados.

Nosotros analizamos el mismo tema para modelos en que los rendimientos de los activos están incorrelacionados (es decir, ruido blanco), y además impredecibles a partir únicamente de su historia pasada, pero son predecibles con un conjunto de información mayor. En otras palabras, el mercado para el activo primitivo es eficientemente débil pero no es eficiente en sentido semi-fuerte. La justificación para tales modelos descansa en la literatura de reversion a la media (ver Shiller (1984), Summers (1986), Poterba y Summers (1988), o Fama y French (1988)), y simplemente refleja el hecho que autocorrelaciones para los rendimientos observados no son compatibles únicamente con rendimientos esperados constantes, sino también con procesos de rendimientos esperados condicionales con alta correlación de primer orden (ver también Campbell (1991)). Además estos modelos no son una posibilidad teórica. Como dice Campbell, Lo y MacKinlay (1997, p. 267), “esta posibilidad parece ser empíricamente relevante para el mercado americano”.

Este artículo está organizado del siguiente modo. En la sección 2, se introduce una versión en tiempo discreto general del proceso de precios que genera rendimientos ruido blanco. Este proceso anida una versión condicional del modelo binomial, el cual usamos para contrastar si la predicibilidad de los rendimientos es importante para la valoración de opciones dentro de un marco libre de preferencias. También analizamos las consecuencias de la

sdiscrepancias entre la frecuencia de trading y la frecuencia de observación de los precios. En la sección 3 derivamos la difusión en tiempo continuo que agrega exactamente al modelo en tiempo discreto, y analizamos los efectos de la predicibilidad de los rendimientos en el caso límite de trading continuo. Con el fin de ganar intuición, consideramos una aproximación de estados discreta al modelo en tiempo continuo. Las conclusiones se encuentran en la sección 4.

2 Análisis en tiempo discreto

2.1 Un modelo en tiempo discreto

Sea $p(t)$ el precio en logaritmo en el instante t de un activo con riesgo que no paga dividendos, y sea $x(t)$ la variable causa en el sentido de Granger a los precios. Consideremos inicialmente un mundo en tiempo discreto donde la frecuencia más alta es 1. Campbell (1991) y Fiorentini y Sentana (1996) demuestran que si el proceso generador de datos conjunto para $\Delta_1 p(t) = p(t) - p(t-1)$ y $x(t)$ es el siguiente VAR(1) bivalente:

$$\begin{pmatrix} \Delta_1 p(t) \\ x(t) - \mu \end{pmatrix} = \begin{pmatrix} \mu \\ 0 \end{pmatrix} + \begin{pmatrix} 0 & 1 \\ 0 & \alpha \end{pmatrix} \begin{pmatrix} \Delta_1 p(t-1) \\ x(t-1) - \mu \end{pmatrix} + \begin{pmatrix} \varepsilon_{1,1}(t) \\ \varepsilon_{2,1}(t) \end{pmatrix} \quad (191)$$

donde $|\alpha| < 1$ y $\varepsilon_1(t) = (\varepsilon_{1,1}(t), \varepsilon_{2,1}(t))'$ es una sucesión de diferencia de martingalas con $E[\varepsilon_1(t)|I(t-1)] = \mathbf{0}$ y $V[\varepsilon_1(t)|I(t-1)] = \Sigma_1 = \begin{pmatrix} \sigma_{1,1}^2 & \sigma_{12,1} \\ \sigma_{12,1} & \sigma_{2,1}^2 \end{pmatrix}$, entonces el proceso continuo-compuesto de rendimientos $\Delta_1 p(t)$ es ruido blanco con varianza constante $\omega^2 = \sigma_{1,1}^2 + \frac{\sigma_{2,1}^2}{1-\alpha^2} \geq \sigma_{1,1}^2$, se demuestra que

$$\sigma_{12,1} = \frac{-\alpha}{1-\alpha^2} \sigma_{2,1}^2 \quad (192)$$

y

$$\sigma_{1,1}^2 \geq \left(\frac{\alpha}{1-\alpha^2} \right)^2 \sigma_{2,1}^2$$

Del mismo modo $\Delta_k p(t) = \sum_{j=0}^{k-1} \Delta_1 p(t-j)$, que es los rendimientos para k -periodos, con k entero, será también ruido blanco, por tanto la razón de varianza $Var(\Delta_k p(t))$ sobre $kVar(\Delta_1 p(t))$ será 1 para todo k .

Las implicaciones de la condición (192) son quizás más fáciles de entender si consideramos funciones de respuesta impulso de variaciones de precios con respecto a los diferentes shocks (ver Fiorentini y Sentana (1996)). Para el caso relevante de $\alpha > 0$, la correlación negativa entre innovaciones implica que el efecto positivo inicial sobre $\Delta_1 p(t)$ de un shock a $\varepsilon_{1,1}(t)$ se compensa débilmente por el impacto negativo pero decadente sobre $x(t)$. Más interesante, un shock a $\varepsilon_{2,1}(t)$ tiene un impacto inmediato negativo muy grande sobre $\Delta_1 p(t)$, que es revertido débilmente por el efecto positivo y decadente sobre $x(t)$. Los modelos de respuesta son tales que un proceso marginal de ruido blanco se obtiene mediante $\Delta_1 p(t)$. Campbell (1991) muestra una intuición económica para tal correlación negativa en un contexto de crecimiento dinámico de Gordon.

Sin embargo, la falta de correlación en todos los horizontes no debería ser una evidencia en favor de rendimientos esperados constantes. En este modelo, los rendimientos de un período son predecibles en la base de $x(t)$, que pueden interpretarse de hecho como rendimientos esperados.⁷² De hecho, dependiendo de los valores de los parámetros, el coeficiente R^2 de la regresión teórica de $\Delta_1 p(t)$ sobre $x(t-1)$ puede ser sustancial (ver Fiorentini y Sentana (1996)). Además, el grado de predicibilidad depende del horizonte, en el sentido de que la razón de la varianza del error de predicción k -periodos hacia adelante, $\sigma_{1,k}^2$, dividido por la varianza del rendimiento de k -periodos, $k\omega^2$, es una función no lineal de k (ver Campbell (1993) y la discusión de abajo). La Figura 1 presenta un dibujo de estas dos varianzas (con la normalización $\omega^2 = 1$) para valores de parámetros representativos de los rendimientos mensuales del mercado americano de la post-guerra donde el rendimiento de dividendo retardado un período se utiliza como variable predictor (ver Fiorentini y Sentana (1996), o capítulo 7 de Campbell, Lo y MacKinlay (1997) para los detalles). En particular, elegimos $\alpha = 0.98$, $\rho_{12,1} = \text{cor}(\varepsilon_{1,1}(t), \varepsilon_{2,1}(t)) = -0.63$ y $R_1^2 = 1.6\%$. Como puede verse, $\sigma_{1,k}^2$ es muy próximo a k en el corto-plazo, pero se hace significativamente más pequeño en el medio plazo, aunque de hecho se incrementa linealmente de nuevo, como la predicción a largo-plazo de $x(t)$ es simplemente su media incondicional, μ .

Sin embargo, dado que la predicibilidad desaparece bajo la medida neu-

⁷²En este respecto, Fiorentini y Sentana (1996) demuestran que cualquier VAR(1) de rango reducido para $\Delta_1 p(t)$ y otra variable $\delta(t)$ que cause en el sentido de Granger puede escribirse como (191) con $x(t-1) = E[\Delta_1 p(t)|I(t-1)]$. La restricción de rango reducido garantiza simplemente que los rendimientos esperados siguen un proceso AR de orden no más alto que 1.

tral al riesgo, given that predictability disappears under a risk neutralized measure, lo que es importante para implementar modelos de valoración de opciones es usar valores correctos de los parámetros relevantes (ver Lo y Wang (1995)). En particular, como $Var(\Delta_1 p(t)) = Var(x(t)) + Var(\varepsilon_{1,1}(t)) \geq \sigma_{1,1}^2$, con igualdad sii $\sigma_{2,1}^2 = 0$, los precios de las opciones obtenidos bajo el supuesto de que $p(t)$ es un paseo aleatorio geométrico con tendencia constante y varianza ω^2 puede ser incorrecto. Como señalan Lo y Wang (1995), el efecto de los precios puede ser particularmente importante para opciones con mayor vencimiento, aún con pequeños niveles de predicibilidad, pues la vega de una opción es una función creciente del tiempo a vencimiento.

2.2 Una versión discreta del modelo discreto

Con el fin de contrastar en un marco libre de preferencias si la predicibilidad de los rendimientos es importante para la valoración de opciones en tiempo discreto, usaremos una versión condicional del árbol binomial de Cox, Ross y Rubinstein (1979), donde los rendimientos esperados siguen una cadena de Markov en tiempo discreto con dos estados.

Sea $z(t)$ una variable binaria que indica si los rendimientos esperados en el período t son bajos o altos. Asumimos que $\Delta_1 p(t)$ y $x(t)$ evolucionan según (191), con las siguientes distribuciones condicionales para $\varepsilon_1(t)$:

a) cuando $z(t-1) = 0$

$\varepsilon_{1,1}(t) \setminus \varepsilon_{2,1}(t)$	$z(t) = 0$	$z(t) = 1$	
	$-\sigma_{2,1} \sqrt{\frac{1-q_{0,1}}{q_{0,1}}}$	$\sigma_{2,1} \sqrt{\frac{q_{0,1}}{1-q_{0,1}}}$	
$\sigma_{1,1} \sqrt{\frac{1-\pi_{0,1}}{\pi_{0,1}}}$	(1) $\pi_{0,1}$	0	$\pi_{0,1}$
$-\sigma_{1,1} \sqrt{\frac{\pi_{0,1}}{1-\pi_{0,1}}}$	(2) $q_{0,1} - \pi_{0,1}$	(3) $1 - q_{0,1}$	$1 - \pi_{0,1}$
	$q_{0,1}$	$1 - q_{0,1}$	


b) cuando $z(t-1) = 1$

$\varepsilon_{1,1}(t) \setminus \varepsilon_{2,1}(t)$	$z(t) = 1$	$z(t) = 0$	
	$\sigma_{2,1} \sqrt{\frac{1-q_{1,1}}{q_{1,1}}}$	$-\sigma_{2,1} \sqrt{\frac{q_{1,1}}{1-q_{1,1}}}$	
$-\sigma_{1,1} \sqrt{\frac{1-\pi_{1,1}}{\pi_{1,1}}}$	(4) $\pi_{1,1}$	0	$\pi_{1,1}$
$\sigma_{1,1} \sqrt{\frac{\pi_{1,1}}{1-\pi_{1,1}}}$	(5) $q_{1,1} - \pi_{1,1}$	(6) $1 - q_{1,1}$	$1 - \pi_{1,1}$
	$q_{1,1}$	$1 - q_{1,1}$	



En el caso relevante de $\rho_{12,1} < 0$, elegimos $q_{0,1} = q_{1,1} = (\alpha + 1)/2 = q_1$ y $\pi_{0,1} = \pi_{1,1} = q_1 \rho_{12,1}^2 / [(1 - q_1) + q_1 \rho_{12,1}^2]$, entonces es directo demostrar que $E[\varepsilon_1(t)|z(t-1) = 0] = E[\varepsilon_1(t)|z(t-1) = 1] = 0$ y $V[\varepsilon_1(t)|z(t-1) = 0] = V[\varepsilon_1(t)|z(t-1) = 1] = \Sigma_1$.

Gráficamente, la estructura del árbol es:



La principal ventaja de tal modelo binomial condicional es que habiendo tres estados posibles de la naturaleza para cada valor de $z(t-1)$, en dos de ellos, concretamente (2)-(3) y (5)-(6), el precio del activo con riesgo, $p(t)$, es el mismo. Como consecuencia, podemos valorar activos derivados con pagos un período hacia delante en el futuro con versiones neutralizadas al riesgo de $\pi_{0,1}$ y $\pi_{1,1}$, a pesar que los mercados no pueden ser completos mediante "dynamic trading". Es fácil ver que,

$$\bar{\pi}_{0,1} = \frac{e^{(\log R_f - \mu)} - e^{-M_1}}{e^{-m_1} - e^{-M_1}}$$

$$\bar{\pi}_{1,1} = \frac{e^{M_1} - e^{(\log R_f - \mu)}}{e^{M_1} - e^{m_1}}$$

donde

$$M_1 = \frac{\sigma_{2,1}}{2\sqrt{q_1(1-q_1)}} + \sigma_{1,1} |\rho_{12,1}| \sqrt{\frac{q_1}{1-q_1}} > 0$$

$$m_1 = \frac{\sigma_{2,1}}{2\sqrt{q_1(1-q_1)}} - \frac{\sigma_{1,1}}{|\rho_{12,1}|} \sqrt{\frac{1-q_1}{q_1}} \leq 0$$

y R_f es el rendimiento del tipo de interés bruto de un activo seguro.

La ausencia de oportunidades de arbitraje requiere $0 \leq \bar{\pi}_{0,1} \leq 1$ y $0 \leq \bar{\pi}_{1,1} \leq 1$, o equivalentemente $m_1 \leq \mu - \log R_f \leq M_1$ y $-M_1 \leq \mu - \log R_f \leq$

$-m_1$ respectivamente, que requiere al menos que $m_1 \leq 0$. En principio, tales condiciones sobre la “prima de riesgo” $\mu - \log R_f$ puede que no se verifique sin más restricciones sobre el proceso generador de rendimientos (191). Por ejemplo, si asumimos que la restricción de ruido blanco (192) se verifica, y hagamos $\mu = \log R_f$, entonces $\rho_{12,1}^2 \leq \alpha/(1+\alpha)$ se convierte en una condición suficiente y necesaria.

Para activos derivados tales como opciones call europeas con vencimiento en $t+1$, $t+2$, etc., necesitaríamos descomponer $\bar{\pi}_{0,1}$ en $\bar{q}_{0,1} - \bar{\pi}_{0,1}$ y $1 - \bar{q}_{0,1}$, y similarmente $\bar{\pi}_{1,1}$ en $\bar{q}_{1,1} - \bar{\pi}_{1,1}$ y $1 - \bar{q}_{1,1}$. Aunque esto es imposible sin conocer el precio de algún otro activo, sin embargo sabemos que $\bar{\pi}_{0,1} \leq \bar{q}_{0,1} \leq 1$ y $\bar{\pi}_{1,1} \leq \bar{q}_{1,1} \leq 1$. Por tanto, podemos acotar el precio del derivado calculándolo para cada par posible de valores admisibles de $\bar{q}_{0,1}, \bar{q}_{1,1}$.⁷³ Resulta que las cotas de este modo son muy justas para los valores de los parámetros considerados en la sección 2.1.

Una situación interesante surge cuando $\mu = \log R_f$, la condición (192) se verifica, y $\rho_{12,1}^2 = \alpha/(1+\alpha)$. En este caso, los precios de algunos commodities contingentes implícitos son 0, y los precios de opciones call europeas sobre activos con riesgo son independientes de $z(t-1)$ para todos los precios de ejercicio y vencimientos. Sin embargo, tan pronto como $\rho_{12,1}^2 < \alpha/(1+\alpha)$, los precios de las opciones generalmente dependen de $z(t-1)$. Excepciones notables son las opciones at-the-money, cuyos precios resultan ser independientes si los rendimientos esperados son altos o bajos.

La Figura 2 presenta el valor de opciones call europeas de 1 y 4 periodos como función del precio de ejercicio cuando los rendimientos son bajos y altos.⁷⁴ Como normalización, fijamos el precio actual del activo subyacente igual a 1, y tomamos $\mu = \log R_f = 0$. Nótese que independientemente de si los rendimientos esperados son bajos o altos, el precio de la call es el mismo que el valor del activo primitivo (o sea 1) cuando el precio de ejercicio es 0, y tiende a 0 cuando el precio de ejercicio va a infinito. Como los precios de las opciones deben ser convexos con respecto al precio de ejercicio, y el valor de las opciones at-the-money no depende de la variable estado en este modelo, las opciones call out-of-the-money alcanzan mayores precios cuando

⁷³Para este propósito, es conveniente hacer $\bar{q}_{0,1} - \bar{\pi}_{0,1} = \bar{\lambda}_0(1 - \bar{\pi}_{0,1})$, $1 - \bar{q}_{0,1} = (1 - \bar{\lambda}_0)(1 - \bar{\pi}_{0,1})$, $\bar{q}_{1,1} - \bar{\pi}_{1,1} = \bar{\lambda}_1(1 - \bar{\pi}_{1,1})$ y $1 - \bar{q}_{1,1} = (1 - \bar{\lambda}_1)(1 - \bar{\pi}_{1,1})$ con $\bar{\lambda}_0, \bar{\lambda}_1 \in [0, 1]$.

⁷⁴Dado la estructura de nuestro modelo, la función de pseudo-pricing en Hansen y Richard (1987), no tiene en cuenta los valores de la variable condicional, conduciendo simplemente a la media de igual ponderación de los precios de los activos cuando $z(t-1) = 0$ y $z(t-1) = 1$.

$z(t-1) = 1$ que cuando $z(t-1) = 0$, mientras lo contrario ocurre en las opciones call in-the-money. Una estructura similar aparece para opciones call de 4 periodos. Sin embargo, la diferencia entre precios es mayor para opciones de 4 periodos que para opciones de un período, que está en la línea de la evidencia de Lo y Wang (1995).

2.3 Las Consecuencias de la Agregación Temporal

Con el fin de capturar la predicibilidad en los rendimientos, tendríamos que estimar el proceso VAR(1) bivalente (191). Desafortunadamente, si los rendimientos son predecibles, cualquier discrepancia entre la frecuencia de trading y la frecuencia de observación de los precios resulta relevante en la estimación (191).⁷⁵

En particular, supongamos que como económetras, únicamente observamos $p(t)$ y $x(t)$ para todos los períodos de trading k . Si asumimos por simplicidad que $x(t)$ es una variable stock, el proceso conjunto agregado para $\Delta_k p(t) = p(t) - p(t-k)$ y $x(t)$ es también un VAR(1).⁷⁶ Concretamente

$$\begin{pmatrix} \Delta_k p(t) \\ x(t) - \mu \end{pmatrix} = \begin{pmatrix} \mu k \\ 0 \end{pmatrix} + \begin{pmatrix} 0 & \frac{1-\alpha^k}{1-\alpha} \\ 0 & \alpha^k \end{pmatrix} \begin{pmatrix} \Delta_k p(t-k) \\ x(t-k) - \mu \end{pmatrix} + \begin{pmatrix} \varepsilon_{1,k}(t) \\ \varepsilon_{2,k}(t) \end{pmatrix}$$

donde $\varepsilon_k(t)$ es tal que $E[\varepsilon_k(t)|I(t-k)] = \mathbf{0}$ y $V[\varepsilon_k(t)|I(t-k)] = \Sigma_k$, con

$$\sigma_{1,k}^2 = k\sigma_{1,1}^2 + \frac{2\sigma_{12,1}}{1-\alpha} \left(k - \frac{1-\alpha^k}{1-\alpha}\right) + \frac{\sigma_{2,1}^2}{(1-\alpha)^2} \left[k + \frac{1-\alpha^{2k}}{1-\alpha^2} - \frac{2(1-\alpha^k)}{1-\alpha}\right]$$

$$\sigma_{12,k} = \frac{(1-\alpha^k)\sigma_{12,1}}{1-\alpha} + \frac{\sigma_{2,1}^2}{1-\alpha} \left(\frac{1-\alpha^k}{1-\alpha} - \frac{1-\alpha^{2k}}{1-\alpha^2}\right)$$

$$\sigma_{2,k}^2 = \sigma_{2,1}^2 \frac{1-\alpha^{2k}}{1-\alpha^2}$$

⁷⁵ Agradecemos a John Campbell por hacer que prestemos atención a este punto.

⁷⁶ Para averiguar el proceso para los datos temporalmente agregados, es más conveniente reescribir (191) como $\begin{pmatrix} p(t) \\ x(t) - \mu \end{pmatrix} = \begin{pmatrix} \mu \\ 0 \end{pmatrix} + \begin{pmatrix} 1 & 1 \\ 0 & \alpha \end{pmatrix} \begin{pmatrix} p(t-1) \\ x(t-1) - \mu \end{pmatrix} + \begin{pmatrix} \varepsilon_{1,1}(t) \\ \varepsilon_{2,1}(t) \end{pmatrix}$ and entonces de manera recursiva sustituimos hacia atrás. Como la primera columna de la matriz del VAR(1) es $(1,0)'$ para todo k , podemos fácilmente escribir hacia atrás el proceso de agregación temporal en términos de rendimientos de k períodos.

Se demuestra directamente que si (192) se verifica,

$$\sigma_{1,k}^2 = k\sigma_{1,1}^2 + \left[k - \left(\frac{1 - \alpha^k}{1 - \alpha} \right)^2 \right] \frac{\sigma_{2,1}^2}{1 - \alpha^2} = k\omega^2 - \left(\frac{1 - \alpha^k}{1 - \alpha} \right)^2 \frac{\sigma_{2,1}^2}{1 - \alpha^2} \leq k\omega^2$$

Cuando $\alpha \leq \sqrt{2} - 1$, $k\sigma_{1,1}^2 \leq \sigma_{1,k}^2$ para todo k . Sin embargo, cuando $\alpha > \sqrt{2} - 1$, es posible que $\sigma_{1,k}^2/k \leq \sigma_{1,1}^2$ para k menor que $1/(1 - \alpha)^2$. Por ejemplo, si $\alpha = 0.98$, $\sigma_{1,k}^2/k \leq \sigma_{1,1}^2$ para cualquier $k \leq 2500$.

La solución obvia a este problema es reconocer la agregación temporal explícitamente, y estimar el modelo VAR(1) anterior de los datos muestreados a la frecuencia k en términos de los parámetros del proceso subyacente (191). En muchos casos de interés, aunque, la razón de la actual frecuencia de trading respecto a la frecuencia de observación sea desconocida. Por tanto, parece natural analizar el caso límite del trading continuo.

3 Análisis en Tiempo Continuo

3.1 A Continuous Time Diffusion

Sea $\mathbf{y}(t) = \begin{pmatrix} p(t) \\ x(t) \end{pmatrix}$, $\mathbf{v} = \begin{pmatrix} \mu(1 + \frac{\ln \alpha}{1 - \alpha}) \\ -\mu \ln \alpha \end{pmatrix}$, $\mathbf{A} = \begin{pmatrix} 0 & \frac{\ln \alpha}{1 - \alpha} \\ 0 & \ln \alpha \end{pmatrix}$ con $0 < \alpha < 1$, y sea la siguiente difusión en tiempo continuo

$$d\mathbf{y}(t) = [\mathbf{v} + \mathbf{A}\mathbf{y}(t)]dt + d\mathbf{W}(t) \quad (193)$$

donde $\mathbf{W}(t)$ es un proceso de Wiener bivalente con $E[d\mathbf{W}(t)d\mathbf{W}(t)'] = \Sigma_0 dt$ y $\mathbf{y}(0) = \mathbf{y}_0$. Es bien conocido (ver por ejemplo Arnold (1974)) que la solución del sistema de arriba de ecuaciones lineales estocásticas de primer orden es

$$\mathbf{y}(t) = e^{\mathbf{A}t}\mathbf{y}_0 + \int_0^t e^{\mathbf{A}(t-r)}\mathbf{v}dr + \int_0^t e^{\mathbf{A}(t-r)}d\mathbf{W}(r), \quad t \geq 0 \quad (194)$$

Además seamos que la discretización exacta del proceso multivariante Ornstein-Uhlenbeck (194) verifica el siguiente sistema de ecuaciones lineales en diferencias estocásticas de primer orden:

$$\mathbf{y}(t) = \mathbf{g}_h + \mathbf{F}_h\mathbf{y}(t - h) + \boldsymbol{\varepsilon}_h(t), \quad t = h, 2h, \dots \quad (195)$$

donde $\mathbf{g}_h = \int_0^h e^{\mathbf{A}r} \mathbf{v} dr$, $\mathbf{F}_h = e^{\mathbf{A}h}$, $\varepsilon_h(t) \sim iid N(0, \Sigma_h)$ y $\Sigma_h = \int_0^h e^{\mathbf{A}r} \Sigma_0 e^{\mathbf{A}'r} dr$ para cualquier número real positivo h (ver también Bergstrom (1984)).

En nuestro caso, dado la estructura de la matriz $\mathbf{A}$, obtenemos

$$\mathbf{g}_h = \begin{pmatrix} \mu(h - \frac{1-\alpha^h}{1-\alpha}) \\ \mu(1 - \alpha^h) \end{pmatrix}$$

$$\mathbf{F}_h = \begin{pmatrix} 1 & \frac{1-\alpha^h}{1-\alpha} \\ 0 & \alpha^h \end{pmatrix}$$

$$\sigma_{1,h}^2 = h\sigma_{1,0}^2 + \frac{2}{1-\alpha} \left(h - \frac{\alpha^h - 1}{\ln \alpha} \right) \sigma_{12,0} + \frac{1}{(1-\alpha)^2} \left(h + \frac{\alpha^{2h} - 4\alpha^h + 3}{2 \ln \alpha} \right) \sigma_{2,0}^2$$

$$\sigma_{12,h} = \frac{\alpha^h - 1}{\ln \alpha} \left(\sigma_{12,0} - \frac{\alpha^h - 1}{2(1-\alpha)} \sigma_{2,0}^2 \right)$$

$$\sigma_{2,h}^2 = \frac{\alpha^{2h} - 1}{2 \ln \alpha} \sigma_{2,0}^2$$

Si $h = 1$, igualamos a Σ_1 y resolvemos para Σ_0 , finalmente obtenemos que (193) agrega exactamente a (191) con innovaciones gaussianas si:

$$\sigma_{1,0}^2 = \sigma_{1,1}^2 + \frac{2}{(1-\alpha)} \left[1 + \frac{\ln \alpha}{1-\alpha} \right] \sigma_{12,1} + \frac{1}{(1-\alpha)^2} \left[1 + \frac{2\alpha \ln \alpha}{1-\alpha^2} \right] \sigma_{2,1}^2$$

$$\sigma_{12,0} = -\frac{\ln \alpha}{1-\alpha} \sigma_{12,1} + \frac{\ln \alpha}{1-\alpha^2} \sigma_{2,1}^2$$

$$\sigma_{2,0}^2 = -\frac{2 \ln \alpha}{1-\alpha^2} \sigma_{2,1}^2$$

El modelo (193) resulta ser un caso especial del proceso bivalente Ornstein-Uhlenbeck comentado por Lo and Wang (1995), en donde existe una raíz unitaria pero no hay tendencias determinísticas. Sin embargo, sólo se analiza con detalle el caso de $\sigma_{12,0} = 0$, que implican necesariamente correlación serial en los rendimientos discretos. En particular, la condición (192), que garantiza que sobre períodos enteros son ruido blanco, es equivalente en el marco de tiempo continuo a:

$$\sigma_{12,0} = \frac{-1}{2(1-\alpha)} \sigma_{2,0}^2. \quad (196)$$

De hecho, la condición (196) implica que $\Delta_h p(t)$ es ruido blanco para cualquier número real positivo h . Para ver por qué, expresemos (193) como

$\dot{\mathbf{y}}(t) = \mathbf{v} + \mathbf{A}\mathbf{y}(t) + \boldsymbol{\xi}(t)$, donde $\boldsymbol{\xi}(t)$ es la “derivada” de $\mathbf{W}(t)$. Si reescribimos esta expresión en términos del operador diferencial D como $(D\mathbf{I} - \mathbf{A})\mathbf{y}(t) = \mathbf{v} + \boldsymbol{\xi}(t)$, es fácil probar usando los resultados sobre filtros (ver Priestley (1981)) que la densidad espectral de $\dot{p}(t)$ es constante cuando la condición (196) se verifica.⁷⁷

Sin embargo, los rendimientos son aún predecibles. Concretamente, el R^2 de la regresión teórica de $\Delta_h p(t)$ sobre $x(t-h)$ es

$$R_h^2 = \frac{-(\alpha^h - 1)^2}{2h(1 - \alpha)^2 \ln \alpha} \frac{\sigma_{2,0}^2}{\sigma_{1,0}^2}$$

La Figura 3 presenta un dibujo de R_h^2 como función de h para los mismos valores de los parámetros que antes. Como se esperaba, obsérvese que converge a 0 cuando $h \rightarrow 0$, pues la variación inducida por la tendencia es de orden h , mientras la variación inducida por la difusión es de orden $h^{1/2}$. Del mismo modo, converge a 0 cuando $h \rightarrow \infty$ pues la predicibilidad llega a no ser apreciable proporcionalmente en el largo plazo. Sin embargo, obsérvese que al mismo tiempo R_h^2 puede ser considerable ($\simeq .334$) para $h \simeq 60$.

Es bien conocido que en el mundo de tiempo continuo, la fórmula de Black-Scholes es válida aún en el caso de ser la tendencia una función de la variable estado $x(t)$, y el valor derecho del parámetro de la varianza para valorar opciones debería ser $\sigma_{1,0}^2$ (ver Lo y Wang (1995)). Pero el resultado sorprendente que nosotros obtenemos de (196) es que $\sigma_{1,0}^2 = \omega^2$, por tanto $\text{Var}(\Delta_h p(t))/h$ es un estimador apropiado de la volatilidad de rendimientos instantáneos. Por tanto, parece que los efectos de la predicibilidad y agregación temporal comentados en la sección anterior se anule el uno con el otro en el límite (tiempo continuo).

3.2 Una Aproximación discreta al modelo en Tiempo Continuo

Con el fin de ganar alguna intuición sobre los resultados de arriba, consideremos el siguiente proceso bivalente trinomial $iid(\mathbf{0}, \mathbf{I})$ con iguales estados

⁷⁷Agradecemos a Lars Hansen por esta prueba más simple.



probables propuesto por He (1990):

$\varepsilon_1 \backslash \varepsilon_2$	$-\sqrt{\frac{3}{2}}$	0	$\sqrt{\frac{3}{2}}$	
$-\sqrt{2}$	0	(b) $\frac{1}{3}$	0	$\frac{1}{3}$
$\sqrt{\frac{1}{2}}$	(a) $\frac{1}{3}$	0	(c) $\frac{1}{3}$	$\frac{2}{3}$
	$\frac{1}{3}$	$\frac{1}{3}$	$\frac{1}{3}$	

Sea $\varepsilon_{1,h}(t) = \sigma_{1,h}\varepsilon_1$, $\varepsilon_{2,h}(t) = (\sigma_{12,h}/\sigma_{1,h})\varepsilon_1 + \sqrt{\sigma_{2,h}^2 - \sigma_{12,h}^2/\sigma_{1,h}^2}\varepsilon_2$ y generemos $\Delta_h p(t)$ y $x(t) - \mu$ según (195). Si $h = 1/N$, con N entero, este proceso agrega exactamente a (191), a pesar de no existir innovaciones Gaussianas. Al mismo tiempo, converge débilmente a (193) cuando $h \rightarrow 0$ (ver He (1990)).

Obsérvese que aunque hay tres posibles estados de naturaleza para cada valor de $x(t-h)$, en dos de ellos, (a) y (c), el precio del activo con riesgo, $p(t)$, es el mismo (Sección 2.2). Como resultado, si $\sigma_{2,0}^2 = \sigma_{12,0} = 0$ por tanto $x(t) = \mu, \forall t$, obtenemos una versión asimétrica del proceso binomial incondicional de Cox, Ross y Rubinstein (1979).

Sea $\bar{\pi}[x(t-h)]$ la probabilidad neutral al riesgo del estado (b) como una función de $x(t-h)$. Es fácil ver que

$$\bar{\pi}[x(t-h)] = \frac{\exp\left\{h(\log R_f - \mu) + \frac{1-\alpha^h}{\alpha-1}[x(t-h) - \mu] - \sqrt{\frac{1}{2}}\sigma_{1,h}\right\} - 1}{\exp\left\{-(\sqrt{2} + \sqrt{\frac{1}{2}})\sigma_{1,h}\right\} - 1}$$

permanece entre 0 y 1 verificando

$$-\sqrt{\frac{1}{2}}\sigma_{1,h} \leq h(\mu - \log R_f) + \frac{1-\alpha^h}{1-\alpha}[x(t-h) - \mu] \leq \sqrt{2}\sigma_{1,h}$$

Como $\sigma_{1,h}$ es de orden $h^{1/2}$ mientras $h(\mu - \log R_f) + \frac{1-\alpha^h}{1-\alpha}[x(t-h) - \mu]$ es de orden h , esta falta de condición de arbitraje es creciente para que se satisfaga cuando $h \rightarrow 0$.

Para h positivo, $\bar{\pi}[x(t-h)]$ depende de las desviaciones de los rendimientos esperados de su media a largo plazo, μ . Sin embargo, no es difícil ver que tal dependencia disminuye a la tasa h , y además $\lim_{h \rightarrow 0} \bar{\pi}[x(t-h)] = 1/3$, que es la probabilidad actual del correspondiente estado. Como $\sigma_{1,h} = h^{1/2}\sigma_{1,0} + o(h)$ cuando la condición (196) se verifica, esto confirma que la fórmula de BS es válida en el límite con ω como el parámetro relevante.

Podemos usar el modelo trinomial para ver si los resultados del trading continuo resulta ser una guía razonable cuando la frecuencia de trading es pequeña pero finita. Dado que el número de estados después de un intervalo unitario de tiempo es 3^N cuando $h = 1/N$, elegimos $N = 10$ por simplicidad. Para los propósitos del ejercicio, arbitrariamente particionamos $1 - \bar{\pi} [x(t - h)]$ igualmente entre el primer y último estado.⁷⁸ La Figura 4 presenta el precio de una opción call europea de un período como función del precio de ejercicio, cuando el rendimiento esperado actual es $\pm$ una desviación estándar de su media, μ . De nuevo, elegimos $\mu = \log R_f = 0$ y $p(t) = 0$ para la normalización. Como marco, incluimos precios obtenidos a partir de la fórmula de Black-Scholes, además de la versión asimétrica de la aproximación de Cox, Ross y Rubinstein (1979) mencionado anteriormente. Aunque los dos precios obtenidos bajo el supuesto de no predicibilidad son prácticamente buenos para un amplio rango de precios de ejercicio, parece que el valor inicial de $x(t)$ aún ejerce alguna influencia sobre el precio de las opciones sobre el rango señalado, al menos para $N = 10$.

4 Conclusiones

Analizamos el efecto de la predicibilidad del rendimiento de un activo en los precios de las opciones sobre ese activo con rendimientos serialmente incorrelacionados. Para una versión condicional de un enfoque de árbol binomial de Cox, Ross y Rubinstein (1979) donde los rendimientos esperados sigue una cadena de Markov en tiempo discreto de dos períodos, demostramos que la predicibilidad importa, concretamente para opciones a más largo plazo (ver Lo y Wang (1995)).

Sin embargo, en un mundo en tiempo discreto con rendimientos predecibles, cualquier discrepancia entre la frecuencia de trading y la de observación de los precios resulta ser relevante al estimar los parámetros del modelo. Por esta razón, también analizamos el caso límite de trading continuo. En este mundo, la fórmula de BS es válida a pesar de la predicibilidad, y además, la varianza muestral de los rendimientos correspondientes a los períodos finitos resulta ser un estimador apropiado de la varianza instantánea de los

⁷⁸ Alternativamente, podríamos asumir que $x(t)$ es el precio sin tendencia de otro activo financiero. En ese caso, es posible demostrar que las probabilidades neutrales al riesgo de los estados (a) y (c) convergen a un $1/3$ cuando $h \rightarrow 0$. La forma de particionar $1 - \bar{\pi} [x(t - h)]$ apenas tiene efecto sobre los resultados de la Figura 4.



rendimientos. Por tanto, parece que lo que es importante para implementar modelos de valoración de opciones no es la predicibilidad del rendimiento del activo, sino su correlación serial. Esto también se verifica para modelos más generales de precios. En particular, supongamos que la tendencia sigue un proceso estacionario en covarianza lineal general, por tanto el modelo conjunto para los rendimientos actuales y esperados puede escribirse como

$$\begin{aligned}\dot{p}(t) &= \mu(t) + \xi_1(t) \\ \mu(t) - \mu &= g(D)\xi_2(t)\end{aligned}$$

Por ejemplo, $g(D) = (1 + Db_1 + \dots + D^qb_q)/(D^p + D^{p-1}a_1 + \dots + a_p)$ para el proceso continuo ARMA(p,q) comentado en Brockwell (1995). Aquí, los rendimientos están seriamente incorrelacionados para cualquier frecuencia λ si (y solo si) $|g(i\lambda)|^2 \sigma_{22,0} + (g(i\lambda) + g(-i\lambda)) \sigma_{12,0}$ no es una función de λ . En ese caso $Var(\Delta_{hp}(t))/h$ es aún un estimador apropiado de la volatilidad de los rendimientos instantáneos, a pesar que los rendimientos permanecen predecibles cuando $g(D) \neq 0$.

5 Referencias

Arnold, L. (1974): *Stochastic Differential Equations: Theory and Applications*, Wiley, New York.

Bergstrom, A.R. (1984): "Continuous Time Stochastic Models and Issues of Aggregation over Time", in *Handbook of Econometrics* vol. 2, ed. by Z. Griliches and M.D. Intriligator, North Holland, Amsterdam.

Brockwell, P.J. (1995): "A Note on the Embedding of Discrete-Time ARMA Processes", *Journal of Time Series Analysis* 16, 451-460.

Campbell, J.Y. (1991): "A Variance Decomposition for Stock Returns", *Economic Journal* 101, 157-179.

Campbell, J.Y. (1993): "Why Long Horizons: A Study of Power against Persistent Alternatives", NBER Technical Working Paper 142.

Campbell, J.Y., Lo A.W. y MacKinlay, A.C. (1997): *The Econometrics of Financial Markets*, Princeton University Press, Princeton.

Cox, J.C., Ross, S.A. y Rubinstein, M. (1979): "Option Pricing: A Simplified Approach", *Journal of Financial Economics* 7, 229-263.

Fama, E.F. y K.R. French (1988): "Permanent and Temporary Components of Stock Prices", *Journal of Political Economy*, 96, 246-273.

Fiorentini, G. y Sentana, E. (1996): "Conditional Means of Time Series Processes and Time Series Processes for Conditional Means", LSE Financial Markets Group Discussion Paper 257.

Hansen, L.P. y Richard, S.F. (1987): "The Role of Conditioning Information in Deducing Testable Restrictions Implied by Dynamic Asset Pricing Theories", *Econometrica* 55, 587-613.

He, H. (1990): "Convergence from Discrete- to Continuous-Time Contingent Claims Prices", *Review of Financial Studies* 3, 523-546.

Lo, A.W. y Wang, J. (1995): "Implementing Option Pricing Models when Asset Returns are Predictable", *Journal of Finance* 50, 87-129.

Poterba, J. y Summers L.H. (1988): "Mean Reversion in Stock Returns: Evidence and Implications". *Journal of Financial Economics*, 22, 27-60.

Priestley, M.B. (1981): *Spectral Analysis and Time Series*, Academic Press, London.

Shiller, R.J. (1984): "Stock Prices and Social Dynamics". *Brookings Papers on Economic Activity*, 2, 457-498.

Summers, L.H. (1986): "Does the Stock Market Rationality Reflect Fundamental Values ?", *Journal of Finance*, 41, 591-601.

Figure 1




Figure 2




Figure 3





Figure 4



6 *Capítulo 4: Opciones a corto plazo con volatilidad estocástica*

1 Introducción

Una cuestión principal para el contraste empírico de modelos de valoración de opciones es si la distribución del activo subyacente es consistente con la distribución asumida por el modelo de valoración de opciones teórico. Por tanto, siempre y cuando se encuentren sesgos en los modelos de valoración de opciones tradicionales; el objetivo es saber quién es el *asesino* del modelo teórico analizado.

Dados los supuestos de Black-Scholes (1973), (BS) a partir de ahora, los precios de las opciones sobre el mismo activo subyacente con la misma fecha fecha de vencimiento pero con distintos precios de ejercicio deberían tener la misma volatilidad implícita. Sin embargo, la estructura de sonrisa de volatilidad sugiere que la fórmula BS tiende a infravalorar opciones muy dentro del dinero y opciones muy fuera del dinero⁷⁹. Diversos trabajos han intentado explicar este aparente fracaso de la fórmula BS. Das y Sundaram (1997) atribuyen la existencia de la sonrisa a la presencia del exceso de curtosis en la distribución condicional de la serie de rendimientos del activo subyacente. El exceso de curtosis hace que las observaciones más extremas sean más probables que en el modelo BS. Esto incrementa el valor de las opciones fuera del dinero y dentro del dinero con respecto a las opciones en el dinero generando la smile. Sin embargo, al menos en el mercado americano, la estructura implícita en los datos es el de una clara asimetría en la forma de la smile. Su origen se debe a la presencia de asimetría en la distribución acentuando de este modo un lado de la sonrisa⁸⁰. Dada esta evidencia, extensiones al mod-

⁷⁹Después del crash de Octubre de 1997, la volatilidad implícita obtenida de las opciones sobre índices bursátiles en el mercado americano procedente de la fórmula BS resulta ser diferente según los precios de ejercicio. Esto se conoce como la famosa "*sonrisa de volatilidad*". De hecho, como señalan Rubinstein (1994), Dumas, Fleming y Whaley (1996), y Aït-Sahalia y Lo (1997), las volatilidades implícitas de las opciones sobre el S&P 500 decrecen de forma monótona cuando la razón precio ejercicio/precio actual activo subyacente aumenta.

⁸⁰En el caso del mercado de opciones español, contrario a la evidencia del mercado americano, se observa una smile casi perfecta. Por supuesto, hay que tener cuidado al realizar este tipo de comparaciones. La evidencia del mercado español está basada en opciones con vencimiento a corto plazo mientras en el mercado americano en opciones con

elo de BS que muestren exceso de curtosis y asimetría han sido propuestos en los últimos años siguiendo estas dos líneas de investigación. Modelos de difusión con salto, donde el salto viene expresado por un proceso de Poisson compuesto, y el de volatilidad estocástica son los desarrollos principales en la literatura teórica de valoración de opciones⁸¹.

Un reciente e importante artículo que trata de resumir los modelos de valoración de opciones alternativos es el de Bakshi, Cao y Chen (1997). Ellos obtienen un modelo de valoración de opciones con fórmula cerrada con volatilidad estocástica, tipos de interés y saltos estocásticos. Siguiendo a Bates (1996), estiman el modelo en un contexto de sección cruzada y analizan la bondad del modelo y coberturas de los modelos de valoración de opciones anidados. Bakshi, Cao y Chen (1997) concluyen que la volatilidad estocástica y los saltos son importantes para la valoración. Además, se verifica que los modelos únicamente con volatilidad estocástica son los que mejor cobertura realizan. Por otro lado, Das y Sundaram señalan que los modelos de volatilidad estocástica valoran mejor que los procesos con salto, aunque ninguno de ellos puede explicar correctamente las estructuras de curtosis, asimetría y sonrisas de volatilidad que se encuentran en la literatura empírica de valoración de opciones.

En este artículo, nos concentramos en un modelo de volatilidad estocástica en un contexto de serie temporal. El modelo de volatilidad estocástica de Hull y White (1987) constituye el primer modelo de valoración de opciones con fórmula cerrada donde la volatilidad no es constante. Se demuestran que cuando la volatilidad es estocástica y está incorrelacionada con el precio del activo subyacente entonces el precio de una opción europea es el precio de BS integrado sobre la distribución de probabilidad de la varianza media durante la vida de la opción⁸². Desafortunadamente se requiere un precio de mercado para la prima de riesgo de la volatilidad.

vencimiento a más largo plazo, véase el artículo de Bakshi y Chen (1997). Además de las condiciones del mercado, los costes de transacción representados por el spread relativo del bid-ask parece provocar de forma significativa la figura de la smile. Ver Peña, Rubio y Serna (1998).

⁸¹Alternativamente, Corrado y Su (1996) aplican una expansión Gram-Charlier de la función de densidad normal para obtener los términos de ajuste de asimetría y curtosis de la fórmula de BS.

⁸²Otra aproximación no estocástica permite que la volatilidad dependa funcionalmente del precio del activo subyacente. Varias propuestas para la forma funcional del proceso de volatilidad han sido propuestas. El famoso modelo de varianza de elasticidad constante de Cox y Ross (1976) resulta ser el más destacado.

Los últimos avances en esta literatura incorporan los modelos de Stein y Stein (1991), Heston (1993) y Bates (1996). En concreto, Heston (1993) obtiene una solución en forma cerrada para una opción call europea a partir de la integral de la densidad del precio futuro del subyacente que se obtiene con la transformación inversa de Fourier. En el modelo de Heston a diferencia de los modelos anteriores se permite una correlación distinta de cero entre los incrementos de los procesos de Wiener correspondientes al activo subyacente y a la volatilidad⁸³.

El objetivo principal del artículo consiste en analizar la bondad del modelo de volatilidad estocástica de Heston (1993) con respecto al modelo BS. Nuestro principal interés es investigar la valoración de opciones en mercados donde existe un número muy limitado de precios de ejercicio negociados simultáneamente, y donde la liquidez es muy estrecha respecto al mercado americano. Esto genera graves consecuencias sobre la de la estimación mediante sección cruzada de los parámetros propuesto por Bates (1996) y Bakshi, Cao y Chen (1997). No hay suficientes precios disponibles para estimar conjuntamente todos los parámetros del modelo de valoración de opciones teórico conduciendo a una estimación de los parámetros en un contexto de serie temporal. Esta metodología puede resultar relevante en mercados más estrechos que el mercado americano.

En el presente trabajo empleamos una base de datos de precios de transacciones intradiarias correspondientes a opciones sobre el índice bursátil IBEX-35. El artículo presenta la siguiente estructura: descripción de los datos en la Sección 2. El modelo teórico empleado aparece en la Sección 3. La Sección 4 presenta resultados empíricos correspondientes a la estimación de serie temporal de los parámetros de la volatilidad estocástica. La Sección 5 presenta resultados empíricos sobre la bondad del modelo de Heston frente al

⁸³Un enfoque alternativo sobre volatilidad no constante ha sido sugerido por Rubinstein (1994), Jackwerth y Rubinstein (1996) y Jackwerth (1996), y una serie de artículos de Derman y Kani (1994), Dupire (1994), Chriss (1995), Derman, Kani y Chriss (1996). En lugar de imponer una forma funcional paramétrica para la volatilidad, se construye un modelo binomial o trinomial que ajuste perfectamente los precios de las opciones observadas. Este procedimiento captura (por construcción) las características más destacadas de los datos. En particular, el árbol implícito empleado en la estimación numérica debe reproducir correctamente la sonrisa de volatilidad. Los modelos más conocidos en esta familia usan árboles binomiales recombinatorios implícitos por la sonrisa de los precios de las opciones europeas. Una vez que los precios y probabilidades de transición correspondientes a los nodos del árbol se han calculado, cualquier opción americana u opción "path-dependent" puede valorarse de forma consistente con el mercado.

modelo BS, concretamente el modelo BS. Finalmente, en la Sección 6 están las conclusiones.

2 Datos

Nuestra base de datos comprende todos los precios de las opciones call negociados diariamente en MEFF durante el período 2 de Enero de 1996 hasta el 30 de Abril de 1996 y datos intradiarios del IBEX-35 desde Enero de 1994 hasta Abril de 1996. Dada la concentración de liquidez, nuestro conjunto de observaciones diarias incluye aquellos precios de calls con vencimiento más cercano. Además, eliminamos todas las transacciones que ocurren la última semana antes del vencimiento pasando por tanto en nuestra base de datos al siguiente contrato con vencimiento en el mes siguiente.

La preocupación fundamental en este tipo de investigación es el uso de precios simultáneos para las opciones y el activo subyacente. Con el fin de evitar enormes variaciones en el precio del activo subyacente, nos restringimos a la ventana de 45 minutos correspondiente al intervalo desde las 16:00h a las 16:45h. Durante nuestro período muestral se verifica que el 25% de las transacciones de cruce ocurren durante esta ventana. Todas las transacciones después de las 16:45h. fueron suprimidas con el fin de eliminar los problemas potenciales por las negociaciones correspondientes a los últimos 15 minutos del mercado para influir sobre los requerimientos de márgenes de los creadores de mercado. Además, el uso de datos correspondientes al mismo período todos los días evita la posibilidad de efectos intradiarios en el mercado de opciones sobre el IBEX-35. Finalmente, se elimina de la muestra todos los precios de opciones put y call que violan las condiciones de arbitraje.

Como activo subyacente se usa la media aritmética de los precios bid y ask del futuro asociado con cada opción durante el intervalo de 45 minutos señalado con anterioridad⁸⁴. Recuérdese que la fecha de vencimiento de los contratos de futuros coincide con la fecha de vencimiento de los contratos de opciones. Como proxy del activo sin riesgo, se utiliza la serie diaria de repos con vencimientos de una, dos y tres semanas. Uno de estos tres tipos de

⁸⁴Podría resultar que la falta de liquidez en el mercado de futuros sea la causa de la falta de variación en el precio del activo subyacente durante la ventana de 45 minutos, sin embargo; este no es el caso. De hecho, el mercado de futuros resulta ser, al menos, tan líquido como el mercado spot en términos de medidas comparables de volumen de negociación.

interés será empleado dependiendo del período hasta la fecha de vencimiento de la opción.

Según French (1984), la volatilidad resulta ser un fenómeno que está relacionado básicamente con los días de negociación. Mientras los tipos de interés están en función de la fecha de calendario. Por tanto, empleamos la fórmula de Black (1976) ajustada por las dos medidas temporales que reflejan días de negociación y calendario.

3 El Modelo de Valoración de Heston

Describimos brevemente el modelo de volatilidad estocástica que aplicamos en este artículo. Como señalamos anteriormente, nos centramos en el modelo de Heston (1993) el cual obtiene una solución con forma-cerrada para el precio de una opción call europea sobre un activo con volatilidad estocástica. La fórmula de valoración tiene la misma estructura que la fórmula de BS salvo las probabilidades. Estas se obtienen aplicando el teorema de inversión sobre la ecuación característica.

El modelo propuesto por Heston generaliza el proceso geométrico browniano permitiendo que la volatilidad siga un proceso de raíz cuadrada con reversión a la media, o sea; el modelo propuesto por Cox, Ingersoll y Ross (1985):

$$\begin{aligned} dS_t &= \mu S_t dt + \sqrt{V_t} S_t dW_{1t} \\ dV_t &= k [\theta - V_t] dt + \sigma V_t^{1/2} dW_{2t} \\ dW_{1t} dW_{2t} &= \rho dt \\ \lambda(S, V, t) &= \lambda V_t \end{aligned} \tag{197}$$

donde μ es la tasa instantánea esperada del rendimiento del suyacente, V_t es la varianza instantánea estocástica esperada, θ es la media a largo plazo de la varianza, k la tasa a la que la varianza converge a su media, y σ representa la volatilidad de la varianza del proceso. Los parámetros de la varianza del proceso, θ , k y σ son todas constantes estrictamente positivas. W_{1t} y W_{2t} son procesos de Wiener standard con correlación instantánea. Finalmente la prima de riesgo de la volatilidad se asume proporcional a la varianza. Esto se justifica teniendo en cuenta que el modelo de consumo de Breeden (1979) sugiere que:

$$\lambda(S, V, t) = \gamma \text{cov}(dV_t, dC_t/C_t)$$

donde γ es el coeficiente de aversión relativa al riesgo y C es el consumo agregado. Además el marco de Cox, Ingersoll y Ross (1985) es consistente con un proceso de consumo donde el crecimiento del consumo presenta una correlación constante con el activo subyacente. Esto implica una prima de riesgo proporcional a la varianza condicional. Hay que señalar que la prima de riesgo es consistente con la ausencia de arbitraje, por tanto el modelo de valoración de opciones se obtiene bajo un contexto de no-arbitraje.

Bajo la medida neutral al riesgo (medida P^*), podemos escribir (197) como:

$$\begin{aligned} dS_t &= rS_t dt + \sqrt{V_t} S_t dW_{1t}^* \\ dV_t &= k^* [\theta^* - V_t] dt + \sigma V_t^{1/2} dW_{2t}^* \\ dW_{1t}^* dW_{2t}^* &= \rho dt \end{aligned} \quad (198)$$

donde $k^* = k + \lambda$ y $\theta^* = k\theta/(k + \lambda)$.

Sea $C(S, v, t)$ el valor de una opción call europea donde $S \equiv S_t$ and $v \equiv V_t$ para abreviar. $C(S, v, t)$ debe verificar la siguiente ecuación en derivadas parciales de segundo orden

$$\begin{aligned} \frac{1}{2} v \sigma^2 C_{vv} + r S C_S + k^* (\theta^* - v) C_v \\ + \frac{1}{2} v S^2 C_{SS} + \rho \sigma v S C_{Sv} + C_t - r C = 0 \end{aligned} \quad (199)$$

sujeta a la condición terminal

$$C(S_T, V_T, T) = \max(S_T - K, 0). \quad (200)$$

La solución de las ecuaciones (199) y (200) tiene la forma

$$C(S, v, t) = S_t P_1 - K e^{-r(T-t)} P_2$$

donde

$$P_j = \frac{1}{2} + \frac{1}{\pi} \int_0^\infty \operatorname{Re} \left(\frac{e^{-i\phi \ln(K)} F_j}{i\phi} \right) d\phi, \quad j = 1, 2$$

son las probabilidades neutrales al riesgo que tienen la misma interpretación que las correspondientes a la fórmula de BS. $\operatorname{Re}(\cdot)$ es la parte real de un número complejo y F_j es la ecuación característica de $x | v$ donde $x \equiv \ln(S)$ bajo la medida P^* , es decir

$$F_j(x, v, T - t; \phi) = \exp[C(T - t; \phi) + D(T - t; \phi)v + i\phi x]$$

donde

$$C(T-t; \phi) = \frac{a}{\sigma^2} \left\{ (b_j - \rho\sigma\phi i + d)(T-t) - 2 \ln \left[\frac{1 - ge^{d(T-t)}}{1-g} \right] \right\}$$

$$D(T-t; \phi) = \frac{b_j - \rho\sigma\phi i + d}{\sigma^2} \left[\frac{1 - e^{d(T-t)}}{1 - ge^{d(T-t)}} \right]$$

$$g = \frac{b_j - \rho\sigma\phi i + d}{b_j - \rho\sigma\phi i - d}$$

$$d = \sqrt{(\rho\sigma\phi i - b_j)^2 - \sigma^2 (2u_j\phi i - \phi^2)}$$

$$a = k\theta$$

$$b_1 = k + \lambda - \rho\sigma$$

$$b_2 = k + \lambda$$

$$u_1 = 1/2; \quad u_2 = -1/2$$

verificándose que $C(0) = D(0) = 0$. Por tanto, las probabilidades P_j dependen del vector de parámetros $(k^*, \theta^*, \sigma, \rho)$. Estos parámetros podemos estimarlos mediante sección cruzada dados los precios de las opciones obteniendo los parámetros bajo la medida neutral al riesgo. Sin embargo dado el número limitado de precios de opciones disponibles cada día, el enfoque de sección cruzada no es posible. Bajo el contexto de serie temporal, estimamos los parámetros del modelo bajo la distribución real del proceso ajustando el sesgo de discretización mediante la estimación de inferencia indirecta que se desarrolla en la sección siguiente.

4 Inferencia Indirecta

4.1 Metodología

Para estimar el proceso bajo la medida de probabilidad original dada por (197), se asume que los datos disponibles son observaciones en tiempo discreto de un proceso en tiempo continuo. Para estimar (197) es necesario discretizar el proceso el cual, en este caso, no tiene una discretización exacta;



por tanto al aplicar la metodología de máxima verosimilitud (MV) obtenemos estimadores sesgados. Para evitar este sesgo, empleamos la estimación indirecta propuesta por Gouriéroux, Monfort y Renault (1993). El proceso consta de dos etapas. En primer lugar, mediante MV estimamos el modelo auxiliar correspondiente. En segundo lugar, los estimadores del modelo auxiliar se comparan con estimadores MV de un conjunto de datos simulados de procesos discretos de (197). En concreto, introducimos una discretización de (197) con una frecuencia de magnitud τ , siendo $1/\tau$ un número entero. Las discretizaciones utilizadas son las de Euler y Nowman (1997).

A continuación, se describe los pasos necesarios para el procedimiento de estimación indirecta:

(i) *Proceso generador de datos* (PGD) para el activo: Sea $X_t \equiv \ln S_t$, entonces

$$dX_t = (\mu - V_t/2) dt + V_t^{1/2} dW_{1t} \quad (201)$$

$$dV_t = k[\theta - V_t] dt + \sigma V_t^{1/2} dW_{2t} \quad (202)$$

$$dW_{1t}dW_{2t} = \rho dt.$$

Representamos el conjunto de parámetros como

$$\Omega \equiv (\mu, k, \theta, \sigma, \rho).$$

(ii) *Modelo auxiliar*: sea $R_t \equiv x_t - x_{t-1}$, entonces

$$R_t = \mu + \xi_t = \mu + h_t \epsilon_t; \quad \epsilon_t \stackrel{iid}{\sim} N(0, 1)$$

$$h_t = \omega + \beta h_{t-1} + \alpha \left(\xi_{t-1} + \gamma h_{t-1}^{1/2} \right)^2 \sim \text{Nagarch}^{85} (1, 1).$$

Sea $\Psi \equiv (\mu, \omega, \alpha, \beta, \gamma)$ el conjunto de parámetros del modelo auxiliar.

(iii) *Discretización de PGD* con frecuencia τ :

(a) Discretización de (201):

$$x_t = x_{t-\tau} + \mu\tau - \frac{V_{t-\tau}}{2}\tau + V_{t-\tau}^{1/2}\tau^{1/2}\eta_{1t}$$

(b) Discretización de (202):

⁸⁵Ver León y Mora (1998).



(b.1) Discretización de Euler:

$$V_t = k\theta\tau + (1 - k\tau) V_{t-\tau} + \varepsilon_t$$

donde

$$\varepsilon_t = \sigma\tau^{1/2}V_{t-\tau}^{1/2} \left[\rho\eta_{1t} + (1 - \rho^2)^{1/2} \eta_{2t} \right]$$

y

$$(\eta_{1t}, \eta_{2t})' \stackrel{iid}{\sim} N(0, I).$$

(b.2) Discretización de Nowman:

$$V_t = \theta(1 - e^{-k\tau}) + e^{-k\tau}V_{t-\tau} + \varepsilon_t$$

donde

$$\varepsilon_t = \sigma \left(\frac{1 - e^{-2k\tau}}{2k} \right)^{1/2} V_{t-\tau}^{1/2} \left[\rho\eta_{1t} + (1 - \rho^2)^{1/2} \eta_{2t} \right]$$

y

$$(\eta_{1t}, \eta_{2t})' \stackrel{iid}{\sim} N(0, I).$$

(iv) Procedimiento de la estimación indirecta:

(iv.1) Estimación del modelo auxiliar ($\tau = 1$) $\Rightarrow \hat{\Psi}$.

(iv.2) Valores iniciales de $\Omega \Rightarrow \Omega_0$.

(iv.3) Simular $(\eta_{1t}, \eta_{2t})'_{(T/\tau) \times 1}$ con $\tau = 1/10$, entonces

$$\Upsilon_\tau \equiv \{(\eta_{1t}, \eta_{2t})' : t = 1, \dots, T/\tau\}.$$

(iv.4) Simular con la discretización de Euler (Nowman), entonces

$$\mathbf{X}(\Omega_0, \Upsilon_\tau) \equiv \{\tilde{x}_t; t = 0, \tau, 2\tau, \dots, T/\tau\}.$$

(iv.5) Tomar de $\mathbf{X}(\Omega_0, \Upsilon_\tau)$ los siguientes valores:

$$\Gamma(\Omega_0, \Upsilon_\tau) \equiv \{\tilde{x}_0, \tilde{x}_{10\tau}, \tilde{x}_{20\tau}, \dots, \tilde{x}_T\}.$$

(iv.6) $\hat{\Psi}(\Omega_0, \Upsilon_\tau) \equiv$ vector de estimadores MV del modelo auxiliar con $\tau = 1/10$ para $\Gamma(\Omega_0, \Upsilon_\tau)$.

(iv.7) Si $\hat{\Psi} = \hat{\Psi}(\Omega_0, \Upsilon_\tau) \Rightarrow$ Estimadores indirectos son $\Omega_0 \Rightarrow \boxed{\text{FIN}}$

(iv.8) Si $\hat{\Psi} \neq \hat{\Psi}(\Omega_0, \Upsilon_\tau) \Rightarrow \boxed{\text{IR A (iv.2)}} \Rightarrow$ Nuevos valores para $\Omega \Rightarrow \Omega_1$. Continuar el proceso y parar si $\hat{\Psi} = \hat{\Psi}(\Omega_1, \Upsilon_\tau)$, en caso contrario volver a (iv.2) y repetir el proceso.

4.2 Resultados Empíricos

En primer lugar, estimamos mediante inferencia indirecta el modelo de Heston con una serie temporal de rendimientos horarios del IBEX-35 del período in-sample desde el 2 de Enero, 1994 hasta el 2 de Enero, 1996. Como el primer rendimiento horario incorpora ajustes de la llegada de información procedente del cierre del mercado el día anterior hasta la apertura de hoy, entonces el rendimiento presenta una variabilidad más alta en promedio que el resto de los rendimientos horarios. Esto implica que el primer rendimiento no es un rendimiento horario, por tanto lo eliminamos de la muestra. En definitiva, nuestra muestra consta de 2450 observaciones horarias.

Los resultados del período in-sample se presenta en la Tabla 1. Consideramos cuatro combinaciones alternativas de simulación y frecuencia, y dos discretizaciones determinadas. Los resultados contenidos en la primera columna se obtienen simulando el proceso una vez ($N=1$) y generamos una serie de 2450×10 datos pues $\tau = 1/10$. En la segunda columna de la Tabla 1, simulamos 10 veces ($N=10$), y generamos 10 series de tamaño 2450×10 siendo la frecuencia $\tau = 1/10$. Por tanto, nuestros resultados finales se basan en la siguiente minimización:

$$\min_{\Omega} \left(\hat{\Psi} - 1/10 \sum_{i=1}^{10} \hat{\Psi}_i \right)^2.$$

En la tercera columna el proceso se simula una vez ($N=1$), pero la longitud de la serie es de 2450×10 . Dado que $\tau = 1/10$, tenemos un total de $2450 \times 10 \times 10$ observaciones. Obsérvese que ahora estimamos el modelo Nagarch (1,1) para datos simulados con la misma frecuencia que los datos reales pero con una muestra de tamaño diez veces superior que en los dos casos anteriores. Esta es la metodología empleada en el procedimiento rolling para la estimación out-of-sample que será usado para realizar el contraste de valoración de Heston con la discretización de Euler. Finalmente, los resultados de la columna 4 simula el proceso una vez ($N=1$), pero la frecuencia es de $\tau = 1/50$.

Las estimaciones contenidas en la Tabla 1 sugieren que, independientemente del procedimiento empleado, los resultados tienden a ser muy similares. Además, se observa que no existe diferencia en cuanto a la discretización empleada. También hay que destacar el signo positivo de la correlación⁸⁶ y de valor próximo a cero.

⁸⁶Debido al coeficiente de asimetría negativo en el Nagarch (1,1), cabría esperarse un coeficiente de correlación negativo indicando por tanto la sobreacción de los agentes a las malas noticias frente a las buenas noticias.

En la estimación out-of-sample, estimamos el mismo proceso 80 veces usando sistemáticamente 2450 observaciones pasadas. Este procedimiento rolling de inferencia indirecta es necesario para obtener los estimadores de los parámetros de la fórmula de Heston día a día entre el 3 de Enero, 1996 y el 30 de Abril, 1996. La Figura 1 presenta la evolución de los parámetros asociados al proceso de varianza estocástica y correlación para el período out-of-sample. Podemos observar en la figura que la volatilidad a largo plazo (la desviación estándar de θ), la tasa de convergencia de la varianza instantánea a la media a largo plazo, k , y la volatilidad de la varianza del proceso, σ , permanecen estables en el período out-of-sample. Sin embargo, el coeficiente de correlación ρ muestra una tendencia creciente y resulta ser positivo durante todo el período out-of-sample.

5 Contraste Empírico

5.1 Período In-Sample

Los contrastes empíricos del modelo de Heston están basados en todas las opciones call disponibles durante la ventana de 45 minutos correspondiente al intervalo desde las 16:00 hasta las 16:45 durante el período desde el 3 de Enero, 1996 hasta el 30 de Abril, 1996.

La Tabla 2 describe algunas características muestrales de los precios de las opciones call empleados en este trabajo, en concreto precios medios, spreads bid-ask relativo medios y el número de calls para cada categoría de grado en dinero. Definimos el grado en dinero (moneyness) como la razón entre precio de ejercicio y precio del futuro. Una opción call se define como muy fuera del dinero (deep out-of-the-money) si la razón K/F pertenece al intervalo $(1.03, 1.08)$; fuera del dinero (out-of-the-money) si $1.03 > K/F \geq 1.01$; en el dinero (at-the-money) cuando $1.01 > K/F \geq 0.99$; dentro del dinero (in-the-money) cuando $0.99 > K/F \geq 0.97$; y muy dentro del dinero (deep-in-the-money) si $0.97 > K/F \geq 0.90$. Existen 768 opciones call, con opciones OTM, ATM y ITM representando el 51%, 32% y 17% respectivamente. La media de los precios de las opciones call comprende desde las 12.88 pesetas para opciones deep OTM a 185.42 pesetas para opciones deep ITM. La media del spread relativo bid-ask se mueve justamente en la dirección opuesta al precio medio. En concreto, comprende desde 0.39 para calls deep OTM a 0.10 para calls deep ITM.

En la Tabla 3 se obtiene la volatilidad implícita⁸⁷ media para cada nivel de moneyness correspondiente a los modelos de BS y Heston. La Figura 2 contiene la representación de las smiles asociadas a la Tabla 3. Obsérvese que en Heston debido a que no extraemos los parámetros a partir del precio de las opciones y por tanto, no podemos estimar la prima de riesgo entonces obtenemos las volatilidades medias para cada grupo de moneyness para diferentes valores de la prima de riesgo λ ⁸⁸. Melino y Turnbull (1990) aplican una metodología similar, es decir; en primer lugar estiman los parámetros del modelo de volatilidad estocástica propuesto para valorar derivados sobre divisas en un marco de serie temporal aplicando GMM y posteriormente para obtener el precio de la opción es necesario tener un valor de λ , entonces se presentándose una parrilla ad-hoc de distintos valores de λ .

Como sabemos de la Sección 3, la prima de riesgo de la volatilidad viene dada por la siguiente expresión

$$\lambda(S, V, t) = \gamma \text{cov}(dV_t, dC_t/C_t)$$

donde C_t representa el consumo agregado y γ el coeficiente de aversión absoluta al riesgo. Esto implica que el signo de λ depende del signo de la covarianza entre el cambio de la varianza instantánea y el cambio del consumo agregado. En nuestro caso, el futuro sobre el índice tiene una covarianza positiva con el consumo agregado; por tanto el signo de λ dependerá del signo del coeficiente de correlación ρ . Si esta correlación es negativa (positiva), λ debería ser negativa (positiva)⁸⁹. Como no queremos asumir *a priori* un

⁸⁷En el caso de Heston la volatilidad implícita tiene una interpretación distinta que en el caso de BS pues en Heston se obtiene volatilidades instantáneas mientras en BS la volatilidad tiene una medida diferente pues es la volatilidad promedia comprendida desde hoy hasta el vencimiento de la opción.

⁸⁸Nótese que, una vez que hemos estimado para cada día los parámetros del proceso de varianza y la correlación, es decir; k, θ, σ y ρ usando la metodología de rolling inferencia indirecta, necesitamos obtener además los parámetros de la prima de riesgo, λ y varianza instantánea, V_t , antes de obtener un precio de la opción call. Al tener dos parámetros para estimar, λ y V_t , parece razonable estimarlos mediante la técnica de sección cruzada aplicada por Bakshi, Cao y Chen (1997) pero en nuestro caso sobre menos parámetros pues el resto ha sido obtenida mediante inferencia indirecta. Desafortunadamente no encontramos un mínimo global conjunto para λ y V_t .

⁸⁹Kapadia (1998) comenta que una prima de riesgo negativa de la volatilidad sugiere que las opciones sobre acciones actúan como cobertura de la cartera de mercado, y por tanto el signo negativo es consistente con que los rendimientos de las acciones reaccionan negativamente a shocks positivos de volatilidad.

signo particular de λ , estimamos precios teóricos de opciones con tres valores posibles de λ : 0, 0.5 y -0.5⁹⁰.

Sea $\hat{\Omega}_t = (\hat{k}_t, \hat{\theta}_t, \hat{\sigma}_t, \hat{\rho}_t)$ el conjunto de parámetros estimados por inferencia indirecta para un día particular t de la muestra y para cada opción call i ($i = 1, \dots, n_t$) y cada día t definimos el error de valoración como:

$$e_{it} = \hat{c}_{it}(K_i) - c_{it}(K_i)$$

donde K_i es el precio de ejercicio i , $\hat{c}_{it}(K_i)$ es el precio teórico de la opción call i en el día t , y $c_{it}(K_i)$ el precio de mercado. Para cada uno de los valores λ de arriba, minimizamos la siguiente suma de errores cuadráticos para obtener la varianza instantánea diaria, es decir;

$$\min_{V_t} \sum_{i=1}^{n_t} \left[e_{it} \left(V_t, \lambda; \hat{\Omega}_t \right) \right]^2. \quad (203)$$

En definitiva, para cada uno de los tres valores de λ obtenemos estimaciones diarias de la varianza instantánea resolviendo (203) para la muestra desde el 2 de Enero, 1996 hasta el 29 de Abril, 1996. La Tabla 3 contiene tres series de las medias muestrales de las volatilidades implícitas correspondientes a Heston para cada uno de los distintos valores de λ y otra serie de elaboración similar pero bajo el modelo de BS. Se observa que a mayor prima de riesgo, mayor es la volatilidad instantánea media. En todos los casos la volatilidad instantánea media de Heston supera a la correspondiente de BS como puede verse también en la Figura 1. En la Figura 3 se representa las volatilidades de todas las opciones call disponibles en nuestra muestra, 768 datos, para BS y Heston en cada uno de los valores de λ citados observándose de nuevo el mismo comportamiento, es decir; la volatilidad instantánea de Heston supera a la volatilidad implícita de BS independientemente del valor de λ .

5.2 Período Out-of-Sample

En primer lugar, analizaremos la capacidad predictiva del modelo de Heston comparando la serie de precios de opciones call comprendida entre el 3 de Enero, 1996 y el 30 de Abril, 1996 (768 opciones) con la serie de predicciones de estos precios. Para realizar la predicción del precio de una opción

⁹⁰Desde 1963 a 1997 la prima de riesgo de mercado media anualizada del índice bursátil español es de 6.8% con una desviación estándar de 18.5%.

determinada en un día $t+1$, utilizaremos los parámetros por inferencia indirecta y varianza instantánea estimados en t dado un valor determinado de λ . Mientras el precio del subyacente y el tipo de interés corresponden al día $t+1$. En definitiva, para realizar las predicciones out-of-sample los parámetros estimados en la inferencia indirecta y las varianzas instantáneas estimadas pertenecen al período 2 de Enero, 1996 al 29 de Abril, 1996. Por último, en el caso de BS utilizaremos también la volatilidad implícita obtenida en t . La Tabla 4 presenta el error de predicción de los dos modelos en distintas formas. El panel A contiene el error de predicción en términos absolutos que es la media muestral de la diferencia absoluta entre precio teórico y precio de mercado para cada grupo de moneyness y el total. El panel B contiene el error de predicción porcentual que es la media muestral del precio teórico menos el precio de mercado dividido por el precio de mercado. De nuevo, calculamos este estadístico para cada categoría de moneyness y toda la muestra.

Puede observarse, que en términos absolutos, el modelo de Heston tiende a valorar ligeramente mejor que BS. El error absoluto de todas las calls es aproximadamente de 2.8 pesetas para el modelo de Heston independientemente de la prima de riesgo de volatilidad asumida, y 3.2 pesetas para el modelo BS. Hay que destacar que el nivel de riesgo de la volatilidad no parece alterar la valoración en el modelo de Heston. Los errores de predicción obtenidos bajo los distintos valores de λ resultan ser prácticamente similares. Puede haber alguna evidencia en favor de la prima de riesgo positiva pero podemos concluir que los precios de las opciones no resultan ser sensibles a la prima de riesgo de la volatilidad. Kapadia (1998) demuestra que los beneficios con la cobertura delta en un modelo de volatilidad estocástica tiene una distribución con media cero cuando la prima de riesgo de la volatilidad es cero⁹¹. Este resultado se sostiene también con BS.

Hay que señalar también que la ligera superioridad de Heston frente a BS no se mantiene en todas las categorías de moneyness. En concreto, Heston tiende a valorar mejor las opciones call ATM y ITM mejor que BS. Sin embargo, se mantiene el resultado opuesto para opciones call OTM. Esto también ocurre al analizar el error de predicción porcentual en el panel B. Heston, independientemente del nivel de la prima de riesgo de volatilidad impuesta tiende a sobrevalorar las opciones call OTM, y al mismo tiempo,

⁹¹Si la prima de riesgo de la volatilidad está valorada, entonces la ganancia media con la cobertura delta es proporcional a la magnitud y signo de la prima de riesgo de la volatilidad. La comparación entre coberturas dinámicas de Heston y BS resulta ser más complicada que el análisis de Bakshi, Cao y Chen (1997).

infravalora las opciones ITM. Sin embargo, el error porcentual en opciones ATM es prácticamente de valor cero. De hecho, las opciones call ATM son claramente más consistentes con un modelo de volatilidad estocástica que bajo el supuesto tradicional de lognormalidad. BS, por otro lado, tiende a infravalorar calls deep OTM y calls deep ITM. Esto resulta ser consistente con la forma de U de la sonrisa de volatilidad. En el caso de Heston, la evidencia sugiere una mueca en lugar de la sonrisa.

En resumen, independientemente del valor de λ y para toda la muestra, Heston tiende a sobrevalorar mientras BS tiende a infravalorar las calls. Desafortunadamente, estos estadísticos simples no ayudan a realizar inferencias en términos de mejora de un modelo frente a otro. En este trabajo, para realizar la inferencia señalada con anterioridad se contrasta la proporción de precios teóricos fuera de las correspondientes bandas del bid-ask⁹². Utilizaremos el siguiente estadístico Z para la diferencia de dos proporciones:

$$Z = \frac{p_1 - p_2}{\sqrt{p_1(1-p_1)/n_1 + p_2(1-p_2)/n_2}}$$

donde p_1 es siempre la proporción de precios de BS fuera de las bandas bid-ask, y p_2 es la proporción equivalente para Heston. n_1 y n_2 son los tamaños muestrales correspondientes a estas proporciones. Este estadístico se distribuye asintóticamente como una variable normal estandarizada.

Los resultados empíricos se muestran en la Tabla 5. Dado que estamos interesados en conocer si un valor teórico infravalora o sobrevalorar los precios de mercado, el estadístico Z se calcula para obtener la proporción de precios inferiores al precio bid por parte del modelo teórico, y la proporción de precios superiores al precio ask por parte del modelo teórico. Si un modelo teórico tiende a infravalorar los precios de mercado, se obtendría una proporción mayor de precios por debajo del precio bid. Por otro lado, si el modelo tiende a sobrevalorar los precios de mercado, se obtendría una proporción más alta de precios superiores al precio ask.

Al considerar todos los precios de las opciones call, el p-valor correspondiente a la mejora estadística de Heston frente a BS es igual a 0.068. La proporción de los precios de BS fuera de los límites bid-ask es 48%, mientras la proporción del modelo de Heston es 42% observándose una ligera mejora del segundo frente al primero. Sin embargo, no está claro debido a los costes de implementación que Heston resulte ser útil a nivel práctico.

⁹²Ver Corrado y Su (1996).

Nótese que el 35% de los precios BS están por debajo del bid mientras Heston valora el 18% de los precios por debajo del bid. Por tanto, podemos concluir que BS, en media, significativamente infravalora los precios de mercado con respecto a Heston. Al mismo tiempo, el 24% de los precios de Heston superan el precio ask. Podemos concluir que el modelo de Heston tiende significativamente a sobrevalorar los precios de mercado respecto a BS.

Al clasificar las calls según la categoría de moneyness también se obtiene conclusiones similares. Una opción es OTM si $K/F > 1$, y una call se clasifica como ITM si $K/F < 1$. En general, dentro de cada categoría de moneyness, ningún modelo es estadísticamente superior. Una vez más, BS tiende a infravalorar en opciones OTM e ITM con respecto al modelo de Heston (y precios de mercado). Lo contrario se verifica para Heston con respecto a BS (y precios de mercado). En este último caso existe una fuerte tendencia de Heston a sobrevalorar las opciones OTM como puede reflejarse en la Tabla 4.

Como señalamos arriba, el error de predicción porcentual de Heston para opciones ATM resulta ser bastante pequeño. Podemos concluir que la fórmula de Heston funciona bastante bien para opciones ATM. Las opciones call son ATM cuando $1.01 > K/F \geq 0.99$. Repitiendo el ejercicio de arriba, Heston ($\lambda = 0$) tiende a dar menores proporciones de precios fuera de los límites bid-ask que en los casos anteriores. Sin embargo, el p-valor para la diferencia con respecto a la proporción de BS es 0.078. Como antes, BS tiende a dar una proporción de precios inferior al bid más alta que Heston. Mientras, Heston presenta una proporción de precios superior al ask más alta que BS. La fórmula de Heston tiene proporciones similares por encima del ask y por debajo del bid.

Siguiendo a Peña, Rubio y Serna (1998) y Bakshi, Cao y Chen (1997), realizamos una regresión para estudiar la relación entre los errores de predicción porcentuales y factores que son específicos a las opciones o dependientes del mercado. Dado un modelo de valoración de opciones, definimos e_{it} el error de predicción porcentual de la opción call i -ésima en el día t . Finalmente, estimamos la siguiente regresión para todo el período:

$$e_{it} = \alpha + \beta_1 X_{it} + \beta_2 \tau_{it} + \beta_3 SP_t + \beta_4 VOL_t + \beta_5 TERM_t + \omega_{it}$$

donde X_{it} es el grado en dinero (moneyness) de la opción call i en el día t definido como la razón entre el precio de ejercicio (K) y el precio del futuro



(F); τ_{it} es el período anualizado desde t hasta el vencimiento de la opción i ; SP_t es la media relativa del spread bid-ask de todas las opciones call y put correspondientes a la ventana entre las 16:00 y 16:45 el día t ; VOL_t es la desviación estándar anualizada de la serie de rendimientos intradiarios de frecuencia 1 minuto del IBEX-35; y $TERM_t$ es el diferencial de rendimiento entre el repo a un mes anualizado y el bono del Tesoro⁹³ anualizado a diez años.

La Tabla 6 contiene los resultados de la regresión para todo el período muestral, o sea 768 opciones, con errores estándar de los coeficientes ajustados por el estimador consistente a la heterocedasticidad de White (1980).

Las variables explicativas empleadas en las regresiones tienden a ser estadísticamente significativas. Sin embargo, existen importantes diferencias entre los errores porcentuales asociados a BS y Heston.

Hay que destacar la no significatividad estadística del coeficiente estimado relacionado a la volatilidad (VOL) al considerar el modelo de Heston independientemente de la prima de riesgo usada en el análisis; mientras el mismo coeficiente resulta ser negativo y significativo en BS. Esto representa evidencia favorable para los modelos de volatilidad estocástica. De nuevo, el supuesto de volatilidad constante bajo BS no parece representar el comportamiento adecuado en la valoración de opciones. En media, BS tiende a dar precios de opciones más bajos para reducidos niveles de volatilidad mientras Heston es lo suficiente flexible para capturar las variaciones de volatilidad.

Los sesgos tradicionales no son corregidos por ninguno de los modelos. El sesgo asociado con el moneyness tiene signo opuesto en los dos tipos de modelos. Como es de esperar, Heston tiende a valorar calls OTM peor que calls ITM. Sin embargo, en media, encontramos el resultado opuesto en BS. El sesgo asociado al tiempo hasta el vencimiento parece ser relevante para los dos tipos de modelos. En media, los errores de predicción porcentuales son mayores cuanto mayor es el tiempo hasta el vencimiento.

La influencia de los errores de porcentuales de predicción del diferencial de rendimiento de tipos de interés y el spread medio para opciones call y put correspondientes a la ventana de 45 minutos son diferentes según el modelo de valoración. En Heston, cuanto mayor sea el rendimiento a largo plazo respecto al rendimiento a corto plazo, mayor es el error de predicción porcentual. Este resultado sugiere que la introducción de tipos de interés

⁹³Se ha estimado la misma regresión para las variables dependientes del mercado con retardo un día obteniendo resultados muy similares.

estocásticos en el modelo de valoración de opciones acabando al final en un modelo de volatilidad y tipos de interés estocásticos⁹⁴.

Con respecto a la variable spread, se han estimado regresiones incluyendo el spread bid-ask relativo de la call i en la fecha t . Por tanto, tenemos ahora una variable específica del contrato. Sorprendentemente, los coeficientes estimados resultan ser no significativos independientemente del modelo de valoración considerado. Con ello, estamos incorporando una variable de costes de transacción directamente asociada a la liquidez de cada opción individual. De nuevo, esta variable no parece ser significativa al explicar los errores de predicción porcentuales. Por otro lado, al introducir el spread medio sobre todas las opciones call y put para un día particular t , el coeficiente estimado resulta ser positivo y significativo en el caso de Heston. Esta variable agregada puede indicar la media de selección adversa que confrontan los market makers al negociar opciones en el mercado español. Se observa que cuanto mayor sea la media del spread (mayor es la media de selección adversa entre los traders) más elevado es el error de predicción porcentual en Heston. Sin embargo esta variable resulta ser irrelevante en BS. En definitiva, el sesgo relacionado con el supuesto de volatilidad constante resulta ser más importante que los sesgos asociados con la variable dependiente del mercado como el spread medio o la estructura de tipos.

En resumen, los errores de predicción bajo Heston tienen sesgos de money-ness, período hasta el vencimiento, spread bid-ask medio y sesgos de volatilidad. Mientras BS presenta sesgos de money-ness, vencimiento y volatilidad. Ninguno de los modelos capta de forma adecuada las características de la distribución implícita del activo subyacente.

6 Conclusiones

Este es uno de los primeros artículos que ha investigado empíricamente el comportamiento del modelo de volatilidad estocástica de Heston para valorar opciones⁹⁵. Constituye uno de los primeros artículos de desarrollo en un contexto de serie temporal⁹⁶. Esta metodología de estimación en etapas

⁹⁴Ver Bakshi y Chen (1997), y Bakshi, Cao y Chen (1997).

⁹⁵Bates (1996) utiliza opciones sobre divisas, concretamente sobre el marco alemán; mientras Bakshi, Cao y Chen (1997) emplean opciones sobre el índice S&P 500.

⁹⁶Bakshi, Cao y Chen (1998) estiman los parámetros bajo neutralidad al riesgo en un contexto mixto de serie temporal y corte transversal utilizando la metodología del método



propuesta en el artículo constituye una posible solución ante la imposibilidad de aplicar la técnica de sección cruzada.

Los resultados empíricos muestran la poca ganancia en cuanto a valoración al aplicar el modelo de Heston frente al modelo tradicional de BS. En media, sobre la muestra de opciones call disponibles, el modelo de Heston mejora de forma marginal respecto a BS no justificando su uso debido a los costes de implementación.

Dado estos resultados, resulta inútil estudiar la cobertura dinámica de Heston frente a BS. Además, debido a que utilizamos opciones con vencimiento a muy corto plazo puede resultar más relevante estudiar procesos de volatilidad estocástica con saltos estocásticos.

Una investigación interesante sería incorporar de forma endógena los costes de liquidez en la valoración de opciones con volatilidad estocástica, etc. Por último, la introducción de árboles implícitos binomiales o mixturas de distribuciones pueden resultar métodos más prometedores para valorar opciones.

de los momentos simulados para opciones sobre el índice S&P 500 y LEAPS.

7 Referencias

Aït-Sahalia, Y., y A. Lo (1998): "Nonparametric estimation of state-price densities implicit in financial asset prices", *Journal of Finance* 53, p. 499-547.

Bakshi, G., Cao, C., y Z. Chen (1998): "Pricing and hedging long-term options", próximamente en *Journal of Econometrics*.

Bakshi, G., Cao, C., y Z. Chen (1997): "Empirical performance of alternative option pricing models", *Journal of Finance* 52, p. 2003-2049.

Bakshi, G. y Z. Chen (1997): "An alternative valuation model for contingent claims", *Journal of Financial Economics* 1, p. 123-165.

Ball, C. y A. Roma (1994): "Stochastic volatility option pricing", *Journal of Financial and Quantitative Analysis* 29, p. 589-607.

Bates, D. (1996): "Jumps and stochastic volatility: exchange rate processes implicit in Deutsche mark options", *Review of Financial Studies* 9, p. 69-107.

Black, F. (1976): "The pricing of commodity contracts", *Journal of Financial Economics* 3, p. 167-179.

Black, F. y M. Scholes (1973): "The pricing of options and corporate liabilities", *Journal of Political Economy* 81, p. 637-659.

Breeden, D.T. (1979): "An intertemporal asset pricing model with stochastic consumption and investment opportunities", *Journal of Financial Economics* 7, p. 265-296.

Chriss, N. (1995): "How to grow a smiling tree", Harvard University, Department of Mathematics Working Paper.

Corrado, C. y T. Su (1996): "Skewness and Kurtosis in S&P 500 index returns implied by option prices", *Journal of Financial Research* 19, p. 175-192.

Cox, J. y S. Ross (1976): "The valuation of options for alternative stochastic processes", *Journal of Financial Economics* 3, p. 145-160.

Das, S. y R. Sundaram (1997): "Of smiles and smirks: A term-structure perspective", Working Paper, Harvard Business School.

Derman, E. y I. Kani (1994): "Riding on a smile", *Risk* 7, p. 32-39.

Derman, E., I. Kani y N. Chriss (1996): "Implied trinomial trees of the volatility smile", *Journal of Derivatives* 3, p. 7-22.

Dumas, B., J. Fleming y R. Whaley (1996): "Implied volatility functions: empirical tests", NBER, Working paper 5500.

Dupire, B. (1994): "Pricing with a smile", *Risk* 7, p. 18-20.

French, D. (1984): "The weekend effect on the distribution of stock prices:

implications for option pricing", *Journal of Financial Economics* 13, p. 547-559.

Gouriéroux, C., Monfort, A., y E. Renault (1993): "Indirect Inference", *Journal of Applied Econometrics* 8, p. 85-118.

Heston, S. (1993): "A closed-form solution for options with stochastic volatility with applications to bond and currency options", *Review of Financial Studies* 6, p. 327-344.

Hull, J. y A. White (1987): "The pricing of options on assets with stochastic volatilities", *Journal of Finance* 42, p. 281-300.

Jackwerth, J.C. (1996): "Implied binomial trees: generalizations and empirical tests", University of California at Berkeley, Working paper RPF-262.

Jackwerth, J.C. y M. Rubinstein (1996): "Recovering probability distributions from option prices", *Journal of Finance* 51, p. 1611-1631.

Kapadia, N. (1998): "Do equity options price volatility risk? Empirical evidence", Working Paper, University of Massachusetts.

León, A. y J. Mora (1998): "Modelling conditional heteroskedasticity: application to the IBEX-35 stock return index", próximamente en *Spanish Economic Review*.

Melino, A. y S.M. Turnbull (1990): "Pricing foreign currency options with stochastic volatility", *Journal of Econometrics* 45, p. 239-265.

Nowman, K. (1997): "Gaussian estimation of single-factor continuous time models of the term structure of interest rates", *Journal of Finance* 52, p. 1695-1706.

Peña, I., Rubio, G. y G. Serna (1998): "Why do we smile? On the determinants of the implied volatility function", Working Paper, Universidad del País Vasco.

Rubinstein, M. (1994): "Implied binomial trees", *Journal of Finance* 49, p. 771-818.

Stein, E. y J. Stein (1991): "Stock price distributions with stochastic volatility: an analytical approach", *Review of Financial Studies* 4, p. 727-752.

White, H. (1980): "A heteroskedasticity-consistent covariance matrix estimator and a direct test for heteroskedasticity", *Econometrica* 48, p. 817-838.

TABLA 1

INFERENCIA INDIRECTA EN EL PERÍODO IN-SAMPLE
Enero 1994-Diciembre 1995

Los parámetros del siguiente proceso se estiman con la metodología de inferencia indirecta:

$$dS_t = \mu S_t dt + \sqrt{V_t} S_t dW_{1t}$$

$$dV_t = \kappa(\theta - V_t)dt + \sigma\sqrt{V_t}dW_{2t}$$

$$dW_{1t}dW_{2t} = \rho dt$$

donde μ es la tasa esperada instantánea del rendimiento del activo subyacente, V_t es la varianza instantánea estocástica, θ es la media a largo plazo de la varianza, κ es la tasa de convergencia de la varianza a su media, σ representa la volatilidad del proceso de varianza estocástica, y ρ es la correlación instantánea. El modelo auxiliar empleado en la estimación es modelo Nagarch(1,1)^{1/}:

$$R_t = \mu + \xi_t = \mu + h_t \varepsilon_t \stackrel{\text{iid}}{\approx} N(0,1)$$

$$h_t = \omega + \beta h_{t-1} + \alpha \left(\xi_{t-1} + \gamma h_{t-1}^{1/2} \right)^2$$

donde R_t es el rendimiento horario del índice IBEX-35, y γ es el parámetro de asimetría del Nagarch. Dos técnicas de discretización (Euler y Nowman) se emplean en la estimación. Diversas frecuencias y simulaciones se han utilizado también.

	N = 1; $\tau = 1/10^{2/}$ Longitud = 2.450		N = 10; $\tau = 1/10^{3/}$ Longitud = 2.450		N = 1 $\tau = 1/10^{4/}$ Longitud = 2.450x10		N = 1; $\tau = 1/50^{5/}$ Longitud = 2.450	
	Euler	Nowman	Euler	Nowman	Euler	Nowman	Euler	Nowman
$\hat{\mu}^{6/}$	0.619	0.617	0.696	0.696	0.702	0.702	0.868	0.868
$\sqrt{\hat{\theta}}^{7/}$	12.09	12.08	12.77	12.77	11.92	11.92	11.73	12.26
$\hat{\kappa}$	0.029	0.029	0.034	0.033	0.034	0.034	0.025	0.025
$\hat{\sigma}^{8/}$	1.631	1.633	1.864	1.868	1.857	1.860	1.542	1.542
$\hat{\rho}$	0.044	0.044	0.038	0.038	0.020	0.020	0.087	0.087

1/ Los estimadores de los parámetros del Nagarch(1,1) son:

$$\hat{\mu} = 0.00412; \hat{\omega} = 0.00301; \hat{\alpha} = 0.07680; \hat{\beta} = 0.89025; \hat{\gamma} = -0.1225$$

2/ El proceso es simulado una vez ($N = 1$), por tanto se utilizan 2.450x10 datos pues $\tau = 1/10$, donde 2.450 es el número de rendimientos horarios disponibles desde Enero 1994 a Diciembre 1995.

3/ El proceso es simulado 10 veces ($N = 10$), por tanto se generan 10 series de tamaño 2.450x10 pues como en 2/, $\tau = 1/10$.

4/ El proceso se simula una vez ($N = 1$), pero ahora se emplean 2.450x10x10 datos pues $\tau = 1/10$. Es decir, la calibración del Nagarch se realiza con más datos: 2.450x10.

5/ El proceso es simulado una vez ($N = 1$), pero ahora se emplean 2.450x50 datos pues $\tau = 1/50$.

6/ Está anualizado y en términos porcentuales.

7/ Representa la desviación estándar de la varianza a largo plazo. Está anualizada y en términos porcentuales.

8/ Anualizado y en términos porcentuales.

TABLA 2

CARACTERÍSTICAS MUESTRALES DE OPCIONES SOBRE EL FUTURO IBEX-35

Precios medios, spread relativo medio bid-ask y número de opciones call se presentan para cada categoría de moneyness. Todas las opciones call correspondientes a la ventana de 45 minutos desde las 16:00 a las 16:45 desde el 2 de Enero, 1996 hasta el 30 de Abril, 1996 son empleadas. K es el precio de ejercicio y F representa el precio del futuro del índice IBEX-35. Moneyness se define como la razón del precio de ejercicio respecto al precio del futuro. OTM, ATM, e ITM son opciones out-of-the-money, at-the-money e in-the-money respectivamente.

	Moneyness (K/F)	Precio medio	Spread Bid-Ask medio	Número de observaciones
CALLS DEEP OTM:	1.03-1.08	12.88	0.3903	116
CALLS OTM:	1.01-1.03	28.68	0.2205	273
CALLS ATM:	0.99-1.01	57.20	0.1491	245
CALLS ITM:	0.97-0.99	98.54	0.1273	108
CALLS DEEP ITM:	0.90-0.97	185.42	0.0987	26
TODAS CALLS:	-	50.52	0.2015	768

TABLA 3

VOLATILIDADES IMPLÍCITAS DE HESTON Y BS

	Moneyness (K/F)	BS	HESTON		
			$\lambda=0$	$\lambda=0.5$	$\lambda=-0.5$
CALLS DEEP OTM:	1.03-1.08	0.1698	0.1708	0.1720	0.1696
CALLS OTM:	1.01-1.03	0.1611	0.1718	0.1728	0.1707
CALLS ATM:	0.99-1.01	0.1636	0.1736	0.1747	0.1725
CALLS ITM:	0.97-0.99	0.1625	0.1722	0.1733	0.1710
CALLS DEEP ITM:	0.90-0.97	0.1755	0.1781	0.1793	0.1769
TODAS CALLS:	-	0.1639	0.1725	0.1736	0.1714

TABLA 4

ERROR DE PREDICCIÓN OUT-OF-SAMPLE PARA HESTON Y BS:

ERROR ABSOLUTO Y ERROR PORCENTUAL

PANEL A: ERROR ABSOLUTO					
	Moneyness (K/F)	Black-Scholes (Ptas.)	Heston (Ptas.)		
			($\lambda=0$)	($\lambda=0.5$)	($\lambda=-0.50$)
CALLS DEEP OTM:	1.03-1.08	1.829	2.033	2.030	2.038
CALLS OTM:	1.01-1.03	2.641	2.815	2.819	2.774
CALLS ATM:	0.99-1.01	3.847	2.874	2.854	2.896
CALLS ITM:	0.97-0.99	4.690	3.593	3.586	3.600
CALLS DEEP ITM:	0.90-0.97	4.357	3.809	3.795	3.823
TODAS CALLS:	-	3.249	2.859	2.852	2.853
PANEL B: ERROR PORCENTUAL					
	Moneyness (K/F)	Black-Scholes (%)	Heston (%)		
			($\lambda=0$)	($\lambda=0.5$)	($\lambda=-0.50$)
DEEP OTM CALLS:	1.03-1.08	-7.091	5.916	6.009	5.673
CALLS OTM:	1.01-1.03	1.189	8.429	8.583	8.310
CALLS ATM:	0.99-1.01	-3.894	-0.053	-0.021	-0.089
CALLS ITM:	0.97-0.99	-3.285	-1.351	-1.331	-1.371
CALLS DEEP ITM:	0.90-0.97	-2.560	-2.251	-2.243	-2.260
TODAS CALLS:	-	-2.439	3.607	3.689	3.513

TABLA 5

CONTRASTE NO PARAMÉTRICO PARA LOS MODELOS DE HESTON Y BS

Categorías	BS	Heston ($\lambda=0$)	Z-stat. (p-valor)	Heston ($\lambda=0.5$)	Z-stat. (p-valor)	Heston ($\lambda=-0.5$)	Z-stat. (p-valor)
<u>TODAS LAS OPCIONES CALL:</u>							
$p(\text{Bid} > c_{\text{MODEL}} > \text{Ask})$	0.4761	0.4249	1.825 (0.068)	0.4249	1.825 (0.068)	0.4233	1.882 (0.060)
$p(c_{\text{MODEL}} < \text{Bid})$	0.3487	0.1837	6.730 (0.000)	0.1821	6.804 (0.000)	0.1901	6.434 (0.000)
$p(c_{\text{MODEL}} > \text{Ask})$	0.1274	0.2412	-5.253 (0.000)	0.2428	-5.319 (0.000)	0.2332	-4.919 (0.000)
<u>OPCIONES CALL OTM($K/F > 1$):</u>							
$p(\text{Bid} > c_{\text{MODEL}} > \text{Ask})$	0.4821	0.4347	1.421 (0.155)	0.4347	1.421 (0.155)	0.4324	1.421 (0.155)
$p(c_{\text{MODEL}} < \text{Bid})$	0.3184	0.1351	6.694 (0.000)	0.1329	6.791 (0.000)	0.1419	6.399 (0.000)
$p(c_{\text{MODEL}} > \text{Ask})$	0.1637	0.2995	-4.864 (0.000)	0.3018	-4.940 (0.000)	0.2905	-4.566 (0.000)
<u>OPCIONES CALL ITM($K/F < 1$):</u>							
$p(\text{Bid} > c_{\text{MODEL}} > \text{Ask})$	0.4615	0.4011	1.166 (0.244)	0.4011	1.166 (0.244)	0.4011	1.1656 (0.244)
$p(c_{\text{MODEL}} < \text{Bid})$	0.4231	0.3022	2.418 (0.015)	0.3022	2.418 (0.015)	0.3077	2.303 (0.021)
$p(c_{\text{MODEL}} > \text{Ask})$	0.0385	0.0989	-2.294 (0.022)	0.098	-2.294 (0.022)	0.0934	-2.123 (0.034)
<u>OPCIONES CALL ATM($1.01 > K/F > 0.99$):</u>							
$p(\text{Bid} > c_{\text{MODEL}} > \text{Ask})$	0.4583	0.3750	1.762 (0.078)	NA		NA	
$p(c_{\text{MODEL}} < \text{Bid})$	0.3981	0.1806	5.134 (0.000)	NA		NA	
$p(c_{\text{MODEL}} > \text{Ask})$	0.0602	0.1944	-4.272 (0.000)	NA		NA	

TABLA 6

ERRORES DE PREDICCIÓN PORCENTUALES Y VARIABLES EXPLICATORIAS

Para un modelo de valoración de opciones determinado, se estima la siguiente para explicar los errores porcentuales de todas las opciones call de la ventana de 45 minutos desde las 16:00 a las 16:45 desde el 3 de Enero, 1996 hasta el 30 de Abril, 1996:

$$e_{it} = \alpha + \beta_1 X_{it} + \beta_2 \tau_{it} + \beta_3 SP_t + \beta_4 VOL_t + \beta_5 TERM_t + \omega_{it}$$

donde e_{it} es el error de predicción porcentual de la opción call i asociado al día t ; X es el moneyness de la opción call i del día t definido como la razón entre el precio de ejercicio (K) y el futuro (F); τ_{it} es el tiempo hasta el vencimiento anualizado de la opción call i del día t ; SP es el spread medio bid-ask relativo de todas las opciones call y put pertenecientes al intervalo desde las 16:00 hasta las 16:45 en la fecha t ; VOL_t es la desviación estándar anualizada de la serie de rendimientos intradiaria de un minuto del índice IBEX-35; y $TERM_t$ es el diferencial de rendimiento entre el bono del Tesoro anualizado a diez años y el rendimiento anualizado del repo a un mes. Los estadísticos t entre paréntesis se han construido con errores estándar consistentes a la heterocedasticidad con la metodología de White (1980). Un total de 768 opciones call se emplearon en las regresiones.

Coeficiente	Black-Scholes	Heston ($\lambda=0$)	Heston ($\lambda=0.5$)	Heston ($\lambda=-0.5$)
Constante	0.751 (1.86)	-1.136 (-2.72)	-1.148 (-2.74)	-1.110 (-2.67)
Moneyness (X)	-0.788 (-2.00)	0.958 (2.32)	0.974 (2.35)	0.932 (2.26)
Tiempo hasta vto. (τ)	0.023 (2.83)	0.020 (2.31)	0.019 (2.26)	0.020 (2.33)
Spread (SP)	0.204 (1.39)	0.387 (2.68)	0.392 (2.71)	0.390 (2.70)
Volatilidad (VOL)	-1.352 (-2.10)	-0.926 (-1.47)	-0.942 (-1.50)	-0.895 (-1.42)
Estruct. tipos (TERM)	0.033 (0.77)	0.106 (2.52)	0.106 (2.51)	0.103 (2.47)

FIGURA 1: INFERENCIA INDIRECTA (Enero 1996-Abril 1996)




FIGURA 2: SMILES (Enero 1996-Abril 1996)





FIGURE 3: IMPLIED VOLATILITIES (January 96-April 96)



8 Conclusiones

En primer lugar, como resultado de la incorporación de rendimientos de activos que resultan ser ruido blanco con respecto a su historia pasada pero predecibles con respecto a conjuntos de información mayor se demuestra que la predecibilidad puede importar en un mundo discreto, especialmente en opciones de mayor vencimiento.

En un mundo discreto con rendimientos predecibles, cualquier discrepancia entre la frecuencia de trading y la frecuencia de observación de los precios resulta ser relevante al estimar los parámetros del modelo. Por esa razón, analizamos el caso límite del trading continuo. En este mundo, la fórmula de BS resulta ser válida a pesar de la predicibilidad y además la varianza muestral de los rendimientos para períodos finitos sigue siendo un estimador apropiado de la varianza instantánea de los rendimientos. Además lo que resulta ser importante en la valoración de opciones es la correlación serial.

En segundo lugar, los resultados empíricos procedentes del contraste del modelo de Heston (1993) muestran la poca ganancia en cuanto a valoración al aplicar el modelo de Heston frente al modelo tradicional de BS. En media, sobre la muestra de opciones call disponibles, el modelo de Heston mejora de forma marginal respecto a BS no justificando su uso debido a los costes de implementación. Un tema pendiente a realizar para medir una vez más la bondad de ajuste a los datos del modelo de Heston consistiría en introducir como input una varianza instantánea diferente en función del grado en dinero para predecir valores de opciones correspondientes al día siguiente y compararlo con BS, introduciendo en este último también una volatilidad distinta en función del grado de dinero. Esta idea surge como pretensión a acercarse más a la realidad en el sentido de que el trader valora a través de la smile. Es decir; sabiendo que BS no se cumple por el supuesto de volatilidad constante y por tanto no resulta en principio ser el modelo adecuado, entonces utiliza el modelo BS corrigiéndolo con la smile; o sea introduce un input de volatilidad en BS en función del grado en dinero.

Finalmente, con respecto al capítulo 1 una de las aportaciones pequeñas a tener en cuenta sería la extensión de la idea de Nelson y Ramaswamy (1990) sobre la aplicación de transformaciones mediante el lema de Ito sobre sistemas de ecuaciones diferenciales estocásticas para tener una matriz de varianzas y covarianzas homocedástica en el modelo transformado, concretamente el proceso de difusión bivalente de Heston (1993). Con ello se consigue valorar opciones mediante árboles sin que exista el problema de no-recombining.

Hilliard y Schwartz (1996) aplican el modelo de Nelson y Ramaswamy por etapas, es decir, transformando de una en una las ecuaciones estocásticas que definen el proceso generador de datos en Heston; mientras en el capítulo 1 se realiza en una única etapa.