


Ecuaciones Diferenciales Estocásticas

Simulación numérica utilizando el método de Monte Carlo

Índice

Esquema.	2
Ideas clave	3
4.1 Introducción y objetivos	3
4.2 Muestreo de variables aleatorias utilizando el método de Monte Carlo	4
4.3 Resolución numérica de ecuaciones diferenciales aleato- rias utilizando el método de Monte Carlo	9
4.4 Referencias bibliográficas	15
4.5 Cuaderno de ejercicios	16

Esquema



4.1 Introducción y objetivos

En el tema anterior, para visualizar y entender el concepto de PE, se ha requerido simularlo computacionalmente a través del muestreo de las VAs involucradas en el mismo. Concretamente, en la Figura 1, se ha muestreado en la VA, A , del PE $X(t) = At$. Por otro lado, también se ha explicado cómo simular el PE de Wiener a través del muestreo de una distribución normal tipificada.

Este tema está dedicado a describir una técnica de simulación estadística denominada método por Monte Carlo (MMC). Básicamente consiste en muestrear reiteradas veces un elemento estadístico y trabajar con cada una de las simulaciones realizadas. El MMC es un método de muestreo estadístico que fue popularizado en 1940 por físicos del *Laboratorio Nacional de los Alamos*. Para profundizar más en este método se recomienda consultar (Kroese et al., 2013) y (Ross, 1990).

El MMC también se utiliza para aproximar expresiones matemáticas complejas que son costosas de evaluar con exactitud, por ejemplo la aproximación de integrales definidas. En este tema nos centramos en utilizar el MMC para muestrear VAs y para obtener una aproximación de la solución de una ecuación diferencial aleatoria.

4.2 Muestreo de variables aleatorias utilizando el método de Monte Carlo

Esta sección está dedicada a utilizar el MMC para simular VAs. Comenzaremos describiendo el método inverso. Se basa en obtener simulaciones de una VA uniforme y aplicarles una transformación determinada. Esta transformación, define la VA que queremos muestrear en términos de una VA uniforme. Seguidamente nos centramos en determinar un método para poder simular una VA uniforme. De este modo, conociendo un procedimiento que nos permita como muestrear en una VA uniforme tendremos conocimiento suficiente para obtener simulaciones de cualquier VA. Sin embargo, el método inverso requiere calcular la inversa de una función, la cual no es siempre es posible. En este tema también se estudiará cómo muestrear una VA Gaussiana a partir de una aproximación de su función de distribución. Finalizaremos esta sección mostrando cómo simular una VA discreta Poisson.

Método inverso para muestrear variables aleatorias

El método inverso es una técnica que nos permite muestrear VAs a partir de simulaciones de una VA uniforme. Se basa en la siguiente idea. Supongamos que X es una VA continua con función de distribución F_X (la cual es continua y estrictamente creciente). Dado x tal que $-\infty < x < \infty$ fijo, se tiene que

$$F_X(x) = \mathbb{P}[\{\omega \in \Omega : X(\omega) \leq x\}] = u \in [0, 1]. \quad (1)$$

Como $F_X(x)$ es continua y estrictamente creciente es biyectiva y, por tanto, existe su función inversa,

$$x = F_X^{-1}(u). \quad (2)$$

Con esta última expresión se concluye que a partir de un $u \in [0, 1]$ podemos obtener, mediante F_X^{-1} , un valor x según la distribución de X .

Definición 1: Método de transformación inversa

Sea $F_X = \mathbb{P}[\{\omega \in \Omega : X(\omega) \leq x\}]$ la función de distribución de la VA X . Si $U \sim ([0, 1])$, entonces $F^{-1}(U)$ tiene función de distribución $F_X(x)$.

Con este resultado, si F_X denota la función de distribución de X , entonces la VA generada mediante la transformación $F^{-1}(U)$ es la misma que X , i.e. $F_X^{-1}(U) \sim X$.

Para más información sobre esta técnica se recomienda consultar (Devroye, 2006, Capítulo 2).

A continuación, describimos un ejemplo donde se muestrea una VA utilizando este método.

Ejemplo 1. Muestreo de una VA exponencial a través del método inverso

Sea $X \sim \text{Exp}(\lambda)$, $\lambda > 0$. El objetivo es muestrear en esta VA utilizando el método inverso. Se sabe que la función de distribución de una VA exponencial viene dada por

$$F_X(x) = 1 - e^{-\lambda x}, \quad x > 0, \quad \lambda > 0.$$

Por tanto, la inversa, $F^{-1}(x)$, está dada por

$$F_X^{-1}(u) = \frac{1}{\lambda} \log(1 - u), \quad u \in]0, 1[.$$

Si $U \sim U([0, 1])$, entonces podemos generar muestras de X a través de la siguiente transformación

$$X = -\frac{1}{\lambda} \log(1 - U), \quad U \sim U([0, 1]).$$

El comando en Mathematica para simular una VA Exponencial de parámetro “ λ ” par “ M ” veces viene dado por

```
-1/par Log[1 - RandomVariate[UniformDistribution[0, 1], M]].
```

Muestreo de una variable aleatoria uniforme

El método inverso requiere poder muestrear en una VA uniforme U sobre el intervalo unidad. En esta sección proponemos un método popular para generar valores en una $U([0, 1])$. Se trata de un generador de números pseudoaleatorios basado en grandes congruencias lineales.

En primer lugar consideramos a, c valores enteros positivos, m suficientemente grande y X_0 un entero positivo (que se suele denominar semilla).

Definimos la siguiente congruencia:

$$X_{n+1} \equiv (aX_n + c) \bmod(m), \quad n = 0, 1, \dots \quad (3)$$

Hacemos un inciso recordando que para dos números enteros k_1 y k_2 la operación $k_1 \bmod(k_2)$ se define como el resto de dividir k_1 entre k_2 , por tanto $0 \leq k_1 \bmod(k_2) \leq k_2$.

A continuación definimos la sucesión, $\{U_n = \frac{X_n}{m} : n = 0, 1, 2, \dots\}$ mediante

$$U_n = \frac{X_n}{m}, \quad n = 0, 1, 2, \dots, \quad 0 \leq U_n \leq 1, \quad \forall n \geq 0.$$

Para ciertos valores de los parámetros a, c y m la sucesión U_n posee propiedades estadísticas para números que están aleatoriamente distribuidos uniformemente entre 0 y 1.

Los generadores basados en congruencias lineales eventualmente se repiten, si $X_{i+p} =$

X_i , entonces el menor p que cumple esto se denomina longitud del ciclo o periodo del generador. A continuación mostramos un criterio para determinar el periodo de la sucesión definida por la expresión (3).

Proposición 1

El periodo de una congruencia lineal, como la que se ha definido en la expresión (3), es m si y solo se verifican las siguientes condiciones

- ▶ Máximo común divisor de c y m es 1.
- ▶ Cada factor primo de m divide a $a - 1$.
- ▶ Si 4 divide a m , entonces 4 divide a $a - 1$.

Si $c = 0$ y m es un número primo, el mayor periodo posible es $m - 1$. Esto ocurre cuando $a^k - 1$ no es divisible por m para $k = 1, 2, \dots, m - 2$. Un generador basado en congruencias lineales que cumple estas propiedades es

$$X_{n+1} = 16807X_n \bmod (2^{31} - 1), \quad n = 0, 1, 2, \dots,$$

es decir, $a = 7^5$, $c = 0$, $m = 2^{31} = 2147483647$. La longitud del ciclo para este generador es $m - 1$.

Muestreo de una variable aleatoria normal

Hasta aquí hemos definido un método para poder simular VAs a partir de la inversa de su función de distribución de probabilidad. Sin embargo, como ya se ha mencionado al principio de esta sección, obtener la inversa de una función de distribución o incluso la propia función de distribución no siempre es posible. El ejemplo más común en estos casos es el muestreo en una variable aleatoria normal. Se sabe que la función de densidad de probabilidad de una VA normal es integrable pero no existe una expresión analítica de su primitiva, y consecuentemente tampoco se conoce una

expresión explícita de su función de distribución. A continuación, mostramos cómo aproximar la inversa de la función de distribución de una VA Gaussiana. Utilizando el método inverso, se pueden obtener simulaciones de ella.

Sea $X \sim N(\mu, \sigma^2) = \mu + \sigma N(0, 1)$ una VA normal. La función de densidad de probabilidad de una VA $N(0, 1)$ viene dada por

$$f_X(x) = \frac{1}{\sqrt{2\pi}} e^{-\frac{x^2}{2}}, \quad -\infty < x < \infty,$$

la función de distribución se puede calcular a través de la siguiente integral

$$F_X(x) = \frac{1}{\sqrt{2\pi}} \int_{-\infty}^x e^{-\frac{y^2}{2}} dy, \quad -\infty < x < \infty.$$

Como no existe una expresión explícita de la función de distribución se han desarrollado métodos para aproximar la inversa de la función de distribución. Por ejemplo, si definimos $y = \sqrt{-2 \log(1 - u)}$, entonces para $u \sim U([0, 0.5])$, se tiene

$$F_X^{-1}(u) \approx \frac{p_0 + p_1 y + p_2 y^2 + p_3 y^3 + p_4 y^4}{q_0 + q_1 y + q_2 y^2 + q_3 y^3 + q_4 y^4},$$

siendo

$$\begin{array}{ll} p_0 = -0.322232431088, & q_0 = 0.099348462606, \\ p_1 = -1, & q_1 = 0.588581570495, \\ p_2 = -0.342242088547, & q_2 = 0.531103462366, \\ p_3 = -0.0204231210245, & q_3 = 0.10353775285, \\ p_4 = -0.0000453642210148, & q_4 = 0.0038560700634. \end{array}$$

Para poder utilizar el método inverso necesitaríamos poder muestrear también en una $U([0, 1])$ y nuestra aproximación solo está definida para valores $0 \leq u \leq 0.5$. Dado que toda VA gaussiana es simétrica, sería suficiente con muestrear para $u \in U([0, 0.5])$ y proyectar para $u \in U([0.5, 1])$.

Muestreo de una variable aleatoria Poisson

Finalizamos esta sección describiendo un método para muestrear en una distribución de probabilidad discreta: una distribución Poisson.

Supongamos que $X \sim \text{Po}(\lambda)$ con $\lambda > 0$. Para ello, construiremos una sucesión $\{Y_n\}$ distribuida según una VA Poisson de parámetro λ ($\mathbb{E}[Y_n] = \lambda$). Asumimos que disponemos de una sucesión $\{U_n\}$ de números aleatorios distribuidos uniformemente en el intervalo $[0, 1]$ (como se ha visto en el método de congruencias lineales). La función de distribución viene dada por

$$F_{Y_n}(y) = \mathbb{P}[Y_n \leq y] = \sum_{\substack{i=1 \\ y_i \leq y}}^{\infty} \mathbb{P}(Y_n = y_i) = e^{-\lambda} \sum_{i=0}^m \frac{\lambda^k}{k!}, \quad m \leq y < m+1.$$

Por tanto para determinar Y_n dado U_n , la suma calculada hasta m se determina del siguiente modo

$$e^{-\lambda} \sum_{k=0}^{m-1} \frac{\lambda^k}{k!} < U_n \leq e^{-\lambda} \sum_{k=0}^m \frac{\lambda^k}{k!}, \quad U_n \sim U([0, 1]).$$

Si definimos $Y_n = m$ tendríamos un muestreo de la VA $X \sim \text{Po}(\lambda)$.

4.3 Resolución numérica de ecuaciones diferenciales aleatorias utilizando el método de Monte Carlo

Una vez hemos explicado diferentes métodos para muestrear en VA procedemos a describir una técnica de simulación para aproximar la solución de una ecuación diferencial aleatoria (EDA).

En primer lugar, debemos conocer qué se entiende por EDA. Básicamente es una ecuación diferencial donde los elementos que la componen, parámetros y funciones, son VAs o PEs. La solución de una EDA viene dada por un PE. El tema siguiente está dedicado a definir las bases y los fundamentos de este concepto.

Para describir el MMC y aproximar la solución de EDAs lo haremos sobre un ejemplo. Consideramos el siguiente problema de valores iniciales (PVI) determinista

$$\begin{aligned} X'(t) &= -aX(t), \\ X(0) &= b, \end{aligned} \tag{4}$$

siendo a y $b \in \mathbb{R}$. Si aleatorizamos este PVI, obtenemos el siguiente problema de valores iniciales aleatorio (PVIA)

$$\begin{aligned} X'(t) &= -AX(t), \\ X(0) &= B, \end{aligned} \tag{5}$$

siendo A y B VAs que asumiremos independientes y con función de densidad de probabilidad conjunta $f_{A,B}$ y función de distribución conjunta $F_{A,B}$.

La resolución de una ecuación diferencial en el ámbito aleatorio tiene un sentido más amplio que en el determinista. Mientras que en las ecuaciones diferenciales no aleatorias, la solución viene dada por una función, en el ámbito aleatorio viene dado por un PE. Como hemos mencionado en el tema anterior, dado un PE, $X(t)$, podemos obtener su media, $\mu_X(t)$, su varianza, $\sigma_X^2(t)$, su covarianza, $\mathbb{C}ov_X(t_1, t_2)$, su primera función de densidad de probabilidad, $f_X(x, t)$, etc. Todos estos elementos nos permiten tener una descripción estadística completa de la solución del PVIA. Si el PVIA describe un fenómeno real, a través de su solución PE, podremos obtener información estadística sobre el proceso que se pretende estudiar. Sin embargo, no siempre es posible obtener el PE solución.

Con esta idea en mente, en los siguientes pasos nos centramos en utilizar el MMC

para aproximar el PE solución de un PVIA. Vamos a describir el MMC para aproximar la solución del PVIA (5). El procedimiento para aproximar cualquier otro es análogo.

Método de Monte Carlo para aproximar la solución PE de un problema de valores iniciales

- A partir de la función de distribución conjunta, $F_{A,B}$ y utilizando métodos de simulación de VAs, como el que se ha explicado la sección anterior, generamos M simulaciones independientemente e idénticamente distribuidas. Denotamos

$$Z^{(i)} = (a^i, b^i), \quad i = 1, 2, \dots, M,$$

a cada una de ellas.

- Para cada uno de los muestreos, $i = 1, 2, \dots, M$, resolvemos cada uno de los PVI deterministas

$$\begin{aligned} (X^{(i)})(t) &= -a^{(i)} X^{(i)}(t), \\ X^{(i)}(0) &= b^{(i)}. \end{aligned} \tag{6}$$

La solución vendrá dada por $X^{(i)}(t) = X(t, Z^{(i)})$. Dado que $Z^{(i)}$ son simulaciones independientes e idénticamente distribuidas, $X(t, Z^{(i)})$, $1 \leq i \leq M$ también lo serán.

- A partir de $X(t, Z^{(i)})$, $i = 1, 2, \dots, M$, podemos obtener información estadística aproximada del PE solución, como la media del PE, $\mathbb{E}[X(t)]$, a través de la media muestral

$$\bar{X}_M(t) = \frac{1}{M} \sum_{i=1}^M X(t, Z^{(i)}) \approx \mathbb{E}[X(t)], \tag{7}$$

o la varianza, $\mathbb{V}[X(t)]$, a través de la varianza muestral,

$$\sigma^2[X_M(t)] = \frac{1}{M} \sum_{i=1}^M (X(t, Z^{(i)}) - \bar{X}_M(t))^2 \approx \mathbb{V}[X(t)].$$

A continuación mostramos un ejemplo donde se ilustra la aproximación de la solución del PVIA (5) considerando solamente aleatoriedad en la condición inicial. Dado que la

solución exacta de este PVIA es conocida, compararemos aproximaciones de la media y de la varianza obtenidas a través MMC con la exacta.

Ejemplo 2.

Consideramos el PVIA dado por la expresión (5). Sea $A = 1$ y $B \sim U([0, 1])$. Muestreamos $M = 20$ en la VA B y resolvemos cada PVI. En la Figura 1 ilustramos cada una de las soluciones deterministas para cada uno de los muestreos.




Figura 1: Trayectorias deterministas del PVIA para cada una de las simulaciones en el contexto del Ejemplo 2

Veamos cómo aproxima la media el MMC. Sabemos que la solución PE del PVI (5) con $A = 1$ y $B \sim U([0, 1])$ viene dado por $X(t) = Be^{-t}$, aplicando propiedades del operador media

$$\mathbb{E}[X(t)] = \mathbb{E}[Be^{-t}] = \mathbb{E}[B]e^{-t} = \frac{1}{2}e^{-t}. \quad (8)$$

La Tabla 1 muestra aproximaciones de la media utilizando diferentes M . Cómo vemos, conforme M aumenta estas aproximaciones convergen a la media exacta que hemos descrito en la expresión (8).

La expresión exacta de la varianza viene dada por $\sigma_X^2(t) = \mathbb{V}[X(t)] = \frac{e^{-2t}}{12}$, por tanto la desviación típica $\sigma_X(t) = \frac{1}{2\sqrt{3}}e^{-t}$.

La Tabla 2 muestra aproximaciones de la desviación típica utilizando diferentes M . De igual modo que con la media, vemos que efectivamente que conforme M aumenta las aproximaciones convergen a la desviación típica exacta. Obsérvese que las aproximaciones no son monótonas ni para la media ni para la desviación típica.

$M = 20$	$M = 50$	$M = 100$	$M = 1000$
$0.534086e^{-t}$	$0.487041e^{-t}$	$0.520565e^{-t}$	$0.484646e^{-t}$

Tabla 1: Aproximaciones de la media en el contexto del Ejemplo 2 para distintos M .

$M = 20$	$M = 50$	$M = 100$	$M = 1000$
$0.280843e^{-t}$	$0.303476e^{-t}$	$0.307459e^{-t}$	$0.285814e^{-t}$

Tabla 2: Aproximaciones de la desviación típica en el contexto del Ejemplo 2 para distintos M .

Una vez hemos comprobado con un ejemplo que el MMC es efectivo para aproximar la media y la varianza de un PE solución sería interesante poder cuantificar la calidad de estas aproximaciones. En el siguiente apartado mostraremos un resultado muy conocido en probabilidad que nos va a permitir poder cuantificar cómo de buenas son las aproximaciones realizadas por MMC.

A continuación, se muestra una píldora audiovisual en el que se explica en Matemática cómo obtener una solución aproximada del PE solución de una EDA utilizando el MMC.



Accede al vídeo: Resolución con Mathematica de una EDA utilizando el MMC

Calidad de las aproximaciones

Teorema 1: Teorema central del límite

Sean $X_1, X_2, \dots, X_M$ VAs independientes e idénticamente distribuidas con $\mathbb{E}[X_i] = \mu$ y $\mathbb{V}[X_i] = \sigma^2 < \infty$. Definimos

$$\bar{X}_M(t) = \frac{1}{M} \sum_{i=1}^M X_i, \quad U_M = \sqrt{M} \left(\frac{\bar{X}_M(t) - \mu}{\sigma} \right).$$

Entonces, la función de distribución U_M converge a $\mathbf{N}(0; 1)$, es decir

$$U_M \xrightarrow[M \rightarrow \infty]{d} Z, \quad Z \sim \mathbf{N}(0; 1),$$

donde $\xrightarrow[M \rightarrow \infty]{d}$ indica la convergencia en distribución.

Obsérvese que del Teorema 1 se tiene que

$$\bar{X}_M(t) = \frac{\sigma (U_M + \mu)}{\sqrt{M}} \xrightarrow[M \rightarrow \infty]{d} \mathbf{N} \left(\mu; \frac{\sigma^2}{M} \right).$$

Como hemos mencionado en el segundo paso del MMC para aproximar PVIA, las distintas soluciones $X^{(i)}(t, Z^{(i)})$, $M \geq 0$ son independientes e idénticamente distribuidas con media $\mathbb{E}[X(t)]$ y varianza $\mathbb{V}[X(t)]$. Si nos fijamos en (7) y aplicando el Teorema 1, tenemos que la media de todas las simulaciones realizadas por MMC converge a la media del PE solución, es decir

$$\bar{X}_M(t) = \frac{1}{M} \sum_{i=1}^M X^{(i)}(t, Z^{(i)}) \xrightarrow[M \rightarrow \infty]{d} \mathbf{N} \left(\mathbb{E}[X(t)]; \frac{\mathbb{V}[X(t)]}{M} \right).$$

Por tanto podemos decir que el ratio de convergencia, $\mathcal{O}$, del MMC para aproximar la media del PE solución viene dada por $\mathcal{O}(\frac{1}{\sqrt{M}})$. La convergencia es lenta, sin embargo el MMC es muy utilizado debido a su simplicidad. Además es importante subrayar que la tasa de convergencia es independiente de la cantidad total de elementos aleatorios

que componen el PVIA.

4.4 Referencias bibliográficas

Devroye, L. (2006). Nonuniform random variate generation. *Handbooks in operations research and management science*, 13:83–121.

Kroese, D. P., Taimre, T., and Botev, Z. I. (2013). *Handbook of monte carlo methods*, volume 706. John Wiley & Sons.

Ross, S. M. (1990). *A course in simulation*. Number 04; QA273, R6.

4.5 Cuaderno de ejercicios

Ejercicio 1. Consideramos el siguiente PVIA

$$\begin{aligned}X'(t) &= -AX^2(t), \\X(0) &= X_0,\end{aligned}\tag{9}$$

donde $t > 0$, $a > 0$ y $X_0 \sim \text{Exp}(1)$. Se pide lo siguiente:

1. Calcula el PE solución analíticamente.
2. Calcula la media y varianza del PE obtenido en el apartado anterior.
3. Aplicar el método de Monte Carlo para aproximar la media y la varianza de la solución PE del siguiente PVIA utilizando $M = 10^2$ y $M = 10^4$ simulaciones.

Solución: Para resolver este ejercicio utilizaremos *Mathematica*

1. Para calcular la solución escribimos el siguiente comando

```
eqs = {X'[t] == -a*X[t]^2, X[0] == X0};  
sol = DSolve[eqs, X[t], t];
```

La solución del problema (9) viene dado por

$$X(t) = \frac{X_0}{1 + AX_0 t}.$$

2. Para calcular la media del PE solución utilizamos el siguiente comando

```
Xt = X[t]/.sol;  
lambda =1;  
EXt = Integrate[Xt*lambda*E^(-lambda*X0),{X0,0,\[Infinity]},  
Assumptions -> {t \[Element] Reals, t>0}];
```

Para calcular la varianza, dado que $\mathbb{V}[X(t)] = \mathbb{E}[X(t)^2] - \mathbb{E}[X(t)]^2$, escribimos el siguiente comando

```
VXt = Integrate[(Xt - EXt)^2*lambda*E^(-lambda*X0),  
{X0,0,\[Infinity]}, Assumptions -> {t \[Element] Reals, t>0}];
```

3. En primer lugar generamos $M = 10^2$ y $M = 10^4$ simulaciones del PE solución. El comando es el siguiente.

```
M1 = 100;  
M2 = 200;  
  
ExpRV = ExponentialDistribution[lambda];  
XMC1 = Xt /. {X0 -> RandomVariate[ExpRV, M1], a -> a};  
XMC2 = Xt /. {X0 -> RandomVariate[ExpRV, M2], a -> a};
```

A continuación calculamos la media y la varianza del PE solución a través de estas simulaciones.

```
XMC1mean = Mean[Mean[XMC1]];  
XMC1var = Mean[Mean[(XMC1 - XMC1mean)^2]];  
XMC2mean = Mean[Mean[XMC2]];  
XMC2var = Mean[Mean[(XMC2 - XMC2mean)^2]];
```

Una vez hemos obtenido aproximaciones por MC las comparamos gráficamente con las obtenidas en el apartado 2. El comando para comparar las medias es el siguiente:

```
pe1 = Plot[XMC1mean, {t,0.01,10}, AxesOrigin->{0,0},
PlotLegends->LineLegend[{Red}, {"E[X(t)] Monte Carlo (M1)"}],
PlotStyle->Red];
pe2 = Plot[XMC2mean, {t,0.01,10}, AxesOrigin->{0,0},
PlotLegends->LineLegend[{Black}, {"E[X(t)] Monte Carlo (M2)"}],
PlotStyle->Black];
pe = Plot[EXt,{t,0.01,10}, AxesOrigin->{0,0},
PlotLegends->LineLegend[{Blue}, {"E[X(t)] exacto"}],
PlotStyle->Blue];
Show[pe1,pe2,pe, PlotLabel -> "Valor esperado exacto vs.
aproximado por Monte Carlo", AxesLabel->{t, "E[X(t)]"}]
```

El comando para comparar las varianzas es el siguiente:

```
pv1 = Plot[XMC1var,{t,0.01,10}, AxesOrigin->{0,0},
PlotLegends->LineLegend[{Red}, {"V[X(t)] Monte Carlo (M1)"}],
PlotStyle->Red];
pv2 = Plot[XMC2var,{t,0.01,10}, AxesOrigin->{0,0},
PlotLegends->LineLegend[{Black}, {"V[X(t)] Monte Carlo (M2)"}],
PlotStyle->Black];
pv = Plot[VXt,{t,0.01,10}, AxesOrigin->{0,0},
PlotLegends->LineLegend[{Blue}, {"V[X(t)] exacta"}],
PlotStyle->Blue];
Show[pv1,pv2,pv, PlotLabel -> "Varianza exacta vs.
aproximada por Monte Carlo", AxesLabel->{t, "V[X(t)]"}]
```

Ejercicio 2. Consideremos el siguiente PVIA

$$\begin{aligned}y'(t) &= ay(t) + b, \\ y(t_0) &= y_0.\end{aligned}\tag{10}$$

Simular en Mathematica la solución para distintos instantes de tiempo t considerando que

► $t_0 = 0, y_0 = 2, a \sim \text{Exp}(5)$ y $b \sim U(0, 1)$.

Solución: En el siguiente video se muestra la resolución en Mathematica