


Ecuaciones Diferenciales Estocásticas

Modelización de problemas reales mediante Ecuaciones Diferenciales aleatorias (EDAs)

Índice

Esquema.	2
Ideas clave	3
7.1 Introducción y objetivos	3
7.2 Descripción del modelo SIS	4
7.3 Solución del modelo SIS y obtención de la primera función de densidad de probabilidad	7
7.4 Expresiones para la media y la varianza e intervalos de confianza	9
7.5 Distribución estadística del tiempo para que se alcance un porcentaje dado de susceptibles	11
7.6 Número básico de reproducción o R_0	12
7.7 Ajuste paramétrico para la representación de datos reales	14
7.8 Resultados numéricos	17
7.9 Referencias bibliográficas	18

Esquema



7.1 Introducción y objetivos

Las ecuaciones diferenciales aleatorias son una potente herramienta en la modelización matemática, ya que, permiten describir comportamientos y fenómenos reales teniendo en cuenta la incertidumbre presente en la recogida de información (muestras, errores, etc.). Por ejemplo, a la hora de estudiar un comportamiento social, como por ejemplo el hábito de fumar, los resultados pueden estar afectados según la muestra que se considere. Cuanto menor sea esa muestra más probable es que represente peor la sociedad y por tanto, más inciertos pueden ser los resultados obtenidos. Cuanto mayor sea la muestra, mejor representará el comportamiento de la sociedad, pero más difícil será trabajar con la misma.

El objetivo de este tema es combinar todos los conceptos que se han estudiado en temas anteriores acerca de ecuaciones diferenciales aleatorias para modelar un problema real: el consumo de tabaco en la sociedad.

En primer lugar, presentaremos y estudiaremos un modelo conocido en epidemiología, el modelo SIS. Este modelo viene descrito a través de una EDA. A continuación, obtendremos su solución y calcularemos la primera función de densidad de probabilidad utilizando el MTV explicado en el Tema 6. Seguidamente, obtendremos expresiones para la media y la varianza de la solución PE utilizando la 1-FPD.

En epidemiología, hay dos conceptos que suelen ser interesantes a la hora de estudiar una enfermedad. El primero es conocer el instante de tiempo en el que cierta enfermedad alcanza una cantidad o porcentaje dado de personas infectadas. El segundo es conocer el número de reproducción básica R_0 (que tanto hemos oído hablar última-

mente con la Covid-19). Este valor representa el número de infectados secundarios por un infectado. Durante este tema también se estudiará cómo calcularlo.

Una vez ya se han descrito los aspectos más importantes del modelo SIS, lo aplicaremos para modelizar el consumo de tabaco en España durante los años 1987 a 2006. Estos datos son recogidos a través de encuestas y se considerarán que tienen incertidumbre intrínseca. Se obtendrán los parámetros del modelo que describen los datos dados y se mostrará una representación gráfica de los resultados obtenidos.

Los objetivos que trataremos de alcanzar en este tema serán los siguientes:

- ▶ Presentación del modelo SIS.
- ▶ Obtención de la solución PE y cálculo de su primera función de densidad de probabilidad.
- ▶ Cálculo de momentos de la solución.
- ▶ Cálculo de la FDP de la VA del tiempo
- ▶ Obtención del número de reproducción básica.
- ▶ Aplicación a datos reales para modelar el consumo de tabaco en España.

7.2 Descripción del modelo SIS

Los modelos epidemiológicos tipo SIS constituyen representaciones matemáticas que permiten describir la propagación de enfermedades contagiosas a través del contacto entre individuos (Hethcote, 2000; Brauer and Castillo-Chávez, 2001). Los modelos SIS son útiles para modelar enfermedades cuya infección no le otorga inmunidad al individuo. Esto quiere decir que un individuo susceptible (S) que ha sido infectado (I) puede recuperarse de la enfermedad y volver a ser susceptible (S) de contraer la enfermedad otra vez. Esto se suele representar como $S \rightarrow I \rightarrow S$ (Susceptible-Infectado-

Susceptible). Existen muchas enfermedades que se pueden describir con un modelo tipo SIS incluyendo la gonorrea, meningitis, etc. (Castillo-Chávez et al., 1996; Hethcote and Yorke, 1984; Hethcote, 1989). Los modelos epidemiológicos tipo SIS también se suelen utilizar para modelizar la dinámica de estilos de vida no saludables como el sobrepeso (Cortés et al., 2012) o el consumo de tabaco (Casabán et al., 2016). A pesar de su simplicidad matemática los modelos SIS constituyen la base de modelos más sofisticados donde se consideran otros factores como la inmunidad, vacunación, factores ambientales y culturales, etc.

Los modelos SIS son formulados como problemas de valores iniciales basados en sistemas no lineales de ecuaciones diferenciales de la forma

$$\begin{cases} S'(t) = -\beta S(t)I(t) + \gamma I(t), \\ I'(t) = \beta S(t)I(t) - \gamma I(t), \end{cases} \quad t > 0, \quad (1)$$

cuyas condiciones iniciales son

$$S(0) = S_0, \quad I(0) = I_0. \quad (2)$$

$S(t)$ y $I(t)$ denotan la proporción, o equivalentemente el porcentaje, de los susceptibles e infectados en el instante de tiempo t , respectivamente. En el instante inicial, $t = 0$, estos valores corresponden con S_0 y I_0 , respectivamente. Asumimos que

$$S(t) + I(t) = 1, \quad \forall t \geq 0, \quad (3)$$

esto significa que todos los individuos de la población son clasificados en susceptibles o infectados. Los parámetros $\beta > 0$ y $\gamma > 0$ denotan la tasa de infección y la tasa de recuperación de la enfermedad, respectivamente. En la Figura 1, se muestra un diagrama del modelo SIS.

Parece lógico considerar en un modelo poblacional los nacimientos y las muertes de los individuos. El comportamiento del consumo del tabaco, que es lo que se pretende estudiar, es muy similar tanto si se considera la demografía como si no (Hethcote, 1989). Esto motiva el considerar el modelo en su versión simple (sin demografía)

(1)–(3).




Figura 1: Representación del modelo SIS con un diagrama de cajas (1)–(2).

Desde un punto de vista práctico, dada la incertidumbre que está involucrada en la representación física de los parámetros del modelo, S_0 , γ y β , parece más realista considerarlos como variables aleatorias en vez que valores deterministas. La condición inicial representa el porcentaje de susceptibles en el instante inicial. En la práctica, este valor se obtiene después de muestrear en la población a estudiar, y por tanto, tiene cierta variabilidad que debe ser considerada. Como S_0 representa un porcentaje, está entre 0 y 1, por tanto podría ser modelado por una VA uniforme en el intervalo $(0, 1)$ o una VA beta, que es más flexible y generaliza la uniforme. Respecto a los parámetros γ y β sabemos que son tasas, y por tanto son positivos. Estos parámetros están relacionados con las tasas de recuperación y de contagio de la enfermedad, respectivamente. Es importante remarcar que en la práctica estos valores no se saben de forma cierta. Esto motiva tratarlos como VAs con sus distribuciones de probabilidad y con soporte positivo, como exponenciales, gamma o gaussianas truncadas en un dominio positivo. Como se verá en las siguientes secciones, estos tipos de distribuciones de probabilidad serán asumidas cuando describamos datos reales con el modelo SIS.

En la literatura además del modelo SIS, existen otro tipo de modelos compartimentales. En el siguiente video hacemos un resumen de los más utilizados.



Accede al vídeo: Modelos compartimentales más conocidos

7.3 Solución del modelo SIS y obtención de la primera función de densidad de probabilidad

El objetivo de esta sección es determinar la solución del modelo SIS (1)–(3) y su primera función de densidad de probabilidad. Para ello se calculará para un tiempo t fijo la 1-PDF de cada una de las variables $S(t)$ y $I(t)$.

Se sabe que $S(t) + I(t) = 1$, por tanto se puede reescribir (1)–(2) como el siguiente problema de valores iniciales PVI

$$\begin{cases} S'(t) = \beta(S(t))^2 - (\gamma + \beta)S(t) + \gamma, & t > 0, \\ S(0) = S_0. \end{cases} \quad (4)$$

Como se ha dicho anteriormente consideramos que los parámetros del modelo S_0, γ y β son VAs, siendo

$$\begin{aligned} \mathcal{D}_{S_0} &= \{s_0 = S_0(\omega), \omega \in \Omega : 0 \leq s_{0,1} \leq s_0 \leq s_{0,2} \leq 1\}, \\ \mathcal{D}_\gamma &= \{\gamma = \gamma(\omega), \omega \in \Omega : 0 \leq \gamma_1 \leq \gamma \leq \gamma_2\}, \\ \mathcal{D}_\beta &= \{\beta = \beta(\omega), \omega \in \Omega : 0 \leq \beta_1 \leq \beta \leq \beta_2\}, \end{aligned} \quad (5)$$

los dominios respectivos. La función de densidad de probabilidad conjunta del vector aleatorio formado por los parámetros del modelo (S_0, γ, β) será denotada mediante $f_{S_0, \gamma, \beta}(s_0, \gamma, \beta)$. Es importante mencionar que en la parte donde se aplique el modelo a datos reales, los parámetros son considerados VAs independientes, por tanto $f_{S_0, \gamma, \beta}(s_0, \gamma, \beta) = f_{S_0}(s_0)f_\gamma(\gamma)f_\beta(\beta)$. Sin embargo, para realizar el estudio teórico más general consideraremos la FPD conjunta $f_{S_0, \gamma, \beta}(s_0, \gamma, \beta)$.

El PE solución del problema (4) viene dado por

$$S(t) = \frac{\gamma(1 - S_0) + (S_0\beta - \gamma)e^{(\gamma - \beta)t}}{\beta(1 - S_0) + (S_0\beta - \gamma)e^{(\gamma - \beta)t}}, \quad t \geq 0. \quad (6)$$

La obtención de la 1-FDP, $f_1(s, t)$, del PE solución, $S(t)$, del PVI aleatorio (4) nos permite tener una descripción probabilística completa del porcentaje de susceptible en cada instante de tiempo t . Una vez se obtenga una expresión cerrada de la 1-FDP de $S(t)$, como $S(t) + I(t) = 1$ podremos obtener también la 1-FPD de $I(t)$.

Fijamos $t \geq 0$, y aplicamos el método de transformación de variables explicado en el Tema 6 con la siguiente indentificación

$$\mathbf{U} = (S_0, \gamma, \beta), \quad \mathbf{V} = (X, Y, Z), \quad \mathbf{V} = \mathbf{r}(\mathbf{U}),$$

$$\mathbf{r}: \mathbb{R}^3 \rightarrow \mathbb{R}^3, \quad \mathbf{r}(S_0, \gamma, \beta) = (r_1(S_0, \gamma, \beta), r_2(S_0, \gamma, \beta), r_3(S_0, \gamma, \beta))^T = (X, Y, Z)^T,$$

siendo

$$X = \frac{\gamma(1 - S_0) + (S_0\beta - \gamma)e^{(\gamma-\beta)t}}{\beta(1 - S_0) + (S_0\beta - \gamma)e^{(\gamma-\beta)t}}, \quad Y = \gamma, \quad Z = \beta.$$

Despejando S_0 , β y γ , se tiene que

$$S_0 = \frac{Y + e^{(Y-Z)t}(-1 + X)Y - XZ}{Y + e^{(Y-Z)t}(-1 + X)Z - XZ}, \quad \gamma = Y, \quad \beta = Z. \quad (7)$$

Aplicando el método de transformación de vectores aleatorios la 1-FDP conjunta del vector aleatorio (X, Y, Z) viene dada por

$$f_{X,Y,Z}(x, y, z) = f_{S_0,\gamma,\beta} \left(\frac{y + e^{(y-z)t}(-1 + x)y - xz}{y + e^{(y-z)t}(-1 + x)z - xz}, y, z \right) \frac{e^{(y-z)t}(y - z)^2}{(y + e^{(y-z)t}(-1 + x)z - xz)^2}, \quad (8)$$

donde $J = (e^{(y-z)t}(y - z)^2) / (y + e^{(y-z)t}(-1 + x)z - xz)^2 > 0$ es el jacobiano de $\mathbf{s} = \mathbf{r}^{-1}$,

$$\mathbf{s}: \mathbb{R}^3 \rightarrow \mathbb{R}^3, \quad \mathbf{s}(X, Y, Z) = (s_1(X, Y, Z), s_2(X, Y, Z), s_3(X, Y, Z)) = (S_0, \gamma, \beta).$$

Por tanto la 1-FDP de la VA $S = S(t)$, para t fijo, es la marginal respecto de (γ, β) de la FDP conjunta (8), es decir,

$$f_S(s) = \int_{\mathcal{D}_\gamma} \int_{\mathcal{D}_\beta} f_{S_0,\gamma,\beta} \left(\frac{\xi + e^{(\xi-\eta)t}(-1 + s)\xi - s\eta}{\xi + e^{(\xi-\eta)t}(-1 + s)\eta - s\eta}, \xi, \eta \right) \frac{e^{(\xi-\eta)t}(\xi - \eta)^2}{(\xi + e^{(\xi-\eta)t}(-1 + s)\eta - s\eta)^2} d\eta d\xi. \quad (9)$$

Como este desarrollo es válido para cada uno de los $t \geq 0$, la 1-FDP de la solución $S(t)$ del PVI (4) viene dado por

$$f_1(s, t) = \int_{\mathcal{D}_\gamma} \int_{\mathcal{D}_\beta} f_{S_0, \gamma, \beta} \left(\frac{\xi + e^{(\xi-\eta)t}(-1+s)\xi - s\eta}{\xi + e^{(\xi-\eta)t}(-1+s)\eta - s\eta}, \xi, \eta \right) \frac{e^{(\xi-\eta)t}(\xi - \eta)^2}{(\xi + e^{(\xi-\eta)t}(-1+s)\eta - s\eta)^2} d\eta d\xi. \quad (10)$$

Denotando por $S = S(t)$ y $I = I(t)$ para t fijo, sabiendo que $S(t) + I(t) = 1$ y utilizando el método de transformación de variables aleatorias descrito en el Tema 1 (que es una generalización del descrito en el Tema 6) se puede obtener la FDP de la VA $I = I(t)$, t fijo,

$$I(t) = \frac{(\beta - \gamma)(1 - S_0)e^{(\beta-\gamma)t}}{\beta(1 - S_0)e^{(\beta-\gamma)t} + S_0\beta - \gamma}, \quad t \geq 0, \quad (11)$$

que viene dada por

$$f_1(i, t) = \int_{\mathcal{D}_\gamma} \int_{\mathcal{D}_\beta} f_{S_0, \gamma, \beta} \left(\frac{\xi - \eta - e^{(\xi-\eta)t}i\xi + i\eta}{\xi - \eta - e^{(\xi-\eta)t}i\eta + i\eta}, \xi, \eta \right) \frac{e^{(\xi-\eta)t}(\xi - \eta)^2}{(\xi - \eta - e^{(\xi-\eta)t}i\eta + i\eta)^2} d\eta d\xi. \quad (12)$$

7.4 Expresiones para la media y la varianza e intervalos de confianza

Como se ha mencionado en el Tema 6, conocer la 1-FDP del PE solución nos permite obtener una descripción completa probabilística del PE solución. A partir de la 1-FDP se puede calcular información estadística asociada a la solución $(S(t), I(t))^T$. En concreto en esta sección calcularemos la media y la varianza de $S(t)$. Sabemos que vienen definidas por

$$\mu_S(t) = \mathbb{E}[S(t)] = \int_{-\infty}^{\infty} s f_1(s, t) ds, \quad (\sigma_S(t))^2 = \mathbb{V}[S(t)] = \int_{-\infty}^{\infty} s^2 f_1(s, t) ds - (\mu_S(t))^2, \quad (13)$$

donde $f_1(s, t)$ ha sido obtenida anteriormente en (10). Para calcular la media de $I(t)$, $\mu_I(t)$, se puede hacer lo mismo pero cambiando $f_1(s, t)$ por $f_1(i, t)$, que ha sido ob-

tenida en (12).

Además de calcular el comportamiento medio del PE del modelo SIS y su variabilidad, para $\hat{t} \geq 0$ fijo, podríamos estar interesados en determinar la probabilidad de que el porcentaje de susceptibles esté dentro de un intervalo específico, denotado como, $[s_1(\hat{t}), s_2(\hat{t})] = [\hat{s}_1, \hat{s}_2]$. Esto se puede calcular fácilmente a partir de $f_1(s, t)$ a través de la siguiente integral

$$\mathbb{P} [\{\omega \in \Omega : S(\hat{t}; \omega) \in [\hat{s}_1, \hat{s}_2]\}] = \int_{\hat{s}_1}^{\hat{s}_2} f_1(s, \hat{t}) \, ds. \quad (14)$$

En cuanto a la validación y predicción del modelo, la 1-FDP, es también muy útil a la hora de construir intervalos para cualquier $(1 - \alpha) \times 100\%$ nivel de confianza. Por ejemplo, para un $\alpha \in (0, 1)$ fijo y para cada $\hat{t} \geq 0$ fijo se puede determinar $s_1(\hat{t})$ y $s_2(\hat{t})$ de modo que

$$\int_0^{s_1(\hat{t})} f_1(s, \hat{t}) \, ds = \frac{\alpha}{2} = \int_{s_2(\hat{t})}^1 f_1(s, \hat{t}) \, ds, \quad (15)$$

donde

$$1 - \alpha = \mathbb{P} [\{\omega \in \Omega : S(\hat{t}; \omega) \in [s_1(\hat{t}), s_2(\hat{t})]\}] = \int_{s_1(\hat{t})}^{s_2(\hat{t})} f_1(s, \hat{t}) \, ds. \quad (16)$$

En general, se suele considerar que $\alpha = 0.05$, lo que implica la construcción del intervalo de confianza al 95 %

Notar que con las expresiones análogas para (14)–(16) se pueden calcular el porcentaje de infectados cambiando $f_1(s, \hat{t})$ por $f_1(i, \hat{t})$, (definida en (12)).

7.5 Distribución estadística del tiempo para que se alcance un porcentaje dado de susceptibles

Hasta ahora, se ha calculado la distribución estadística del porcentaje de susceptibles (e infectados) en cada instante de tiempo t . Desde un punto de vista aplicado, es bastante útil conocer cuándo se alcanza un nivel dado de susceptibles. Con este fin, denotamos por T_S el tiempo en el que una proporción de la población ρ_S , sea susceptible, es decir, $\rho_S = S(T)$. Despejando T_S de la solución (6) del PVI (4) se tiene

$$T_S = \frac{1}{\gamma - \beta} \ln \left(\frac{(1 - S_0)(\beta \rho_S - \gamma)}{(1 - \rho_S)(\beta S_0 - \gamma)} \right).$$

A continuación, aplicamos el teorema de transformación de vectores aleatorios descrito en el Tema 6 a

$$\mathbf{U} = (S_0, \gamma, \beta), \quad \mathbf{V} = (X, Y, Z), \quad \mathbf{V} = \mathbf{r}(\mathbf{U}),$$

con

$$\mathbf{r}: \mathbb{R}^3 \rightarrow \mathbb{R}^3, \quad \mathbf{r}(S_0, \gamma, \beta) = (r_1(S_0, \gamma, \beta), r_2(S_0, \gamma, \beta), r_3(S_0, \gamma, \beta)) = (X, Y, Z),$$

donde

$$X = \frac{1}{\gamma - \beta} \ln \left(\frac{(1 - S_0)(\beta \rho_S - \gamma)}{(1 - \rho_S)(\beta S_0 - \gamma)} \right), \quad Y = \gamma, \quad Z = \beta.$$

Despejando S_0 , γ y β , se tiene que

$$S_0 = \frac{Y(1 + e^{X(Y-Z)}(-1 + \rho_S)) - Z\rho_S}{Y + Z(e^{X(Y-Z)}(-1 + \rho_S) - \rho_S)}, \quad \gamma = Y, \quad \beta = Z. \quad (17)$$

Considerando que $\rho_S \in (0, 1)$, aplicando el teorema de transformación de vectores aleatorios, la FDP de (X, Y, Z) viene dada por

$$f_{X,Y,Z}(x, y, z) = f_{S_0, \gamma, \beta} \left(\frac{y(1 + e^{x(y-z)}(-1 + \rho_S)) - z\rho_S}{y + z(e^{x(y-z)}(-1 + \rho_S) - \rho_S)}, y, z \right) \cdot \frac{e^{x(y-z)}(y-z)^2(1 - \rho_S)}{(y + z(e^{x(y-z)}(-1 + \rho_S) - \rho_S))^2} |y - z\rho_S|, \quad (18)$$

donde $J = (e^{x(y-z)}(y-z)^2(-1 + \rho_S)(y - z\rho_S)) / (y + z(e^{x(y-z)}(-1 + \rho_S) - \rho_S))^2$ es el jacobiano de $\mathbf{r}$,

$$\mathbf{r} : \mathbb{R}^3 \rightarrow \mathbb{R}^3, \quad \mathbf{r}(X, Y, Z) = (r_1(X, Y, Z), r_2(X, Y, Z), r_3(X, Y, Z)) = (S_0, \gamma, \beta).$$

Como $(X, Y, Z) = (T_S, \gamma, \beta)$, la 1-FDP de la VA tiempo T_S es la marginalización respecto de γ , y β de la FDP conjunta (18)

$$f_1(t, \rho_S) = \int_{\mathcal{D}_\gamma} \int_{\mathcal{D}_\beta} f_{S_0, \gamma, \beta} \left(\frac{\xi(1 + e^{t(\xi-\eta)}(-1 + \rho_S)) - \eta\rho_S}{\xi + \eta(e^{t(\xi-\eta)}(-1 + \rho_S) - \rho_S)}, \xi, \eta \right) \cdot \frac{e^{t(\xi-\eta)}(\xi - \eta)^2(1 - \rho_S) |\xi - \eta\rho_S|}{(\xi + \eta(e^{t(\xi-\eta)}(-1 + \rho_S) - \rho_S))^2} d\eta d\xi. \quad (19)$$

Siguiendo el mismo procedimiento, podemos calcular la distribución del tiempo hasta alcanzar un porcentaje de infectados dado, ρ_I , es decir

$$f_1(t, \rho_I) = \int_{\mathcal{D}_\gamma} \int_{\mathcal{D}_\beta} f_{S_0, \gamma, \beta} \left(\frac{\xi + \eta(-1 + \rho_I) - e^{t(\xi-\eta)}}{\xi - \eta(1 + (-1 + e^{t(\xi-\eta)})\rho_I)}, \xi, \eta \right) \cdot \left| \frac{e^{t(\xi-\eta)}(\xi - \eta)^2(\xi + \eta(-1 + \rho_I))\rho_I}{(\xi - \eta(1 + (-1 + e^{t(\xi-\eta)})\rho_I))^2} \right| d\eta d\xi. \quad (20)$$

7.6 Número básico de reproducción o R_0

En epidemiología, el número básico de reproducción R_0 , asociado a una infección es bastante útil para conocer si la enfermedad se propagará o si no. En el caso del modelo SIS (1)–(3), este valor viene dado por

$$R_0 = \frac{\beta}{\gamma}, \quad \begin{cases} \text{si } R_0 < 1 \equiv \beta < \gamma, & \text{la enfermedad desaparecería } t \rightarrow +\infty, \\ \text{si } R_0 > 1 \equiv \beta > \gamma, & \text{la enfermedad se propagaría } t \rightarrow +\infty. \end{cases}$$

A partir de la expresión (11) es fácil ver también si la enfermedad se propaga o no en función de β y γ , ya que

$$\lim_{t \rightarrow +\infty} I(t) = \lim_{t \rightarrow +\infty} \frac{(\beta - \gamma)(1 - S_0)e^{(\beta - \gamma)t}}{\beta(1 - S_0)e^{(\beta - \gamma)t} + S_0\beta - \gamma} = 0 \quad \text{si } \beta < \gamma,$$

$$\lim_{t \rightarrow +\infty} S(t) = \lim_{t \rightarrow +\infty} \frac{\gamma(1 - S_0) + (S_0\beta - \gamma)e^{(\gamma - \beta)t}}{\beta(1 - S_0) + (S_0\beta - \gamma)e^{(\gamma - \beta)t}} = 1 \quad \text{si } \beta < \gamma.$$

Por tanto, la epidemia desaparecerá cuando el porcentaje de susceptible sea menor que la tasa de recuperación, γ , de la enfermedad, es decir, cuando se verifique $\beta < \gamma$.

En nuestro contexto, ambos parámetros β y γ son considerados VAs, por tanto, para estudiar si la enfermedad desaparece se debe calcular la siguiente probabilidad en el escenario estocástico.

$$\mathbb{P}[\mathcal{S}], \quad \mathcal{S} = \{\omega \in \Omega : \beta(\omega) < \gamma(\omega)\} = \{\omega \in \Omega : R_0(\omega) < 1\}. \quad (21)$$

Esta probabilidad se puede calcular utilizando el método de transformación de vectores aleatorios descrito en el Tema 6. Consideramos

$$\mathbf{U} = (U_1, U_2) = (\gamma, \beta), \quad V = \frac{U_2}{U_1} = \frac{\beta}{\gamma} = R_0,$$

por tanto,

$$f_{R_0}(r_0) = \int_{\mathcal{D}(\gamma)} f_{\gamma, \beta}(\xi, r_0\xi) |\xi| \, d\xi,$$

donde $f_{\gamma, \beta}(\cdot, \cdot)$ denota la distribución marginal respecto de (γ, β) de la FDP conjunta

de los inputs S_0 , γ y β . Como consecuencia, teniendo en cuenta que $R_0(\omega) > 0$ para todo $\omega \in \Omega$, la probabilidad (21) se puede calcular como

$$\mathbb{P}[\mathcal{S}] = \int_0^1 \int_{\mathcal{D}(\gamma)} f_{\gamma, \beta}(\xi, r_0 \xi) |\xi| \, d\xi \, dr_0. \quad (22)$$

7.7 Ajuste paramétrico para la representación de datos reales

Los modelos epidemiológicos tipo SIS son útiles para describir la propagación de enfermedades cuya infección no proporciona ningún tipo de inmunidad al individuo. En este tipo de modelos la población se divide en dos grupos susceptibles e infectados.

Existen también hábitos sociales que se pueden describir con un modelo SIS como por ejemplo, el consumo de tabaco. Nótese que una persona que deja de fumar puede volver a ser fumador en el futuro. En esta sección, como se ha mencionado en la introducción, aplicaremos el modelo SIS, (1)–(3), para describir la evolución de los fumadores varones mayores de 16 años en España. En nuestro contexto esta población ha sido dividida en dos grupos, los no fumadores, que en nuestro caso son considerados como la población susceptible, y los que sí que fuman, que son los infectados. La Tabla 1 recoge el porcentaje de no fumadores, denotados mediante S_j , en los años 1987, 1993, 1995, 1997, 2001, 2003, 2006. Dada la naturaleza de los parámetros, se han considerado distribuciones de probabilidad específicas para S_0 , β y γ . Estos parámetros se consideraran independientes a lo largo de este estudio. Como la condición inicial S_0 representa un porcentaje, debe estar entre 0 y 1, consideramos que S_0 sigue una distribución beta de parámetros $a, b > 0$, es decir, $S_0 \sim \text{Be}(a; b)$. La distribución beta es más flexible que otras candidatas como la uniforme, ya que, permite adaptarse mejor a situaciones más complejas. Para la tasa de infección β , que sabemos que tiene que ser positiva, consideramos que sigue una distribución exponencial de parámetro $\lambda_\beta > 0$, truncada en el intervalo $(0, 1000)$. Finalmente, para la tasa de recuperación γ se ha considerado una distribución gaussiana de parámetros $\mu_\gamma > 0$ y $\sigma_\gamma > 0$ trun-

cada en el intervalo $(0, 1)$. El principal motivo de esta elección es por la positividad de la VA γ y la flexibilidad de la distribución gaussiana. Una vez llegados a este punto, es importante enfatizar en que la generalización en los resultados desarrollados en las secciones anteriores permite elegir cualesquiera distribuciones de probabilidad de los parámetros del modelo.

año (t_j)	1987 ($j = 0$)	1993 ($j = 6$)	1995 ($j = 8$)	1997 ($j = 10$)	2001 ($j = 14$)	2003 ($j = 16$)	2006 ($j = 19$)
S_j	0.4488	0.5144	0.5278	0.5514	0.5783	0.6244	0.6467

Tabla 1: Percentage of non-smokers Spanish men aged over 16 years old during the period 1987–2006. Source (web,).

Con la finalidad de determinar los valores $a, b, \lambda_\beta, \mu_\gamma$ y σ_γ asociados a las distribuciones de probabilidad de los parámetros del modelo, minimizaremos el error cuadrático, $E(a, b, \lambda_\beta, \mu_\gamma, \sigma_\gamma)$, entre los datos S_j y la media de $S(t) = S(t; a, b, \lambda_\beta, \mu_\gamma, \sigma_\gamma)$ evaluadas en los instantes de tiempos que tenemos datos $t_j, j \in \mathcal{J} = \{0, 6, 8, 10, 14, 16, 19\}$. La función que se pretende minimizar es

$$\min_{a, b, \lambda_\beta, \mu_\gamma, \sigma_\gamma > 0} E(a, b, \lambda_\beta, \mu_\gamma, \sigma_\gamma) = \sum_{j \in \mathcal{J}} (S_j - \mathbb{E}[S(t_j; a, b, \lambda_\beta, \mu_\gamma, \sigma_\gamma)])^2, \quad (23)$$

donde, según (13) y, teniendo en cuenta que $S(t) = S(t; a, b, \lambda_\beta, \mu_\gamma, \sigma_\gamma) \in (0, 1)$, la media $\mathbb{E}[S(t_j; a, b, \lambda_\beta, \mu_\gamma, \sigma_\gamma)]$ puede ser calculada como

$$\mathbb{E}[S(t_j; a, b, \lambda_\beta, \mu_\gamma, \sigma_\gamma)] = \int_0^1 s f_1(s, t_j) ds, \quad j \in \mathcal{J}. \quad (24)$$

A continuación, describimos la expresión de la 1-FDP $f_1(s, t)$ que viene definida por (10), teniendo en cuenta todas las hipótesis que se han asumido hasta ahora. En primer lugar, mencionar que $S_0 \sim \text{Be}(a; b)$, $\beta \sim \text{Exp}(\lambda_\beta)$ está truncada en el intervalo $(0, 1000)$ y $\gamma \sim \text{N}(\mu_\gamma; \sigma_\gamma)$ está truncada en $(0, 1)$, por tanto teniendo en cuenta (5), los dominios $\mathcal{D}_{S_0}$, $\mathcal{D}_\beta$ y $\mathcal{D}_\gamma$ vienen definidos por $s_{0,1} = 0, s_{0,2} = 1; \beta_1 = 0, \beta_2 = 1000$,

y $\gamma_1 = 0$, $\gamma_2 = 1$, respectivamente. Por tanto, sus FDP vienen dadas por

$$f_{S_0} \left(\frac{\xi + e^{(\xi-\eta)t}(-1+s)\xi - s\eta}{\xi + e^{(\xi-\eta)t}(-1+s)\eta - s\eta} \right) = \frac{\Gamma(a+b)}{\Gamma(a)\Gamma(b)} \left(\frac{\xi + e^{(\xi-\eta)t}(-1+s)\xi - s\eta}{\xi + e^{(\xi-\eta)t}(-1+s)\eta - s\eta} \right)^{a-1} \cdot \left(\frac{e^{(\xi-\eta)t}(-1+s)(\eta-\xi)}{\xi + e^{(\xi-\eta)t}(-1+s)\eta - s\eta} \right)^{b-1}, \quad (25)$$

$$f_{\beta}(\eta) = \frac{\lambda_{\beta} e^{-\lambda_{\beta}\eta}}{\int_0^{1000} \lambda_{\beta} e^{-\lambda_{\beta}\eta} d\eta}, \quad (26)$$

y

$$f_{\gamma}(\xi) = \begin{cases} e^{-\frac{(\xi-\mu_{\gamma})^2}{2(\sigma_{\gamma})^2}} \frac{1}{\sqrt{2\pi}\sigma_{\gamma} \left(\frac{1}{2}\text{erfc}\left(\frac{\mu_{\gamma}-1}{\sqrt{2}\sigma_{\gamma}}\right) - \frac{1}{2}\text{erfc}\left(\frac{\mu_{\gamma}}{\sqrt{2}\sigma_{\gamma}}\right) \right)}, & \text{if } 0 < \xi \leq 1, \\ 0, & \text{otherwise,} \end{cases} \quad (27)$$

siendo $\text{erfc}(z) = 1 - \frac{2}{\sqrt{\pi}} \int_0^z e^{-t^2} dt$ la función de error complementaria.

La FDP del PE solución viene dado por

$$f_1(s, t) = \int_0^1 \int_0^{1000} f_{S_0} \left(\frac{\xi + e^{(\xi-\eta)t}(-1+s)\xi - s\eta}{\xi + e^{(\xi-\eta)t}(-1+s)\eta - s\eta} \right) f_{\gamma}(\xi) f_{\beta}(\eta) \frac{e^{(\xi-\eta)t}(\xi-\eta)^2}{(\xi + e^{(\xi-\eta)t}(-1+s)\eta - s\eta)^2} d\eta d\xi. \quad (28)$$

Con la finalidad de calcular el mínimo de la función de error, $E(a, b, \lambda_{\beta}, \mu_{\gamma}, \sigma_{\gamma})$, dada por (23)–(27), se ha utilizado el algoritmo de optimización de Nelder-Mead (Nelder and Mead, 1964) en el software *Mathematica*[®] (Mat,). Los resultados obtenidos son

$$a^* = 708.755, \quad b^* = 893.394, \quad \lambda_{\beta}^* = 1362.230, \quad \mu_{\gamma}^* = 0.0231162, \quad \sigma_{\gamma}^* = 0.0000526. \quad (29)$$

Existen diferentes algoritmos de optimización. En este tema se ha añadido un recurso a fondo en el que se explican dos de ellos: Nelder Mead, que es el que utilizamos en este tema y Particle Swarm Optimization.

7.8 Resultados numéricos

La Figura 2 muestra la 1-PDF (27)–(28) para los valores óptimos a^* , b^* , λ_β^* , μ_γ^* y σ_γ^* dados en (29). Obsérvese que el centro de la masa de probabilidad de la VA que describe el porcentaje de susceptibles en el tiempo t , $S(t)$, aumenta conforme su dispersión se reduce en el tiempo. Este comportamiento se puede observar mejor en la Figura 3 donde la media, $\mu_S(t)$, y la desviación estandar, $\sigma_S(t)$, de $S(t)$ has sido despreciados. Los resultados obtenidos reflejan los datos históricos. Se puede observar que el porcentaje de no fumadores españoles aumenta conforme el tiempo aumenta.




Figura 2: Gráfica de $f_1(s, t)$ que representa la distribución estadística de los fumadores durante el periodo 1987–2006.




Figura 3: Función media (izquierda) y varianza (derecha) de los fumadores durante el periodo de tiempo 1987–2006.

Con la finalidad de validar el modelo, se han construido los intervalos de confianza. Como se conoce la expresión exacta de la FDP para $S(t)$ en cada t , podemos determinar estos valores utilizando (15)–(16). En este caso, nótese que las aproximaciones

utilizando intervalos de confianza gaussianos de la forma $\mu_S(t) \pm 2\sigma_S(t)$ proporciona resultados similares para cada caso durante el periodo 1987–2006. En la Figura 4 se muestran estos intervalos junto con los datos reales.

En la Tabla 2, se presentan los niveles de confianza $\mu_S(t) \pm 2\sigma_S(t)$ utilizando una expresión exacta para la FDP (10) para los años en los que tenemos datos disponibles. Nótese que estos valores son muy cercanos a 95.45 %, que corresponde al caso donde la PDF sea gaussiana. En la Figura 4, se observa que todos los datos están dentro de los intervalos de confianza, por tanto el modelo es capaz de capturar la variabilidad de los datos reales y como consecuencia el modelo es validado en un intervalo de confianza del 95 %.




Figura 4: Media (línea sólida) e intervalos de confianza (líneas punteadas) de los no fumadores en el intervalo de tiempo 1987–2006.

year (t_j)	1987 ($j = 0$)	1993 ($j = 6$)	1995 ($j = 8$)	1997 ($j = 10$)	2001 ($j = 14$)	2003 ($j = 16$)	2006 ($j = 19$)
Nivel de confianza	0.9550	0.9544	0.9545	0.9546	0.9549	0.9550	0.9552

Tabla 2: Probabilidades asociadas a los intervalos de confianza teniendo en cuenta el modelo SIS.

7.9 Referencias bibliográficas

- Mathematica. <http://www.wolfram.com/mathematica>. Accessed: 2015-02-15.
- National Spanish Health Survey (Encuesta Nacional de Salud de España, ENSE). <http://estadistico.inteligenciadegestion.msssi.es/publicoSNS/comun/ArbolNodos.aspx>. Accessed: 2015-02-15.
- Brauer, F. and Castillo-Chávez, C. (2001). *Mathematical Models in Population Biology and Epidemiology*. Springer, New York.
- Casabán, M.-C., Cortés, J.-C., Navarro-Quiles, A., Romero, J.-V., Roselló, M.-D., and Villanueva, R.-J. (2016). A comprehensive probabilistic solution of random sis-type epidemiological models using the random variable transformation technique. *Communications in Nonlinear Science and Numerical Simulation*, 32:199–210.
- Castillo-Chávez, C., Huang, W., and Li, J. (1996). Competitive exclusion in gonorrhea models and other sexually-transmitted diseases. *SIAM Journal Applied Mathematics*, 56(2):494–508.
- Cortés, J. C., Romero, J. V., Roselló, M. D., and Villanueva, R. J. (2012). Applying the Wiener-Hermite random technique to study the evolution of excess weight population in the region of Valencia (Spain). *American Journal of Computational Mathematics*, 2(4):274–281.
- Hethcote, H. (1989). *Biomathematics*, volume 18 of *Applied Mathematical Ecology*, chapter Three Basic Epidemiological Models, pages 120–144. Springer-Verlag, Heidelberg.
- Hethcote, H. and Yorke, J. (1984). *Gonorrhea Transmission Dynamics and Control*, volume 56 of *Lecture Notes in Biomathematics*. Springer-Verlag, Berlin.
- Hethcote, H. W. (2000). The mathematics of infectious diseases. *SIAM Review*, 42(4):599–653.
- Nelder, J. A. and Mead, R. (1964). A simplex method for function minimization. *Computer Journal*, 7(1):308–313.