



1. En qué consiste el aprendizaje supervisado y el aprendizaje no supervisado

EL aprendizaje supervisado es un paradigma de Machine Learning que consiste en el entrenamiento de un modelo en base a datos etiquetados con lo que se denomina 'ground truth'. El objetivo es ejecutar el modelo sobre los datos, estudiando una métrica y una función de pérdidas calculada entre los valores estimados por el modelo y los valores etiquetados. Con esto el modelo, en el caso de Redes Neuronales, busca aproximar una función generalista ajustando los pesos de las neuronas del modelo.

El algoritmo de backpropagation, que consiste en propagar desde la salida (output) del modelo hasta la entrada (input) los pesos del modelo se emplea para re-ajustar los pesos para la siguiente ronda de entrenamiento. Este proceso de ejecutar en feedforward (input-output) y en backpropagation (output-input) se repite durante varias 'epoch' o rondas de entrenamiento, buscando aproximar los outputs del modelo a los valores etiquetados lo máximo posible.

Este método puede llegar a lo conocido como overfitting (sobre-ajuste). Este problema se da si el modelo ha aprendido los valores etiquetados, o la conexión entre input y output de manera demasiado estricta, impidiendo al modelo ser capaz de generalizar. Un ejemplo sería, para un caso de clasificación, que somos capaces de detectar si una imagen es de un perro o de un gato, si y sólo si, la imagen en cuestión ha sido vista durante el entrenamiento.

Por otro lado, el aprendizaje no supervisado no cuenta con la existencia de un dataset etiquetado para buscar los patrones en los datos. Esto lleva que se tengan algoritmos con una naturaleza estadística, como pueden ser los algoritmos de clustering que buscan categorizar en grupos puntos diversos por similitud, o algoritmos basados en una idea de agente-arena, en el que el agente debe ajustar los pesos con el objetivo de maximizar una función de recompensa dada.



2. Cinco casos de aplicación de aprendizaje supervisado y cinco no supervisado

● 2.1 Ejemplos de Aplicación de Aprendizaje Supervisado

Como se ha dicho con anterioridad estos algoritmos se emplean en tareas con un dataset etiquetado. Lo que les lleva a ser especialmente útiles en tareas como:

- I. Clasificación de imágenes, en las que se busca asignar una clase determinada a cada imagen de un conjunto.
- II. Detección de objetos, donde el objetivo es estudiar segmentos de imagen para asignar a estas regiones de la imagen la clase asociada al objeto designado con información lo más precisa de la localización

del objeto en ésta.

III. Predicción de series temporales, en las que el modelo intenta estimar valores futuros en función de valores pasados una vez ha sido entrenado sobre conjuntos de datos que consideramos que muestran relación con la serie que se busca predecir.

IV. Detección de sentimientos en un texto, que equivale a una tarea de clasificación. En este caso no se busca clasificar input basado en imágenes, sino en cadenas de texto tokenizado y pre-etiquetado con una emoción o sentimiento.

V. Estimación de estado de salud en función de los datos del paciente. Una de las aplicaciones más interesante para la medicina, que busca asignar un nivel de severidad de la enfermedad, en el caso de que exista, de un paciente en función de los datos considerados relevantes.

● 2.2 Ejemplos de Aplicación de Aprendizaje No Supervisado

En el caso de los modelos de aprendizaje no supervisado, el objetivo es estudiar patrones latentes en la información suministrada. Esto les lleva a ser especialmente útiles en casos de:

I. Detección de anomalías, tanto si estamos hablando de sistemas bancarios para estudiar posibles transferencias fraudulentas o en casos de ciberseguridad posibles ataques al sistema. La anomalía implica un valor poco común en el conjunto de datos que debe ser estudiado para entender su procedencia.

II. Reducción de la dimensionalidad, un ejemplo claro PCA analysis, cuyo objetivo es reducir la dimensión de la información proporcionada con el objetivo de hacer un estudio más preciso y apropiado, evitando costes computacionales innecesarios.

III. Segmentación de la información en grupos, un uso de los algoritmos de clustering. Que es ampliamente utilizado en áreas como marketing para estudiar el mercado entendiendo a los clientes en términos de grupos en función de sus intereses y comportamiento de compra.

IV. Detección de temas abstractos en un texto, es decir, detectar los temas objeto de un texto dado, generalmente analizando la semántica asociada a las palabras empleadas en éste.

V. Compresión de imágenes, de nuevo reduciendo la dimensionalidad de la información contenida en la imagen.

3. Tres métodos o algoritmos de aprendizaje supervisado y tres no supervisado

A continuación, estudiaremos tres de los algoritmos de aprendizaje supervisado más utilizados: Árboles

de Decisión, Máquina de Vectores de Soporte y Navie Bayes.

● 3.1 Aprendizaje Supervisado

* 3.1.1 Árboles de Decisión (Decision Tree)

El árbol de decisión es un grafo que representa elecciones y sus resultados en forma de árbol. Los nodos del grafo representan un evento o elección y las ramas o aristas del gráfico representan las reglas o condiciones de decisión. Los árboles de decisión se pueden aplicar tanto a problemas de regresión como de clasificación e implican la estratificación o segmentación del espacio predictor en varias regiones simples (Suthaharan, 2016). Para los árboles de regresión, estos atribuyen valores a nuevos nodos dividiendo los datos en subconjuntos. Por otro lado, los árboles de clasificación otorgan etiquetas categóricas a nuevos nodos segmentando los datos en subconjuntos y estableciendo la categoría más frecuente en cada nodo. Los dos modelos basados en árboles son sencillos de entender y pueden gestionar diversos tipos de datos, lo que los hace herramientas adaptables tanto para el análisis predictivo como para entender relaciones complejas en los datos.




Figura 1. Particiones (izquierda) y estructura de un árbol de decisión para clasificación para tres clases: 1, 2 y 3. Fuente: Loh, W.-Y. (2011).

3.1.1.1 Formulación matemática

Una formulación matemática rigurosa de los árboles de decisión la podemos encontrar en la documentación de Scikitlearn (<https://scikit-learn.org/1.5/modules/tree.html>). Dados los vectores de entrenamiento $x_i \in \mathbb{R}$, $i = 1, \dots, l$ y un vector de etiquetas $y \in \mathbb{R}$, representaremos a los datos en el nodo m como Q_m con n_m muestras. Para cada división de candidatos $\theta = (j, t_m)$ compuesto por un atributo j y un umbral t_m , la partición de los datos en $Q_m^{left}(\theta)$ y $Q_m^{right}(\theta)$ subconjuntos viene dado por $Q_m^{left}(\theta) = \{(x, y) \mid x_j \leq t_m\}$ y $Q_m^{right}(\theta) = Q_m \setminus Q_m^{left}$.

La calidad de una división de candidatos de un nodo m es entonces calculada usando una función de impureza (impurity function) o función de pérdida $H()$ dependiendo de si es para clasificación o regresión y viene dado por $G(Q_m, \theta) = \frac{n_m^{left}}{n_m} H(Q_m^{left}(\theta)) + \frac{n_m^{right}}{n_m} H(Q_m^{right}(\theta))$

Seleccionando los parámetros que minimizan la impureza o pérdida $\theta^* = \operatorname{argmin}_{\theta} G(Q_m, \theta)$ este proceso se hará de manera recursiva hasta que $n_m < \min_{\text{samples}}$ ó $n_m = 1$.

* 3.1.2 Navie Bayes

Es una técnica de clasificación basada en el teorema de Bayes con un supuesto de independencia entre los predictores. En términos simples, un clasificador Naive Bayes supone que la presencia de un atributo particular en una clase no está relacionada con la presencia de ningún otro atributo. El clasificador Naive Bayes se utiliza mucho en la clasificación de texto, por ejemplo, para asignar temas en el texto, detectar spam, identificar edad/género a partir del texto y realizar análisis de sentimientos.

3.1.2.1 Formulación matemática

De acuerdo a Kamperis (2020), dado un set de atributos $x_1, \dots, x_n$ y un set de clases C , se quiere construir un modelo que devuelva un valor de $P(C_k | x_1, \dots, x_n)$. Por tanto, si se toma la probabilidad máxima sobre este rango de probabilidades se puede obtener la mejor estimación de la clase correcta tal que $C_{\text{predicted}} = \operatorname{argmax}_{C_k \in C} P(C_k | x_1, \dots, x_n) = \operatorname{argmax}_{C_k \in C} \frac{P(x_1, \dots, x_n | P(C_k)) P(C_k)}{P(x_1, \dots, x_n)}$

Asumiendo que los atributos $x_1, \dots, x_n$ son independientes entonces $P(C_k | x_1, \dots, x_n) = \prod_{i=1}^n P(x_i | C_k)$ y el modelo se simplifica de tal manera que $C_{\text{predicted}} = P(C_k) \prod_{i=1}^n P(x_i | C_k)$

* 3.1.3 Máquina de Vectores de Soporte (SVM)

Las máquinas de vectores de soporte (SVM por su siglas en inglés) son modelos de aprendizaje supervisados cuyos algoritmos de aprendizaje analizan los datos utilizados para la clasificación y el análisis de regresión. Además de realizar una clasificación lineal, las SVM pueden realizar una clasificación no lineal de manera eficiente utilizando el llamado truco del kernel, mapeando implícitamente sus entradas en espacios de atributos de alta dimensión. Básicamente, dibuja márgenes entre clases (hiperplano). Los márgenes se trazan de tal manera que la distancia entre el margen y las clases (vectores de soporte) sea máxima y, por tanto, minimice el error de clasificación (ver Figura 2).




Figura 2. Representación gráfica de los términos más importantes del algoritmo SVM y cómo funciona. Fuente: <https://www.analyticsvidhya.com/blog/2021/10/support-vector-machine-ssvm-a-complete-guide-for-beginners/>.

Las SVM son altamente adaptables, lo que las hace adecuadas para diversas aplicaciones, como clasifica-

ción de texto, clasificación de imágenes, detección de spam, identificación de escritura a mano, análisis de expresión genética, detección de rostros y detección de anomalías.

3.1.3.1 Formulación matemática

Consideremos un conjunto de datos de entrenamiento con X como matriz de atributos (cada fila es un punto de datos). También considerar y como vector de etiquetas (1 o -1 para cada clase). Se quiere encontrar un hiperplano que se defina como (Saini, A. 2021) $w \cdot X + b = 0$, donde w es el vector de pesos (normal al hiperplano) y b es el bias (intercepto).

Se quiere maximizar el margen entre las clases. El margen se define como la distancia perpendicular desde el hiperplano al punto de datos más cercano de cada clase $\operatorname{argmax}(w^*, b^*) = \frac{2}{\|w\|}$, sujeto a $y_i (w \cdot X + b) \geq 1$

Con lo que se asegura que los puntos de datos estén correctamente clasificados y a una distancia mayor o igual a 1 del hiperplano (margen).

● 3.2 Aprendizaje No Supervisado

Los algoritmos de aprendizaje no supervisados aprenden pocas características de los datos. Cuando se introducen nuevos datos, utilizan características aprendidas previamente para reconocer la clase de los datos. Se utilizan principalmente para agrupación y reducción de características (Naeem, S. et al. 2023).

* 3.2.1 Agrupamiento de K-Medias (K-Means clustering)

El procedimiento sigue un método sencillo que clasifica un conjunto de datos determinados en varios grupos. La idea principal es definir K-centros (o centroides), uno para cada grupo. Diferentes ubicaciones de centroides conducen a resultados diferentes, por tanto, la mejor opción es colocarlos lo más lejos posible uno del otro (Kodinariya, T. & Makwana, P. 2013).

El siguiente paso es tomar cada punto perteneciente a un conjunto de datos determinado y asociarlo con el centroide más cercano. Cuando no quedan puntos pendientes, se completa la primera etapa y se pasa a recalcular los K nuevos centroides como el centroide de los conglomerados resultantes del paso anterior (Figura 3).




Figura 3. Técnica de aprendizaje no supervisado mediante método de k-medias. Fuente: <https://www.linkedin.com/pulse/k-means-clustering-applications-real-world-mz4df/>.

En algunos casos, K no está claramente definido y debemos pensar en el número óptimo de estos. La agrupación de K -Medias funciona mejor cuando los datos están bien separados. Este método se utiliza ampliamente para la compresión de imágenes, motores de recomendación, agrupación de documentos y segmentación de clientes.

3.2.1.1 Formulación matemática

Este algoritmo tiene como objetivo minimizar una función objetivo, en este caso una función de error al cuadrado. La función objetivo (Sinaga, K. & Yang, M. (2020)) $w(S, C) = \sum_{j=1}^K \sum_{i \in S_j} \|y_i - c_j\|^2$, donde S es una partición de grupo K de atributos representadas por los vectores y_i en el espacio de atributos de dimensión M , que consta de S_j grupos no vacíos y que no se superponen, cada uno con un centroide $c_j, j = 1, 2, \dots, K$.

* 3.2.2 Máquina de Boltzmann restringida (RBM)

Las máquinas de Boltzmann restringidas (RBM por su siglas en inglés) se utilizan normalmente para el aprendizaje no supervisado. Este método toma un conjunto de datos de entrada y los divide en dos partes: la capa visible y la capa oculta. La capa visible está compuesta por neuronas conectadas al conjunto de datos original, mientras que la capa oculta está compuesta por neuronas que no están conectadas al conjunto de datos original. El objetivo de este algoritmo es aprender la relación entre las capas de entrada y salida. Debido a la flexibilidad de los RBM, desempeñan un papel vital en diversas aplicaciones, como la reducción de dimensionalidad, el filtrado colaborativo, el modelado de temas (topic-modeling), la clasificación y el aprendizaje de atributos (feature learning).

3.2.2.1 Formulación matemática

Al tratarse de un método basado en una red neuronal su formulación detallada puede resultar compleja, lo que excede el alcance de este trabajo. Sin embargo, podemos resumirlo en que este método aprende una distribución de datos de probabilidad utilizando un conjunto de muestras de distribución, llamados datos de entrenamiento. Durante el entrenamiento, los parámetros de RBM, los pesos W_{ij} y los sesgos a_i, b_j , se ajustan para que la distribución marginal de los giros visibles $p(v)$ coincida con la distribución de datos representada por el entrenamiento del conjunto de datos. Después de un entrenamiento exitoso, el muestreo de la capa visible de RBM debería (idealmente) producir nuevas muestras que también provengan de la misma distribución subyacente de los datos de entrenamiento.

Una forma de determinar la distribución de probabilidad más cercana a la de entrenamiento se puede

obtener a través de la divergencia Kullback–Leibler (<https://courses.physics.illinois.edu/phys498cmp/sp2022/ML/RBM.html>) $O = \sum_v q(v) \log \left(\frac{q(v)}{p(v)} \right)$, donde O es la entropía relativa de las distribuciones, $p(v)$ es la distribución marginal de RBM y $q(v)$ es la distribución de los datos. Los valores óptimos de W_{ij} , a_i y b_j se obtienen mediante descenso del gradiente $W_{ij} \rightarrow W_{ij} - \eta \frac{\partial O}{\partial W_{ij}}$, $a_i \rightarrow a_i - \eta \frac{\partial O}{\partial a_i}$ y $b_j \rightarrow b_j - \eta \frac{\partial O}{\partial b_j}$, donde η es la tasa de aprendizaje.

* 3.2.3 Codificador automático (Autoencoder)

Se trata de un tipo de red neuronal que se utiliza para el aprendizaje no supervisado. Funciona tomando un conjunto de datos de entrada que son codificados en una capa oculta (Li, P. & Li, J. 2023). Estos luego se decodifican y se comparan con el conjunto de datos de entrada original. Si hay un alto grado de similitud entre los dos conjuntos, el codificador ha hecho su trabajo correctamente. De lo contrario, el codificador deberá ajustarse hasta que exista un alto grado de similitud entre los dos conjuntos. Los codificadores automáticos se utilizan ampliamente en la clasificación y reconstrucción de imágenes.




Figura 4. Funcionamiento del algoritmo de codificador automático. Fuente: <http://www.analyticsvidhya.com/blog/2021/06/complete-guide-on-how-to-use-autoencoders-in-python/>.

4. Conclusión sobre los métodos, aplicaciones y futuro del aprendizaje automático

● 4.1 Conclusión Técnica

Se han revisado detalladamente técnicas fundamentales de aprendizaje supervisado y no supervisado, así como sus aplicaciones y desafíos, destacando la relevancia actual del aprendizaje automático y su impacto significativo en diversas industrias, como la salud, las finanzas y la tecnología. Con base en este análisis, se pueden extraer varias conclusiones que reflejan la importancia de una correcta selección y ajuste de algoritmos dependiendo del problema a resolver.

Se concluye que el aprendizaje supervisado plantea como principal limitación la necesidad de datos etiquetados, lo que puede resultar prohibitivo en términos de tiempo y costo en ciertos problemas. Se extraen las siguientes conclusiones de los modelos de aprendizaje supervisado estudiados:

I. Árboles de Decisión: Su capacidad para dividir el espacio de características en particiones jerárquicas los hace altamente interpretables. Sin embargo, es crucial manejar la poda y el número mínimo de muestras por nodo para evitar problemas de sobreajuste.

II. Máquinas de Vectores de Soporte (SVM): Su robustez frente a datos de alta dimensionalidad, gracias al truco del kernel, las posiciona como una solución idónea en tareas complejas de clasificación no lineal. No obstante, su costo computacional aumenta exponencialmente con el tamaño del conjunto de datos.

III. Naive Bayes: Aunque sus supuestos de independencia entre variables pueden parecer restrictivos, este método es sorprendentemente efectivo en dominios como la clasificación de texto, donde las dependencias entre características son débiles o manejables.

Por otro lado, se concluye que el desafío principal del aprendizaje no supervisado radica en su naturaleza exploratoria: los resultados no siempre son directamente interpretables y pueden requerir ajustes significativos en su configuración. Entre los algoritmos no supervisados estudiados se concluye que:

I. K-means: Su simplicidad algorítmica y velocidad lo hacen ideal para segmentación básica. Sin embargo, depende de la correcta elección del número K y de centroides iniciales, lo cual puede afectar significativamente los resultados si los datos presentan estructuras complejas.

II. Máquinas de Boltzmann Restringidas (RBM): Su capacidad para modelar distribuciones de probabilidad subyacentes las convierte en herramientas poderosas en tareas de reducción de dimensionalidad y generación de datos. Sin embargo, su entrenamiento requiere ajustes precisos en los hiperparámetros y puede ser computacionalmente costoso.

III. Autoencoders: Representan un enfoque más moderno para la representación y compresión de datos, con aplicaciones que van desde la reconstrucción de imágenes hasta la generación de nuevas muestras sintéticas. Su eficacia está directamente relacionada con la cantidad y calidad de los datos disponibles para su entrenamiento.

De la comparativa entre ambos modelos se extrae que los modelos supervisados son más precisos en tareas bien definidas, pero menos versátiles para descubrir patrones en datos no estructurados. En cambio, los no supervisados son ideales para análisis exploratorios y preprocesamiento de datos, aunque su eficacia puede ser limitada sin una correcta ingeniería de características y contextualización del dominio.

● 4.2 Reflexión sobre el Futuro

El futuro del aprendizaje automático está en la convergencia y la integración. Algoritmos híbridos, como el aprendizaje semi-supervisado, están demostrando su capacidad para aprovechar conjuntos de datos parcialmente etiquetados, mientras que técnicas avanzadas como los modelos generativos adversarios (GANs) y los transformers están redefiniendo los límites de lo que es posible en aprendizaje no

supervisado y supervisado.

Es probable que el desarrollo de modelos más explicables y robustos ante datos escasos o sesgados ocupe un lugar central. Además, la optimización de recursos computacionales será clave para democratizar el acceso a estas herramientas, especialmente en entornos con limitaciones de infraestructura, como el uso de modelos comprimidos (model pruning y quantization) o la implementación de computación en el edge para reducir la dependencia de la nube.

Estas tendencias, junto con la integración de nuevos paradigmas como el aprendizaje federado y el edge computing, permitirán una adopción más amplia y responsable del aprendizaje automático en diversos campos. Además, se espera que los avances en la colaboración humano-máquina transformen significativamente la manera en que se diseñan y entrenan los modelos, haciendo posible una interacción más intuitiva y efectiva con los algoritmos, lo cual podría mejorar la adaptabilidad y la personalización en aplicaciones prácticas.

5. Infografía




Figura 5. Infografía.



6. Referencias

- Bishop, C. M. (2006). *Pattern Recognition and Machine Learning*. Springer.
- Gareth, J., Daniela, W., Trevor, H., & Robert, T. (2013). *An introduction to statistical learning: with applications in R*. Spinger.
- Goodfellow, I., Bengio, Y., & Courville, A. (2016). *Deep Learning*. MIT Press.
- Hastie, T., Tibshirani, R., & Friedman, J. (2009). *The Elements of Statistical Learning: Data Mining, Inference, and Prediction*. Springer.
- Kamperis, S. (2020). *How to implement a naive Bayes classifier with tensorflow*. Let's talk about science! <https://ekamperi.github.io/machine%20learning/2020/12/31/naive-bayes-classifier-in-tensorflow.html>
- Khanday, N. Y., & Sofi, S. A. (2021). *Taxonomy, state-of-the-art, challenges and applications of visual understanding: A review*. Computer Science Review, 40, 100374. <https://doi.org/https://doi.org/10.1016/j.cosrev.2021.100374>
- Kodinariya, T. M., & Makwana, P. R. (2013). *Review on determining the number of Clusters in K-Means Clustering*. International Journal, 1(6), 90-95.
- Li, P., Pei, Y., & Li, J. (2023). *A comprehensive survey on design and application of autoencoders in deep learning*. Applied Soft Computing, 138, 110176. <https://doi.org/https://doi.org/10.1016/j.asoc.2023.110176>
- Loh, W. Y. (2011). *Classification and regression trees*. Wiley interdisciplinary reviews: data mining and knowledge discovery, 1(1), 14-23.
- Naeem, S., Ali, A., Anam, S., & Ahmed, M. M. (2023). *An unsupervised machine learning algorithm: Comprehensive review*. International Journal of Computing and Digital Systems.
- Saini, A. (2021). *Guide on Support Vector Machine (SVM) Algorithm*. <https://www.analyticsvidhya.com/blog/2021/10/support-vector-machinessvm-a-complete-guide-for-beginners/>
- Sinaga, K. P., & Yang, M. S. (2020). *Unsupervised K-Means Clustering Algorithm*. IEEE Access, 8, 80716-80727. <https://doi.org/10.1109/ACCESS.2020.2988796>
- Suthaharan, S. (2016). *Decision tree learning*. Machine Learning Models and Algorithms for Big Data Classification: Thinking with Examples for Effective Learning, 237-269.
- Suthaharan, S. (2016). *Support Vector Machine*. En: Machine Learning Models and Algorithms for Big Data Classification. Integrated Series in Information Systems, vol 36. Springer, Boston, MA. https://doi.org/10.1007/978-1-4899-7641-3_9
- Zhang, H. (2004). *The optimality of naive Bayes*. Aa, 1(2), 3. <https://cdn.aaai.org/FLAIRS/2004/Flairs04-097.pdf>