

Tema 2

Estadística robusta

Técnicas Multivariantes

Dra. Elena Giménez de Ory


Grado en Matemática Computacional
Escuela Superior en Ingeniería y Tecnología



- 1 Resumen y objetivos
- 2 Métodos paramétricos
- 3 Métodos no paramétricos
- 4 Estadística robusta

1

Resumen y objetivos



En este tema vamos a estudiar:

- Métodos paramétricos
 - Normalidad
 - Homocedasticidad
 - Tamaño muestral
- Métodos no paramétricos
- Estadística robusta
 - Outliers y errores groseros
 - Estimadores robustos

2





Métodos paramétricos





Los métodos paramétricos forman parte de la Estadística clásica Se utilizan cuando:

- Partimos de una distribución conocida en la que uno o más parámetros son desconocidos
- Ejemplo: asumimos que la estatura de la población sigue una distribución normal, con media y desviación típica desconocidas
- La media y la desviación típica son los parámetros que deseamos conocer: estimadores
- Condiciones que se asumen: observaciones independientes, variancias poblacionales similares (homocedasticidad), relación lineal entre variables, distribución normal...

Son ampliamente utilizados porque pueden obtenerse tests uniformemente de máxima potencia (con error tipo ii mínimo) y hay gran cantidad de pruebas

- La normalidad es una condición muy habitual en las pruebas paramétricas (Teorema Central del Límite)
- Para poder asumirla necesitamos que los datos provengan de una única distribución y tener una muestra lo suficientemente grande
- Hay distintas formas de comprobar la normalidad, mediante test de hipótesis (recomendado), gráficamente (no es una prueba)
- Si no podemos asumir esta condición (o alguna de las anteriores): métodos no paramétricos o estadística robusta





3

Métodos no paramétricos

También forman parte de la estadística clásica, se utilizan cuando no se cumple alguno de los requisitos anteriores. Ojo, pueden requerir que se cumpla algún requisito (por ejemplo, los datos provienen de una misma distribución)

- Hay versiones no paramétricas de algunas pruebas muy utilizadas: Mann-Whitney (t de Student), Kruskal-Wallis (ANOVA), Kolmogorov-Smirnov (Shapiro-Wilk)...
- Hay menos contrastes no paramétricos que paramétricos
- La potencia de estas pruebas suele ser menor
- Algunos autores defienden su uso generalizado: si la muestra cumple las condiciones para aplicar pruebas paramétricas la pérdida de potencia no es muy grande. Si no, es necesario utilizar pruebas no paramétricas para no aumentar el error de tipo I

4

Estadística robusta

La estadística robusta puede aplicarse en un ámbito aún más amplio que los contrastes no paramétricos, por ejemplo con muestras de datos que proceden de más de una población o en las que hay presencia de outliers.

- Los tests robustos tienen menos potencia que los paramétricos
- El enfoque tradicional ha sido eliminar los datos anómalos, pero no es lo aconsejable si no se trata de datos erróneos
- Existen estimadores robustos para la posición (media) y dispersión (desviación típica)
- Existen pruebas robustas que son la generalización de pruebas clásicas (Kruskall-Wallis, Mann-Whitney...)
- Existen métodos de regresión robustos

Estimadores robustos de posición:

- Media α -recortada: se hace la media con las $n - \alpha$ observaciones centrales
- Media α -windsorizada: similar al anterior, pero se sustituyen los valores extremos por el último valor
- Mediana: divide la muestra ordenada en dos partes con el mismo número de elementos
- Trimedia: media ponderada entre la mediana (doble) y los cuartiles 1 y 3

Ejemplo: Sea la muestra 1, 2, 3, 4, 5, 6, 7, 100, calcular la media 0.25-recortada, la media 0.25-windsorizada, la mediana y la trimedia y compararlas con la media aritmética.
Media 0.25-recortada, media 0.25-windsorizada, mediana y trimedia: 4,5
Media aritmética: 16

Estimadores robustos de dispersión:

- Median Absolute Deviation (MAD): $Me(|X_i - \bar{X}|)$
- Rango intercuartílico (RIQ): Se calcula la diferencia entre los cuartiles Q_3 y Q_1

Ejemplo: Calcular los estimadores MAD y RIQ para la muestra del ejemplo anterior y compararla con la desviación típica

$$MAD = 2$$

$$RIQ = 4$$

$$\sigma = 34$$

Entonces, ¿qué metodología es mejor? Depende

- Si sabemos que nuestros datos "se comportan bien" los métodos paramétricos tienen la mayor potencia y hay gran cantidad de pruebas y de documentación
- Ojo, para aplicar pruebas paramétricas siempre es necesario comprobar que se cumplen los supuestos sobre la muestra
- Si la muestra tiene outliers o sospechamos que hay más de una población mezclada, entonces debe usarse estadística robusta
- En general, la eliminación de datos anómalos debe estar muy justificada

Objetivos de estos ejercicios:

- Introducción al análisis descriptivo de datos
- Utilizar distintos tipos de pruebas
- Introducción y repaso a la regresión lineal
- Repasar la interpretación del p-valor
- Repasar la generación de muestras aleatorias

unir

LA UNIVERSIDAD
EN INTERNET