

Tema 3

Introducción al aprendizaje automático

Técnicas Multivariantes

Dra. Elena Giménez de Ory

Grado en Matemática Computacional
Escuela Superior en Ingeniería y Tecnología



- 1 Resumen y objetivos
- 2 Aprendizaje automático
- 3 Técnicas de validación
- 4 Técnicas de remuestreo

1

Resumen y objetivos

APRENDIZAJE AUTOMÁTICO

ALGORITMOS QUE APRENDEN DE LOS DATOS

SUPERVISADO: Se entrenan con datos etiquetados

Problemas de clasificación y de regresión

NO SUPERVISADO: Se entrenan con datos sin etiquetar

ESTRATEGIA DE VALIDACIÓN DE LOS ALGORITMOS

Partición en datasets de entrenamiento y de test

Validación cruzada

Validación cruzada anidada

Remuestreo

DILEMA SESCO-VARIANZA

Sesgo

Varianza

- Modelos simples: infra-ajuste
- Modelos complejos: sobre-ajuste
- Modelos adecuados


En este tema vamos a estudiar:

- Aprendizaje automático
- Ajuste y predicción del modelo
- Técnicas de validación
- Técnicas de remuestreo

2

Aprendizaje automático

El aprendizaje automático o *machine learning* es la ciencia de programar computadoras de forma que puedan aprender de los datos. Este campo ha experimentado un gran crecimiento en los últimos años debido al aumento de la capacidad de computación y a la gran cantidad de datos disponibles



Es especialmente útil para resolver problemas como:


- Reconocimiento facial
- Filtro de spam
- Interacción con asistentes virtuales
- Recomendación de productos
- ...

- También se está aplicando mucho en áreas que tradicionalmente eran de estadística: regresión, clusterización, etc.
- Las dos áreas buscan lo mismo: extraer información de los datos
- La estadística tiene más andamiaje matemático (propiedades de los estimadores, contrastes de hipótesis, buenas propiedades de los estimadores) y se aplican en problemas de baja dimensión, mientras que el aprendizaje automático trata de realizar predicciones en conjuntos de alta dimensión
- Hay muchas cuestiones que son comunes: visualización y depuración de los datos, predicciones, etc.
- Hay muchos aspectos de convergencia y aunque se trabaje con *machine learning* siempre hay que tener en cuenta los modelos, la interpretación, etc.

3


Técnicas de validación

En los problemas de predicción (por ejemplo, ajuste) o clasificación pueden surgir dos problemas: sobreajuste (overfitting) o subajuste (underfitting)



Entrenamiento y test


- Evaluar la bondad del modelo para evitar sobreajuste
- Datos de validación y datos de test
- Método más sencillo: partición dataset validación y dataset test



- Dataset de entrenamiento para aprendizaje automático y dataset de test para validar el modelo
- Error en el dataset de entrenamiento y error en el dataset de validación
- Error en validación menor
- Si el error en test es demasiado alto, problema de sobreajuste
- Método sencillo pero no utiliza todos los datos para el modelo predictivo

Validación cruzada

- Se hace una partición con n elementos
- Cada conjunto se utiliza como test en distintos ajustes
- Total: n ajustes
- Las particiones pueden influir en los errores
- Repetir la partición k veces




Validación cruzada

- LOOCV (Leave One Out Cross Validation)
- Desaparece la incertidumbre a la hora de distribuir los datos entre las distintas particiones
- Permite identificar medidas influyentes: si un resultado de la validación es muy diferente al resto es posible que el dato correspondiente a esa partición sea una medida influyente
- Puede ser computacionalmente costoso
- Puede presentar problemas de sobreajuste


Validación cruzada anidada

- Se emplea cuando además de ajustar el modelo se quieren establecer los hiperparámetros
- Bucle interior: estimación de los hiperparámetros
- Bucle exterior: estimación del modelo

Validación cruzada anidada



Bucle interior 1



4

Técnicas de remuestreo

- Se emplean cuando el tamaño muestral no es muy grande
- Jackknife: consiste en obtener las n -muestras derivadas de la muestra original a partir de eliminar una observación
- Bootstrap: El Bootstrapping es la técnica de remuestreo en el cual se obtiene una muestra del mismo tamaño que la original haciendo muestreo con reemplazamiento (tema 8)

Optimismo

- Entrenar el modelo o algoritmo con todos los datos disponibles
- Obtener el error del entrenamiento.
- Corregir este error mediante el *optimismo*: se emplea bootstrapping para generar muestras (que pueden tener distinto número de variables) cuyo ajuste se compara con el original. Esto se repite varias veces y da lugar a una corrección del error en el modelo original

Objetivos de estos ejercicios:

- Descarga de base de datos
- Descripción de las variables de una base de datos
- Análisis descriptivo básico
- Creación de datasets

unir

LA UNIVERSIDAD
EN INTERNET