

Tema 5

Técnicas de avanzadas

Técnicas Multivariantes

Dra. Elena Giménez de Ory


Grado en Matemática Computacional
Escuela Superior en Ingeniería y Tecnología



- 1 Resumen y objetivos
- 2 Regresión lineal múltiple
- 3 Coeficientes de determinación
- 4 Colinealidad
- 5 Extensiones de los modelos lineales
- 6 Extensiones de los modelos lineales
- 7 Regresión lineal múltiple en la práctica

1

Resumen y objetivos



En este tema vamos a estudiar:


- Regresión lineal múltiple
- Selección de variables
- Extensión de los modelos lineales
- Regresión lineal en la práctica

2

Regresión lineal múltiple

Supongamos que tenemos dos variables predictoras de una tercera variable relacionadas linealmente:

$$Y = \beta_0 + \beta_1 \cdot X_1 + \beta_2 \cdot X_2$$



Esto se puede generalizar a n dimensiones: Modelo sin error:

$$Y = \beta_0 + \beta_1 \cdot X_1 + \beta_2 \cdot X_2 + \dots + X_n$$

Modelo con error:

$$\beta_0 + \beta_1 \cdot X_1 + \beta_2 \cdot X_2 + \dots + X_n + \epsilon$$

donde:

β_0 es el intercepto del modelo,


$\beta_j, j = 1, \dots, n$ son los parámetros de regresión,

Y es la variable dependiente

$X_j, j = 1, \dots, n$ son las variables independientes

ϵ es el error

Notación:



$X, Y, \beta_0, \beta_j, \epsilon$: variables y parámetros del modelo, teóricos
 x_{ij}, y_i : valor i-ésimo de la muestra para las variables X_j e Y
 $\hat{b}_0, \hat{b}_j$: estimación de los parámetros teóricos β_0, β_j
 e_i : error en la posición i-ésima $e_i = \hat{y}_i - y_i$

Cuando se utilice la regresión lineal múltiple para construir un modelo hay que:

- Justificar que las variables pueden tener una relación lineal
- Realizar un análisis de colinealidad
- Si se utiliza mínimos cuadrados, comprobar que los residuos siguen una distribución normal y que las varianzas son homogéneas (homocedasticidad)
- Comprobar que el peso de cada variable no es cero
- Si no se cumple, analizar por qué: faltan datos, modelo inadecuado, presencia de outliers...

3

Coeficientes de determinación

El **coeficiente de determinación**, R^2 , es una medida de la bondad de ajuste del modelo que toma valores comprendidos entre 0 y 1.

Problema: puede haber variables que aporten muy poca información al modelo pero algo sumen, por lo que es necesario un coeficiente que penalice los modelos complejos. Suele utilizarse el **coeficiente de determinación ajustado**, R^2_{adj} , que se interpreta igual que el anterior.

4

Colinealidad

Es importante quitar del modelo las variables que tengan una fuerte dependencia lineal entre ellas (colinealidad). Puede sospecharse que hay colinealidad si tenemos un valor R^2 elevado pero hay pocas variables significativas. Hay varios métodos:

- Se calculan los autovalores de la matriz de varianzas-covarianzas y se mira si hay alguno muy próximo a cero. Este es el posible candidato
- Se calcula el autovector asociado a ese autovalor y se mira qué componentes son mayores
- Se calcula el VIF (Variance Inflation Factor) para cada variable
- Con valores a partir de 4-5, hay sospecha de colinealidad. Con valores mayores de 10, es más que probable

¿Qué hacer si se han detectado problemas de colinealidad?

- Se repite el ajuste sin las variables candidatas y se estudia el comportamiento de R_{adj}^2
- Opción más conservadora: eliminar las variables en que haya colinealidad

5

Extensiones de los modelos lineales

Modelos de regresión polinómica

Son una extensión de la regresión lineal a polinomios de orden superior:

$$Y = \beta_0 + \beta_1 \cdot X + \beta_2 \cdot X^2 + \beta_3 \cdot X^3$$

- Cuidado con el sobreajuste
- Pueden transformarse en problemas de regresión lineal con la transformación $X_1 = X$; $X_2 = X^2$ y $X_3 = X^3$

6

Extensiones de los modelos lineales

Modelos con variables predictoras categóricas

Para incluir variables categóricas en el análisis:

- Utilizar variables indicadoras (dummy)
- Definir tantas como sea necesario

Modelos con la variable respuesta transformada

Pues interesar transformar la variable dependiente (ejemplo, tomar su log)

- Realizar el análisis igual
- Al analizar los resultados, tener en cuenta que la variable respuesta está transformada

7

Regresión lineal múltiple en la práctica

Datos faltantes:

- Es muy común que falten datos en alguna de las variables
- Opción más conservadora: eliminar todo el registro
- Opción más controvertida: estimar los valores faltantes con la mediana (variable cuantitativa) o moda (variable cualitativa)

Variables en distintas escalas:

- Se resta su media y se divide por su desviación típica
- En general, útil para estandarizar el efecto de cada variable sobre el total
- En regresión lineal solo varía el intercepto

unir

LA UNIVERSIDAD
EN INTERNET