

Tema 6

Técnicas de regresión avanzadas II

Técnicas Multivariantes

Dra. Elena Giménez de Ory

Grado en Matemática Computacional
Escuela Superior en Ingeniería y Tecnología



- 1 Resumen y objetivos
- 2 Introducción
- 3 Mínimos cuadrados recortados
- 4 Regresión penalizada
 - Regresión Ridge
 - Regresión LASSO
 - Red Elástica
- 5 Ejercicios resueltos

1

Resumen y objetivos

Regresión Avanzada II

Mínimos Cuadrados Recortados

Método robusto

Outliers

Coste computacional

Regresión Penalizada

Selección de variables

Reducir varianza del modelo

Orden de la penalización

Red Elástica

Combinación de regresión LASSO y de regresión Ridge

Es necesario ajustar hiperparámetros α y r

r (LASSO ratio)

Hiperparámetro de encogimiento α

- r define la proporción de regresión LASSO respecto al total de la Red Elástica
- $r = 0 \rightarrow$ regresión ridge
- $r = 1 \rightarrow$ regresión LASSO
- r se puede fijar de antemano. α se suele ajustar con técnicas de validación

En este tema vamos a estudiar:

- Regresión por LTS
- Regresión penalizada
 - Ridge
 - LASSO
 - Red Elástica

2

Introducción


Cuando se hace regresión lineal (simple o múltiple) podemos encontrarnos con varios problemas:

- Modelo no lineal. Solución: buscar otro tipo de ajuste
- Presencia de outliers. Posible solución: **mínimos cuadrados recortados**
- Colinealidad. Posible solución: **regresión penalizada**

3

Mínimos cuadrados recortados





YUAN AND ZHONG



- La regresión LTS consiste en hacer una regresión por mínimos cuadrados ordinarios sobre todos los subconjuntos de la muestra con h elementos y quedarnos con el que tenga menor error
- h es una cota superior (idealmente, el supremo) para el número máximo de outliers, $n/2 \leq h < n$
- h se estima por el conocimiento previo que tengamos sobre la muestra o sobre la población
- Problema: computacionalmente muy costoso, ya que $\binom{n}{h}$ en general va a ser un número muy grande
- Fast LTS: solución suboptimal en muestras grandes, solución óptima en muestras pequeñas

Otra forma de aplicar LTS (apuntes):

- Fijar h , rep (número de ajustes que vamos a hacer) y $rep2$ (número de modificaciones sobre el conjunto seleccionado)
- Tomar rep submuestras de tamaño h , calcular la regresión por OLS y quedarnos con la que tenga menor error
- Sobre esa muestra, realizar $rep2$ reemplazamientos de 1 elemento del subconjunto escogido por otro que se haya quedado fuera y quedarnos con el que tenga menor error




4

Regresión penalizada

- Especialmente útil si hay problemas de colinealidad o sospecha de que pueda haber
- También se usa cuando hay muchas variables predictoras en relación al tamaño de la muestra
- Se pueden eliminar variables o minimizar su importancia en el modelo
- En este tema: Ridge, LASSO y Red Elástica

- 1 Resumen y objetivos
- 2 Introducción
- 3 Mínimos cuadrados recortados
- 4 Regresión penalizada
 - Regresión Ridge
 - Regresión LASSO
 - Red Elástica
- 5 Ejercicios resueltos


- En la regresión Ridge se busca minimizar el error cuadrático medio, pero con la restricción de que $\sum_{i=1}^p \beta_i^2 < s$ donde s es conocido como el parámetro de ajuste.
- Esta restricción no suele seleccionar variables, pero sí puede minimizar su importancia en el modelo
- Es muy importante estandarizar las variables antes de realizar el ajuste
- Ventaja 1: en caso de colinealidad el peso de las variables se reparte, lo que disminuye el error en ciertas estimaciones
- Ventaja 2: aunque puede aumentar el sesgo ligeramente, disminuye la varianza global y, por tanto, el error cuadrático medio. Muy útil si cambia la muestra (entrenamiento-test)



- 1 Resumen y objetivos
- 2 Introducción
- 3 Mínimos cuadrados recortados
- 4 Regresión penalizada**
 - Regresión Ridge
 - **Regresión LASSO**
 - Red Elástica
- 5 Ejercicios resueltos

- En la regresión LASSO (Least Absolute Shrinkage and Selection Operator) se busca minimizar el error cuadrático medio, pero con la restricción de que $\sum_{i=1}^p |\beta_i| < s$ donde s es conocido como el parámetro de ajuste
- Esta restricción sí elimina variables con facilidad, por lo que se puede utilizar para seleccionarlas
- Si se eliminan variables el modelo resultante es más sencillo pero con mayor varianza

Dimension Reduction of Feature Space with LASSO



Fuente: <https://towardsdatascience.com/>


- 1 Resumen y objetivos
- 2 Introducción
- 3 Mínimos cuadrados recortados
- 4 Regresión penalizada**
 - Regresión Ridge
 - Regresión LASSO
 - **Red Elástica**
- 5 Ejercicios resueltos

- Es una combinación lineal de las regresiones Ridge y LASSO
- $(1 - r) \sum_{i=1}^p \beta_i^2 + r \sum_{i=1}^p |\beta_i| < s$
- Determinar r y $\alpha = \frac{1}{s}$ mediante técnicas de validación cruzada



Cómo determinar los parámetros r y α

- Hacer una partición de la muestra (200)
- Para un valor de r , determinar el valor de α que minimice el error para diferentes valores de α
- Repetir esto 200 veces (validación cruzada) para obtener la función de densidad. El valor de α así obtenido minimiza el error
- Repetir esto mismo para los valores de r del intervalo discretizado


Para un valor de r , determinar el valor de α que minimice el error para diferentes valores de α



Repetir esto 200 veces (validación cruzada) para obtener la función de densidad. El valor de α así obtenido minimiza el error



Repetir esto mismo para los valores de r del intervalo discretizado



5

Ejercicios resueltos

- Muestran cómo realizar los distintos tipos de regresión de este tema
- Los comandos son análogos a los de temas anteriores
- Preguntas importantes (pensar en casa, debatir en el foro, etc.): ¿cómo saber qué tipo de regresión es mejor para un conjunto de datos concreto? ¿En qué parámetros debo fijarme?

unir

LA UNIVERSIDAD
EN INTERNET