

Tema 7

Técnicas de clasificación

Técnicas Multivariantes

Dra. Elena Giménez de Ory

Grado en Matemática Computacional
Escuela Superior en Ingeniería y Tecnología




- 1 Resumen y objetivos
- 2 Introducción
- 3 Método de los K vecinos más cercanos

1

Resumen y objetivos

Técnicas de clasificación y regresión logística



En este tema vamos a estudiar:

- Problemas de clasificación
- Regresión logística
- Método de los K vecinos más cercanos

2

Introducción

¿Qué es un problema de clasificación? Ejemplos:

- Un paciente llega a la sala de urgencias de un hospital. En el triaje es necesario clasificarlo como urgente o no.
- Un servicio de banca online debe determinar si una transacción es fraudulenta o no.
- Un filtro anti-spam de un correo electrónico debe determinar si los correos entrantes son fraudulentos o no.

Es decir, necesitamos hacer regresión sobre una variable dependiente cualitativa.

¿Por qué no se puede hacer regresión lineal sobre variables codificadas o *dummie* Porque el resultado puede no ser interpretable

- Ejemplo: Infarto = 0, Ictus = 1, Ataque epiléptico = 2
- Si la predicción da un valor < 1 p > 0


¿Cuándo sí podría usarse? Cuando la variable dependiente represente una escala y tenga sentido un orden y, por tanto, los posibles valores intermedios

Para obtener valores de probabilidad (entre 0 y 1) de la variable respuesta la regresión logística emplea la función logística:

$$p(X) = \frac{e^{\beta_0 + \beta_1 X}}{1 + e^{\beta_0 + \beta_1 X}}$$

Operando resulta:

$$\frac{p(X)}{1 - p(X)} = e^{\beta_0 + \beta_1 X}$$



La interpretación de los resultados y la predicción es análoga a la regresión lineal (ver apuntes para más detalle).

Posibles problemas (comunes a todos los tipos de regresión): variables confusoras
Ejemplo: relación entre el consumo de café, tabaco y riesgo cardiovascular

3


Método de los K vecinos más cercanos

Si la variable de respuesta es multinomial, una técnica de clasificación sencilla y muy utilizada es el método de los K vecinos más cercanos (KNN). Consiste en clasificar una

nueva observación basándonos en la clasificación de los K puntos más próximos. Ejemplo:

Categorías .^aptoz " no aptoz dos variables independientes X_1 y X_2 Se localizan las K

observaciones más cercanas y se calcula el promedio




En este caso, dado que dos de los tres puntos más cercanos son “apto” y el otro “no apto” se tendría que:

$$Pr(Y = \text{apto} | X = x_0) = 2/3;$$

$$Pr(Y = \text{no apto} | X = x_0) = 1/3.$$

Escogiendo el valor que obtiene una mayor probabilidad, decidiríamos que la nueva observación x_0 sería “apto”.



¿Qué valor de K escoger?

- Cuanto menos sea K más flexibles serán las regiones
- Puede aplicarse la VC para determinar el valor de K que minimice el error de clasificación
- En caso de variables dicotómicas evitar valores de K pares o ponderar en función de la distancia

- *Estandarizar las variables predictoras.* Como se van a definir las distancias a las observaciones de entrenamiento es necesario que todas las variables tengan una misma escala para que sean comparables entre sí. Esto se va a conseguir estandarizando las variables predictoras. En Python, una de las maneras de realizar esto es mediante la función **preprocessing.scale()** de la librería *sklearn*.
- *Ajustar el parámetro K* que minimice el error de clasificación utilizando validación cruzada. Para ello se emplea la función **KNeighborsClassifier()** de la librería *sklearn.neighbors* donde el parámetro K se introduce como el argumento **n_neighbors**.
- *Construir el clasificador* con el valor de K óptimo para poder predecir nuevas observaciones.

unir

LA UNIVERSIDAD
EN INTERNET