

Tema 8

Árboles de decisión y métodos de ensamble

Técnicas Multivariantes

Dra. Elena Giménez de Ory

Grado en Matemática Computacional
Escuela Superior en Ingeniería y Tecnología




- 1 Resumen y objetivos
- 2 Árboles de decisión
- 3 Métodos de ensamble
- 4 Métodos de ensamble
- 5 Métodos de ensamble
- 6 Boosting

1

Resumen y objetivos

Árboles de decisión y métodos de ensemble



En este tema vamos a estudiar:


- Árboles de decisión
- Métodos de ensamble
- Random forest
- Boosting

2

Árboles de decisión

Permiten resolver problemas de regresión o clasificación (en función del tipo de variable respuesta)

- Son sencillos de interpretar, representación muy gráfica
- No es necesario realizar ninguna asunción sobre la muestra
- Secuencia de condiciones sobre las variables predictoras y su relación con la variable respuesta



Iris Versicolor




Iris Setosa



Iris Virginica

- Primera línea: pregunta que clasifica
- Segunda línea: medida de impureza
- Tercera línea: número de observaciones en ese nodo
- Cuarta línea: número de observaciones de cada tipo (variable dependiente)
- Quinta línea: clasificación en las hojas




Medidas de impureza:

- Gini: Si vale 0, el nodo es puro. $G_i = 1 - \sum_{k=1}^n P_{i,k}^2$. Menor coste computacional
- Entropía: Si vale 0, el nodo es puro. $H_i = - \sum_{k=1}^n P_{i,k} \cdot \log_2(p_{i,k})$. Nodos más balanceados


Ejemplos (nodo profundidad 2, derecha):

- Gini: $G_{2d} = 1 - \left(\left(\frac{0}{46} \right)^2 + \left(\frac{1}{46} \right)^2 + \left(\frac{45}{46} \right)^2 \right) = 1 - 0,957 = 0,043$
- Entropía: Si vale 0, el nodo es puro.
 $H_{2d} = - \left(0 + \frac{1}{46} \cdot \log_2 \left(\frac{1}{46} \right) + \frac{45}{46} \cdot \log_2 \left(\frac{45}{46} \right) \right) = -(-0,120 - 0,031) = 0,151$

Visualización de un árbol de decisión



Visualización de un árbol de decisión




Los árboles de decisión también pueden mostrar la probabilidad de pertenecer a una clase dada.

Ejemplo (nodo profundidad 2, derecha):

- *Iris setosa* = $0/54 = 0\%$.
- *Iris versicolor* = $49/54 = 90,7\%$.
- *Iris virginica* = $5/54 = 9,3\%$.


Hiperparámetros del modelo (para evitar sobre ajuste):


- *min_samples_split* : El mínimo número de muestras que puede tener un nodo para que se pueda dividir.
- *min_samples_leaf*: El mínimo número de muestras que puede tener un nodo hoja.
- *min_weight_fraction_leaf*: Como el anterior, pero cuando se utilizan pesos en las observaciones.
- *max_leaf_nodes*: Máximo número de nodos hoja.
- *max_features*: El máximo número de variables que son consideradas por el algoritmo para decidir cada división.



Regresión:


- Igual que en el caso anterior, pero con la variable dependiente numérica
- Se sustituye la medida de impureza por el error cuadrático medio






Inconvenientes de los árboles de decisión:

- Son sensibles a la rotación de los datos
- Son sensibles a pequeñas variaciones de la muestra





3

Métodos de ensamble

Se agrupan predicciones de grupos de predictores (ensable) para reducir el sesgo

- Escoger métodos muy diferentes entre sí (por ejemplo, podemos promediar las clasificaciones obtenidas mediante una regresión logística, un árbol de decisión y por el método KNN).
- Emplear el mismo método de predicción pero entrenándolo con diferentes muestras de entrenamiento. Cuando esta muestra se obtiene con remplazamiento, el método de ensamble se conoce como *bagging*, que es la abreviatura de bootstrap aggregating. Cuando el muestreo se realiza sin remplazamiento, el método de ensamble se conoce como *pasting*.

Se aumenta ligeramente el sesgo para reducir la varianza

4

Métodos de ensable

Cuando se haga bagging:


- No se van a utilizar todos los elementos de la muestra
- Lo que queden fuera (oob) pueden utilizarse como test

Random forests:

- Se combinan árboles de decisión que generan las divisiones en función de una selección aleatoria de las variables

5

Métodos de ensamble



6

Boosting

Ensamble de predictores débiles para lograr un predictor fuerte

- Adaboosting
- Gradient boosting

En el método del Gradient Boosting es necesario seleccionar, entre otros hiperparámetros:

- La profundidad máxima permitida, d , de cada uno de los árboles de decisión.
- El número máximo de árboles, N , es decir, de predictores en el ensamble.
- La tasa de aprendizaje (*learning rate*), λ , que va a determinar la velocidad a la cual se van a ir incorporando los nuevos predictores a los residuos.

unir

LA UNIVERSIDAD
EN INTERNET