

Tema 9

PCA y clusterización

Técnicas Multivariantes

Dra. Elena Giménez de Ory

Grado en Matemática Computacional
Escuela Superior en Ingeniería y Tecnología



- 1 Resumen y objetivos
- 2 Algunos problemas del aprendizaje no supervisado
- 3 Análisis de componentes principales
- 4 Clusterización

1

Resumen y objetivos

Reducción de la dimensión y clustering

Técnicas de aprendizaje no supervisado

Resuelven

Problemas sin
variable respuesta

Observaciones
sin etiquetar

Paso previo al análisis
supervisado

Análisis de componentes principales

Sirven para reducir la
dimensión:

Variables centradas

Descomposición SVD

Capturar máxima varianza original

Escoger número de
Componentes
principales

Método gráfico
Varianza determinada
Criterio de Kaiser

Clustering

Realizan grupos de
observaciones
parecidas

K-Medias

Método iterativo

Inercia

Escoger centroides
iniciales

Escoger número de
grupos

En este tema vamos a estudiar:

- Algunos problemas del aprendizaje no supervisado
- Análisis de componentes principales
- Clusterización

2

Algunos problemas del aprendizaje no supervisado

Las técnicas de aprendizaje no supervisado se emplean cuando o bien no se conoce la etiqueta a priori o bien no es posible etiquetar los datos. Algunos ejemplos son:


- Reducción de la dimensionalidad
- Clustering
- Detección de anomalías
- Estimación de la función de densidad

3


Análisis de componentes principales


Análisis de componentes principales

- Es una de las principales técnicas para reducir la dimensión
- Se busca proyectar los datos en un subespacio de dimensión menor
- Criterio: maximizar la varianza de los datos




- Es una de las principales técnicas para reducir la dimensión
- Si se puede reducir a dimensión 2 o 3, la muestra se puede representar gráficamente
- Se busca proyectar los datos en un subespacio de dimensión menor
- Criterio: maximizar la varianza de los datos. Se consigue eligiendo las nuevas variables entre los autovectores de la matriz de varianzas-covarianzas de los datos
- Una vez calculados los autovectores nos fijamos en 2 cosas: cuánta varianza explican y cómo es la combinación lineal de vectores cartesianos





- Criterio: maximizar la varianza de los datos. Se consigue eligiendo las nuevas variables entre los autovectores de la matriz de varianzas-covarianzas de los datos
- Una vez calculados los autovectores nos fijamos en 2 cosas: cuánta varianza explican y cómo es la combinación lineal de vectores cartesianos



Ejemplo (<https://jllloisperez.com>): Tenemos las calificaciones de 15 alumnos en las siguientes materias:

- Lengua
- Matemáticas
- Física
- Inglés
- Filosofía
- Historia
- Química
- Educación Física

Es un espacio de dimensión 8 que vamos a intentar reducir mediante el PCA

Tabla de Pesos de los Componentes

	<i>Componente</i>	<i>Componente</i>
	1	2
LENGUA	0,500113	0,0853043
MATEMATICAS	-0,112909	0,555049
FÍSICA	-0,0517681	0,574789
INGLÉS	0,498752	0,036556
FILOSOFÍA	0,450292	0,121881
HISTORIA	0,49264	0,0635768
QUIMICA	-0,0726488	0,573763
EDUCACIÓN FÍSICA	0,187002	-0,0694516

Fuente: <https://jllloisperez.com>)

Análisis de Componentes Principales

<i>Componente</i>		<i>Porcentaje de</i>	<i>Porcentaje</i>
<i>Número</i>	<i>Valor propio</i>	<i>Varianza</i>	<i>Acumulado</i>
1	3,61041	51,577	51,577
2	1,8083	25,833	77,410
3	0,834195	11,917	89,327
4	0,461938	6,599	95,926
5	0,207834	2,969	98,895
6	0,0714179	1,020	99,916
7	0,00590614	0,084	100,000

Fuente: <https://jllloisperez.com>)

En resumen, ¿cómo elegir el tamaño del subespacio final?

- Si queremos hacer una representación gráfica de los datos, debemos reducir a dimensión 2 o 3
- Si queremos capturar la mayor parte de la información, fijar un porcentaje de varianza explicada (con flexibilidad)
- Criterio de Kaiser: escoger aquellas componentes principales cuya varianza sea mayor que 1
- Además: mirar los pesos (combinación lineal) para interpretar los resultados



4

Clusterización

Consiste en agrupar los datos de la muestra, de tal forma que las observaciones que pertenezcan a un mismo grupo o *cluster* tengan características similares y diferentes a las de otros grupos. Se diferencia de la clasificación en que no existen clases predefinidas (es un método no supervisado).

Aplicaciones:

- Segmentación de clientes
- Análisis de datos
- Reducción de la dimensionalidad
- Detección de anomalías
- Clasificación en aprendizaje semi-supervisado
- Búsqueda de imágenes
- Detección de patrones en imágenes
- ...



El proceso de clusterización tiene una parte subjetiva. Por ejemplo, los alumnos de Técnicas Multivariantes se pueden clasificar:

- Hombres, Mujeres
- Colombianos, Ecuatorianos, Españoles, Argentininos...
- Ingenieros informáticos, Matemáticos, Físicos, Ingenieros civiles...
- Profesores universitarios, recién titulados, trabajadores de banca...

En general es imposible que todas las variables se comporten de forma semejante en cada cluster, por lo que vamos a seleccionar en cuáles nos fijamos

Una vez definido el criterio de clusterización, hay que definir qué consideramos parecido: distancia (conjuntos continuos).

- $d(x, y) = 0 \Leftrightarrow x = y$
- $d(x, y) = d(y, x)$
- Desigualdad triangular: $d(x, y) \leq d(x, z) + d(z, y)$

Esta idea genérica y formal de distancia da muchas posibilidades: distancia euclídea, distancia r , distancia ∞ , distancia Mahalanobis...

Una vez definido el criterio de clusterización, hay que definir qué consideramos parecido: distancia (conjuntos continuos).

- $d(x, y) = 0 \Leftrightarrow x = y, \forall x, y$
- $d(x, y) = d(y, x), \forall x, y$
- Desigualdad triangular: $d(x, y) \leq d(x, z) + d(z, y), \forall x, y, z$

Esta idea genérica y formal de distancia da muchas posibilidades: distancia euclídea, distancia r , distancia ∞ , distancia Mahalanobis...

Para datos no continuos se pueden utilizar otras distancias (distancia de edición para correctores ortográficos) u otras medidas de similitud


Algoritmos de clustering:


- Por particiones (K-means)
- Por densidad (DBSCAN)
- Jerárquicos (BIRCH)


K-means. Basado en centroides (centro geométrico del cluster)

- Se generan K centroides, introducidos manualmente, de manera aleatoria o generados previamente.
- Se le asigna a cada observación del conjunto de datos el cluster del centroide K más cercano.
- Se computan los nuevos centroides para cada cluster K.
- Se repiten los pasos anteriores (se reasignan las observaciones a los nuevos clusters formados por los nuevos centroides K y se actualizan dichos centroides) hasta que las observaciones ya no varían más de cluster

La elección de los centroides influye en la clusterización final









¿Cómo escoger el número de centroides (k)?

- Realizar la clusterización para distintos valores de k
- Medir la inercia en cada caso
- Quedarse con el valor de K en que empieza el codo





unir

LA UNIVERSIDAD
EN INTERNET