

Tema 10

Visualización de los datos

Técnicas Multivariantes

Dra. Elena Giménez de Ory


Grado en Matemática Computacional
Escuela Superior en Ingeniería y Tecnología



- 1 Resumen y objetivos
- 2 Visualización como análisis descriptivo
- 3 Principales tipos de datos y gráficos

1

Resumen y objetivos



En este tema vamos a estudiar:

- Visualización como análisis descriptivo
- Visualización para la difusión de resultados
- Principales tipos de datos y de gráficos
- Gráficos en Python

2

Visualización como análisis descriptivo





Cuarteto de Anscombe

I		II		III		IV	
X	Y	X	Y	X	Y	X	Y
10	8.04	10	9.14	10	7.46	8	6.58
8	6.95	8	8.14	8	6.77	8	5.76
13	7.58	13	8.74	13	12.74	8	7.71
9	8.81	9	8.77	9	7.11	8	8.84
11	8.33	11	9.26	11	7.81	8	8.47
14	9.96	14	8.10	14	8.84	8	7.04
6	7.24	6	6.13	6	6.08	8	5.25
4	4.26	4	3.10	4	5.39	19	12.50
12	10.84	12	9.13	12	8.15	8	5.56
7	4.82	7	7.26	7	6.42	8	7.91
5	5.68	5	4.74	5	5.73	8	6.89

Cuarteto de Anscombe

Propiedad	Valor	Precisión
Media de x	9	Exacto
Varianza muestral de x: σ^2	11	Exacto
Media de y	7.50	Hasta el segundo decimal
Varianza muestral de y: σ^2	4.125	± 0.003
Correlación entre x e y	0.816	Hasta el tercer decimal
Recta de regresión lineal	$y = 3.00 + 0.50x$	Hasta el segundo decimal
Coefficiente de determinación R^2	0.67	Hasta el segundo decimal

Visualización como análisis descriptivo



- En el primer conjunto de datos existe una correlación lineal moderada entre x e y .
- En el segundo conjunto de datos la correlación entre x e y es no lineal.
- En el tercer conjunto de datos existe una correlación lineal muy fuerte entre x e y exceptuando uno de los puntos que tiene un comportamiento anómalo.
- Por último, en el cuarto conjunto todos los datos tienen el mismo valor de x excepto un valor alojado que produce un fuerte apalancamiento de los estadísticos descriptivos.

Hay muchos contextos en los que es necesario representar los datos sobre los que estáis trabajando a un tercero de forma muy clara e intuitiva:

- En la publicación de resultados científicos.
- En la divulgación de resultados en prensa.
- Para realizar un informe para otro sector de la empresa o para un superior.
- Presentación de resultados a un cliente.
- Exposición de los resultados de un trabajo de investigación ante un tribunal de un trabajo fin de estudios.

Los gráficos deben cumplir:

- Es importante que el usuario o cliente encuentre el gráfico sencillo e intuitivo, además de que pueda comprender la información reflejada en la visualización.
- Se deben seguir guías de estilo. Además, todos los gráficos de un mismo documento deben ser consistentes y mantener una coherencia entre sí. Por ejemplo, emplear tamaños similares, utilizar mismos tipos de fuentes, usar mismos colores de los fondos, etc.
- En la medida de lo posible se deben utilizar técnicas de visualización que puedan amplificar la cognición, incrementando la capacidad de procesamiento de los datos y reduciendo la búsqueda de información en el texto.

Errores en la muestra:

- Valores anómalos. Ya se ha tratado en temas anteriores como lidiar con ellos.
- Atributos dependientes con valores contradictorios. (por ejemplo, que aparezca en la misma observación una persona que tenga: status de *fumador* = *nunca fumadora* y *número de cigarrillos al día* = 20)
- Identificadores no únicos. Que dos observaciones tengan el mismo identificador cuando no estamos tratando con datos longitudinales.
- Valores ausentes. Habría que valorar imputar.

Curado de datos:

- **Análisis de información.** Se necesita analizar la información del conjunto de datos para poder detectar los problemas anteriormente mencionados. Se necesita conocer la estructura de los datos, qué variables están relacionadas entre sí, codificaciones de variables categóricas como numéricas, los rangos de valores posible de las variables y los tipos de datos que contienen (si esperamos un valor numérico que no sea un carácter), etc.
- **Verificación.** Una vez que se tiene suficiente conocimiento sobre la base de datos, se deben verificar que los datos no presentan inconsistencias. En caso de detectar estas inconsistencias, corregirlas.
- **Almacenamiento de datos limpios.** Una vez que se ha limpiado el conjunto de datos, se puede guardar la base de datos limpia (sin sobrescribir los datos en bruto, por si en el futuro se tuviese que volver a ellos).

3


Principales tipos de datos y gráficos

Tipos de datos que podemos querer visualizar:

- Datos unidimensionales. Tipos de datos lineales como textos o listas alfabéticas organizadas de una manera secuencial. La utilidad de su visualización depende de su cantidad. Se pueden representar en una línea o eje.
- Datos bidimensionales. Ejemplos: datos en los que se consideran dos dimensiones diferenciadas o mapas.
- Datos tridimensionales. Se suelen utilizar para representar objetos del mundo real con volumen o para representar una variable frente a otras dos. Su utilización para la impresión en papel se ve en cierto modo limitada.
- Datos multidimensionales. No hay representación directa: se pueden hacer visualizaciones de las variables por separado o reducir la dimensionalidad.
- Datos temporales. Son datos que ordenados cronológicamente y tienen un comienzo y un final. Un valor unidimensional temporal se puede representar como si fuera un dato bidimensional.

Tipos de gráficos:

- **Gráfico de líneas.** Es un gráfico de dos dimensiones donde cada pareja de valores se une con la siguiente mediante una línea. Se suele emplear en las series temporales.
- **Gráfico de dispersión** o *scatterplot*. Es un gráfico de dos dimensiones donde cada pareja de valores se representa mediante un punto.
- **Histograma.** El histograma representa las frecuencias de una variable discreta (o la discretización de una variable continua) por intervalos, con lo que podemos obtener una representación de la distribución de la variable. A partir del histograma es posible representar la función de densidad de la variable representada en un **diagrama de kernel de densidad**, que consiste en una suavización del histograma.
- **Diagrama de cajas y bigotes** o *boxplot*. Es un gráfico que permite representar algunos de los estadísticos descriptivos claves de una distribución.



Representación de variables cualitativas:

- **Diagrama de barras.** Representa la frecuencia de diferentes categorías de una variable o diferentes valores que son comparables. También se puede emplear para representar variables discretas que no tengan muchos valores.
- **Diagrama de sectores.** Representa porcentajes de una variable en diferentes categorías. Se utiliza únicamente, si se puede visualizar correctamente. Es decir, si todas las categorías tienen valores distinguibles. Se recomienda no emplearlo si existen muchos valores similares, ya que en ese caso es preferible utilizar un diagrama de barras.

unir

LA UNIVERSIDAD
EN INTERNET