

Curso: Optimización - Sesión: 1

Tema 1: CONCEPTOS PREVIOS

Prof. Marlon Ernesto Moscoso Martínez

UNIVERSIDAD INTERNACIONAL DE LA RIOJA





Optimización PER11087

2024 - 2025

email: marlonernesto.moscoso-externo@unir.net

PROBLEMA

¿Qué necesitamos saber para resolver
problemas de optimización?



Contenido

1 Introducción informal a la optimización matemática

- Esquema
- Consideraciones Importantes
- Modelación Matemática

2 Definiciones básicas

- Álgebra Matricial
- Continuidad - Diferenciabilidad

3 Clasificación de Problemas de Optimización


4 Métodos Heurísticos

- Algoritmos Genéticos
- Algoritmos de Enjambre

5 Teoría de control y optimización

6 Recomendaciones

Esquema del Tema





Conceptos Previos


Consideraciones Importantes

- 1 El curso está fuertemente enfocado al cálculo numérico y en este sentido, aprovecharemos este primer tema para introducir algunos **resultados teóricos fundamentales** que justificarán el enfoque más algorítmico de los siguientes temas.
- 2 Desde esta introducción formal, se observa una fuerte relación entre los problemas de **optimización de funciones continuas** y el cálculo matemático.
- 3 La idea básica, es poner en contexto los problemas y ejemplificar ciertos aspectos del problema de optimización.

■ Para llevar esto a cabo, en la mejor disposición:

👍 Se proveen los conceptos y herramientas necesarias para encarar, con ciertas garantías, un subconjunto amplio de problemas de optimización (de funciones continuas) conocido como **optimización convexa**.

👍 En esta sección, esencialmente repasaremos conceptos y resultados de cursos de **álgebra lineal** y **cálculo multivariante**.



■ A grosso modo: **La optimización**, es la “capacidad de resolver o hacer algo de la manera más eficiente posible y, en el mejor de los casos, utilizando la menor cantidad de recursos”.

■ **Consecuencias:** La diversidad y a veces, que resulten irresolubles, aunque tienen algo en común: “tratar de obtener la mejor solución”.

Definición [Optimización]

✓ **Definición Material:** La **optimización** (también conocida como optimización matemática o programación matemática) es la selección del mejor elemento respecto a un criterio de un conjunto de elementos disponible.

✓ **Definición Test:** La **optimización o programación matemática**, es el estudio de ciertos problemas donde es necesario encontrar un valor extremo (máximo y/o mínimo), a partir de valores dados a un cierto número de variables independientes.

Ejemplos

👍 El qué tan **buena** es una solución, está ligado a un criterio y esto resulta muy general. Veamos,

⚙️ **Ejemplo 1:** Encontrar el camino más corto entre dos puntos.

En este caso, la mejor solución es la **longitud** más corta.

👍 A veces, nuestro problema puede contener **restricciones** que dificultan encontrar una solución.

⚙️ **Ejemplo 2:** Encontrar el camino más corto entre dos puntos sobre una esfera.

Sólo se toman por válidos, los caminos
que están contenidos en una esfera.

Ejemplo


✓ Un ejemplo sencillo de optimización, puede ser **minimizar** (o maximizar) una función de variable real. Por ejemplo,

$$\text{minimizar } x^2, x \in \mathbb{R}$$

Basta ver que la función x^2 es convexa y por tanto, en $x = 0$ se alcanza un mínimo.

✗ Cambiando el problema por:

$$\text{minimizar } x^2, x \in (0, \infty)$$



La respuesta anterior deja de ser cierta, ya que para todo $x_1 \in (0, \infty)$, siempre existe $x_2 \in (0, \infty)$, tal que $f(x_1) > f(x_2)$.

■ Sea $S \subseteq \mathbb{R}^n$, un conjunto y $f : S \rightarrow \mathbb{R}$. Entonces, el problema

minimizar $f(\mathbf{x})$, $\mathbf{x} \in S$

¿Este problema tiene solución? Si existe, ¿es única?

👍 No tiene sentido buscar la solución de un problema si no sabemos que existe.

👍 La teoría de Optimización, nos dice si tiene sentido buscarla.

■ **En términos de algoritmos:** Una condición **suficiente**, nos dice si tiene sentido buscar una solución del problema y una condición **necesaria**, nos da un criterio para saber si la hemos encontrado.

Optimización ➔

f tiene extremos $\longleftrightarrow f$ función objetivo

Teorema [Weierstrass]

Si f es una función continua en S y S es compacto, entonces existe $\mathbf{x}^* \in S$, tal que $f(\mathbf{x}) \geq f(\mathbf{x}^*)$, para todo $\mathbf{x} \in S$. $\square$

- **Hipótesis sobre la función objetivo:** f es continua.
- **Hipótesis sobre el conjunto de soluciones factibles:** S es un compacto.
- **Tesis del teorema:** Existe un mínimo que se alcanza en $\mathbf{x}^*$.
- Las hipótesis sobre la función objetivo y el conjunto de soluciones factibles conforman las **condiciones suficientes** para la existencia de un mínimo.

¿Las condiciones Necesarias?

- Si f es diferenciable y $\mathbf{x}^*$ realiza un mínimo, entonces $\nabla f(\mathbf{x}^*) = \mathbf{0}$.

Modelación Matemática

$$\left\{ \begin{array}{ll} \min_{\mathbf{x} \in \mathbb{X}} & f(\mathbf{x}) \\ \text{Sujeto a:} & h(\mathbf{x}) = 0 \\ & g(\mathbf{x}) \leq 0 \\ & \mathbf{x} \in \mathbb{X} \end{array} \right. \quad \text{O bien,}$$

$$\left\{ \begin{array}{ll} \max_{\mathbf{x} \in \mathbb{X}} & f(\mathbf{x}) \\ \text{Sujeto a:} & h(\mathbf{x}) = 0 \\ & g(\mathbf{x}) \leq 0 \\ & \mathbf{x} \in \mathbb{X} \end{array} \right.$$

👉 $\mathbf{x}$, representa las **variables** del problema, dispuestas en un cierto dominio $\mathbb{X}$.

👉 $f(\mathbf{x})$, representa la **función objetivo** del problema, la cual se quiere optimizar (Maximizar o Minimizar).

👉 $h(\mathbf{x}) = 0$ y/o $g(\mathbf{x}) \leq 0$, representan las **restricciones** del problema.

■ Encontrar el punto de la recta $\ell := ax + by = c$ más cercano a $(x_0, y_0) \in \mathbb{R}^2$.

Ejemplo 1 [$a = b = 1$, $c = 2$, $(x_0, y_0) = (2, 2)$]

Encontramos el punto de la recta $x + y = 2$ más cercano a $(2, 2)$.

Modelación Matemática

$$\left\{ \begin{array}{ll} \min_{\mathbf{x} \in \mathbb{X}} & f(\mathbf{x}) \\ \text{Sujeto a:} & h(\mathbf{x}) = 0 \\ & \mathbf{x} \in \mathbb{X} \end{array} \right. \rightarrow \left\{ \begin{array}{ll} \min_{(x,y) \in \mathbb{R}^2} & (x-2)^2 + (y-2)^2 \\ \text{Sujeto a:} & x + y - 2 = 0 \\ & (x, y) \in \mathbb{R}^2 \end{array} \right.$$



Problema 1

Hallar la solución del **Ejemplo 1**

Ejemplo 2

Determinar el valor mínimo de x , considerando que $x^2 \leq y$ y además, $x^2 + y^2 \leq 2$.

Modelación Matemática

$$\left\{ \begin{array}{ll} \min & x \\ (x,y) \in \mathbb{R}^2 & \\ \text{Sujeto a:} & x^2 \leq y \\ & x^2 + y^2 \leq 2 \end{array} \right. \rightarrow$$

Problema es equivalente al resuelto en el **Ejemplo 1**.

Definiciones Básicas

📊 Álgebra Matricial

Sea $M \in \mathcal{M}_{n \times n}(\mathbb{R})$. Entonces, recordemos que:

- ① M es invertible, si y sólo si, existe M^{-1} , tal que:

$$M \cdot M^{-1} = I = M^{-1} \cdot M$$

- ② M es invertible, si y sólo si, $\det(M) \neq 0$. Además,

$$\det(M^{-1}) = [\det(M)]^{-1}$$

- ③ M es simétrica, si y sólo si, $M^T = M$.

- ④ M es **definida negativa** (positiva) si $\mathbf{x}^T M \mathbf{x} < 0$ ($\mathbf{x}^T M \mathbf{x} > 0$), para todo $\mathbf{x} \in \mathbb{R}^n$ no nulo.

- ④ Diremos que $\lambda \in \mathbb{C}$, es un autovalor de autovector $\mathbf{v}$, si $M\mathbf{v} = \lambda\mathbf{v}$.
- ⑤ Las matrices definidas negativas (positivas), son exactamente aquellas que tienen todos sus autovalores negativos (positivos). Si los autovalores son no positivos (no negativos), entonces la matriz es semidefinida negativa (positiva).
- ⑥ Supongamos que $M \in \mathcal{M}_{n \times n}$. Un menor de orden $k \leq n$ es el determinante de la submatriz resultante al eliminar $n - k$ filas y $n - k$ columnas. Dado k , el menor principal de orden k es el determinante de la matriz obtenida al eliminar las $n - k$ últimas filas y las $n - k$ últimas columnas. Denotaremos por M_k al menor principal de orden k .

Criterio de Sylvester

- 1 M es **definida positiva**, si y solo si, todos los menores principales son positivos.
- 2 Si, para $k = 1, 2, \dots, n - 1$, todos los menores son positivos y $M_n = 0$, entonces la matriz es **semidefinida positiva**.
- 3 El criterio es un poco más complicado para el caso de matrices **definidas negativas**:

M es **definida negativa**, si y solo si, $(-1)^k M_k > 0$

Si, para $k = 1, 2, \dots, n - 1$, $(-1)^k M_k > 0$ y $M_n = 0$, entonces la matriz es **semidefinida negativa**.

Condiciones Analíticas

Sea $\mathcal{U} \subset \mathbb{R}^n$ abierto y $f : \mathcal{U} \rightarrow \mathbb{R}$. Recordemos,

❶ f es continua en el punto $\mathbf{x}_0$ si, para todo $\varepsilon > 0$, existe $\delta > 0$ tal que, si $\|\mathbf{x} - \mathbf{x}_0\| < \delta$, entonces $|f(\mathbf{x}) - f(\mathbf{x}_0)| < \varepsilon$. Diremos que f es continua en $\mathcal{U}$, si es continua para todo $\mathbf{x} \in \mathcal{U}$.

❷ f es una función **Lipschitz**, si existe $K > 0$, tal que

$$|f(\mathbf{x}) - f(\mathbf{y})| \leq K \|\mathbf{x} - \mathbf{y}\|$$

para cualquier par $\mathbf{x}, \mathbf{y} \in \mathcal{U}$.

③ Sean $\mathbf{x}_0, \mathbf{v} \in \mathcal{U}$, con $\|\mathbf{v}\| = 1$. Si existe el límite:

$$\lim_{h \rightarrow 0} \frac{f(\mathbf{x}_0 + h\mathbf{v}) - f(\mathbf{x}_0)}{h}$$

diremos que es la derivada de f con respecto a la dirección $\mathbf{v}$ y lo denotaremos por $D_{\mathbf{v}}f(\mathbf{x}_0)$.

④ Si $\mathbf{v} = \mathbf{e}_i$ es un vector de la base canónica de $\mathbb{R}^n$, entonces utilizamos la notación $\frac{\partial f}{\partial x_i}(\mathbf{x}_0) := D_{\mathbf{e}_i}f(\mathbf{x}_0)$ y la llamaremos derivada parcial de f con respecto de x_i . Diremos que la función es diferenciable si, para todo punto, existen todas las derivadas parciales y son continuas.

⑤ Un punto $\mathbf{x}_0$ realiza un mínimo local de f , si existe un $\delta > 0$ tal que $f(\mathbf{x}_0) \leq f(\mathbf{x})$ para todo $\mathbf{x} \in B_\delta(\mathbf{x}_0)$ (la bola con centro $\mathbf{x}_0$ y radio δ).

Un punto $\mathbf{x}_0$ realiza un mínimo global si $f(\mathbf{x}_0) \leq f(\mathbf{x})$ para todo $\mathbf{x} \in \mathcal{U}$. La definición de máximo local y global es análoga.

⑥ Si $\mathbf{x}_0 \in \mathcal{U}$ es tal que $\nabla f(\mathbf{x}_0) = \mathbf{0}$, entonces diremos que tenemos un punto crítico.

⑦ Sea $\mathbf{x}_0$ un punto crítico de f . Supongamos que existen vectores $\mathbf{v}$ y $\mathbf{w}$ tales que $t = 0$ realiza un mínimo local de la función unidimensional $f_{\mathbf{v}}(t) = f(\mathbf{x}_0 + t\mathbf{v})$ y realiza un máximo local de la función unidimensional $f_{\mathbf{w}}(t) = f(\mathbf{x}_0 + t\mathbf{w})$. Entonces decimos que $\mathbf{x}_0$ es un punto de silla.

⑧ Diremos que el abierto $\mathcal{U}$ es convexo, si para cualquier par $\mathbf{x}, \mathbf{y} \in \mathcal{U}$, la cantidad $(1 - t)\mathbf{x} + t\mathbf{y} \in \mathcal{U}$ para todo $t \in [0, 1]$. Si la función f es diferenciable y $\mathcal{U}$ es convexo, se cumple el teorema del valor medio de Lagrange. Esto es, para todo par $\mathbf{x}, \mathbf{y} \in \mathcal{U}$, existe una cantidad $\alpha \in (0, 1)$ tal que:

$$f(\mathbf{x}) - f(\mathbf{y}) = \langle \nabla f((1 - \alpha)\mathbf{x} + \alpha\mathbf{y}), \mathbf{y} - \mathbf{x} \rangle$$

Notamos que la hipótesis sobre $\mathcal{U}$ (asumir que es convexo) es clave para poder evaluar la función f en $(1 - \alpha)\mathbf{x} + \alpha\mathbf{y}$ en la identidad anterior. Por otro lado, si la función f verifica la siguiente desigualdad:

$$f((1 - \alpha)\mathbf{x} + \alpha\mathbf{y}) \leq (1 - \alpha)f(\mathbf{x}) + \alpha f(\mathbf{y})$$

para cualquier par $\mathbf{x}, \mathbf{y} \in \mathcal{U}$, diremos que f es convexa.

⑨ Si x_0 realiza un mínimo (máximo) de f entonces $\nabla f(x_0) = \mathbf{0}$. Es decir, todo punto óptimo es un punto crítico. **El recíproco no es cierto.**

Observación

- Que el gradiente sea nulo es, entonces, una condición necesaria para la optimalidad.

Vamos a anunciar un resultado que proporciona una condición suficiente.

Dados $\mathbf{x}, \mathbf{y} \in \mathcal{U}$, denotaremos por $[\mathbf{x}, \mathbf{y}]$ al subconjunto de $\mathcal{U}$ donde cada elemento se escribe como: $z = (1 - \alpha)\mathbf{x} + \alpha\mathbf{y}$, para algún $\alpha \in [0, 1]$.

Teorema

Sea $\mathcal{U}$ un abierto convexo y $f : \mathcal{U} \rightarrow \mathbb{R}$ una función de clase $\mathcal{C}^2$. Supongamos que $\mathbf{x}_0$ es un punto crítico, entonces:

- ① Si la matriz Hessiana $H(\mathbf{x}_0)$ es definida positiva, entonces $\mathbf{x}_0$ realiza un mínimo local.
- ② Si la matriz Hessiana $H(\mathbf{x}_0)$ es definida negativa, entonces $\mathbf{x}_0$ realiza un máximo local.
- ③ Si la matriz Hessiana $H(\mathbf{x}_0)$ es indefinida, entonces $\mathbf{x}_0$ es un punto de silla.

Ejemplo 3

Consideramos la función:

$$f(x, y, z) = x^2 + y^2 + z^2 - xy + yz - xz$$

y nos preguntamos por sus extremos relativos.

Solución: Sabemos que:

$$\nabla f(x, y, z) = (2x - y - z, 2y - x + z, 2z + y - x)$$

Luego, $\nabla f(x, y, z) = \mathbf{0}$, si y solo si, el sistema

$$\begin{cases} 2x - y - z = 0 \\ 2y - x + z = 0 \\ 2z + y - x = 0 \end{cases} \text{ tiene solución, pero } \begin{vmatrix} 2 & -1 & -1 \\ 2 & -1 & 1 \\ 2 & 1 & -1 \end{vmatrix} \neq 0$$

Por tanto, la solución es única y $(x, y, z) = (0, 0, 0)$.

Más aún. la matriz Hessiana en $(0,0,0)$ está dada por:

$$Hf(0,0,0) = \begin{bmatrix} 2 & -1 & -1 \\ -1 & 2 & 1 \\ -1 & 1 & 2 \end{bmatrix}$$

donde:

$$M_1 = 2, \quad M_2 = \begin{vmatrix} 2 & -1 \\ -1 & 2 \end{vmatrix} = 3 \quad \text{y} \quad M_3 = |Hf(0,0,0)| = 4$$

Luego, $H(0,0,0)$ es definida positiva y por tanto, $f(0,0,0) = 0$ es un mínimo local, que en su defecto también es global. 

Ejemplo 4

Consideramos la función:

$$f(x, y) = x^3 - 12xy + 8y^3$$

y nos preguntamos por sus extremos relativos.

Solución: En este caso, $\nabla f(x, y) = (3x^2 - 12y, -12x + 24y^2)$, lo que nos proporciona dos puntos críticos: $(0, 0)$ y $(2, 1)$. La matriz Hessiana, está dada por:

$$Hf(x, y) = \begin{vmatrix} 6x & -12 \\ -12 & 48y \end{vmatrix}$$

Con esto podemos ver que en $(0, 0)$ hay un punto de silla y en $(2, 1)$, hay un mínimo. (Usar autovalores)



Consideramos ahora las funciones $g : \mathcal{U} \rightarrow \mathbb{R}^m$ y $h : \mathcal{U} \rightarrow \mathbb{R}^p$. En su forma más general, un problema de optimización tiene la forma:

$$\left\{ \begin{array}{ll} \min_{\mathbf{x} \in \mathcal{U}} & f(\mathbf{x}) \\ \text{Sujeto a:} & h(\mathbf{x}) = \mathbf{0} \\ & g(\mathbf{x}) \leq \mathbf{0} \\ & \mathbf{x} \in \mathcal{U} \end{array} \right. \quad \text{O bien,} \quad \left\{ \begin{array}{ll} \max_{\mathbf{x} \in \mathcal{U}} & f(\mathbf{x}) \\ \text{Sujeto a:} & h(\mathbf{x}) = \mathbf{0} \\ & g(\mathbf{x}) \leq \mathbf{0} \\ & \mathbf{x} \in \mathcal{U} \end{array} \right.$$

■ Aquí $g(\mathbf{x}) \leq \mathbf{0}$ se debe interpretar de la manera siguiente:


Si nombramos $g(\mathbf{x}) = (g_1(\mathbf{x}), \dots, g_m(\mathbf{x}))$, entonces $g(\mathbf{x}) \leq \mathbf{0}$ si $g_i(\mathbf{x}) \leq 0$ para todo $i = 1, \dots, m$.

■ De manera similar se interpreta la condición $h(\mathbf{x}) = \mathbf{0}$. Hay otras formas generales de escribir problemas de optimización. Ésta se llama **forma estándar**.

Ejemplo 4 [Una variable]

Se necesita hallar el máximo de de la función $f(x) = x^3 - 2x + 3$, siempre que $x \leq 1$.

Solución: Al ser un polinomio de grado 3, resulta evidente que tiene al menos una raíz real y usando el teorema de Bolzano, resulta también sencillo verificar que $f(x) = 0$ si y sólo si, $x \in [-2, -1]$.




Planteamiento

$$\left\{ \begin{array}{ll} \max_{x \in \mathbb{R}} & x^3 - 2x + 3 \\ \text{Sujeto a:} & x \leq 1 \\ & x \in \mathbb{R} \end{array} \right.$$

Ejemplo 5 [Dos variables]

Se necesita hallar el máximo de la función $f(a, b) = \sin^2(a) \cos(b)$, siempre que $a, b \in (0, 2\pi]$.

Solución: Este caso resulta un poco más complicado, en efecto si usamos Matlab queda:



Planteamiento

$$\left\{ \begin{array}{ll} \max_{(a,b) \in \mathbb{R}^2} & \sin^2(a) \cos(b) \\ \text{Sujeto a:} & a \in (0, 2\pi] \\ & b \in (0, 2\pi] \end{array} \right.$$



Reflexiones

- 1 Es posible formular un problema de diversas maneras. Por tanto, no existe una formulación única.
 - 2 Si se quiere minimizar $f(\mathbf{x})$, también se puede maximizar $-f(\mathbf{x})$
 - 3 Resulta necesario uniformizar la formulación, para así generar un método.
-
-

Definición [Región factible]

La **región factible** $\mathcal{F}$ de un problema de optimización, es el conjunto de puntos que satisfacen todas las restricciones del problema, es decir:

$$\mathcal{F} = \{\mathbf{x} \in \mathbb{X} : h(\mathbf{x}) = 0, g(\mathbf{x}) \leq 0\}$$

En consecuencia,

Definición [Solución factible]

Se dice que $\mathbf{x} \in \mathbb{X}$ es una **solución factible**, si y sólo si $\mathbf{x} \in \mathcal{F}$.

¿Cuál de estas soluciones interesan?

- 👍 La solución que interesa, es la que proporciona el valor más favorable de la función objetivo.
- 👍 El valor más favorable significa obtener el valor más grande si la función objetivo debe maximizarse, o el valor más pequeño si la función objetivo debe minimizarse.

Definición [Solución óptima]

Sea $\mathbf{x}^* \in \mathcal{F}$. Entonces, $\mathbf{x}^*$ es una solución óptima siempre que:

- ① $f(\mathbf{x}) \leq f(\mathbf{x}^*)$, para todo $\mathbf{x} \in \mathcal{F}$ si el objetivo es maximizar f .
- ② $f(\mathbf{x}) \geq f(\mathbf{x}^*)$, para todo $\mathbf{x} \in \mathcal{F}$ si el objetivo es minimizar f .

Para los ejemplos anteriores, tenemos que las regiones factibles están dadas por:

Ejemplo 4 $\mathcal{F} = \{x \in \mathbb{R} : x \leq 1\} = (-\infty, 1]$. Por ejemplo, $x = 0$ es una solución factible, pero $x = \sqrt{\frac{2}{3}}$ es la solución óptima.

Ejemplo 5 $\mathcal{F} = \{(a, b) \in \mathbb{R}^2 : 0 < a \leq 2\pi, 0 < b \leq 2\pi\}$. Por ejemplo, $(a, b) = (\pi, \pi)$ es una solución factible, pero $(a, b) = (\frac{\pi}{2}, 2\pi)$ es una solución óptima.

Entonces, podemos clasificar en distintos tipos de problemas:

- ➊ **Optimización sin restricciones:** Un problema sin restricciones se puede interpretar como el problema anterior con g y h siendo funciones idénticamente nulas (o, si se quiere, tomando $m = p = 0$).
- ➋ **Optimización con restricciones de desigualdad:** Tomamos $m \neq 0$ y $p = 0$.
- ➌ **Optimización con restricciones de igualdad:** Tomamos $m = 0$ y $p \neq 0$.
- ➍ **Optimización con restricciones mixtas:** Tomamos $m \neq 0$ y $p \neq 0$.
- ➎ **Optimización lineal:** Cuando la función objetivo es de la forma $c^T \mathbf{x}$, esto es, una función lineal.

Clasificación de Problemas de Optimización

① De acuerdo a la forma de $f(x)$ y las restricciones:

- **Programación Lineal:** $f(x)$ y las restricciones son lineales.
- **Programación No Lineal:** $f(x)$ es no lineal y las restricciones pueden ser no lineales.

② De acuerdo a la presencia o no de restricciones:

- **Optimización No Restringida:** El problema de optimización no tiene restricciones.
- **Optimización Restringida:** El problema de optimización tiene restricciones.

Clasificación de Problemas de Optimización

③ Según su dimensionalidad:

- **Optimización Unidimensional:** Función objetivo de una variable.
- **Optimización Multidimensional:** Función objetivo de varias variables.

④ Según el número de funciones objetivo:

- **Optimización con un Objetivo:** Una sola función objetivo.
- **Optimización con múltiples funciones Objetivo:** Varias funciones objetivo.

Teorema (Karush - Kuhn - Tucker)

Consideramos un problema de optimización en forma estándar con f, g y h funciones de clase $\mathcal{C}^1$. Sea

$$\mathcal{F} = \{\mathbf{x} \in \mathcal{U} : h(\mathbf{x}) = 0, g(\mathbf{x}) \leq 0\}$$

el conjunto de las soluciones factibles y $\mathbf{x}_0 \in \mathcal{F}$. Entonces:

- ① Si f es una función convexa, $\mathcal{F}$ es un conjunto convexo y $\mathbf{x}_0$ realiza un mínimo local, entonces $\mathbf{x}_0$ realiza también un mínimo global.

Continuación ...

② Si f, g_i son funciones convexas y $h_j = A_j \mathbf{x} + b_j$, $j = 1, \dots, p$ con A_j matrices $n \times p$ y $b_j \in \mathbb{R}^p$. Entonces dado $\mathbf{x}_0 \in \mathcal{F}$, si existen constantes $\mu_i \geq 0$, $i = 1, \dots, m$ y λ_j , $j = 1, \dots, p$, tales que:

$$\nabla f(\mathbf{x}_0) = \sum_{i=1}^m \mu_i \nabla g_i(\mathbf{x}_0) + \sum_{j=1}^p \lambda_j \nabla h_j(\mathbf{x}_0) = \mathbf{0}$$

y

$$\mu_i g_i(\mathbf{x}_0) = 0, \quad i = 1, \dots, m$$

entonces $\mathbf{x}_0$ realiza un mínimo global.

Optimización Discreta

Generalizando un poco más la escritura de nuestro problema de optimización, podemos escribir:

$$\begin{cases} \min_{\mathbf{x} \in \mathbb{X}} & f(\mathbf{x}) \\ \text{Sujeto a:} & \mathbf{x} \in \mathcal{F} \end{cases}$$

donde f es un campo escalar. Consideremos $\mathbb{X}$ un conjunto discreto, entonces:

- 1 $\mathbb{X} = \mathbb{R}^n$ (Variables enteras)
- 2 $\mathbb{X} = \{0, 1\}^n$ (Variables binarias)
- 3 $\mathbb{X} = \mathbb{R}^r \times \mathbb{Z}^s \times \{0, 1\}^t$ (posiblemente con $r = 0$, $s = 0$ o $t = 0$ - Variables mixtas)

Ejemplo

Supongamos que, en una empresa, hay n trabajos a repartir entre n trabajadores. Supongamos también que pretendemos asignar a cada persona un solo trabajo. Supongamos que el costo de que el trabajador i realice el trabajo j es c_{ij} . El costo se puede asignar de distintas maneras, por ejemplo, puede ser el tiempo estimado tardará el trabajador i a completar el trabajo j . Nos planteamos el problema de realizar la asignación de trabajos minimizando el costo. Tomamos $\mathbb{X} = \{0, 1\}^{n^2}$. Convendremos que $x_{ij} = 1$ si al trabajador i se le asigna el trabajo j y $x_{ij} = 0$ en otro caso. Como cada a cada trabajador se le puede asignar un sólo trabajo, tenemos la restricción:

$$\sum_{j=1}^n x_{ij} = 1 \quad , \quad j = 1, \dots, n$$

Como todo trabajo tiene que ser asignado, tenemos la restricción



$$\sum_{i=1}^n x_{ij} = 1 \quad , \quad j = 1, 2, \dots, n.$$

El costo total de cada asignación será $\sum_{j=1}^n \sum_{i=1}^n c_{ij} x_{ij}$.

En particular, podemos escribir el problema de optimización como minimizar

$$\left\{ \begin{array}{ll} \min & \sum_{j=1}^n \sum_{i=1}^n c_{ij} x_{ij} \\ \text{Sujeto a:} & \sum_{i=1}^n x_{ij} = 1 \quad , \quad j = 1, 2, \dots, n. \\ & \sum_{j=1}^n x_{ij} = 1 \quad , \quad i = 1, 2, \dots, n. \end{array} \right.$$

Podemos clasificar este problema como un problema lineal de variables binarias con restricciones.



Métodos Heurísticos

■ Los **algoritmos metaheurísticos** son, en el contexto de la optimización, técnicas de búsqueda globales adecuadas para tratar problemas complicados. Ya hemos visto que, para tratar problemas de optimización continuos, necesitamos ciertas hipótesis sobre las funciones involucradas en el problema.

■ Aunque se cumplan tales hipótesis, a veces, la dimensión del problema puede ser tan grande que evaluar la matriz Hessiana tiene un costo computacional prohibitivo. Más adelante, veremos que muchos de los algoritmos que plantearemos para la solución de problemas continuos tienen hipótesis extras para asegurar su convergencia. Todo este cúmulo de circunstancias justifican la implementación de métodos metaheurísticos.


■ El **método heurístico** más simple que uno puede imaginar, es el método de ensayo y error. Esto es, verificar la condición de optimalidad para un conjunto de soluciones factibles (cuanto más soluciones factibles, mejor).

■ Una gran parte de los métodos metaheurísticos de alto nivel dependen de ciertos parámetros aleatorios, lo que significa que la solución obtenida depende fuertemente de la manera en que se generan ciertas variables aleatorias. Veremos:

✓ **Algoritmos Genéticos:** La idea general de estos algoritmos es codificar toda solución factible como una cadena de símbolos (los genes).

✓ **Algoritmos de enjambre:** Estos algoritmos pretenden emular el comportamiento de un enjambre (generalmente de insectos o partículas)

Teoría



Teoría de Control

Un **sistema dinámico**, es un conjunto de estados y una regla que rige el cambio de estos estados a través del tiempo.

Las **ecuaciones diferenciales**, dan lugar a sistemas dinámicos continuos y son la base para afrontar muchos de los problemas de la vida real.

Matemáticamente un sistema dinámico continuo, es un problema de Cauchy asociado a una ecuación diferencial, esto es

$$\begin{cases} \mathbf{x}' &= f(\mathbf{x}, t, \mathbf{c}) \\ \mathbf{x}(0) &= \mathbf{x}_0 \end{cases}$$

Donde $t \in \mathbb{R}$ (podemos suponerlo positivo), $\mathbf{x} \in \mathbb{R}^n$ y $\mathbf{c} \in \mathbb{R}^m$ es una constante del sistema.

Introducir un **control**, significa considerar una función $\alpha : \mathbb{R} \longrightarrow \mathbb{R}^m$ y considerar el problema:

$$\begin{cases} \mathbf{x}' &= f(\mathbf{x}, t, \alpha(t)) \\ \mathbf{x}(0) &= \mathbf{x}_0 \end{cases}$$

Dado, t y $\mathbf{x}_0$, llamamos respuesta del sistema a la trayectoria $\mathbf{x}$ de la solución del problema de Cauchy anterior. En principio, no se tiene ninguna pista acerca de qué control utilizar.

Por tanto, el problema también induce, de manera natural, un funcional de costo, escrita como:

$$F(\alpha) := \int_0^t r(\mathbf{x}(s), \alpha(s)) ds + g(\mathbf{x}(t))$$

Se espera:

- ✓ Minimizar el funcional F , pero las soluciones ahora se eligen en un espacio de dimensión infinita.
- ✓ Se deben usar técnicas de Análisis Funcional y Cálculo Variacional, para formular condiciones de necesidad y suficiencia.
- ✓ Surgen preguntas naturales sobre si existe un control óptimo o no, si es posible determinarlo caracterizando su existencia o bien, si es posible calcularlo.

Recomendaciones

- 1 Realizar una revisión de **Álgebra Básica**
 - **Polinomios - Raíces.**
 - Evaluación de Funciones.
- 2 Realizar un repaso exhaustivo de Cálculo Diferencial.
 - **Derivadas** de funciones básicas - Propiedades.
 - Cálculo de **Valores Extremos.**
- 3 Realizar un repaso del Cálculo Multivariable.
 - Funciones de varias variables.
 - Derivadas Parciales - **Gradiente - Jacobiano - Hessiano.**
- 4 Revisar algunos conceptos de Álgebra Lineal, tales como:
 - Matrices
 - Sistemas de Ecuaciones
 - Formas cuadráticas

UNIVERSIDAD INTERNACIONAL DE LA RIOJA

