

Curso: Optimización - Sesión: 3

Tema 2: OPTIMIZACIÓN UNIDIMENSIONAL - PARTE II

Prof. Marlon Ernesto Moscoso Martínez

UNIVERSIDAD INTERNACIONAL DE LA RIOJA




Optimización PER11087

2024 - 2025

email: marlonernesto.moscoso-externo@unir.net

PROBLEMA

¿Cómo localizar el extremo local de la función $f(x)=x^3-3x+4$ usando los métodos de Newton-Raphson y de rectas inexactas?



Algoritmo iterativo:

$$x_{k+1} = x_k - \frac{f'(x_k)}{f''(x_k)}$$

Figura 1. Método de Newton para optimización

↓¹/₉ Contenido


1 Métodos basados en Regularidad

- Método de Bisección
- Método de Newton


2 Método de Rectas Inexactas



Esquema del Tema



Métodos basados en Regularidad




Método de Bisección

- Supongamos $f \in \mathcal{C}^1(I)$ [**Función unimodal**].
- Podemos reducir el problema de minimización a encontrar un cero de la derivada, basándonos en el Teorema de Bolzano.
- Dado un intervalo $[a_0, b_0]$, evaluamos la derivada de la función en sus extremos. Supongamos la derivada toma signos distintos. Esto implica que la función es creciente en uno de los extremos y decreciente en el otro. Por tanto, el extremo relativo estará contenido en el intervalo.
- Definimos $c_0 = \frac{a_0 + b_0}{2}$, esto es, el punto medio del intervalo. Evaluamos ahora la derivada en c_0 .

Algoritmo de Bisección

- Si la derivada es nula, entonces c_0 es el mínimo.
- Supongamos que la derivada en c_0 es distinta de cero. Entonces, es positiva o negativa. En cualquier caso, su signo será opuesto al de a_0 o al de b_0 . El algoritmo se puede esquematizar de la siguiente manera:
 - Dados a_0 y b_0 , se calcula $c_0 = \frac{a_0+b_0}{2}$.
 - Calculamos el valor $f'(c_0)$. Si $|f'(c_0)|$ es suficientemente pequeño (menor que una tolerancia dada), entonces el programa retorna c_0 .
 - En caso contrario, comprobamos el signo de $f'(c_0)$ y reemplazamos a_0 o b_0 por c_0 de manera que el nuevo intervalo tome valores con signos opuestos en sus extremos.



Método de Newton-Raphson

- Este método, ayuda en la búsqueda de las raíces de una función dada, construyendo una sucesión que se aproxime a dichos puntos.
- Este método exige derivabilidad, para ser utilizado para encontrar un cero de una función.
- Consideremos el desarrollo de Taylor de primer orden en un entorno de $x_n \in \mathcal{F}$:

$$f(x) \approx f(x_n) + f'(x_n)(x - x_n)$$


- Al evaluar en x_{n+1} , queda:

$$f(x_{n+1}) = f(x_n) + f'(x_n)(x_{n+1} - x_n)$$

Si asumimos que $x_{n+1} \rightarrow x^*$, entonces $f(x_{n+1}) \approx 0$.

■ En consecuencia, nos queda:

$$x_{n+1} = x_n - \frac{f(x_n)}{f'(x_n)}$$



■ Consideremos el desarrollo en serie de Taylor de orden 2 de la función f alrededor de un punto x_0 :

$$f(x_0 + h) = f(x_0) + f'(x_0)h + \frac{1}{2}f''(x_0)h^2 + \mathcal{O}(h^3)$$

Método de Newton-Raphson

- Encontramos el mínimo del polinomio de orden 2 en h :

$$f(x_0) + f'(x_0)h + \frac{1}{2}f''(x_0)h^2$$


En este caso, hay que calcular el mínimo de la parábola, que viene dado por:

$$h = \frac{f'(x_0)}{f''(x_0)}$$



- Como se necesita minimizar una función, entonces si queremos aplicar el método de Newton es imperante aplicárselo a f' .
- Para efectos de hallar valores extremos de una función, debemos entonces pedir a la función que sea de clase $\mathcal{C}^2$.
- En este caso, el método iterativo queda reflejado por:

$$x_{n+1} = x_n - \frac{f'(x_n)}{f''(x_n)}$$



Algoritmo de Newton

- El algoritmo iterativo construido con el esquema del método de Newton se desglosa en los siguientes puntos:

Algoritmo Método de Newton

Establece punto inicial $\mathbf{x}$ y tolerancia δ

Mientras $|f'(\mathbf{x})| > \delta$ realiza

 Calcula $f'(\mathbf{x})$ y $f''(\mathbf{x})$

 Actualiza $\mathbf{x} \leftarrow \mathbf{x} - \frac{f'(\mathbf{x})}{f''(\mathbf{x})}$

Imprime $\mathbf{x}$ y $f(\mathbf{x})$

Ejemplo 3

Supongamos que tenemos el siguiente problema de optimización:


$$\text{minimizar } x^4 + x^3 - 2x^2 - 4x + 1$$

■ Esta función tiene un mínimo que se puede calcular a mano. Este es:

$$x^* = -\frac{1}{4} + \frac{1}{12} \sqrt[3]{621 - 48\sqrt{87}} + \frac{\sqrt[3]{207 + 16\sqrt{87}}}{42^{2/3}} \approx 1.066$$

⚠ Implementar el Método de Newton para tratar de aproximar este mínimo.

Métodos de rectas



Inexactas

- El esfuerzo computacional en adelante, estará enfocado en el cálculo del gradiente (Derivada) de la función para así calcular la dirección del descenso al mínimo.
- Consecuentemente, la eficiencia de los métodos depende, en gran medida, de la capacidad que uno tenga de calcular eficientemente el gradiente de la función con precisión.
- Si se requiere mucha precisión, el coste computacional del método crecerá. En algunos métodos, no es necesario calcular el gradiente con una gran precisión para obtener una convergencia rápida.

■ Consideremos el problema: $\min_{\mathbf{x} \in \mathbb{R}} f(\mathbf{x})$, donde f es una función diferenciable para todo $\mathbf{x} \in \mathbb{R}$.

■ Este problema, se puede resolver aplicando los métodos de descenso. Estos métodos, generan una secuencia de puntos que van reduciendo el valor de la función objetivo, o más formalmente se construye una sucesión de puntos $\{x_k\}_{k \geq 1}$, donde se cumple que:

$$f(x_1) > f(x_2) > f(x_3) > \cdots > f(x_n) > \cdots$$

lo cual, se termina para algún criterio de parada escogido.

■ La familia más importante de estos métodos, son los de **Dirección de Descenso**, los cuales constan de dos pasos fundamentales: Selección de una dirección de descenso y luego, calcular el desplazamiento a lo largo de esa dirección.

Dirección de Descenso

■ Un vector $\mathbf{d} \in \mathbb{R}^n$, es una dirección descenso de f a partir de $\mathbf{x} \in \mathbb{R}^n$, si la derivada direccional de f en la dirección de $\mathbf{x}$, es negativa, es decir:

$$\nabla f(\mathbf{x})^T \cdot \mathbf{d} < 0$$


■ En efecto, si $\mathbf{d} = -\nabla f(\mathbf{x})$, tenemos:

$$\nabla f(\mathbf{x})^T \cdot \mathbf{d} = -\nabla f(\mathbf{x})^T \cdot \nabla f(\mathbf{x}) = -\|\nabla f(\mathbf{x})\|^2 \leq 0$$

Luego, $\mathbf{d}$ es la dirección de máximo descenso, pero no es la única.

■ **Caracterización:** Si $\nabla f(\mathbf{x})^T \cdot \mathbf{d} < 0$, entonces:

$$\|\nabla f(\mathbf{x})\| \|\mathbf{d}\| \cos \theta < 0 \rightarrow \cos \theta < 0 \rightarrow \frac{\pi}{2} < \theta < \frac{3\pi}{2}$$



✏ **Nota:** Por ello, buscar un método para localizar la mejor dirección de descenso es importante.

Proposición

Sea $f : \mathbb{R}^n \rightarrow \mathbb{R}$, $f \in \mathcal{C}^1$. Si existe $\mathbf{d} \in \mathbb{R}^n$, tal que $\nabla f(\mathbf{x})^T \cdot \mathbf{d} < 0$. Entonces, existe $\lambda > 0$ tal que: $f(\mathbf{x} + \lambda \mathbf{d}) < f(\mathbf{x})$. $\square$

 **Observación:** El problema radica en cómo escoger a λ .

Demostración: Sea $\varphi(\lambda) = f(\mathbf{x} + \lambda \mathbf{d}) \rightarrow \varphi(0) = f(\mathbf{x})$. Además,

$$\varphi'(\lambda) = \nabla f(\mathbf{x})^T \cdot \mathbf{d} \rightarrow \varphi'(0) = \nabla f(\mathbf{x})^T \cdot \mathbf{d} < 0$$

ya que, $\mathbf{d}$ es una dirección de descenso. En efecto,

$$\varphi'(0) = \lim_{\lambda \rightarrow 0} \frac{\varphi(\lambda) - \varphi(0)}{\lambda} < 0 \rightarrow \varphi(\lambda) < \varphi(0)$$

de donde, $f(\mathbf{x} + \lambda \mathbf{d}) < f(\mathbf{x})$. $\checkmark$

Algoritmo básico en la iteración k

Paso 1 Dado el punto x_k .

Paso 2 Calculamos la dirección de descenso d_k .


Paso 3 Asignamos $x_{k+1} = x_k + \lambda d_k$, para algún λ que haga "aceptable" a x_{k+1}

⚠ ¿Importa la selección de la dirección de descenso?

Ejemplo 1

Considere a la función $y = \cosh(x)$, donde $x_0 = 2$ y la dirección de descenso es constante $d_k = -1$ con $\lambda_k = 2^{-(k+1)}$. Trate de aproximar el valor donde se alcanza el mínimo ($x^* = 0$).

- Observe que en efecto d_k es una dirección de descenso.
- Sabemos que $y' = \sinh(x)$
- $d_k y' < 0$, ya que $x > 0$.




✍ **Nota:** Parece que 1.5000 es una barrera. En realidad, el problema está en la elección de d y del paso.

Ejemplo 2

Consideremos ahora la función $f(x) = x^2$, con $x_0 = 2$ y con $d_k = -\text{sgn}(x_k)$ y el paso lo determinamos por: $\lambda_k = 2 + 3 \cdot 2^{-k-1}$.

Iteración	x_k	d_k	α_k
0	2.00000	-1	3.500000
1	-1.50000	1	2.750000
2	1.25000	-1	2.375000
3	-1.12500	1	2.187500
4	1.06350	-1	2.093750
5	-1.03125	1	2.046875
$\vdots$	$\vdots$	$\vdots$	$\vdots$
48	-1.00000	-1	2.000000
49	1.00000	1	2.000000
50	-1.00000	-1	2.000000



■ Haciendo un análisis, podemos constatar que a partir de cierto valor de $k \in \mathbb{N}$, la sucesión se comportará:


$$x_k = (-1)^k [1 + 2^{-k}] \rightarrow |x_{k+1}| < |x_k| \rightarrow x_{k+1}^2 < x_k^2$$

Luego, $f(x_{k+1}) < f(x_k)$ y esto verifica que la función decrece y tenemos un punto focal de un método para descender.

⚠ ¿Qué sucede para $k \rightarrow \infty$?

$\lim_{k \rightarrow \infty} x_k$ No Existe

¿Por qué el método no converge?



Ejemplo 3

Consideremos ahora la función $f(x) = x^2$, con $x_0 = 2$ y con $d_k = -1$ y el paso lo determinamos por: $\lambda_k = 2^{-k}$.

■ **Observe que:** $x_{k+1} = x_k + d_k \lambda_k \rightarrow x_{k+1} = x_k - 2^{-k-1}$

Iteración	x_k	d_k	λ_k	x_k
0	2	-1	2^{-1}	$2 = 1 + 2^0$
1	$\frac{3}{2}$	-1	2^{-2}	$\frac{3}{2} = 1 + 2^{-1}$
2	$\frac{5}{4}$	-1	2^{-3}	$\frac{5}{4} = 1 + 2^{-2}$
3	$\frac{9}{8}$	-1	2^{-4}	$\frac{9}{8} = 1 + 2^{-3}$
$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$
$k + 1$	x_k	-1	2^{-k-1}	$x_k = 1 + 2^{-k}$

■ **Observe que:** $x_{k+1} < x_k$, lo que implica directamente que:

$$f(x_{k+1}) < f(x_k)$$

Por tanto, disminuye siempre.


■ Por otra parte,

$$\lim_{k \rightarrow \infty} x_k = 1 \neq 0 = x^*$$

■ **¿El Problema?** Los pasos son cada vez más pequeños y en efecto, aunque $\lambda_k > 0$ se tiene que:

$$\lim_{k \rightarrow \infty} \lambda_k = \lim_{k \rightarrow \infty} 2^{-k-1} = 0$$

En consecuencia, se deben evitar los pasos muy pequeños.



🗨 Observaciones:

- La dirección de descenso es un concepto local. Inspirado en Taylor.
- Esto asume pequeños pasos.
- Cuando hay muchos pasos el Teorema de Taylor deja de aplicarse.
- En cualquier dirección de ascenso, la función podría decrecer para muchos iterados.
- La solución es evitar muchos iterados.

Búsqueda Lineal

■ El proceso de búsqueda de λ , lo realizaremos en dos tandas: **Búsqueda lineal exacta** y la **Búsqueda lineal inexacta**. Veamos,


1 Búsqueda Lineal Exacta

Necesitamos resolver el problema de minimización unidimensional:

$$\min_{\lambda \in \mathbb{R}} \varphi(\lambda)$$

O bien, hallar:

$$\lambda^* = \arg \min \varphi(\lambda)$$



Básicamente, hacemos $\varphi'(\lambda) = 0 \rightarrow \nabla f(\mathbf{x} + \lambda \mathbf{d})^T \cdot \mathbf{d} = 0$.

✍ **Nota:** Para este proceso de búsqueda, se puede aplicar Fibonacci.

Ejemplo 1 Volviendo al Ejemplo anterior, nos queda:

- Sabemos que $f(x) = \cosh x \rightarrow f'(x) = \sinh x$.
- Consideramos $d = -1$, con $x_0 = 2$.
- $f'(2 + \lambda(-1))(-1) = 0 \rightarrow -\sinh(2 - \lambda) = 0 \rightarrow \lambda = 2$

Entonces, con $\lambda = 2$ se hubiese resuelto el problema en un solo paso.

② Búsqueda Lineal Inexacta (Alg. de Contracción de Paso)

Por lo general, se inicia el proceso con $\lambda = 1$ y si no se encuentra la dirección, este se va a ir encogiendo multiplicándolo por un factor $\alpha \in (0, 1)$.

Algoritmo de Contracción de Paso


Establece λ inicial: $\lambda = 1$ y contractor $\alpha = 0.5$

Mientras Condición sea Falsa realiza

Actualiza $\lambda \leftarrow \alpha\lambda$

Imprime λ

🗨 **Observación:** No es posible que se haga un ciclo infinito.



Condición de Armijo - Descenso suficiente

- Sea $\alpha \in (0, 1)$. Se suele tomar inicialmente $\alpha = 10^{-4}$.
- Sabemos que el descenso siempre refiere a: $f(\mathbf{x} + \lambda \mathbf{d}) \leq f(\mathbf{x})$.


Para lo cual, **Larry Armijo** agregó:

$$\begin{array}{ccccc}
 \boxed{f(\mathbf{x} + \lambda \mathbf{d})} & \leq & \boxed{f(\mathbf{x})} & + & \boxed{\alpha \lambda \nabla f(\mathbf{x})^T \cdot \mathbf{d}} \\
 \uparrow & & \uparrow & & \uparrow \\
 \text{Buscado} & & \text{Descenso} & & \text{Pequeño y negativo} \\
 & & \text{Siempre} & & \text{proporcional a } \nabla f(\mathbf{x})
 \end{array}$$

- Escrito en términos de φ , nos queda:

$$\underbrace{\varphi(\lambda)}_{\text{Curva}} \leq \underbrace{\varphi(0) + \alpha \lambda \varphi'(0)}_{\text{Recta de variable } \lambda}$$

■ La idea es que λ sea lo más grande posible y con esto se puedan dar pasos largos o mayores.




Condición de Goldstein - Condición de Curvatura

■ Condición propuesta por **Allen Goldstein**. Sea $\beta \in (\alpha, 1)$. Entonces,


$$\boxed{\beta \nabla f(\mathbf{x})^T \cdot \mathbf{d}} \leq \boxed{\nabla f(\mathbf{x} + \lambda \mathbf{d})^T \cdot \mathbf{d}}$$

$$\downarrow \qquad \qquad \downarrow$$

$$\boxed{\beta \varphi'(0)} \leq \boxed{\varphi'(\lambda)}$$




- Permite que se utilicen valores de λ más grandes. En efecto, prohíbe usar valores pequeños.



Teorema [Wolfe] - Phillip Wolfe - 1969

Sea $f : \mathbb{R}^n \rightarrow \mathbb{R}$ continuamente diferenciable y sea $\mathbf{x}_k \in \mathbb{R}^n$ y $\mathbf{d}_k$ una dirección de descenso. Supongamos que para $\lambda > 0$ el conjunto $\{f(\mathbf{x} + \lambda \mathbf{d}_k)\}$ está acotado inferiormente. Si $0 < \alpha < \beta < 1$, entonces existen $\lambda_G, \lambda_A > 0$ con $\lambda_G < \lambda_A$, tales que: $\mathbf{x}_{k+1} = \mathbf{x}_k + \lambda \mathbf{d}_k$, satisface las condiciones de Armijo y de Goldstein, siempre que $\lambda \in (\lambda_G, \lambda_A)$ $\square$



■ Consideraciones iniciales:

$$\alpha \leftarrow 10^{-4}, \beta \leftarrow 10^{-1}, k \leftarrow 0, \varepsilon \leftarrow 10^{-6}, N \leftarrow 50$$

Establece $\mathbf{x}_0$ inicial

Mientras $\|\nabla f(\mathbf{x}_k)\| \geq \varepsilon$ y $k \leq N$ realiza

 Calcular $\mathbf{d}_k$ (Búsqueda 1-dimensional)

$\lambda \leftarrow 1$

 Mientras $f(\mathbf{x}_k + \lambda \mathbf{d}_k) > f(\mathbf{x}_k) + \alpha \lambda \nabla f(\mathbf{x}_k)^T \cdot \mathbf{d}_k$
 y $\beta \nabla f(\mathbf{x}_k)^T \cdot \mathbf{d}_k > \nabla f(\mathbf{x}_k + \lambda \mathbf{d}_k)^T \cdot \mathbf{d}_k$
 Actualiza $\lambda \leftarrow 0.5\lambda$

 Fin

 Actualiza $\mathbf{x}_k \leftarrow \mathbf{x}_k + \lambda \mathbf{d}_k$

 Actualiza $k \leftarrow k + 1$

Fin

Imprime $\mathbf{x}_k$

Ejemplo 4

Determine el valor óptimo para la función: $f(x) = x^4 + x + 3$

Paso 1: Iniciamos con el punto $x_0 = -1.5$ y $\lambda = 1$

Paso 2: Recordamos las condiciones de Wolfe (Armijo-Goldstein)

$$\textcircled{1} \quad \rightarrow \quad f(x_k + \lambda d_k) \leq f(x_k) + \alpha \lambda f'(x_k) d_k$$

$$\textcircled{2} \quad \rightarrow \quad \beta f'(x_k) d_k \leq f'(x_k + \lambda d_k) d_k$$

Paso 3: Calculamos la derivada de f : $f'(x) = 4x^3 + 1$

Paso 4: Elegimos las constantes: $\beta = 0,1$ y $\alpha = 0,9$, de forma arbitraria, donde $0 < \beta < \alpha < 1$.

👉 Observemos que, para $\lambda = 1$ se verifican las dos condiciones del teorema de Wolfe:

$$\begin{aligned}
 \textcircled{1} \quad 2.5625 &= f(x_0 + \lambda d_0) = f(-1.5 + 1 \cdot 1) \\
 &\leq f(x_0) + \alpha \lambda f'(x_0) d_0 = f(-1.5) + 0.9 \cdot 1 \cdot f'(-1.5) \cdot 1 \\
 &= 6.5625 + 0.9 \cdot 12.5 = 17.8125
 \end{aligned}$$

$$\begin{aligned}
 \textcircled{2} \quad -1.25 = 0.1 \cdot 12.5 \cdot 1 &= \beta f'(x_0) \cdot d_0 \\
 &\leq f'(x_0 + \lambda d_0) \cdot d_0 = f'(-1.5 + 1 \cdot 1) \cdot 1 \\
 &= f'(-0.5) = 0.5
 \end{aligned}$$

👉 Aceptamos el valor de $\lambda = 1$ y tomamos $x_1 = -1,5 + 1 = -0.5$.

Paso 5: Tomamos $x_1 = -0,5$, con $\lambda = 1$.

$$[d_1 = -\text{sgn}(f'(-0.5)) = -1]$$

👉 Observemos que la primera condición de Wolfe (Armijo):

$$\begin{aligned} \textcircled{1} \quad 6.5625 &= f(x_1 + \lambda d_1) = f(-0.5 - 1 \cdot 1) \\ &\not\leq f(x_1) + \alpha \lambda f'(x_1) d_1 = f(-0.5) - 0.9 \cdot 1 \cdot f'(-0.5) \cdot 1 \\ &= 2.5625 - 0.9 \cdot 0.5 = 2.1125 \end{aligned}$$

no se verifica.



λ es **demasiado grande**: Tomemos $\lambda = 0.5$.



En los dos siguientes iterados tampoco se verifica la primera condición de Wolfe, por lo que reduciremos dos veces más hasta tomar el valor $\lambda = 0.125$.

Material para Revisar

$$f(x_1 + \lambda d_1) = 2.5276 \leq 2,56 = f(x_1) + \alpha \lambda d_1 f'(x_1),$$

y

$$d_1 f'(x_1 k + \lambda d_1) = -0.00234 \geq -0.05 = \beta d_1 f'(x_1)$$

👍 Así pues, aceptamos $\lambda = 0.125$. Con lo que:

$$x_2 = -0.5 + (-1)0.125 = -0,625$$

👍 Repitiendo el proceso obtenemos los valores $x_3 = -0.6328$ y $x_4 = -0.6289$.

⚠️ Recuerde que estamos aproximando: $x^* = -\sqrt[3]{\frac{1}{4}} \approx -0.6299$.

UNIVERSIDAD INTERNACIONAL DE LA RIOJA

