

Curso: Optimización - Sesión: 6
TEMA 4: OPTIMIZACIÓN SIN RESTRICCIONES

Prof. Marlon Ernesto Moscoso Martínez

UNIVERSIDAD INTERNACIONAL DE LA RIOJA



Optimización PER11087

2024 - 2025

email: marlonernesto.moscoso-externo@unir.net

PROBLEMA

¿Cómo usar los métodos multivariantes de Newton y el Gradiente para aproximar extremos de funciones?

Función a minimizar: $f(x_1, x_2) = (x_1 - 2)^2 + (x_2 - 3)^2 + e^{\{x_1^2 + x_2^2\}}$

Iteración	x_1	x_2	$f(x_1, x_2)$	Error_1	Error_2
1	0	0	14	1.8028	89.383
2	1	1.5	29.04	0.22986	33.277
3	0.8725	1.3087	16.002	0.23236	11.643
4	0.74361	1.1154	11.162	0.20275	3.3695
5	0.63114	0.94671	9.7393	0.11949	0.57011
6	0.56486	0.84729	9.5144	0.029477	0.024404
7	0.54851	0.82276	9.5058	0.0013775	4.9358e-05
8	0.54774	0.82162	9.5058	2.7974e-06	2.0284e-10
9	0.54774	0.82161	9.5058	1.1496e-11	9.9301e-16


Solución óptima encontrada en la iteración 9:

$x_1 = 0.54774$

$x_2 = 0.82161$

Valor mínimo de $f(x_1, x_2) = 9.5058$

Optimización con Newton multidimensional



↓¹₉ Contenido

1 Introducción y Objetivos

- Esquema
- Objetivos

2 Método de Newton

- Costes del Método de Newton
- Pseudocódigo
- **Ejemplo de Aplicación de Newton**
 - Código Matlab

3 Método del Gradiente

- Dirección de descenso
- Pseudocódigo
- **Ejemplos de Aplicación de Gradiente**
 - Código Matlab

4 Método Cuasi-Newton



Esquema del Tema

Optimización sin Restricciones

Objetivo



$$\min_{\mathbf{x} \in \mathbb{R}^n} f(\mathbf{x})$$

Métodos de Resolución

Newton

Usar Newton
para

$$\nabla f(\mathbf{x}) = 0$$

Gradiente

Algoritmo

$$\mathbf{x}_{k+1} = \mathbf{x}_k - \alpha \nabla f(\mathbf{x}_k)$$

Búsqueda 1-dimensional
para dirección de descenso

Cuasi - Newton

Minimizar

$$q(\mathbf{p}) = f(\mathbf{x}_k) + \nabla f(\mathbf{x}_k)^T \mathbf{p} + \frac{1}{2} \mathbf{p}^T B_k \mathbf{p}$$

Introducción

- Resolveremos problemas de optimización **no** lineal, sin ninguna restricción, esto es:

$$\text{minimizar } f(\mathbf{x})$$

con $f : \mathbb{R}^n \rightarrow \mathbb{R}$.

- Los problemas de optimización sin restricciones, por ejemplo aparecen de manera natural en los ajustes de datos, donde la función objetivo mide la diferencia entre el modelo y los datos reales.
- Denotemos por $\mathbf{x}^*$ un candidato a solución. Para efectos prácticos, no tiene mucho sentido preguntarnos si ésta es una solución **global** ya que eso requeriría calcular información de la función en cada punto de $\mathbb{R}^n$.

■ Los candidatos a solución del problema, serán puntos donde se realicen mínimos locales. Esto es, un punto $\mathbf{x}^*$ que satisface la condición:

$$f(\mathbf{x}^*) < f(\mathbf{x}), \text{ para todo } \mathbf{x} \in \mathbb{R}^n, \text{ tal que } \|\mathbf{x} - \mathbf{x}^*\| < \varepsilon$$

para $\varepsilon > 0$ suficientemente pequeño.

■ El problema local estricto, debe verificar que: $0 < \|\mathbf{x} - \mathbf{x}^*\| < \varepsilon$.

- Si se supone además, que $f \in \mathcal{C}^2\{\mathbf{x}^*\}$. Usando la expansión de Taylor, queda que:

$$f(\mathbf{x}^* + \mathbf{p}) = f(\mathbf{x}^*) + \nabla f(\mathbf{x}^*)^T \mathbf{p} + \frac{1}{2} \mathbf{p}^T \nabla^2 f(\xi) \mathbf{p}$$



- Claramente, si $\mathbf{x}^*$ realiza un extremo, entonces:

$$\nabla f(\mathbf{x}^*) = \mathbf{0}$$

pero esta condición no es suficiente para garantizar un mínimo local, aunque si es necesaria. Es decir, hay puntos donde $\nabla f(\mathbf{x}^*) = \mathbf{0}$, pero en $\mathbf{x}^*$ no se alcanza un extremo.




Objetivos



- 1 Usar la versión del **Algoritmo de Newton**, para la exploración de extremos locales pero en el espacio n - dimensional.
- 2 Explorar la segunda derivada, para determinar que en $\mathbf{x}^*$ se minimiza a f . Por tanto, debe ocurrir que $\nabla^2 f(\mathbf{x}^*)$ sea definido positivo.
- 3 Mejorar el Método de Newton, disminuyendo costes y solicitando menos condiciones de regularidad (**Método del Gradiente**)

Método de Newton

Ejemplo de Aplicación de Newton



Método de Newton

Sea $f : \mathbb{R}^n \longrightarrow \mathbb{R}$ un campo escalar de clase $\mathcal{C}^2$. Entonces:

- Como vimos en el caso 1 - dimensional, el método de Newton es un método clásico para encontrar ceros de funciones no lineales.
- Como se requiere hallar extremos de f , es necesario resolver la ecuación:

$$\nabla f(\mathbf{x}) = \mathbf{0}$$

- En este sentido, resulta necesario hallar la **matriz jacobiana** de ∇f , es decir $\nabla^2 f$ (**Matriz Hessiana**).

■ El esquema numérico, quedaría:

$$\mathbf{x}_{k+1} = \mathbf{x}_k - [\nabla^2 f(\mathbf{x}_k)]^{-1} \nabla f(\mathbf{x}_k)$$

⚠ En este sentido, resulta necesario que la matriz hessiana sea **no** singular.

Forma habitual de Newton

Resulta habitual, escribir el esquema del **Método de Newton** como:

$$\mathbf{x}_{k+1} = \mathbf{x}_k + \mathbf{p}_k$$

donde $\mathbf{p}_k$ es la solución del sistema lineal:

$$\nabla^2 f(\mathbf{x}_k) \mathbf{p}_k = -\nabla f(\mathbf{x}_k)$$

■ La fórmula del método de Newton representa una iteración del esquema que aproxima el cero de una representación lineal de la función. Esa aproximación lineal, viene dada por:

$$\nabla f(\mathbf{x}_k + \mathbf{p}) \approx \nabla f(\mathbf{x}_k) + \nabla^2 f(\mathbf{x}_k) \mathbf{p}$$

■ Esta aproximación lineal, es el gradiente de la función cuadrática:

$$q_k(\mathbf{p}) = f(\mathbf{x}_k) + \nabla f(\mathbf{x}_k)^T \mathbf{p} + \frac{1}{2} \mathbf{p}^T \nabla^2 f(\mathbf{x}_k) \mathbf{p}$$

⚠ q_k corresponde a los tres primeros términos de la expansión en serie de Taylor de la función f alrededor del punto $\mathbf{x}_k$.

- La función cuadrática q_k , nos ofrece una nueva interpretación del método de Newton para minimizar f .
- En cada una de las iteraciones del método, se aproxima f por q_k y luego, se minimiza q_k .
- Se actualiza entonces el valor $\mathbf{x}_{k+1} = \mathbf{x}_k + \mathbf{p}$.



Observación



En cada iteración, se aproxima una función no lineal por una función cuadrática.



Costes del Método de Newton



- El método de Newton tiene convergencia cuadrática y esta convergencia no está garantizada.
- Si el método converge, entonces la convergencia se dará en un extremo relativo.
- Costes asociados al uso del método de Newton:
 - ① El cálculo del esquema.
 - ② El cálculo de las derivadas.
 - ③ El espacio de almacenamiento necesario para efectuar todas las operaciones.
- En su versión clásica, un iterado del método de Newton requiere calcular las segundas derivadas y resolver un sistema lineal.

- Para una función de n variables, las dimensiones de la matriz Hessiana son $n \times n$.
- Cada una de esas entradas significa, en general, programar cada una de las segundas derivadas parciales lo cual puede ser muy tedioso.
- Luego hay que resolver un sistema lineal de dimensiones $n \times n$, lo cual tiene un coste computacional del orden de n^3 .
- En resumen, el coste de un iterado del método de Newton crece rápidamente con n .

☰ Pseudocódigo

Algoritmo Método de Newton

Establece punto inicial $\mathbf{x}$ y tolerancia ε

Mientras $\|\nabla f(\mathbf{x})\| > \varepsilon$ realiza

 Calcula $\nabla f(\mathbf{x})$

 Calcula $\nabla^2 f(\mathbf{x})$ y $[\nabla^2 f(\mathbf{x})]^{-1}$

 Actualiza $\mathbf{x} \leftarrow \mathbf{x} - [\nabla^2 f(\mathbf{x})]^{-1} \nabla f(\mathbf{x})$

Imprime $\mathbf{x}$ y $f(\mathbf{x})$

Ejemplo (Newton)

Determine

$$\min_{(x_1, x_2) \in \mathbb{R}^2} f(x_1, x_2) = 3x_1^2 - 2x_1x_2 + x_2^2 + 3e^{-x_1}$$

Tomando $\mathbf{x}_0 = (0, 0)$ y una tolerancia $\varepsilon = 0.001$.

Paso 1 Calculamos $\nabla f(x_1, x_2)$ y $\nabla^2 f(x_1, x_2)$

$$\nabla f(x_1, x_2) = \begin{bmatrix} 6x_1 - 2x_2 - 3e^{-x_1} \\ -2x_1 + 2x_2 \end{bmatrix} \rightarrow \nabla f(0, 0) = \begin{bmatrix} -3 \\ 0 \end{bmatrix}$$

y

$$\nabla^2 f(x_1, x_2) = \begin{bmatrix} 6 + 3e^{-x_1} & -2 \\ -2 & 2 \end{bmatrix}$$

Paso 2 Calculamos $[\nabla^2 f(x_1, x_2)]^{-1}$ y evaluamos $\mathbf{x}_0 = (0, 0)$:

$$[\nabla^2 f(x_1, x_2)]^{-1} = \frac{1}{8 + 6e^{-x_1}} \begin{bmatrix} 2 & 2 \\ 2 & 6 + 3e^{-x_1} \end{bmatrix}$$

de donde

$$[\nabla^2 f(0, 0)]^{-1} = \frac{1}{14} \begin{bmatrix} 2 & 2 \\ 2 & 9 \end{bmatrix}$$

Paso 3 Buscamos el primer iterado:

$$\begin{aligned} \mathbf{x}_1 &= \mathbf{x}_0 - [\mathbf{H}_f(\mathbf{x}_0)]^{-1} \nabla f(\mathbf{x}_0) \\ &= \begin{bmatrix} 0 \\ 0 \end{bmatrix} - \frac{1}{14} \begin{bmatrix} 2 & 2 \\ 2 & 9 \end{bmatrix} \begin{bmatrix} -3 \\ 0 \end{bmatrix} = \frac{1}{7} \begin{bmatrix} 3 \\ 3 \end{bmatrix} \end{aligned}$$

Paso 4 Calculamos $\|\nabla f(\mathbf{x}_1)\|$

$$\left\| \nabla f \left(\frac{3}{7}, \frac{3}{7} \right) \right\| = \sqrt{\frac{18}{49}} \approx 0.60609 > 0.001$$

Paso 5 Buscamos el segundo iterado:

$$\nabla f \left(\frac{3}{7}, \frac{3}{7} \right) = \begin{bmatrix} -0.2400 \\ 0.0000 \end{bmatrix} \text{ y } \left[\nabla^2 f \left(\frac{3}{7}, \frac{3}{7} \right) \right]^{-1} = \begin{bmatrix} 0.1679 & 0.1679 \\ 0.1679 & 0.6679 \end{bmatrix}$$

Luego,

$$\begin{aligned} \mathbf{x}_2 &= \mathbf{x}_1 - [\mathbf{H}_f(\mathbf{x}_1)]^{-1} \nabla f(\mathbf{x}_1) \\ &= \frac{1}{7} \begin{bmatrix} 3 \\ 3 \end{bmatrix} - \begin{bmatrix} 0.1679 & 0.1679 \\ 0.1679 & 0.6679 \end{bmatrix} \begin{bmatrix} -0.2400 \\ 0.0000 \end{bmatrix} = \begin{bmatrix} 0.4689 \\ 0.4689 \end{bmatrix} \end{aligned}$$

Calculamos $\|\nabla f(\mathbf{x}_2)\|$

$$\|\nabla f(\mathbf{x}_2)\| = \|(-0.00147, 0)\| = 0.00147 > 0.001$$

Paso 6 Buscamos el tercer iterado, entonces:

$$\nabla f(0.4689, 0.4689) = \begin{bmatrix} -0.00147 \\ 0.00000 \end{bmatrix}$$

y

$$[\nabla^2 f(0.4689, 0.4689)]^{-1} = \begin{bmatrix} 0.17015 & 0.17015 \\ 0.17015 & 0.67015 \end{bmatrix}$$

$$\begin{aligned} \mathbf{x}_3 &= \mathbf{x}_2 - [\mathbf{H}_f(\mathbf{x}_2)]^{-1} \nabla f(\mathbf{x}_2) \\ &= \begin{bmatrix} 0.4689 \\ 0.4689 \end{bmatrix} + \begin{bmatrix} 0.17015 & 0.17015 \\ 0.17015 & 0.67015 \end{bmatrix} \begin{bmatrix} 0.00147 \\ 0.00000 \end{bmatrix} = \begin{bmatrix} 0.4691 \\ 0.4691 \end{bmatrix} \end{aligned}$$

Paso 7 Calculamos $\|\nabla f(\mathbf{x}_3)\|$

$$\|\nabla f(\mathbf{x}_3)\| = \|(-0.000295, 0)\| = 0.000295 < 0.001$$

Por tanto, detenemos el algoritmo y se imprime el valor de $\mathbf{x}_3 = (0.4691, 0.4691)$ y su valor en la función:

$$f(0.4691, 0.4691) = 2.31680$$

Método de Newton				
k	x_1	x_2	$\ \nabla f(x_1, x_2)\ $	$f(x_1, x_2)$
0	0	0	3	3
1	0.42857	0.42857	0.60609	2.321660
2	0.46890	0.46890	0.00147	2.316804867
3	0.46910	0.46910	0.0002951	2.316804691

Ejemplo (Newton)

Aplicar el método de Newton al siguiente problema de minimización sin restricciones:

$$\text{minimizar } (x - 2)^4 + (x - 2)^2 y^2 + (y + 1)^2$$

 **Nota:** Resulta sencillo verificar que en efecto, la solución a este problema es justamente: $\mathbf{x}^* = (2, -1)$.

Paso 1 Calcular el Gradiente de f y la Matriz Hessiana

- $\nabla f(x, y) = (4(x - 2)^3 + 2(x - 2)y^2, 2(x - 2)^2 y + 2(y + 1))$
- $\mathbf{H}f(x, y) = \begin{bmatrix} 12(x - 2)^2 + 2y^2 & 4(x - 2) \\ 4(x - 2)y & 2(x - 2)^2 + 2 \end{bmatrix}$

Paso 2 Evaluar en el punto inicial

$$\bullet \nabla f(1, 1) = (-6, 6) \quad \bullet \mathbf{H}f(1, 1) = \begin{bmatrix} 14 & -4 \\ -4 & 4 \end{bmatrix}$$

Paso 3 Hallar la inversa a la matriz Hessiana

$$[\mathbf{H}f(1, 1)]^{-1} = \begin{bmatrix} 14 & -4 \\ -4 & 4 \end{bmatrix}^{-1} \rightarrow [\mathbf{H}f(1, 1)]^{-1} = \frac{1}{20} \begin{bmatrix} 2 & 2 \\ 2 & 7 \end{bmatrix}$$

Paso 4 Calcular el primer iterado $\mathbf{x}_1$

$$\begin{aligned} \mathbf{x}_1 &= \mathbf{x}_0 - [\mathbf{H}f(\mathbf{x}_0)]^{-1} \nabla f(\mathbf{x}_0) \\ &= \begin{bmatrix} 1 \\ 1 \end{bmatrix} - \frac{1}{20} \begin{bmatrix} 2 & 2 \\ 2 & 7 \end{bmatrix} \begin{bmatrix} -6 \\ 6 \end{bmatrix} = \begin{bmatrix} 1 \\ -0.5 \end{bmatrix} \end{aligned}$$



</> Código Matlab

```


1  %%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%
2  %%                                ALGORITMO DE NEWTON                                %%
3  %%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%% PROF. ANDRÉS PÉREZ %%
4  %% Considere la función:  $f(X1,X2)=(X1-2)^4+(X1-2)^2X2^2+(X2+1)^2$  %%
5  %%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%
6  %% Cálculo del Gradiente de f - Vector de Derivadas Parciales
7  Df = @(x) [(4*(x(1)-2)^3 + 2*(x(1)-2)*x(2)^2);
8             (2*x(2)*(x(1)-2)^2+2*(x(2)+1))];
9  %% Cálculo de la Matriz Hessiana - Matriz de segunda derivadas parciales
10 DDF = @(x) [(12*(x(1)-2)^2+2*x(2)^2) (4*(x(1)-2)*x(2));
11             (4*(x(1)-2)*x(2)) (2*(x(1)-2)^2+2)];
12 %% Parámetros de Inicio del Algoritmo
13 x0 = [1,1]; % Iterado Inicial - Punto de Inicio
14 maxiter=10; % Número máximo de iteraciones
15 tol =1E-12; % Tolerancia pedida - Criterio de Parada
16 x=x0; % Inicio de las Variables
17 iter =0; % Contador de iteraciones
18 %% Ciclo para generar los iterados
19 while iter<maxiter
20     D=Df(x); % Vector Gradiente
21     n1= sqrt(D'*D); % Norma del Vector Gradiente - Criterio de Parada
22     % Se imprime cada iterado y el error que se comete en la iteración
23     sprintf (" Iterado %d, aprox=( %f, %f), error= %e \n", iter , x, n1)
24     h= DDF(x)\D; % Cálculo del p correspondiente
25     n2= sqrt(h'*h); % Norma de p - Segundo Criterio de Parada
26     x=x-h'; % Actualización del punto x=(x(1),x(2))
27     if (n1<tol) || (n2<tol) % Pregunta para Criterio de Parada
28         iter = maxiter ;
29         break;
30     end
31     iter = iter +1; % Actualización del Contador
32     end


```

Método de Newton

Iteración	x	y	$ \nabla f(x, y) $
0	1.000000	1.000000	$8.485281e + 00$
1	1.000000	-0.500000	$4.500000e + 00$
2	1.391304	-0.695652	$1.494157e + 00$
3	1.745944	-0.948798	$5.233879e - 01$
4	1.986278	-1.048208	$1.014011e - 01$
5	1.998734	-1.000170	$2.555613e - 03$
6	2.000000	-1.000002	$3.319064e - 06$
7	2.000000	-1.000000	$2.808149e - 12$

Podemos comprobar los resultados en Matlab →





Método del Gradiente

- El **Método del Gradiente** es, posiblemente, la forma más sencilla de modificar el método de Newton para aplicarlo a la optimización no lineal.
- El precio a pagar por esa sencillez, es una gran ineficiencia en términos de velocidad de convergencia para la mayoría de problemas.

Precio Computacional Bajo ↔ Muchos Iterados

■ Ventajas Importantes:

- Un iterado de este método no requiere calcular la segunda derivada de la función, ni resolver un sistema lineal.
- No hace falta reservar espacio para almacenar una matriz.

Definición [Dirección de Descenso]

Sean $f : \mathcal{F} \subseteq \mathbb{R}^n \rightarrow \mathbb{R}$. Se dice que $\mathbf{d} \in \mathbb{R}^n$ es una **dirección de descenso** para f en $\mathbf{x}_0$ si existe $t_0 \in \mathbb{R}^+$, tal que $f(\mathbf{x}_0) > f(\mathbf{x}_0 + t\mathbf{d})$, para todo $t \in (0, t_0)$. $\square$



Interpretación



Partiendo del punto $\mathbf{x}_0$, el vector $\mathbf{d}$ apunta en una dirección de descenso de f , si existe un conjunto de vectores de desplazamiento $t\mathbf{d}$, lo suficientemente pequeños, para los que el valor de f decrece al evaluarse en los puntos de llegada $\mathbf{x}_0 + t\mathbf{d}$.

■ Siendo t suficientemente pequeño y utilizando el teorema de Taylor, con $\mathbf{d}$ una *dirección de descenso*, se cumple que:

$$f(\mathbf{x}_0) > f(\mathbf{x}_0 + t\mathbf{d}) \approx f(\mathbf{x}_0) + t\nabla f(\mathbf{x}_0)^T \mathbf{d}$$

Proposición [Criterio de Descenso]

Sea $f \in \mathcal{C}^1(\mathcal{F})$, con $\mathcal{F} \subseteq \mathbb{R}^n$ y $\mathbf{d}$ es una dirección de descenso de f en $\mathbf{x}_0$, si y sólo si, $\nabla f(\mathbf{x}_0)^T \mathbf{d} < 0$. $\square$


■ Puede verse del producto $\nabla f(\mathbf{x}_0)^T \cdot \mathbf{d}$ visto como un producto interno:

$$\nabla f(\mathbf{x}_0)^T \cdot \mathbf{d} = \|\nabla f(\mathbf{x}_0)\| \|\mathbf{d}\| \cos \theta$$

que la dirección de máximo crecimiento es la del gradiente y la de menor crecimiento negativo, es la opuesta a él.

Ejemplo (Gradiente)

En la figura, se muestran algunas curvas de nivel de la función $f(x_1, x_2) = x_1^2 + 4x_2^2$. Es una función convexa en todo $\mathbb{R}^2$ y tiene su mínimo en $(0,0)$. Determinar la dirección de descenso más pronunciado en el punto $(1, 0.5)$.




Paso 1 Determinar el Gradiente:

$$\nabla f(x_1, x_2) = \begin{bmatrix} 2x_1 \\ 8x_2 \end{bmatrix} \rightarrow \nabla f(1, 0.5) = \begin{bmatrix} 2 \\ 4 \end{bmatrix}$$

Paso 2 Entonces, la dirección de máximo descenso está dada por:

$$\mathbf{d} = -\nabla f(1, 0.5) = \begin{bmatrix} -2 \\ -4 \end{bmatrix}$$

o en su defecto cualquier múltiplo positivo de este.



Lema [Dirección de Máximo Descenso]

Sea $f \in \mathcal{C}^1(\mathcal{F})$, con $\mathcal{F} \subseteq \mathbb{R}^n$. La dirección de máximo descenso de f en $\mathbf{x} \in \mathcal{F}$, es justamente: $\mathbf{d}_{\max} = -\nabla f(\mathbf{x})$. $\square$

¹/₂/₃ Organizando ideas

- 1 Encontrar un punto $\mathbf{x}$ donde la función f tenga un mínimo local.
- 2 Hallar un mecanismo que permita ir de un punto dado a otro haciendo que el valor de la función decrezca en el camino.
- 3 Sabemos que en un entorno o vecindad suficientemente pequeño de $\mathbf{x}^*$ el negativo del gradiente apuntaría en la dirección de máximo descenso.

4 Si $\mathbf{d}_{\max}$ es la dirección de descenso máximo en $\mathbf{x}$, se quisiera determinar $t^* > 0$ talque $f(\mathbf{x} + t^*\mathbf{d}_{\max})$ sea mínima.

5 Se debe observar que esto constituye en sí mismo un problema de optimización en una variable, para resolverlo se puede echar mano de mucha herramienta vista antes.

6 Estamos entonces, ante un proceso de construcción de una sucesión de puntos $\{\mathbf{x}_k\}$. **¿Cuándo nos detenemos?**

7 **Criterios de Parada:** Podemos pensar en:

a $\|\mathbf{x}_{k+1} - \mathbf{x}_k\| < \varepsilon$, para $\varepsilon > 0$ y suficientemente pequeño.

b Si existe un mínimo en $\mathbf{x}^*$, entonces $\nabla f(\mathbf{x}) \rightarrow 0$ cuando $\mathbf{x} \rightarrow \mathbf{x}^*$, entonces el proceso se detiene cuando $\|\nabla f(\mathbf{x})\| < \varepsilon$.

Esquema

El método del gradiente tiene el siguiente esquema:

$$\mathbf{x}_{k+1} = \mathbf{x}_k - t^* \nabla f(\mathbf{x}_k)$$

donde $t^* > 0$, es un escalar tal que $f(\mathbf{x}_{k+1}) < f(\mathbf{x}_k)$. Entonces,

■ La dirección $\mathbf{d}_k = -\nabla f(\mathbf{x}_k)$ es una dirección de descenso (cerca de un mínimo) a no ser que $\nabla f(\mathbf{x}_k) = \mathbf{0}$.

■ Si el escalar t^* es suficientemente pequeño, entonces:

$$f(\mathbf{x}_{k+1}) < f(\mathbf{x}_k)$$

■ Esto equivale a requerir que t^* sea solución del problema de optimización 1-dimensional:

$$\text{minimizar } F(t) = f(\mathbf{x}_k + t\mathbf{d}_k)$$

☰ Pseudocódigo

Algoritmo Método del Gradiente - Descenso Máximo

Establece punto inicial $\mathbf{x}$ y tolerancia ε

Mientras $\|\nabla f(\mathbf{x})\| > \varepsilon$ realiza

Resuelve $\min_{t>0} f(\mathbf{x} - t\nabla f(\mathbf{x}))$ para obtener t^*

Actualiza $\mathbf{x} \leftarrow \mathbf{x} - t^*\nabla f(\mathbf{x})$

Imprime $\mathbf{x}$ y $f(\mathbf{x})$

Observaciones

- Este esquema se obtiene del método de Newton haciendo una aproximación grande de la matriz Hessiana. En particular, se asume que $\nabla^2 f \approx I$, donde I representa la matriz identidad.
- Esta aproximación tan burda de la segunda derivada hace que la velocidad de convergencia del método del gradiente sea lineal.
- En general se tiene que:

$$f(\mathbf{x}_{k+1}) - f(\mathbf{x}^*) \leq \left[\frac{\text{cond}(Q) - 1}{\text{cond}(Q) + 1} \right]^2 (f(\mathbf{x}_k) - f(\mathbf{x}^*))$$

donde $\text{cond}(Q) = \|Q\| \|Q^{-1}\|$, es el número de condición de la matriz: $Q := \nabla^2 f(\mathbf{x}^*)$.

- Para funciones cuyo Hessiano tenga $\text{cond}(Q) \approx 1$ la convergencia será aceptable y podremos utilizarla.

Ejemplo (Gradiente)

Considera la función $f(x, y) = y \sin x - y^2 + 2y^3$. Determina un mínimo de la función en el intervalo $[-\pi, \pi] \times [-1, 1]$ usando el método del gradiente considerando como $\mathbf{x}_0 = (-1, 0.125)$.

Paso 1 Calcular el gradiente de f :

$$\nabla f(x, y) = (y \cos x, \sin x - 2y + 6y^2)$$

Paso 2 Inicio del esquema en $\mathbf{x}_0 = (-1, 0.125)$. Entonces,

$$\begin{aligned}\nabla f(\mathbf{x}_0) &= \nabla f(-1, 0.125) \\ &= (0.125 \cos(-1), \sin(-1) - 2(0.125) + 6(0.125)^2) \\ &= (0.068, -0.998)\end{aligned}$$

Paso 3 Ahora, podemos emplear un paso t constante para acercarnos al óptimo, por ejemplo $t = 0.3$. Así pues,

$$\mathbf{x}_1 = \mathbf{x}_0 - 0.3 \nabla f(-1, 0.125) = (-1.02, 0.42)$$

Paso 4 Como $\|\mathbf{x}_1 - \mathbf{x}_0\| = 0.13$, consideramos que todavía no estamos en el mínimo y seguimos calculando.

Paso 5 Repetimos este procedimiento una segunda vez de forma que:

$$\nabla f(\mathbf{x}_1) = \nabla f(-1.02, 0.42) = (0.22, -0.63)$$


Paso 6 El nuevo valor vendrá dado por:

$$\mathbf{x}_2 = \mathbf{x}_1 - 0.3 \nabla f(\mathbf{x}_1) = (-1.09, 0.61)$$

 **Nota:** El método lo podemos depurar realizando la búsqueda lineal de forma que el valor de t que seleccionamos no esté prefijado sino que tomemos el valor óptimo de t .

¿Cómo hallamos el t^* óptimo?

- Para ello, se pueden emplear métodos de búsqueda, tales como: búsqueda dicotómica, razón áurea, Fibonacci, etc.
- Tendremos que encontrar el valor de $t > 0$ tal que $f(\mathbf{x}_0 - t\nabla f(\mathbf{x}_0))$ es mínimo.
- Para el primer iterado obtenemos que el valor de t óptimo será $t^* = 0.378$.
- De forma que el nuevo valor será $\mathbf{x}_1 = (-1.10, 0.63)$.





 **Nota:** Para calcular el máximo debemos cambiar el signo de la actualización de $\mathbf{x}_{n+1} = \mathbf{x}_n - t^* \nabla f(\mathbf{x}_n)$ a $\mathbf{x}_{n+1} = \mathbf{x}_n + t^* \nabla f(\mathbf{x}_n)$

Ejemplo (Gradiente)

Determine

$$\min_{(x_1, x_2) \in \mathbb{R}^2} f(x_1, x_2) = 3x_1^2 - 2x_1x_2 + x_2^2 + 3e^{-x_1}$$

Tomando $\mathbf{x}_0 = (0, 0)$ y una tolerancia $\varepsilon = 0.001$.



Paso 1 Calculamos $\nabla f(x_1, x_2)$

$$\nabla f(x_1, x_2) = \begin{bmatrix} 6x_1 - 2x_2 - 3e^{-x_1} \\ -2x_1 + 2x_2 \end{bmatrix} \Rightarrow \nabla f(0, 0) = \begin{bmatrix} -3 \\ 0 \end{bmatrix}$$

Paso 2 Buscamos la dirección de máximo descenso:

$$\mathbf{d}_0 = -\nabla f(\mathbf{x}_0) \Rightarrow \mathbf{x}_0 + t\mathbf{d}_0 = (0, 0) + t(3, 0) = (3t, 0)$$

Paso 3 Buscamos el t óptimo:

$$F(t) = f(\mathbf{x}_0 + t\mathbf{d}_0) = 3(3t)^2 + 3e^{-3t} = 27t^2 + 3e^{-3t}$$

$$\text{Luego, } F'(t) = 54t - 9e^{-3t} = 0$$

Paso 4 Usando algún método de búsqueda se puede ver que el óptimo está cerca de $t^* \approx 0.12$. Entonces,

$$\mathbf{x}_1 = \mathbf{x}_0 - 0.12 \nabla f(\mathbf{x}_0) = (0.36, 0) \rightarrow f(0.36, 0) \approx 2.5$$

Paso 5 Repetimos el proceso para $\mathbf{x}_2$. Entonces,

$$\nabla f(x_1, x_2) = \begin{bmatrix} 6x_1 - 2x_2 - 3e^{-x_1} \\ -2x_1 + 2x_2 \end{bmatrix} \rightarrow \nabla f(0.36, 0) \approx \begin{bmatrix} 0.06697 \\ -0.72000 \end{bmatrix}$$

Luego, $\mathbf{d}_1 = -\nabla f(\mathbf{x}_1) = (-0.06697, 0.72000)$

$$\begin{aligned} \mathbf{x}_1 + t\mathbf{d}_1 &= (0.36, 0) + t(-0.06697, 0.72000) \\ &= (0.36 - 0.06697 t, 0.72000 t) \end{aligned}$$

de donde

$$\begin{aligned} F(t) &= f(0.36 - 0.06697 t, 0.72000 t) \\ &= 0.3888 - 0.53286 t + 0.61495 t^2 + 2.09302 e^{0.06697 t} \end{aligned}$$

lo cual implica que:

$$F'(t) = -0.53286 + 1.2299 t + 0.14016 e^{0.06697 t} = 0 \rightarrow t \approx 0.317$$

En este sentido,

$$\mathbf{x}_2 = (0.36, 0) + 0.317(-0.06697, 0.72) = (0.33877, 0.22824)$$

en consecuencia,

$$f(\mathbf{x}_2) = f(0.33877, 0.22824) \approx 2.38$$

...Y así sucesivamente...

Ejemplo (Gradiente)

Considera la función $f(x, y) = x^2 - 24x + y^2 - 10y$. Determina el mínimo.

Paso 1 Sea $\mathbf{x}_0 = (8, 7)$ un punto de partida cualquiera y aplicamos una iteración del método.

Paso 2 Calcular el gradiente de f :

$$\nabla f(x, y) = (2x - 24, 2y - 10) \rightarrow \nabla f(8, 7) = (-8, 4)$$

Paso 3 Calculamos la magnitud del paso t :

$$\begin{aligned} F(t) &= f(\mathbf{x}_0 - t\nabla f(\mathbf{x}_0)) = f((8, 7) - t(-8, 4)) \\ &= (8 + 8t)^2 - 24(8 + 8t) + (7 - 4t)^2 - 10(7 - 4t) \end{aligned}$$

Paso 4 Busquemos el valor extremo de t^* :

$$\begin{aligned} F'(t) &= 16(8 + 8t) - 192 - 8(7 - 4t) + 40 \\ &= 160t - 80 \rightarrow F'(t) = 0 \leftrightarrow t^* = \frac{1}{2} \end{aligned}$$

Paso 5 Ahora, podemos emplear un paso t^* constante para acercarnos al óptimo. Así pues,

$$\mathbf{x}_1 = \mathbf{x}_0 - t^* \nabla f(\mathbf{x}_0) = (8, 7) - \frac{1}{2}(-8, 4) = (12, 5)$$

 **Nota:** El punto de partida para comenzar las iteraciones es arbitrario y al ser evaluado en la función objetivo se alcanza un valor de $f(8, 7) = -149$.

⚠ Ahora bien, si evaluamos la coordenada que se alcanza al realizar una iteración del método la función objetivo obtiene el siguiente valor $f(12, 5) = -169$ que como se puede apreciar reduce el valor de la función objetivo.

¿Cómo determinar si se ha alcanzado la solución óptima del problema no restringido a través del Método del Gradiente?

Para ello se debe verificar que la dirección de descenso en la k -ésima iteración es nula. En efecto, $\nabla f(12, 5) = (0, 0)$.

Comprobación final...

- Cálculo de la Matriz Hessiana:

$$\mathbf{H}f(x, y) = \begin{bmatrix} f_{xx} & f_{xy} \\ f_{yx} & f_{yy} \end{bmatrix} = \begin{bmatrix} 2 & 0 \\ 0 & 2 \end{bmatrix}$$

- Observe que: $M_1 = 2 > 0$ y $M_2 = 4 > 0$, por tanto, la matriz es definida positiva.
- La función objetivo es estrictamente convexa y esto garantiza que $\mathbf{x}_1 = (12, 5)$ realiza el mínimo y es la solución óptima esperada.

</> Código Matlab



```

1  %%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%
2  %%      METODO DEL GRADIENTE OPTIMO MULTIDIMENSIONAL      %%
3  %%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%
4  %%                                PORF. ANDRÉS PÉREZ %%
5  clear all
6  clc
7  %%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%
8  %%      PARAMETROS Y DATOS PARA SER AGREGADOS POR EL USUARIO      %%
9  %%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%
10 Max=0; % Si se va a maximizar se inicia en Max=1, si se va a minimizar
11 % se coloca o se define Max=0
12 f=@(x,y) x^2-24*x + y^2-10*y; % Función Multidimensional
13 grad=@(x,y) 2*x-24, ... % Gradiente de la función
14 @(x,y) 2*y-10;
15 x0=[8;7]; % Punto inicial: debe ser un vector columna
16 Tol=0.09; % Tolerancia del algoritmo
17 MaxIter=100; % Número de iteraciones máximas
18 bk=5; % Límite superior para la búsqueda unidimensional
19 t=0.5; % alpha del algoritmo
20
21 %%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%
22 %%      INICIO DEL ALGORITMO      %%
23 %%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%
24 Fgrad=[grad(1)(x0(1,1),x0(2,1))
25 grad(2)(x0(1,1),x0(2,1))]; % Se evalua el gradiente
26 % en el punto inicial
27
28 if Max==1 % Si se maximiza se escoge el gradiente
29     Fgrad=Fgrad;
30 else
31     Fgrad=-Fgrad; % Si se minimiza entonces, se escoge menos el gradiente
32 end

```

Ejemplo (Gradiente)

Considera la función $f(x,y) = x^2 - 24x + y^2 - 10y$. Determina el mínimo.

```

32
33 iter=1; % Inicio de las iteraciones
34
35 while norm(Fgrad)>=Tol && iter<=MaxIter
36     % [t]=BusquedaDicotomica(f,x0,Fgrad,bk,Max)
37     % [t]=BusquedaSecuencial(f,x0,Fgrad,bk,Max)
38     % [t]=MetodoFibonacci(f,x0,Fgrad,bk,Max)
39     % [t]=Seccion_Aurea(f,x0,Fgrad,bk,Max) % Método Unidimensional
40
41     D(iter, :)=iter,x0,Fgrad,t;
42
43     x0=x0+t*Fgrad; % Se actualiza el elemento para evaluar
44
45     Fgrad=[grad(1)(x0(1,1),x0(2,1))
46 grad(2)(x0(1,1),x0(2,1))]; % Se evalua el gradiente
47 % en la actualización
48
49     if Max==1 % Si se maximiza se escoge el gradiente
50         Fgrad=Fgrad;
51     else
52         Fgrad=-Fgrad; % Si se minimiza se escoge menos el gradiente
53     end
54
55     iter=iter+1; % Se actualiza el contador
56
57     D(iter,:)=iter, x0, Fgrad, t;
58
59 end

```

Método Cuasi - Newton

- Los métodos Cuasi-Newton se encuentran en el grupo de métodos de optimización no-lineal más utilizados.
- Son buenos para encarar un amplio abanico de problemas de tamaño medio y pequeño. Particularmente cuando la matriz Hessiana es difícil (o costosa) de calcular.
- Cuando el número de variables es alto, otros métodos son más adecuados.

- La idea de un método Cuasi-Newton es reemplazar el cálculo de la matriz Hessiana por otra matriz B_k que sea menos exigente de calcular.
- Hay tantos métodos cuasi-Newton como maneras de aproximar la matriz Hessiana. Una vez se ha elegido la manera para aproximar la matriz Hessiana, el resto del método sigue como el método de Newton clásico.
- El gran cambio es que el sistema lineal que se resuelve es:

$$B_k \mathbf{p} = -\nabla f(\mathbf{x}_k)$$

- El paso crítico para obtener un buen método cuasi-Newton es escoger una buena aproximación de la matriz Hessiana.
- Se puede aproximar la segunda derivada utilizando sólo evaluaciones de la primera derivada.
- Si la matriz B_k es definida positiva, esto equivale a minimizar un modelo cuadrático, esto es, se aborda el siguiente problema:

$$\text{minimizar } q(\mathbf{p}) = f(\mathbf{x}_k) + \nabla f(\mathbf{x}_k)^T \mathbf{p} + \frac{1}{2} \mathbf{p}^T B_k \mathbf{p}$$

UNIVERSIDAD INTERNACIONAL DE LA RIOJA

