

Curso: Optimización - Sesión: 8

TEMA 6: OPTIMIZACIÓN CON RESTRICCIONES - MÉTODOS DE RESOLUCIÓN

Prof. Marlon Ernesto Moscoso Martínez

UNIVERSIDAD INTERNACIONAL DE LA RIOJA



Optimización PER11087

2024 - 2025

email: marlonernesto.moscoso-externo@unir.net

PROBLEMA


¿Cómo usar el método de penalización en la solución de un problema de optimización?

Iteración	x1	x2	Valor_F_objetivo	Factor_penalización
0	40	40	3200	0
1	0.33333	0.33333	0.33333	1
2	0.49751	0.49751	0.49751	100
3	0.49998	0.49998	0.49998	10000
4	0.5	0.5	0.5	1e+06

Solución óptima encontrada:

0.5000 0.5000

Valor de la función objetivo: 0.5



1 Introducción y Objetivos


- Esquema
- Objetivos

2 Métodos de Resolución

- Penalización
- Gradiente Reducido
- Programación Cuadrática Secuencial



Esquema del Tema





Recordemos de la Clase Pasada...

Teorema (Lagrange II)

Consideramos el problema:

$$\begin{cases} \min_{\mathbf{x} \in \mathbb{R}^n} & f(\mathbf{x}) \\ \text{Sujeto a:} & G(\mathbf{x}) \geq \mathbf{0} \end{cases}$$

Aquí, f y G son funciones de clase $\mathcal{C}^1$ en $\mathcal{U} \subseteq \mathbb{R}^n$ y con valores en $\mathbb{R}$ y $\mathbb{R}^p$ respectivamente. Supongamos que $\mathbf{x}^*$ es un minimizador local regular. Entonces existe un vector $\boldsymbol{\lambda}^* \in \mathbb{R}_+^m$ de constantes positivas tal que $\lambda_i^* G_i(\mathbf{x}^*) = 0$, para todo $i = 1, \dots, m$ y $(\mathbf{x}^*, \boldsymbol{\lambda}^*)$ es un punto crítico de la función Lagrangiana:

$$L(\mathbf{x}, \boldsymbol{\lambda}) = f(\mathbf{x}) - \sum_{i=1}^n \lambda_i G_i(\mathbf{x})$$



Ejemplo 2 (Lagrange)

Consideramos el problema:
$$\begin{cases} \min_{x \in \mathbb{R}} & x^2 \\ \text{Sujeto a:} & x + 1 \geq 0 \end{cases}$$

Solución: La solución de este problema es bastante obvia, ya que el valor $x = 0$ es una de las soluciones factibles.

- Estandarizamos el problema:

$$\begin{cases} \min_{(x,y) \in \mathbb{R}^2} & x^2 \\ \text{Sujeto a} & x + 1 - y^2 = 0 \end{cases}$$

- La ecuación de Lagrange queda:

$$(2x, 0)^T - \lambda(1, -2y)^T = (0, 0)^T \rightarrow \begin{cases} 2x = \lambda \\ 2\lambda y = 0 \end{cases}$$

Lo que indica que la solución es $(x, \lambda) = (0, 0)$.

La idea es observar a los problemas de optimización con restricciones, desde un punto de vista algorítmico. Para ello, debemos recordar:

- Hemos tratado las condiciones necesarias y suficientes para la existencia de soluciones locales.
- Con esta finalidad, observar el problema sin restricciones ha sido fundamental, ya que se pretende reducir uno con restricciones a uno sin restricciones.
- En el tema anterior se han discutido condiciones necesarias y suficientes para la existencia de soluciones locales y para ello, no se ha perdido de vista el caso sin restricciones.
- La estrategia ha sido reducir el problema con restricciones a otro equivalente sin restricciones.



Recordemos que...

■ Cuando se consideran algoritmos para encontrar el óptimo de una función no lineal sin restricciones, partiendo de una condición inicial, se intenta reducir iterado a iterado, el valor de la función objetivo. Lo cual implica resolver algunos subproblemas:

- 1 Calcular una dirección de búsqueda $\mathbf{d}$.
- 2 Calcular un paso $t > 0$ para obtener un nuevo punto con un menor valor de la función objetivo.

Se aplicará el mismo esquema.

- El principal inconveniente del esquema anterior es que la dirección de búsqueda $\mathbf{d}$ y el paso t deben ser tales que el nuevo punto pertenezca a la región factible.
- Esto implica que, a cada nuevo iterado, uno debe preocuparse de que la solución sigue siendo factible además de que el valor de la función objetivo decrezca.
- En la práctica, se puede esbozar algoritmos que no cumplan con ese requerimiento si el criterio de convergencia también tiene en cuenta la condición para la restricción. Esto es, el algoritmo no cumple la condición de parada hasta que las restricciones se cumplen con una cierta tolerancia.



Objetivos



En realidad, los objetivos para este tema se centran básicamente en lo ya expuesto, es decir, tratar de hallar una dirección de descenso que permita ir disminuyendo en cada iterado el valor de la función objetivo y, por otra parte, el paso adecuado trabaja justamente en que el descenso se de en los mejores términos, evitando pasar por zonas de factibilidad sin ser detectadas.

Métodos de Penalización

$$\begin{cases} \min & f(\mathbf{x}) \\ \text{Sujeto a} & H(\mathbf{x}) = 0 \end{cases}$$

$$F(\mathbf{x}, \rho) = f(\mathbf{x}) + \rho P(\mathbf{x})$$

- Construimos **un problema sin restricciones y una** función de penalización que agregue valores grandes a los puntos que no verifican las restricciones.
- Los valores de penalización se suman a los de la función objetivo, de manera que minimizar ambas funciones debería arrojar buenos resultados para el problema con restricciones.

Ventaja	Desventaja
Sencillez	La solución que da el método solamente es factible en el límite.

 **Nota:** Si el método termina de forma prematura, la solución no es factible.

Entonces,

■ Consideramos un problema de restricciones de igualdad:

$$\begin{cases} \min & f(\mathbf{x}) \\ \text{Sujeto a:} & H(\mathbf{x}) = \mathbf{0} \end{cases}$$

■ La intención, es crear una función de penalización P y reducir el problema a la minimización de una función sin restricciones:

$$F(\mathbf{x}, \rho) = f(\mathbf{x}) + \rho P(\mathbf{x}) \quad (1)$$

Aquí, $\rho > 1$ será el llamado **parámetro de penalización**.

- Existe una cantidad infinita de maneras distintas de escoger la función P y cada una de ellas tendrá un comportamiento distinto.
- Una manera sencilla de construir funciones de penalización es considerar la norma del error cometido en las ecuaciones de restricción.
- Supongamos, pues, que P es una función de penalización y consideramos el problema sin restricciones dado en (1).
- Bajo las condiciones iniciales $\boxed{\mathbf{x}_0 = 1}$ y $\boxed{\rho_0 = 1}$. Es habitual fijar una tolerancia específica para las restricciones $\varepsilon_r > 0$.



En consecuencia, si $\|H(\mathbf{x})\| < \varepsilon_r$ y $\mathbf{x}$ es una solución factible, el algoritmo queda:

1 Comprobamos si tenemos una solución del problema. Esto es: si el gradiente de la función objetivo es nulo y si las restricciones se cumplen. Si tal cosa ocurre, se termina el programa. En caso contrario se avanza al siguiente paso.

2 Solucionamos el problema de minimización sin restricciones dado por F . Aquí, en principio, cualquier método es válido.

3 Actualizamos la iteración. Eso significa aumentar el número de iterados $k \rightarrow k + 1$, tomamos $\mathbf{x}_1$ como la solución del problema resuelto en el paso anterior, actualizamos $\rho_{k+1} = \beta \rho_k$, donde $\beta > 1$. Volvemos a **1**.

Ejemplo 1 (Penalización)

Consideramos el problema:

$$\begin{cases} \min_{(x,y) \in \mathbb{R}^2} & -xy \\ \text{Sujeto a} & x + 2y - 4 = 0 \end{cases}$$

Paso 1

Consideramos como función de penalización la función $\frac{1}{2}H^2$, donde $H(x, y) = x - 2y - 4$.



Paso 2

Reducimos el problema a minimizar a la familia:

$$F(\mathbf{x}, \rho) = -xy + \frac{\rho}{2}(x + 2y - 4)^2$$

Paso 3

Hallamos los candidatos a óptimos resolviendo el sistema $\nabla F = \mathbf{0}$.

$$\begin{cases} -y + \rho(x + 2y - 4) = 0 \\ -x - 2\rho(x + 2y - 4) = 0 \\ H(x, y) = 0 \end{cases}$$

Paso 4 Resolvemos en función de ρ , donde:

$$x(\rho) = \frac{8\rho}{4\rho - 1} \quad y \quad y(\rho) = \frac{4\rho}{4\rho - 1}$$

Paso 5

Estas ecuaciones son singulares en $\rho = \frac{1}{4}$, lo cual no es relevante ya que $\rho > 1$. Además, la solución claramente no es factible, ya que:

$$H(x(\rho), y(\rho)) = \frac{4}{4\rho - 1} \neq 0$$

Tomando $\rho \rightarrow \infty$ tenemos que $x(\rho) \rightarrow 2$ y $y(\rho) \rightarrow 1$, lo cual representa un mínimo del problema con restricciones original.

Para comprobar que en efecto esto es así, construimos la función lagrangiana:

$$L(x, y, \lambda) = -xy + \lambda(x + 2y - 4)$$

y considerando el sistema:

$$\begin{cases} \frac{\partial L}{\partial x} = -y + \lambda = 0 \\ \frac{\partial L}{\partial y} = -x + 2\lambda = 0 \\ \frac{\partial L}{\partial \lambda} = x + 2y - 4 = 0 \end{cases} \quad \rightarrow \quad \begin{cases} y = \lambda \\ x = 2\lambda \\ \lambda = 1 \end{cases} \quad \rightarrow \quad (x, y) = (2, 1)$$


Gradiente Reducido

$$\begin{cases} \min & f(\mathbf{x}) \\ \text{Sujeto a:} & H(\mathbf{x}) = \mathbf{0} \end{cases}$$

$$L(\mathbf{x}, \lambda) = f(\mathbf{x}) + \sum_{i=1}^p \lambda_i H_i(\mathbf{x})$$

$$\begin{bmatrix} x_{k+1} \\ \lambda_{k+1} \end{bmatrix} = \begin{bmatrix} x_k \\ \lambda_k \end{bmatrix} + \begin{bmatrix} q_k \\ v_k \end{bmatrix}$$

■ A diferencia de los métodos de penalización, estos métodos tratan de preservar la factibilidad en cada iterado.

■ **Ventajas:**

- 1 Si cada iterado estima una solución factible, el algoritmo se puede detener antes de haber alcanzado la convergencia y la aproximación obtenida aún puede ser útil.
- 2 Es más fácil medir la convergencia ya que en cada iterado uno puede utilizar directamente la función objetivo.

■ **Desventaja:** El coste computacional.

En efecto, tener que asegurar que cada iterado se encuentra dentro de la región de soluciones factibles conlleva una serie de evaluaciones de las funciones no lineales que determinan las restricciones

Entonces,

■ Consideramos un problema de restricciones de igualdad:

$$\begin{cases} \min & f(\mathbf{x}) \\ \text{Sujeto a:} & H(\mathbf{x}) = \mathbf{0} \end{cases}$$

■ Ahora utilizamos la regla de los multiplicadores de Lagrange para construir una función Lagrangiana:

$$L(\mathbf{x}, \lambda) = f(\mathbf{x}) + \sum_{i=1}^p \lambda_i H_i(\mathbf{x})$$

Este es un problema de minimización sin restricciones,

■ En particular, podemos utilizar un esquema de Newton para tratar de encontrar un óptimo:

$$\begin{bmatrix} \mathbf{x}_{k+1} \\ \lambda_{k+1} \end{bmatrix} = \begin{bmatrix} \mathbf{x}_k \\ \lambda_k \end{bmatrix} + \begin{bmatrix} p_k \\ v_k \end{bmatrix}$$

donde $(p_k, v_k)^T$ es solución del sistema lineal:

$$\begin{bmatrix} \nabla_{\mathbf{x}, \mathbf{x}}^2 L(\mathbf{x}_k, \lambda_k) & -\nabla H(\mathbf{x}_k) \\ -\nabla H(\mathbf{x}_k)^T & 0 \end{bmatrix} \begin{bmatrix} p_k \\ v_k \end{bmatrix} = \begin{bmatrix} -\nabla_{\mathbf{x}} L(\mathbf{x}_k, \lambda_k) \\ H(\mathbf{x}_k) \end{bmatrix}$$

■ Sea Z_k una matriz construida con una base del núcleo de $\nabla H(\mathbf{x}_k)^T$ y Y_k una matriz construida con una base del núcleo de $\nabla H(\mathbf{x}_k)$.

- Podemos separar la dirección de búsqueda p_k como:

$$p_k = Z_k p_z + Y_k p_y,$$

donde p_z , es la solución del sistema:

$$Z_k^T [\nabla_{x,x}^2 L(\mathbf{x}_k, \lambda_k)] Z_k p_z = -Z_k^T \nabla_x L(\mathbf{x}_k, \lambda_k)$$

- La dirección de búsqueda p_y queda determinada imponiendo que el siguiente iterado (esto es, la siguiente aproximación de la solución) sea factible: $H(\mathbf{x}_{k+1}) = 0$.

Como $\mathbf{x}_{k+1} = \mathbf{x}_k + p_k$, tenemos la condición:

$$H(\mathbf{x}_k + Z_k p_z + Y_k p_y) = \mathbf{0}$$

■ Esto es, de hecho, un sistema de ecuaciones no lineales con p ecuaciones y las p variables que determinan p_y (el hecho de que este sistema tenga solución única depende de que la diferencial $DH(\mathbf{x}_k)$ tenga rango máximo, que es una hipótesis que ya hemos discutido como necesaria en el tema anterior).

■ Para resolver este sistema, se necesita un método de resolución de ecuaciones no lineales. Por ejemplo, el **método de Newton**.

Ejemplo 1 (Gradiente Reducido)

Vamos a aplicar el método del gradiente reducido al siguiente problema de minimización con restricciones de igualdad:

$$\begin{cases} \min_{(x,y) \in \mathbb{R}^2} & e^{3x} + e^{-4y} \\ \text{Sujeto a:} & x^2 + y^2 - 1 = 0 \end{cases}$$

Paso 1

Partimos de la condición inicial $\mathbf{x}_0 = (-1, 1)^T$. La cual, de hecho no es factible.

 **Nota:** El método se encargará de corregir este detalle para la siguiente iteración.

Las siguientes cantidades tienen que ser evaluadas en $\mathbf{x}_0$ para encontrar las direcciones de búsqueda del primer iterado.

Paso 2

Calculamos:

$$\nabla f(x, y) = \begin{bmatrix} 3e^{3x} \\ -4e^{-4y} \end{bmatrix}, \quad \nabla^2 f(x, y) = \begin{bmatrix} 9e^{3x} & 0 \\ 0 & 16e^{-4y} \end{bmatrix}$$

donde $H(x, y) = x^2 + y^2 - 1$. Por consiguiente:

$$\nabla H(x, y) = \begin{bmatrix} 2x \\ 2y \end{bmatrix} \quad y \quad \nabla^2 H(x, y) = \begin{bmatrix} 2 & 0 \\ 0 & 2 \end{bmatrix}$$

de donde,

$$\nabla f \begin{bmatrix} -1 \\ 1 \end{bmatrix} = \begin{bmatrix} 3e^{-3} \\ -4e^{-4} \end{bmatrix} = \begin{bmatrix} 0.14936 \\ -0.07326 \end{bmatrix}$$

$$\nabla^2 f \begin{bmatrix} -1 \\ 1 \end{bmatrix} = \begin{bmatrix} 9e^{-3} & 0 \\ 0 & 16e^{-4} \end{bmatrix} = \begin{bmatrix} 0.44808 & 0 \\ 0 & 0.29305 \end{bmatrix}$$

Además,

$$\nabla H \begin{bmatrix} -1 \\ 1 \end{bmatrix} = \begin{bmatrix} -2 \\ 2 \end{bmatrix} \quad y \quad \nabla^2 H \begin{bmatrix} -1 \\ 1 \end{bmatrix} = \begin{bmatrix} 2 & 0 \\ 0 & 2 \end{bmatrix}$$

Paso 3

Encontramos λ_0 que sea solución del problema de minimización unidimensional:

$$\min \|\nabla f(\mathbf{x}_k) - \lambda \nabla H(\mathbf{x}_k)\|_2^2, \quad \mathbf{x}_k = \mathbf{x}_0$$

Por tanto, tomando $\alpha = 0.14936$ y $\beta = -0.07326$, se tiene

$$\min (\alpha + 2\lambda)^2 + (\beta - 2\lambda)^2 \rightarrow \lambda = \frac{\beta - \alpha}{4} = -0.055655$$

Paso 4 Obtenido el valor de λ , podemos calcular las cantidades:

$$\nabla_{\mathbf{x}} L = \nabla f - \lambda \nabla H = \begin{bmatrix} 0.14936 \\ -0.07326 \end{bmatrix} + 0.055655 \begin{bmatrix} -2 \\ 2 \end{bmatrix} = \begin{bmatrix} 0.03805 \\ 0.26067 \end{bmatrix}$$

y además,

$$\begin{aligned} \nabla_{\mathbf{x}, \mathbf{x}}^2 L &= \nabla^2 f - \lambda \nabla^2 H = \begin{bmatrix} 0.44808 & 0 \\ 0 & 0.29305 \end{bmatrix} + 0.055655 \begin{bmatrix} 2 & 0 \\ 0 & 2 \end{bmatrix} \\ &= \begin{bmatrix} 0.55939 & 0 \\ 0 & 0.40436 \end{bmatrix} \end{aligned}$$

Paso 5

Recordamos que $\nabla H = (2x, 2y) = (B, N)$. Llamando $B = 2x$ y $N = 2y$, podemos calcular:

$$Z_k = -B^{-1}NI = \begin{bmatrix} -\frac{y}{x} \\ 1 \end{bmatrix}$$

 **Nota:** En realidad hemos considerado la ecuación $Bx + Ny = 0$, hemos despejado x en función de y y hemos otorgado $y = 1$.

Paso 6 La imagen es todo $\mathbb{R}^2$

$$Y_k = \frac{1}{\sqrt{x^2 + y^2}} \begin{bmatrix} x \\ y \end{bmatrix}$$

Paso 7

Tenemos que $\mathbf{x}_0 = (-1, 1)^T$, luego

$$Z_0 = \begin{bmatrix} -\frac{y}{x} \\ 1 \end{bmatrix}_{(-1,1)} = \begin{bmatrix} 1 \\ 1 \end{bmatrix}$$

Recordamos que la componente p_z de la dirección de búsqueda es solución de:

$$Z_k^T [\nabla_{x,x}^2 L(x_k, \lambda_k)] Z_x q_z = -Z_k^T \nabla_x L(x_k, \lambda_k), \quad k = 0$$

Tenemos todo lo necesario y haciendo cálculos nos queda:

$$(0.963754)p_z = -0.076099, \quad p_z = -0.0078961$$

Paso 8

La otra componente, p_y , es solución de $H(\mathbf{x}_0 + Z_0 p_z + Y_0 p_y) = 0$, donde las cantidades rojas son conocidas:

$$\mathbf{x}_0 + Z_0 p_z + Y_0 p_y$$

Por tanto,

$$\begin{bmatrix} -1 \\ 1 \end{bmatrix} + \begin{bmatrix} 1 \\ 1 \end{bmatrix} (-0.0078961) + \begin{bmatrix} -0.70711 \\ 0.70711 \end{bmatrix} p_y$$

Es decir, tenemos que solucionar la ecuación:

$$(-1.07896 - p_y/\sqrt{2})^2 + (0.92104 + p_y/\sqrt{2})^2 - 1 = 0$$

que tiene dos soluciones:

$$p_y \approx -2.40796 \quad , \quad p_y \approx -0.420468$$

(Tomamos la segunda). La dirección de búsqueda:

$$p_0 = Z_0 p_z + Y_0 p_y = \begin{bmatrix} 0.218355 \\ -0.376276 \end{bmatrix}$$

Finalmente, el primer iterado es:

$$\mathbf{x}_1 = \mathbf{x}_0 + p_0 = \begin{bmatrix} -0.78164 \\ 0.62372 \end{bmatrix}$$

Notamos que $(-0.781642)^2 + (0.623722)^2 = 0.99999 \approx 1$, es decir, este iterado cumple con las restricciones.

Programación Cuadrática Secuencial

$$\begin{cases} \min & \frac{1}{2} q^T [\nabla_{x,x}^2 L(x_k, \lambda_k)] q + q^T [\nabla_x L(x_k, \lambda_k)] \\ \text{Sujeto a:} & [\nabla H(x_k)]^T q + H(x_k) = 0 \end{cases}$$

Programación Cuadrática Secuencial

En este caso, la idea es obtener la dirección de búsqueda resolviendo un problema de optimización cuadrático y con restricciones lineales. Para ello,

- Consideramos un problema como antes:

$$\begin{cases} \min & f(\mathbf{x}) \\ \text{Sujeto a:} & H(\mathbf{x}) = \mathbf{0} \end{cases}$$

- Construimos la función Lagrangiana:

$$L(\mathbf{x}, \lambda) = f(\mathbf{x}) + \sum_{i=1}^p \lambda_i H_i(\mathbf{x})$$

■ Buscamos las condiciones necesarias, es decir: $\nabla L(\mathbf{x}, \lambda) = \mathbf{0}$

■ Usamos de nuevo el método de Newton para tratar de encontrar un óptimo:

$$\begin{bmatrix} \mathbf{x}_{k+1} \\ \lambda_{k+1} \end{bmatrix} = \begin{bmatrix} \mathbf{x}_k \\ \lambda_k \end{bmatrix} + \begin{bmatrix} q_k \\ v_k \end{bmatrix}$$

donde $(q_k, v_k)^T$ es solución del sistema lineal:

$$\begin{bmatrix} \nabla_{\mathbf{x}, \mathbf{x}}^2 L(\mathbf{x}_k, \lambda_k) & -\nabla H(\mathbf{x}_k) \\ -\nabla H(\mathbf{x}_k)^T & \mathbf{0} \end{bmatrix} \begin{bmatrix} q_k \\ v_k \end{bmatrix} = \begin{bmatrix} -\nabla_{\mathbf{x}} L(\mathbf{x}_k, \lambda_k) \\ H(\mathbf{x}_k) \end{bmatrix}$$

¿Qué es lo nuevo?

■ Se varía la dirección con respecto al método del gradiente reducido. Simplemente, nos damos cuenta de que este sistema de ecuaciones son las condiciones necesarias de primer orden del siguiente problema:

$$\begin{cases} \min & \frac{1}{2} \mathbf{q}^T [\nabla_{\mathbf{x}, \mathbf{x}}^2 L(\mathbf{x}_k, \lambda_k)] \mathbf{q} + \mathbf{q}^T [\nabla_{\mathbf{x}} L(\mathbf{x}_k, \lambda_k)] \\ \text{Sujeto a:} & [\nabla H(\mathbf{x}_k)]^T \mathbf{q} + H(\mathbf{x}_k) = \mathbf{0} \end{cases}$$

Aquí, $\mathbf{v}_k$ será el vector de los multiplicadores de Lagrange.

UNIVERSIDAD INTERNACIONAL DE LA RIOJA

