

Curso: Optimización - Sesión: 11
TEMA 8: ALGORITMOS GENÉTICOS - PARTE I

Prof. Marlon Ernesto Moscoso Martínez

UNIVERSIDAD INTERNACIONAL DE LA RIOJA





Optimización PER11087

2024 - 2025

email: marlonernesto.moscoso-externo@unir.net

PROBLEMA

¿Cómo determinar las diversas etapas de un algoritmo genético?



↓¹₉ Contenido

1 Introducción - Objetivos

- Esquema
- Introducción - Objetivos

2 Algoritmos Genéticos

- Algoritmos Genéticos y Biología
- Función Objetivo
- **Descripción del Algoritmo:** Caso Binario

3 Codificación de los Fenotipos

- Proceso de Selección


4 Cruce de fenotipos

- Operadores de Cruce
- Mutación
- Reemplazo



5 Estructura de un Algoritmo Genético



Esquema del Tema



- Los **algoritmos genéticos**, son algoritmos de optimización que pueden ser pensados como métodos de búsqueda global.
- La idea del algoritmo es replicar el proceso de selección natural para encontrar las soluciones más aptas.
- En consecuencia, el algoritmo consiste en, dada una población de individuos, hacerla evolucionar mediante cambios aleatorios en sus genes y luego seleccionar a los mejores individuos de la población para que puedan perpetuarse.
- En el marco de un problema de optimización, las posibles soluciones del problema conforman la población y la función de costo sirve para seleccionar a los individuos más aptos.
- No se necesita ninguna hipótesis adicional del problema.




 Desarrollado en USA en 1970's por: J. Holland, K. DeJong, D. Goldberg. Originalmente aplicado a: Optimización discreta o combinatoria (binario).

■ Características exhibidas:

- No muy rápido.
- Buen metaheurístico para problemas combinatorios.

■ Características especiales:

- Enfatiza la combinación de información de buenos progenitores (crossover/recombinación/cruce)
- Muchas variantes



Algoritmos Exactos vs (Meta) Heurísticos

Algoritmos Exactos

- 1 **Simplex:** Problemas de PL
- 2 **Branch & Bound:** PLE
- 3 **Cortes de Gomory:** PLE
- 4 **Métodos Numéricos:** PNL
 - Newton-Raphson
 - Gradiente

Algoritmos Aproximados

- 1 **Heurísticos:** Algoritmo diseñado para un problema dado.
 - Constructivos.
- 2 **Metaheurísticos:** Algoritmo general aplicable a cualquier problema. Basados en:
 - Trayectorias
 - Poblaciones



Metaheurísticos

Basados en Trayectorias

- Búsqueda Local
- Búsqueda Tabú
- Iterated Local Search
- ⋮

Basados en Poblaciones

- **Algoritmos Genéticos**
- Algoritmo de Estimación de Distribuciones
- PSO
- ⋮



Objetivos



- 1 Comprender la base de un algoritmo genético.
- 2 Determinar cada una de las etapas de un Algoritmo Genético.
- 3 Implementar los algoritmos genéticos en distintas situaciones.



♂♀ Algoritmos Genéticos y Biología

Los algoritmos genéticos están inspirados en los procesos biológicos, donde:

- Cada iteración se considera una **generación**.
- Las **poblaciones**, son los conjuntos de soluciones considerados en cada generación (posibles casos).
- Estas soluciones, reciben el nombre de **fenotipos**.
- Los fenotipos, o individuos se codifican en **cromosomas**. (vectores de ceros y unos).

- Los cromosomas contienen **genes**, los cuales están en posiciones (usualmente fijas) llamadas *loci* (sing. locus) y tienen un valor llamado **alelo**.
- La **adaptación** de un cromosoma, se mide con la función objetivo.
- La función objetivo se llama **función de aptitud** (puede que la función de aptitud no sea exactamente la función objetivo).
- Evaluando los fenotipos en la función de aptitud, uno puede seleccionar qué candidatos son los que se adaptan mejor a su entorno.


Función Objetivo

Supongamos que tenemos los siguientes problemas de optimización:

① $\max_{x \in [1,2]} g(x) = -x^2 + 2x$. Donde $g(x) \geq 0, \forall x \in [1,2]$. Así pues, podemos elegir la función de aptitud igual a la función objetivo: $f(x) = g(x)$.

② $\max_{x \in [1,5]} g(x) = -x^2 + 4x$. La función g es negativa para $x > 4$. Su valor mínimo se alcanza en $x = 5$, donde toma el valor $g(5) = -5$. Sumando a g cualquier cantidad positiva mayor de 5 podemos asegurarnos una función de aptitud positiva. Por ejemplo, $f(x) = g(x) + 6$.

- Cuanto mayor sea la adaptación de un individuo al problema (mejor *fitness*: mayor en maximización, menor en minimización), mayor será la probabilidad de que el mismo sea seleccionado para reproducirse.
- Cada iterado del algoritmo, produce una nueva generación. Esto es, los fenotipos tienen descendencia.
- En la nueva generación, se introducen cambios aleatorios en sus cromosomas, esto es, se producen **mutaciones**.



Codificación de los fenotipos

- Cada fenotipo se codifica en un vector de parámetros numéricos (los cromosomas).
- La dimensión de este vector, supongamos que es N , es la que determina la dimensionalidad del problema.
- Un fenotipo g , vendrá codificado como:

$$g = [p_1, p_2, \dots, p_N]$$

donde p_i es valor numérico del cromosoma i .

 **Nota:** La codificación depende del problema. Si quiere codificar un número real, es común expresarlo mediante en base binaria. Una mala codificación, puede dar lugar a soluciones que no sean óptimas y un mal comportamiento del algoritmo.

Descripción del Algoritmo: Caso Binario



1 La **población inicial** se elige:

- a** Aleatoriamente [<https://www.augeweb.com/azar/>]
- b** Cuasialeatoriamente
- c** Obtener las soluciones iniciales a partir de otro heurístico o metaheurístico.

Es importante mantener la **diversidad** de la población.

El tamaño N de la población: poblaciones pequeñas corren el riesgo de no cubrir adecuadamente el espacio de búsqueda, mientras que poblaciones de gran tamaño pueden suponer excesivo coste computacional.

2 Se evalúa la aptitud de cada uno de los fenotipos.


3 Esto seleccionará cuáles son los que mejor se adaptan para resolver el problema.

 **Nota:** Esta selección puede ser *elitista*, o de otras formas.

4 El siguiente paso es crear un operador de selección que determine la probabilidad de que un subgrupo de fenotipos se reproduzcan en el siguiente iterado.

5 Se necesitan operadores de **cruce** y operadores de **mutación**.

- Mantiene propiedades de los padres.
- Mantienen factibilidad.
- Introducen diversidad.



Selección de padres a cruzar





Selección proporcional al valor de la FO

- Si la función de aptitud es positiva, podemos construir la probabilidad de que un genotipo se perpetúe:


$$p_k = p(g_k) = \frac{f(g_k)}{\sum_{k=1}^N f(g_k)}$$

p_k es la probabilidad de que el individuo k -ésimo sea seleccionado como padre.

- Se muestra tantas veces como individuos se quiera obtener.
- Se considera reemplazamiento.
- Converge a los superindividuos.



Selección de padres a cruzar




Muestreo Universal Estocástico - Baker 1987

- Sectores circulares proporcionales al valor de función objetivo de cada individuo (inverso si estamos minimizando)

- Un único giro de la ruleta.

Los individuos son seleccionados a partir de marcadores igualmente espaciados y con comienzo aleatorio. Esto suele resultar en convergencias más lentas, pero es más sencilla de programar.



- Problema rápida convergencia (superindividuos)



Selección de padres a cruzar

Selección Proporcional al Ranking del individuo



- Evitar problemas de superindividuos basando las probabilidades de selección en fitness relativas, en lugar del absoluto.
- Asignar la probabilidad inversamente proporcional a su posición en el ranking.
- Ranking lineal, exponencial, etc.



Selección de padres a cruzar

Selección por Torneo


- Elegir el tamaño del torneo k (habitualmente $k = 2$).
- Escoger al azar k individuos de la población con o sin reemplazamiento.
- Seleccionar el mejor individuo de este conjunto, y repetir el proceso hasta que tengamos el número de individuos deseado para ser progenitores.




Selección de padres a cruzar

Selección elitista

Se seleccionan siempre los mejores padres - Determinista





Cruce de fenotipos



- 1 Una se vez se ha calculado la aptitud de los distintos fenotipos de una población, hay que calcular los individuos de la siguiente población.
- La manera en que aparejar los distintos fenotipos, puede variar según el problema (*Operadores de cruce*).
 - Asumiendo que se necesitan dos individuos para procrear y generar un cruce cromosómico, se produce, a partir de un par de fenotipos, otro que comparte muchos cromosomas de sus fenotipos paternos.
 - Es aquí donde se introduce la *mutación* aleatoria de algunos de los cromosomas.

2 La condición **indispensable** para que el algoritmo funcione, es que aquellos fenotipos que tengan un mejor valor de la función de adaptación tengan más posibilidades de aparejarse.

■ Una cuestión importante es que, para mantener el número de individuos constantes a lo largo de las sucesivas generaciones, se asume que cada pareja dará lugar a dos hijos.

3 Una vez se ha generado la siguiente generación, el primer iterado se ha completado.

Operadores de Cruce

One-Point Crossover

- Elegir una posición aleatoria común a ambos padres.
- Dividir a los padres en este punto.
- Crear dos hijos copiando la cabecera de los cromosomas padres e intercambiando las colas.

Padres															
0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0
1	1	1	1	1	1	1	1	1	1	1	1	1	1	1	1
Hijos															
0	0	0	0	0	1	1	1	1	1	1	1	1	1	1	1
1	1	1	1	1	0	0	0	0	0	0	0	0	0	0	0

Operadores de Cruce

n-Point Crossover

- Elegir n posiciones aleatorias común a ambos padres.
- Dividir a los padres en estos puntos.
- Crear dos hijos copiando alternativamente las partes de los padres.

Padres									
0	0	0	0	0	0	0	0	0	0
1	1	1	1	1	1	1	1	1	1
Hijos									
0	0	1	0	0	0	0	1	0	0
1	1	0	1	1	1	1	0	1	1

Operadores de Cruce

Uniform Crossover

- Para el primer hijo, se cambia cada gen con probabilidad 0.5.
- El segundo hijo será el complementario del primero.
- Crear dos hijos copiando alternativamente las partes de los padres.


Padres

0	0	0	0	0	0	0	0	0	0	0	0	0
1	1	1	1	1	1	1	1	1	1	1	1	1


Hijos

0	1	0	0	1	0	0	0	1	0	1	0
1	0	1	1	0	1	1	1	0	1	0	1

Mutación



Mutación



Mutación Bit-Flip

- Altera cada gen independientemente con probabilidad de mutación p_m .
- Habitualmente p_m se toma entre $1/\text{tamaño de población}$ y $1/\text{longitud de cromosoma}$.
- Conviene que p_m sea baja. Si es demasiado alta, se pierde la información de los progenitores.


Hijo del Cruce

0 0 0 0 0 0 0 0 0 0 0 0

Hijo Mutado

0 0 1 0 0 0 0 0 1 0 0 0

Nueva Población



Selección de la Nueva Población

Téngase en cuenta que teníamos un número de padres y hemos obtenido tantos descendientes. Debemos elegir N para pasar a la siguiente iteración.



Opciones:

- **Reducción simple:** quedarse con los descendientes y descartar los progenitores.
- **Reducción elitista:** quedarse con los mejores.
- Otras...

Reemplazo

- Después de cada iterado, podemos aplicar la estrategia del reemplazo.
- El último paso de cada generación consiste en reemplazar los elementos con peores aptitudes por nuevos individuos creados de forma aleatoria.
- Esto permite introducir sangre nueva en el sistema para ayudar a explorar el sistema y evitar que el sistema quede atascado en un óptimo local.

Descripción AGS: Caso Binario- Pseudocódigo

```

BEGIN /* Algoritmo Genetico Simple */
  Generar una poblacion inicial.
  Computar la funcion de evaluacion de cada individuo.
  WHILE NOT Terminado DO
    BEGIN /* Producir nueva generacion */
      FOR Tamaño poblacion/2 DO
        BEGIN /*Ciclo Reproductivo */
          Seleccionar dos individuos de la anterior generacion,
          para el cruce (probabilidad de seleccion proporcional
          a la funcion de evaluacion del individuo).
          Cruzar con cierta probabilidad los dos
          individuos obteniendo dos descendientes.
          Mutar los dos descendientes con cierta probabilidad.
          Computar la funcion de evaluacion de los dos
          descendientes mutados.
          Insertar los dos descendientes mutados en la nueva generacion.
        END
      IF la poblacion ha convergido THEN
        Terminado := TRUE
      END
    END
  END
END

```

Parámetros a definir

Existen una serie de parámetros que debemos definir antes de iniciar el algoritmo:

- Tamaño de la Población N .
- Población Inicial.
- Función de selección de padres para la recombinación.
- Cruce.
- Mutación.
- Selección de población para pasar a la siguiente generación.
- Criterio de Parada.

Resumen

Estructura de un Algoritmo Genético



La estructura general de un **algoritmo genético**, es la siguiente:

- 1 Se produce una generación inicial de fenotipos.
- 2 Se calcula la aptitud de cada uno de los individuos.
- 3 Se aparejan los fenotipos según su aptitud.
- 4 Se calcula la nueva generación y se evalúa su aptitud.
- 5 Si no se satisface el criterio de parada, se vuelve al punto **3**

UNIVERSIDAD INTERNACIONAL DE LA RIOJA

